


1. Einführung und Beispiele


Sir Francis Galton

Sir Francis Galton (1822-1911): „Regression toward mediocrity in hereditary stature“



(vgl. Fahrmeir et al.; S. 1)

Der Begriff Regression



Zusammenhang zwischen Größe der Eltern und der ihrer Kinder

$$E(Y) = \bar{Y} + 0.65(x - \bar{x})$$


$$E(Y) = 24 + 0.65x$$

Y: Größe des Kindes x: Größe der Eltern

(vgl. Fahrmeir et al.; S. 2,3)

Gibt es eine Midlife - Crisis ?

Daten über die Zufriedenheit von Personen:



$$E(Y_t) = \beta_0 + \beta_1 x_{1t} + \beta_2 x_{2t} + \beta_3 \log(x_{3t}) + \beta_4 x_{4t} + \dots + f(\text{Alter})$$

x-Variablen: Gehalt, Geschlecht, Gesundheitsstatus etc.

→ **multiple lineare Regression, Splines**

Wirksamkeit der Umweltzone

$$E(NOX_t) = \mu(LEZ(t)) + \beta_1 * temp + ...$$

$\mu(LEZ(t))$: Belastung bei der Umweltzone Stufe 0,1,2,3

Zielgröße: NOX_t : Stündliche Werte von Stickoxiden
→ **Kovarianzanalyse**

Zusammenhang zwischen Lesefähigkeit und Lehrmethode

$$E(Y_{ij}) = \beta_0 + \beta_1 x_{1ij} + \alpha_j$$

Y_{ij} : Lesefähigkeit von Schüler/in i in Klasse j

x_{1ij} : Zahl der Förderstunden

α_j : Klasseneffekt

→ **Gemischtes lineares Modell**

Zusammenhang zwischen dem Auftreten von Chronischer Bronchitis (CBR) und Staubbelastung am Arbeitsplatz

Studie: 1246 Arbeitnehmer

$$P(Y_i = 1) = G(\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 IR_i)$$

Variablen:

Y : Indikator für CBR

x_1 : Staubkonzentration am Arbeitsplatz

x_2 : Dauer der Exposition

IR : Rauchstatus (ja/nein)

→ **Logistisches Regressionsmodell**

- Wir wollen einen Zusammenhang zwischen einer Zielgröße Y und Einflussgrößen x modellieren
- Ziele sind Verstehen, Nachweisen, Prognostizieren
- *Supervised learning*: Wir lernen aus den Daten den Zusammenhang zwischen x und Y
- Zusammenhänge können sehr komplex sein. Daher sind die Methoden auch komplex.

(vgl. Fahrmeir et al.; S. 21)

Inhalt der Vorlesung (1)

- 1 Einführung und Beispiele
- 2 Das einfache lineare Regressionsmodell
- 3 Das multiple lineare Regressionsmodell
- 4 Quadratsummenzerlegung und statistische Inferenz im multiplen linearen Regressionsmodell
- 5 Diskrete Einflußgrößen: Dummy- und Effektkodierung, Mehrfaktorielle Varianzanalyse

Inhalt der Vorlesung (2)

- 6 Metrische Einflußgrößen: Interaktionen, Polynomiale Regression, Trigonometrische Polynome, Regressionssplines, Transformationen.
- 7 Modelldiagnose
- 8 Das allgemeine lineare Modell: Gewichtete KQ-Methode, Autokorrelierte und heteroskedastische Störterme
- 9 Das gemischte lineare Regressionsmodell („Linear mixed Model“)
- 10 Das logistische Regressionsmodell
- 11 Variablenselektion