

2. Das einfache lineare Regressionsmodell

Das einfache lineare Regressionsmodell

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i; \quad i = 1, \dots, n \quad (1.1)$$

$$E(\varepsilon_i) = 0 \quad (1.2)$$

$$V(\varepsilon_i) = \sigma^2 \quad (1.3)$$

$$\{\varepsilon_i \mid i = 1, \dots, n\} \quad \text{stoch. unabhängig} \quad (1.4)$$

$$\varepsilon_i \sim N(0, \sigma^2) \quad (1.5)$$

Y_i : Zielgröße (Zufallsgröße), abhängige Variable

x_i : **feste** bekannte Einflussgröße, unabhängige Variable


ε_i : Zufallsfehler

$\beta_0, \beta_1, \sigma^2$: unbekannte Parameter


n : Anzahl der Beobachtungen

(vgl. Fahrmeir et al.; S. 24, 73-76)


Wahl der Kostenfunktion



Wahl der Kostenfunktion: Absolute Distanz



Wahl der Kostenfunktion: Quadratische Distanz



KQ-Methode: Gauss und Legendre

Erste Veröffentlichung durch Legendre (1805)

Asteroiden-Daten : Gauß (1795 (?))



Wir betrachten Modell (1.1).

Dann heißt


$$(\hat{\beta}_0, \hat{\beta}_1) = \arg \min_{\beta_0, \beta_1} \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i)^2 \quad (1.6)$$

KQ-Schätzer (Schätzer nach der Methode der kleinsten Quadrate) und


$$\hat{\varepsilon}_i := Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i \quad \text{heißen } \mathbf{Residuen}. \quad (1.7)$$

(vgl. Fahrmeir et al.; S. 105-108)


Schätzung: Kleinste Quadrate




Schätzung: Kleinste Quadrate



Schätzung: Kleinste Quadrate



Vergleich mit absoluter Distanz



Existenz und Berechnung des KQ-Schätzers

Der KQ-Schätzer **existiert** und ist **eindeutig**, (falls $\sum_{i=1}^n (x_i - \bar{x})^2 \neq 0$):

$$\hat{\beta}_1 = \frac{S_{xY}}{S_x^2} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(Y_i - \bar{Y})}{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2} \quad (1.8)$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{x}. \quad (1.9)$$

Beweis:

Durch Differenzieren von (1.6) erhält man $(\hat{\beta}_0, \hat{\beta}_1)$ als Lösung der Normalgleichungen

$$\sum_{i=1}^n \hat{\varepsilon}_i = 0 \quad (1.10)$$

$$\sum_{i=1}^n \hat{\varepsilon}_i x_i = 0 \quad (1.11)$$

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i; \quad i = 1, \dots, n$$
$$E(Y_i | x_i) = \beta_0 + \beta_1 x_i$$

Systematische Komponente: $\beta_0 + \beta_1 x_i$

- Zentrale Größe ist der Steigungsparameter β_1

Wenn x um eine Einheit steigt, dann steigt Y **im Durchschnitt** um β_1 Einheiten

Die Größe von β_1 hängt von der Einheit von x ab. Sie kann also nur in Zusammenhang mit x interpretiert werden.

- Interpretation des Achsenabschnitts β_0 :

Erwartungswert von Y bei $x=0$ (In vielen Fällen irrelevant)

$$\begin{aligned}Y_i &= \beta_0 + \beta_1 x_i + \varepsilon_i; \quad i = 1, \dots, n \\E(Y_i | x_i) &= \beta_0 + \beta_1 x_i\end{aligned}$$

Stochastische Komponente : Störterm ε

Interpretation des Parameters σ :

- Standardabweichung des Störterms
- Maß für die durchschnittliche Abweichung der Y -Werte von der Regressionsgeraden

Eigenschaften des KQ-Schätzers I

Gegeben sei Modell (1.1) mit Annahme (1.2).

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i; \quad i = 1, \dots, n \quad (1.1)$$

$$E(\varepsilon_i) = 0 \quad (1.2)$$

➊ Dann ist $(\hat{\beta}_0, \hat{\beta}_1)$ ein **erwartungstreuer** Schätzer für (β_0, β_1) :

$$E(\hat{\beta}_0, \hat{\beta}_1) = (\beta_0, \beta_1). \quad (1.12)$$

Eigenschaften des KQ-Schätzers II

- 2 Für die **Varianzen** von $(\hat{\beta}_0, \hat{\beta}_1)$ gilt unter den Annahmen (1.3), (1.4):

$$V(\varepsilon_i) = \sigma^2 \quad (1.3)$$

$$\{\varepsilon_i \mid i = 1, \dots, n\} \quad \text{stoch. unabhängig} \quad (1.4)$$

$$V(\hat{\beta}_1) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} = \sigma^2 / nS_x^2 \quad (1.13)$$

$$V(\hat{\beta}_0) = \sigma^2 \left[\frac{\sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right] = \sigma^2 \left[\frac{1}{n} + \frac{\bar{x}^2}{nS_x^2} \right] \quad (1.14)$$

Eigenschaften des KQ-Schätzers III

- ③ Unter der NV-Annahme (1.5):

$$\varepsilon_i \sim N(0, \sigma^2) \quad (1.5)$$

ist der KQ-Schätzer $(\hat{\beta}_0, \hat{\beta}_1)$ gleichzeitig der **ML-Schätzer**.

Beweis des Satzes I

- ❶ Es ist zu beachten, dass die x_i fest sind und dass die einzige stochastische Komponente des Modells ε_i ist.

$$\begin{aligned} E(\hat{\beta}_1) &= E \left[\frac{\sum_{i=1}^n (Y_i - \bar{Y})(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \right] \\ &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n E[(\beta_0 + \beta_1 x_i + \varepsilon_i - \beta_0 - \beta_1 \bar{x} - \bar{\varepsilon})(x_i - \bar{x})] \\ &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n [(\beta_0 + \beta_1 x_i + E[\varepsilon_i] - \beta_0 - \beta_1 \bar{x} - E[\bar{\varepsilon}])(x_i - \bar{x})] \\ &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n \beta_1 (x_i - \bar{x})(x_i - \bar{x}) = \beta_1 \end{aligned}$$

$$E(\hat{\beta}_0) = E[\bar{Y} - \hat{\beta}_1 \bar{x}] = E[\beta_0 + \beta_1 \bar{x} + \bar{\varepsilon}] - \beta_1 \bar{x} = \beta_0$$

- ❷ Übung

Beweis des Satzes II

- 3 Die Likelihood von Beobachtungen (y_i, x_i) lautet:

$$L(y_1, \dots, y_n, x_1, \dots, x_n) = \prod_{i=1}^n \left(\sqrt{2 * \pi * \sigma^2} \right)^{-1} \exp \left[-\frac{[\varepsilon_i(\beta_0, \beta_1)]^2}{2\sigma^2} \right]$$

$$\ln L(y_1, \dots, y_n, x_1, \dots, x_n) = -n/2 * \ln(\sigma^2 * 2 * \pi) - \frac{1}{2\sigma^2} \sum_{i=1}^n \varepsilon_i^2$$

Da die Parameter β_0 und β_1 nur in $\sum_{i=1}^n \varepsilon_i^2$ vorkommen, entspricht die Maximierung von $\ln(L(y_i, x_i))$ der Minimierung von $\sum_{i=1}^n \varepsilon_i^2$. Damit entspricht die KQ-Methode der ML-Methode.

Als ML-Schätzung von σ^2 ergibt sich nach Einsetzen von $\hat{\varepsilon}_i := \varepsilon_i(\hat{\beta}_0, \hat{\beta}_1)$:

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n \hat{\varepsilon}_i^2$$

Dieser Schätzer ist nicht erwartungstreu. Daher wird er selten verwendet.

Schätzung von σ^2 und Konfidenzintervalle für β_0 und β_1 I

Gegeben sei das Modell (1.1) bis (1.4).

➊ Dann ist

$$\hat{\sigma}^2 := \frac{1}{n-2} \sum_{i=1}^n \hat{\varepsilon}_i^2 = \frac{1}{n-2} \sum_{i=1}^n (Y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i))^2 \quad (1.15)$$

ein **erwartungstreuer** Schätzer für σ^2 .

Schätzung von σ^2 und Konfidenzintervalle für β_0 und β_1 II

- ② Unter der Normalverteilungsannahme (1.5) gilt:

$$\frac{1}{\sigma^2} \sum_{i=1}^n \hat{\varepsilon}_i^2 \sim \chi_{n-2}^2 \quad (1.16)$$

$$(\hat{\beta}_0, \hat{\beta}_1) \text{ und } \hat{\sigma}^2 \quad \text{stoch. unabhängig} \quad (1.17)$$

Schätzung von σ^2 und Konfidenzintervalle für β_0 und β_1 III

- 3 Unter (1.5) gilt für die Schätzer $\hat{\beta}_1$ und $\hat{\beta}_0$:

$$\frac{\hat{\beta}_1 - \beta_1}{\hat{\sigma}_{\hat{\beta}_1}} \sim t_{n-2} \text{ mit } \hat{\sigma}_{\hat{\beta}_1} := \sqrt{\frac{\hat{\sigma}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}} \quad (1.18)$$

$$\frac{\hat{\beta}_0 - \beta_0}{\hat{\sigma}_{\hat{\beta}_0}} \sim t_{n-2} \text{ mit } \hat{\sigma}_{\hat{\beta}_0} := \sqrt{\hat{\sigma}^2 \left[\frac{\sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right]} \quad (1.19)$$

- ④ Konfidenzintervalle zum Niveau $1 - \alpha$ für β_1 und β_0 unter Normalverteilungsannahme (1.5):

$$[\hat{\beta}_1 - \hat{\sigma}_{\hat{\beta}_1} t_{1-\alpha/2}(n-2); \hat{\beta}_1 + \hat{\sigma}_{\hat{\beta}_1} t_{1-\alpha/2}(n-2)] \quad (1.20)$$

$$[\hat{\beta}_0 - \hat{\sigma}_{\hat{\beta}_0} t_{1-\alpha/2}(n-2); \hat{\beta}_0 + \hat{\sigma}_{\hat{\beta}_0} t_{1-\alpha/2}(n-2)] \quad (1.21)$$

$t_{1-\alpha/2}(n-2)$: $1 - \alpha/2$ -Quantil der $t(n-2)$ -Verteilung

Teil I und **Teil II** später als Spezialfall im multiplen Regressionsmodell

Teil III:

$$\text{Def. t-Verteilung: } \left. \begin{array}{l} Z \sim N(0, 1) \\ W \sim \chi_n^2 \\ Z, W \text{ unabh.} \end{array} \right\} \frac{Z}{\sqrt{\frac{W}{n}}} \sim t_n$$

$$\hat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{\sum (x_i - \bar{x})^2}\right), \text{ da } \hat{\beta}_1 = \sum \frac{x_i - \bar{x}}{\sum (x_i - \bar{x})^2} Y_i \sim NV$$

(Summe von unabh. NV ZG)

Aus der Def. der t-Vert. und Teil II $\Rightarrow$ Behauptung

Teil IV:

Standard-Konstruktion von Konfidenzintervallen

Beispiel: Analyse von Daten aus Reihengräbern in Wenigumstadt

Fragestellung: Zusammenhang zwischen Alter (zum Todeszeitpunkt) und Knochenbälckchendicke des 4. Lendenwirbels

Im Zentrum der Interpretation stehen

- die Parameterschätzung von β_1 ,
- die Schätzung der durchschnittlichen Abweichung von der Regressionsgeraden und
- das Bestimmtheitsmaß R^2 .

Probleme:

- Messfehler
- sehr kleine Werte
- Zufälligkeit der x_i

Quadratsummenzerlegung I

Gegeben sei das Modell (1.1). Dann gilt:

1

$$\underbrace{\sum_{i=1}^n (Y_i - \bar{Y})^2}_{\text{SST}} = \underbrace{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}_{\text{SSE}} + \underbrace{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}_{\text{SSM}} \quad (1.22)$$

mit den **angepassten Größen** $\hat{Y}_i := \hat{\beta}_0 + \hat{\beta}_1 x_i$ (1.23)

SST:	Gesamtstreuung von Y	Sum of Squares Total
SSE:	Streuung der Residuen	Sum of Squares Error
SSM:	Streuung, die das Modell erklärt	Sum of Squares Model

Quadratsummenzerlegung II

2

$$R^2 = \frac{SSM}{SST} = 1 - \frac{SSE}{SST} \quad (1.24)$$

heißt **Bestimmtheitsmaß**.

Es gilt

$$R^2 = r_{xY}^2. \quad (1.25)$$

$r_{xY} :=$ Korrelationskoeffizient nach Bravais-Pearson.

Bemerkung

Zu den obigen Quadratsummen wird üblicherweise die Zahl der Freiheitsgrade angegeben. Sie bezeichnet die Anzahl der frei bestimmbaren Summanden der obigen Quadratsummen (bei geg. x_i)

bei SST: $\sum(Y_i - \bar{Y}) = 0$
 $\Rightarrow$ **df=n-1**

bei SSE: NGL liefern 2 Restriktionen
 $\Rightarrow$ **df=n-2** ($\sum \hat{\varepsilon}_i = 0$; $\sum \hat{\varepsilon}_i x_i = 0$)

bei SSM: $\sum(\hat{Y}_i - \bar{Y})^2 = \sum(\hat{\beta}_0 + \hat{\beta}_1 x_i - \bar{Y})^2 = \sum(\hat{\beta}_1(x_i - \bar{x}))^2$
 $\Rightarrow$ **df=1** (durch Wählen von 1 Y-Wert liegt $\hat{\beta}_1$ fest)

Beweis von 1):

$$\begin{aligned}\sum (Y_i - \bar{Y})^2 &= \sum (Y_i - \hat{Y}_i + \hat{Y}_i - \bar{Y})^2 \\ &= \sum (Y_i - \hat{Y}_i)^2 + \sum (\hat{Y}_i - \bar{Y})^2 + 2 \underbrace{\sum (Y_i - \hat{Y}_i)(\hat{Y}_i - \bar{Y})}_C\end{aligned}$$

$$C = \sum \hat{\varepsilon}_i(\hat{\beta}_0 + \hat{\beta}_1 x_i - \bar{Y}) = 0$$

Interpretation von R^2

R^2 ist das zentrale Maß der Anpassungsgüte der Regression

- R^2 beschreibt den Anteil der Varianz von Y , die durch x erklärt wird.
- R ist invariant gegenüber linearen Skalentransformationen
- R ist symmetrisch bzgl. x und Y .
- Vorsicht: R^2 hängt auch von der Streuung von x in der Stichprobe ab.

In Modell (1.1) mit (1.2) - (1.4) betrachten wir eine weitere Beobachtung x_{n+1} mit zugehörigem unbekanntem Y_{n+1} . Der Prognosewert von Y_{n+1} ist gegeben durch

$$\hat{Y}_{n+1} = \hat{\beta}_0 + \hat{\beta}_1 x_{n+1} \quad (1.26)$$

Für den Erwartungswert und die Varianz des Prognosefehlers gilt:

$$E \left[\hat{Y}_{n+1} - Y_{n+1} \right] = 0 \quad (1.27)$$

$$V \left[\hat{Y}_{n+1} - Y_{n+1} \right] = \sigma^2 \left[1 + \frac{1}{n} + \frac{(x_{n+1} - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right] \quad (1.28)$$

Prognoseintervall für Y_{n+1} zum Niveau $1 - \alpha$:

$$[\hat{Y}_{n+1} - \hat{\sigma}_{\hat{Y}_{n+1}} t_{1-\alpha/2}(n-2); \hat{Y}_{n+1} + \hat{\sigma}_{\hat{Y}_{n+1}} t_{1-\alpha/2}(n-2)] \quad (1.29)$$

$$\text{mit } \hat{\sigma}_{\hat{Y}_{n+1}}^2 = \hat{\sigma}^2 \left[1 + 1/n + (x_{n+1} - \bar{x})^2 / \left(\sum_{i=1}^n (x_i - \bar{x})^2 \right) \right] \quad (1.30)$$

- ① Alle Aussagen gelten nur unter der zentralen Modellannahme des linearen Zusammenhangs von $E(Y)$ und x .
- ② Transformationen sind grundsätzlich möglich. Zu beachten sind dann die geänderte Interpretation der Modellparameter und der Modellannahmen. Insbesondere ist

$$E[g(Y)] \neq g[E(Y)]$$

- ③ Das lineare Modell ist in vielen Beispielen eine sinnvolle Näherung

Lineares Modell als sinnvolle Annäherung I

Gegeben sei ein quadratisches Modell:

$$Y_i = x_i^2 + \epsilon \text{ mit } E(\epsilon) = 0, \quad x_1 = 0, x_2 = 1, x_3 = 2 \text{ und } y_1, y_2, y_3$$


Angenommen wird aber ein lineares Modell:

$$Y_i = \beta_0 + \beta_1 x_i + \epsilon$$

→ **KQ-Schätzung**

Lineares Modell als sinnvolle Annäherung II

$$\begin{aligned}E(\hat{\beta}_1) &= \frac{\sum_{i=1}^3 (x_i - \bar{x})E(Y_i - \bar{Y})}{\sum_{i=1}^3 (x_i - \bar{x})^2} \\&= \frac{1}{2} (-1E(Y_1 - \bar{Y}) + 1E(Y_3 - \bar{Y})) \\&= \frac{1}{2} \left(-(0 - \frac{5}{3}) + (4 - \frac{5}{3}) \right) = 2 \\E(\hat{\beta}_0) &= E(\bar{Y} - \hat{\beta}_1 \bar{x}) = \frac{5}{3} - 2 \cdot 1 = -\frac{1}{3}\end{aligned}$$



Lineares Modell als sinnvolle Annäherung III

Je nachdem, wie die x -Werte (unter Annahme der Richtigkeit des quadratischen Modells) liegen, bekommt man eine andere Regressionsgerade (bei Annahme eines linearen Zusammenhangs).

- Näherung im Bereich $[0, 2]$ ist akzeptabel (abhängig von der Größe des Störterms).
- Prognose außerhalb von $[0, 2]$ ergibt falsche Ergebnisse. Auch das Prognose-Intervall ist vollkommen falsch. z.B. $x = -1$ ergibt Erwartungswert der Prognose von $\hat{Y} = -2\frac{1}{3}$, obwohl $E(Y|x = -1) = 1$ richtig ist.