

3. Das multiple lineare Regressionsmodell

Modelldefinition

$$Y_i = \underbrace{\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip}}_{\mathbf{x}_i' \boldsymbol{\beta}} + \varepsilon_i; \quad i = 1, \dots, n$$
$$\mathbf{x}_i' = (1, x_{i1}, \dots, x_{ip})$$

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon} \quad (2.1)$$

mit

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix} \quad \mathbf{X} = \begin{pmatrix} 1 & x_{11} & \cdots & x_{1p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \cdots & x_{np} \end{pmatrix} \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \vdots \\ \beta_p \end{pmatrix} \quad \boldsymbol{\varepsilon} = \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

$$\begin{aligned} E(\varepsilon_i) &= 0 \\ E(\varepsilon) &= \mathbf{0} \end{aligned} \tag{2.2}$$

$$V(\varepsilon_i) = \sigma^2 \tag{2.3}$$

$$\{\varepsilon_i \mid i = 1, \dots, n\} \quad \text{unabh.} \tag{2.4}$$

$$\text{Aus (2.3), (2.4) folgt: } V(\varepsilon) = \sigma^2 \mathbf{I}$$

$$\varepsilon_i \sim N(0, \sigma^2) \text{ und (2.4)}$$

$$\varepsilon \sim N(\mathbf{0}, \sigma^2 \mathbf{I}) \tag{2.5}$$

Y: Zufallsvektor der Zielgröße

X: feste Design-Matrix (Matrix der Einflussgrößen)

β : Vektor der Regressionsparameter

ε : Störgrößen

(vgl. Fahrmeir et al.; S. 75,76)

- Lineare Abhängigkeit von den Einflussgrößen
- Steigt x_k um eine Einheit, so steigt Y im Erwartungswert um β_k Einheiten, wenn alle anderen x -**Variablen festgehalten werden**
 - Linearer Zusammenhang bei Festhalten der übrigen Variablen
 - β_k charakterisiert den Einfluss von x_k unter Berücksichtigung der übrigen Variablen („Confounder-Korrektur“)

Wir betrachten Modell (2.1). Dann heißt

$$\hat{\beta} = \arg \min_{\beta} \underbrace{(\mathbf{Y} - \mathbf{X}\beta)'(\mathbf{Y} - \mathbf{X}\beta)}_{\sum_{i=1}^n (Y_i - \mathbf{x}'_i \beta)^2} \quad (2.6)$$

KQ-Schätzer.

$$\hat{\varepsilon}_i := Y_i - \mathbf{x}'_i \hat{\beta} \quad (2.7)$$

Es gilt für $(\mathbf{X}'\mathbf{X})$ invertierbar: $\hat{\beta}$ **existiert**, ist **eindeutig** und

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{Y}. \quad (2.8)$$

Der KQ-Schätzer erfüllt die Normalgleichungen:

$$\mathbf{X}'\hat{\varepsilon} = \mathbf{0} \quad (2.9)$$

(vgl. Fahrmeir et al.; S.104-107)

- ➊ Ableiten und Nullsetzen, vergl. Fahrmeir et al.; S.117-119)
- ➋ Mit Hilfe linearer Algebra und Projektionen: vergl. Skript Thomas Nagler Kapitel 5.8.

Produktsummenmatrix

Die Matrix $\mathbf{X}'\mathbf{X}$ heißt Produktsummenmatrix.

Es gilt:

$$\mathbf{X}'\mathbf{X} = \begin{pmatrix} n & \sum x_{i1} & \cdots & \sum x_{ip} \\ \sum x_{i1} & \sum x_{i1}^2 & \cdots & \sum x_{i1}x_{ip} \\ \vdots & \vdots & \ddots & \vdots \\ \sum x_{ip} & \cdots & \cdots & \sum x_{ip}^2 \end{pmatrix} \quad (2.10)$$

Eigenschaften des KQ-Schätzers

Sei das Modell (2.1) mit (2.2) gegeben.

- ❶ Der KQ-Schätzer ist **erwartungstreu**:

$$E(\hat{\beta}) = \beta \quad (2.11)$$

- ❷ Für die Varianz-Kovarianz-Matrix von $\hat{\beta}$ gilt unter (2.3) und (2.4):

$$V(\hat{\beta}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1} \quad (2.12)$$

- ❸ Unter (2.5) gilt:

$$\hat{\beta} \sim N(\beta, \sigma^2(\mathbf{X}'\mathbf{X})^{-1}) \quad (2.13)$$

Hat-Matrix und Residualmatrix

Sei das Modell (2.1) mit einer Designmatrix $\mathbf{X}$ mit $rg(\mathbf{X}) = p + 1$ gegeben. Es gilt:

$$\hat{\mathbf{Y}} = \underbrace{\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}}_{\hat{\boldsymbol{\beta}}} \quad (2.14)$$

$$\mathbf{P} := \underbrace{\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'}_{n \times n} \quad (2.15)$$


$$\hat{\boldsymbol{\varepsilon}} = \mathbf{Y} - \hat{\mathbf{Y}} = \underbrace{(\mathbf{I} - \mathbf{P})\mathbf{Y}}_{\mathbf{Q}} \quad (2.16)$$

$$\mathbf{Q} := \mathbf{I} - \mathbf{P} \quad (2.17)$$

(vgl. Fahrmeir et al.; S. 120)

Geometrische Interpretation

Wir betrachten den Vektorraum $\mathbb{R}^n$. Die Größen $\mathbf{Y}$ und $\mathbf{x}$ sind Vektoren. Die KQ-Schätzung ist eine orthogonale Projektion auf den von den $\mathbf{x}$ -Vektoren aufgespannten Unterraum:



(vgl. Nagler Kap. 5)

Eigenschaften von P und Q

P heißt **Hat-Matrix** ($\hat{Y} = PY$), Q **Residualmatrix**. P und Q sind Projektionsmatrizen und zueinander orthogonal:

$$P' = P, P^2 = P \quad (2.18)$$

$$Q' = Q, Q^2 = Q \quad (2.19)$$

$$PQ = QP = 0 \quad (2.20)$$

(vgl. Fahrmeir et al.; S. 108)

- Beweis durch Nachrechnen (benutze $(\mathbf{AB})' = \mathbf{B}'\mathbf{A}'$)
- Bedeutung von $\mathbf{P}^2 = \mathbf{P}$:
zweimaliges Anwenden der Regression führt zum gleichen Ergebnis
- Bedeutung von $\mathbf{PQ} = \mathbf{0}$:
Regression von Residuen liefert $\hat{y} = 0$.

Für die Varianz-Kovarianz-Matrizen von $\hat{\mathbf{Y}}$ bzw. $\hat{\varepsilon}$ gilt:

$$V(\hat{\mathbf{Y}}) = \sigma^2 \mathbf{P} \quad (2.21)$$

$$V(\hat{\varepsilon}) = \sigma^2 \mathbf{Q} \quad (2.22)$$

$$\text{da } \hat{\varepsilon} = \mathbf{Q}\varepsilon \quad (2.23)$$

Erwartungstreue Schätzung von σ^2

Gegeben sei das Modell (2.1) mit (2.2) bis (2.4).

Dann ist:

$$\hat{\sigma}^2 = \frac{1}{n - (p + 1)} \hat{\varepsilon}' \hat{\varepsilon} = \frac{1}{n - (p + 1)} \sum \hat{\varepsilon}_i^2 \quad (2.24)$$

ein erwartungstreuer Schätzer für σ^2 .

$$\begin{aligned}E(\hat{\varepsilon}'\hat{\varepsilon}) &= E(\varepsilon'\mathbf{Q}'\mathbf{Q}\varepsilon) = E\left(\sum_{i=1}^n \sum_{j=1}^n q_{ij}\varepsilon_i\varepsilon_j\right) \\&= \sum_{i=1}^n E(\varepsilon_i^2)q_{ii} + 0 = \sigma^2 * sp(\mathbf{Q}) \\&= \sigma^2 * (n - sp(\mathbf{P})) = \sigma^2 * (n - (p + 1)) \\\\sp(\mathbf{P}) &= sp(\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}') = sp((\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}) = sp(\mathbf{I}_{p+1})\end{aligned}$$

Bemerkung:

Für Projektionsmatrizen gilt allgemein: $sp(\mathbf{P}) = rg(\mathbf{P})$

Beispiel: Lesetest

Welche Faktoren stehen in Zusammenhang mit den Fehlern bei einem Lesetest ?

Daten von Christa Kieferle (Pädagogik, LMU)

180 Kinder aus 8 Klassen (3. und 4. Klassen Grundschule)

Zielgröße:

Anzahl der Fehler bei einem Lesetest

potentielle Einflussgrößen:

Geschlecht, Jahrgang, Leseförderzeit, sonstiges Lesen, Gameboy ,
Jahrgang.

$$E(Y) = \beta_0 + \beta_1 * GE + \beta_2 * JG + \beta_3 * LZ + \beta_4 * WOL + \beta_5 * WOG + \beta_6 * WOTV$$

Y: Anzahl der Fehler

GE: Indikator für männlich (= 1 für männlich, 0 sonst)

JG: Indikator für Klassenstufe (=1 für 3. Klasse, 0 für 4.Klasse)

LZ: Lesezeit in der Schule

WOL: Wie oft wird sonst gelesen

WOG: Wie oft wird Gameboy gespielt

WOTV: Wie oft TV

Interpretation der Parameter, z.B β_1 : Geschlechtsunterschied

Annahme:

Bei WOL ist der durchschnittliche Unterschied in der Fehlerzahl zwischen den Stufen 1-5 gleich groß. (Änderung um 1 entspricht β_4)