

4. Quadratsummenzerlegung und statistische Inferenz im multiplen linearen Regressionsmodell

Quadratsummenzerlegung

Gegeben sei das Modell (2.1) mit Design-Matrix $\mathbf{X}$ und

$$\text{rg}(\mathbf{X}) = p + 1 =: p'. \quad (3.1)$$


Dann gilt:

$$\underbrace{(\mathbf{Y} - \bar{\mathbf{Y}})'(\mathbf{Y} - \bar{\mathbf{Y}})}_{SST} = \underbrace{(\mathbf{Y} - \hat{\mathbf{Y}})'(\mathbf{Y} - \hat{\mathbf{Y}})}_{SSE} + \underbrace{(\hat{\mathbf{Y}} - \bar{\mathbf{Y}})'(\hat{\mathbf{Y}} - \bar{\mathbf{Y}})}_{SSM} \quad (3.2)$$

Interpretation:

- SST : Gesamt-Streuung, (korrigierte) Gesamt-Quadratsumme, “Total”
- SSE : Fehler-Quadratsumme, “Error”
- SSM : Modell-Quadratsumme, “Model”

Quadratsummenzerlegung



(vgl. Fahrmeir et al.; S. 122) und Nagler, Kap. 5

Zerlegung ohne Absolutglied

Die Zerlegung (3.2) setzt ein Absolutglied in der Regression voraus.

Weitere Zerlegung, die nicht notwendig ein Absolutglied in der Regression voraussetzt:

$$\underbrace{\mathbf{Y}'\mathbf{Y}}_{SST^*} = \underbrace{(\mathbf{Y} - \hat{\mathbf{Y}})'(\mathbf{Y} - \hat{\mathbf{Y}})}_{SSE} + \underbrace{\hat{\mathbf{Y}}'\hat{\mathbf{Y}}}_{SSM^*} \quad (3.3)$$

- SST^* : Nicht korrigierte Gesamt-Quadratsumme
Erfasst auch Abweichungen von $Y = 0$ und nicht nur von $\bar{Y}$.
- SSE : Fehler-Quadratsumme, wie bei (3.2)
- SSM^* : Nicht korrigierte Modell-Quadratsumme

Nachweis der Quadratsummenzerlegung (3.3)

$$\begin{aligned} \mathbf{Y}'\mathbf{Y} &= \mathbf{Y}'\mathbf{I}\mathbf{Y} \\ &\stackrel{2.17}{=} \mathbf{Y}'(\mathbf{Q} + \mathbf{P})\mathbf{Y} \\ &= \mathbf{Y}'\mathbf{Q}\mathbf{Y} + \mathbf{Y}'\mathbf{P}\mathbf{Y} \\ &\stackrel{2.18}{=} \mathbf{Y}'\mathbf{Q}'\mathbf{Q}\mathbf{Y} + \mathbf{Y}'\mathbf{P}'\mathbf{P}\mathbf{Y} \\ &= \hat{\boldsymbol{\epsilon}}'\hat{\boldsymbol{\epsilon}} + \hat{\mathbf{Y}}'\hat{\mathbf{Y}} \quad \text{qed} \end{aligned}$$

P und **Q** sind Projektionsmatrizen.

Nachweis der Quadratsummenzerlegung (3.2) I

Wir definieren:

$$\mathbf{P}_e = \mathbf{e}(\mathbf{e}'\mathbf{e})^{-1}\mathbf{e}', \quad \mathbf{Q}_e = \mathbf{I} - \mathbf{P}_e \text{ mit } \mathbf{e} = (1, 1, \dots, 1)'. \quad (3.4)$$

$\mathbf{P}_e$ entspricht der Regression auf eine Konstante ($E(\mathbf{Y}) = \beta_0$).

$$\mathbf{P}_e \mathbf{Y} = \bar{\mathbf{Y}} \quad (\text{„Mittelwert bilden“})$$

$$\mathbf{Q}_e \mathbf{Y} = \mathbf{Y} - \bar{\mathbf{Y}} \quad (\text{„Mittelwertsbereinigung“})$$

$\mathbf{P}_e$, $\mathbf{Q}_e$ sind dabei auch idempotent mit denselben Eigenschaften wie $\mathbf{P}$ und $\mathbf{Q}$.

$$\begin{aligned} (\mathbf{Y} - \bar{\mathbf{Y}})'(\mathbf{Y} - \bar{\mathbf{Y}}) &= \mathbf{Y}'\mathbf{Q}_e'\mathbf{Q}_e\mathbf{Y} = \mathbf{Y}'\mathbf{Q}_e\mathbf{Y} \\ &= \mathbf{Y}'\mathbf{Q}_e(\mathbf{Q} + \mathbf{P})\mathbf{Y} = \mathbf{Y}'\mathbf{Q}_e\mathbf{Q}\mathbf{Y} + \mathbf{Y}'\mathbf{Q}_e\mathbf{P}\mathbf{Y} \\ &\stackrel{(*)}{=} \dots \end{aligned}$$

Nachweis der Quadratsummenzerlegung (3.2) II

$$(*) \quad \mathbf{Q}_e \mathbf{QY} = \mathbf{Q}_e \hat{\mathbf{e}} = \hat{\mathbf{e}} = \mathbf{QY}$$

↑

„Residuen haben Mittelwert 0“

$$\begin{aligned} (*) \quad \mathbf{Q}_e \mathbf{PQ}_e \mathbf{PY} &= \mathbf{Q}_e \mathbf{PQ}_e \hat{\mathbf{Y}} = \mathbf{Q}_e \mathbf{P}(\hat{\mathbf{Y}} - \bar{\mathbf{Y}}) \\ &= \mathbf{Q}_e \mathbf{P}\hat{\mathbf{Y}} - \mathbf{Q}_e \mathbf{P}\bar{\mathbf{Y}} = \mathbf{Q}_e \hat{\mathbf{Y}} - \mathbf{Q}_e \bar{\mathbf{Y}} = \mathbf{Q}_e \hat{\mathbf{Y}} - \mathbf{0} \end{aligned}$$

↑

„Regression auf $\hat{\mathbf{Y}}$ und $\bar{\mathbf{Y}}$ liefert Identität“

$$\begin{aligned} (\mathbf{Y} - \bar{\mathbf{Y}})'(\mathbf{Y} - \bar{\mathbf{Y}}) &= \mathbf{Y}'\mathbf{Q}'_e\mathbf{Q}_e\mathbf{Y} = \mathbf{Y}'\mathbf{Q}_e\mathbf{Y} \\ &= \mathbf{Y}'\mathbf{Q}_e(\mathbf{Q} + \mathbf{P})\mathbf{Y} = \mathbf{Y}'\mathbf{Q}_e\mathbf{QY} + \mathbf{Y}'\mathbf{Q}_e\mathbf{PY} \\ &\stackrel{(*)}{=} \mathbf{Y}'\mathbf{QY} + \mathbf{Y}'\mathbf{Q}_e\mathbf{PQ}_e\mathbf{PY} \\ &= \hat{\mathbf{e}}'\hat{\mathbf{e}} + \mathbf{Y}'\mathbf{P}'\mathbf{Q}_e\mathbf{PY} \\ &= \hat{\mathbf{e}}'\hat{\mathbf{e}} + (\hat{\mathbf{Y}} - \bar{\mathbf{Y}})'(\hat{\mathbf{Y}} - \bar{\mathbf{Y}}) \end{aligned}$$

Erwartungswerte der Quadratsummen

Wir betrachten das multiple Regressionsmodell (2.1) mit (2.2) bis (2.4) und

$$\mathbf{P}_e = \mathbf{e}(\mathbf{e}'\mathbf{e})^{-1}\mathbf{e}', \quad \mathbf{Q}_e = \mathbf{I} - \mathbf{P}_e \text{ mit } \mathbf{e} = (1, 1, \dots, 1)'$$

Dann gilt für die Erwartungswerte der Quadratsummen:

$$E(SST^*) = E(\mathbf{Y}'\mathbf{Y}) = \sigma^2 n + \beta' \mathbf{X}' \mathbf{X} \beta \quad (3.5)$$

$$E(SST) = E(\mathbf{Y} - \bar{\mathbf{Y}})'(\mathbf{Y} - \bar{\mathbf{Y}}) = \sigma^2(n-1) + \beta'(\mathbf{Q}_e \mathbf{X})'(\mathbf{Q}_e \mathbf{X})\beta \quad (3.6)$$

$$E(SSE) = E(\hat{\varepsilon}'\hat{\varepsilon}) = \sigma^2(n-p') \quad (3.7)$$

$$E(SSM^*) = E(\hat{\mathbf{Y}}'\hat{\mathbf{Y}}) = \sigma^2 p' + \beta' \mathbf{X}' \mathbf{X} \beta \quad (3.8)$$

$$E(SSM) = E(\hat{\mathbf{Y}} - \bar{\mathbf{Y}})'(\hat{\mathbf{Y}} - \bar{\mathbf{Y}}) = \sigma^2 p + \beta'(\mathbf{Q}_e \mathbf{X})'(\mathbf{Q}_e \mathbf{X})\beta \quad (3.9)$$

- ❶ Die stochastischen Eigenschaften der Quadratsummen werden zur Konstruktion von Tests bezüglich β genutzt
- ❷ $\beta = \mathbf{0} \implies E(\mathbf{Y}'\mathbf{Y}) = \sigma^2 n$
- ❸ $\beta_1, \dots, \beta_p = 0 \implies E(SSM) = \sigma^2 p$

Zum Nachweis von 3) benutzt man, dass $\mathbf{Q}_e$ der „Mittelwertsbereinigungs-Operator“ ist:

$$\mathbf{Q}_e \mathbf{x} = (\mathbf{I} - \mathbf{P}_e) \mathbf{x} = \mathbf{x} - \bar{\mathbf{x}}$$

Die erste Spalte von $\mathbf{Q}_e \mathbf{X}$ ist also der Nullvektor.

Allgemein berechnet man den Erwartungswert von quadratischen Formen wie folgt:

$$\begin{aligned}E(\mathbf{Y}'\mathbf{A}\mathbf{Y}) &= E\left(\sum_{i=1}^n \sum_{j=1}^n a_{ij} Y_i Y_j\right) = \sum_{i=1}^n \sum_{j=1}^n a_{ij} E(Y_i Y_j) \\&= \sum_{i=1}^n \sum_{j=1}^n a_{ij} E(Y_i) E(Y_j) + \sum_{i=1}^n \sum_{j=1}^n a_{ij} \text{Cov}(Y_i, Y_j) \\&= E(\mathbf{Y})' \mathbf{A} E(\mathbf{Y}) + \text{sp}(\mathbf{A}\mathbf{V}(\mathbf{Y}))\end{aligned}$$

$\mathbf{V}(\mathbf{Y})$:= Varianz-Kovarianzmatrix von $\mathbf{Y}$

Unter Benutzung von $\text{sp}(\mathbf{A}\mathbf{V}(\mathbf{Y})) = \text{sp}(\mathbf{A}) * \sigma^2 = \text{rang}(\mathbf{A}) * \sigma^2$ für Projektionsmatrizen erhält man obige Identitäten.

Mittlere Quadratsummen

Wir definieren entsprechend der Zahl der Freiheitsgrade die **mittleren Quadratsummen**:

$$MST^* := \frac{SST^*}{n} \quad (3.10)$$

$$MST := \frac{SST}{n-1} \quad (3.11)$$

$$MSE := \frac{SSE}{n-p'} \quad (3.12)$$

$$MSM^* := \frac{SSM^*}{p'} \quad (3.13)$$

$$MSM := \frac{SSM}{p} \quad (3.14)$$

Normalverteilung

Ein n -dimensionaler Zufallsvektor $\mathbf{Z}$ heißt multivariat normalverteilt, falls für seine Dichtefunktion gilt:

$$f_{\mathbf{Z}}(\mathbf{z}) = \frac{1}{\sqrt{\det \mathbf{\Sigma}} \sqrt{(2\pi)^n}} \exp \left[-\frac{1}{2}(\mathbf{z} - \boldsymbol{\mu})' \mathbf{\Sigma}^{-1} (\mathbf{z} - \boldsymbol{\mu}) \right] \quad (3.15)$$

mit positiv definiter, symmetrischer Matrix $\mathbf{\Sigma}$.

Bezeichnung: $\mathbf{Z} \sim N_n(\boldsymbol{\mu}, \mathbf{\Sigma})$

Eigenschaften der Normalverteilung

Ist $\mathbf{Z} \sim N_n(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, so gilt:

1 Momente:

$$\begin{aligned} E(\mathbf{Z}) &= \boldsymbol{\mu} \\ V(\mathbf{Z}) &= \boldsymbol{\Sigma} \end{aligned}$$

2 Lineare Transformationen:

Ist $\mathbf{A} : \mathbb{R}^n \rightarrow \mathbb{R}^m$ eine lineare Transformation mit $\text{rg}(\mathbf{A}) = m$

$$\implies \mathbf{AZ} \sim N_m(\mathbf{A}\boldsymbol{\mu}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}') \quad (3.16)$$

3 Orthogonale Transformation in unabhängige Komponenten (Spektralzerlegung)

Es existiert eine Matrix $\mathbf{T} \in \mathbb{R}^{n \times n}$ mit $\mathbf{T}'\mathbf{T} = \mathbf{I}$ und $\mathbf{T}\boldsymbol{\Sigma}\mathbf{T}' = \text{diag}(\lambda_1, \dots, \lambda_n)$, so dass

$$\mathbf{TZ} \sim N_n(\mathbf{T}\boldsymbol{\mu}, \text{diag}(\lambda_1, \dots, \lambda_n)) \text{ gilt.} \quad (3.17)$$

Chi-Quadrat-Verteilung I

Ist $\mathbf{Z} \sim N_n(\boldsymbol{\mu}, \mathbf{I})$, so heißt $W = \mathbf{Z}'\mathbf{Z}$ (nicht-zentral) Chi-Quadrat-verteilt.

Bezeichnung: $W \sim \chi^2(n, \delta)$

n : Zahl der Freiheitsgrade

$\delta := \boldsymbol{\mu}'\boldsymbol{\mu}$: Nichtzentralitätsparameter

Im Fall $\delta = 0$ erhält man die zentrale $\chi^2(n)$ -Verteilung.

Chi-Quadrat-Verteilung II

Eigenschaften: Ist $W \sim \chi^2(n, \delta)$, so gilt:

① Momente:

$$\begin{aligned} E(W) &= n + \delta \\ V(W) &= 2n + 4\delta \end{aligned}$$

② Allgemeiner Bezug zur Normalverteilung

$$\mathbf{Z} \sim N_n(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \quad \implies \quad \mathbf{Z}'\boldsymbol{\Sigma}^{-1}\mathbf{Z} \sim \chi^2(n, \boldsymbol{\mu}'\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}) \quad (3.18)$$

t-Verteilung

Seien Z und W voneinander unabhängige Zufallsgrößen mit

$$\begin{aligned} Z &\sim N(\delta, 1), \\ W &\sim \chi^2(n). \end{aligned}$$

Dann heißt $T = \frac{Z}{\sqrt{\frac{W}{n}}}$ (nicht-zentral) t-verteilt.

Bezeichnung: $T \sim t(n, \delta)$

n : Zahl der Freiheitsgrade

δ : Nichtzentralitätsparameter

Erwartungswert: Ist $T \sim t(n, \delta)$, so gilt:

$$E(T) = \delta \sqrt{\frac{n}{2}} \frac{\Gamma(\frac{n-1}{2})}{\Gamma(\frac{n}{2})} \quad \text{für } n > 1 \quad (3.19)$$

F-Verteilung

Seien W_1 und W_2 voneinander unabhängige Zufallsgrößen mit:

$$W_1 \sim \chi^2(n_1, \delta),$$

$$W_2 \sim \chi^2(n_2).$$

Dann heißt $X = \frac{W_1/n_1}{W_2/n_2}$ (nicht-zentral) F-verteilt.

Bezeichnung: $X \sim F(n_1, n_2, \delta)$

n_1 : Zählerfreiheitsgrade

n_2 : Nennerfreiheitsgrade

δ : Nichtzentralitätsparameter

Erwartungswert: Ist $X \sim F(n_1, n_2, \delta)$, so gilt:

$$E(X) = \frac{n_2}{n_2 - 2} (1 + \delta/n_1) \text{ für } n_2 > 2 \quad (3.20)$$

Unabhängigkeit von Quadratsummen (Satz von Cochran)

Sei $\mathbf{Z} \sim N(\boldsymbol{\mu}, \mathbf{I})$, $\dim \mathbf{Z} = n$,
 $\mathbf{A} \in R^{n \times n}$, $\mathbf{A}' = \mathbf{A}$, $rg(\mathbf{A}) = r$, $\mathbf{A}^2 = \mathbf{A}$,
 $\mathbf{B} \in R^{n \times n}$, $\mathbf{B}^2 = \mathbf{B}$, $\mathbf{B} = \mathbf{B}'$,
 $\mathbf{C} \in R^{m \times n}$.

Dann gilt:

$$\mathbf{Z}'\mathbf{A}\mathbf{Z} \sim \chi^2(r, \boldsymbol{\mu}'\mathbf{A}\boldsymbol{\mu}) \quad (3.21)$$

$$\mathbf{C}\mathbf{A} = \mathbf{0} \implies \mathbf{C}\mathbf{Z} \text{ und } \mathbf{Z}'\mathbf{A}\mathbf{Z} \text{ sind unabh.} \quad (3.22)$$

$$\mathbf{A}\mathbf{B} = \mathbf{0} \implies \mathbf{Z}'\mathbf{A}\mathbf{Z} \text{ und } \mathbf{Z}'\mathbf{B}\mathbf{Z} \text{ sind unabh.} \quad (3.23)$$

Beweis von (3.21)

Spektralzerlegung von $\mathbf{A}$

$$\mathbf{A} = \mathbf{T}\mathbf{\Sigma}\mathbf{T}'$$

$$\mathbf{\Sigma} = \underbrace{\begin{pmatrix} 1 & & & \\ & \ddots & & \\ & & 1 & \\ & & & 0 \\ & & & & 0 \end{pmatrix}}_r \quad \text{da } \mathbf{A}^2 = \mathbf{A}$$

$$\Rightarrow \mathbf{Z}'\mathbf{A}\mathbf{Z} = \mathbf{Z}'\mathbf{T}\mathbf{\Sigma}\mathbf{T}'\mathbf{Z}$$

Für $\tilde{\mathbf{Z}} := \mathbf{T}'\mathbf{Z}$ gilt: $\text{Var}(\tilde{\mathbf{Z}}) = \mathbf{T}'\mathbf{I}\mathbf{T} = \mathbf{I}$

$$\Rightarrow \mathbf{Z}'\mathbf{A}\mathbf{Z} = \tilde{\mathbf{Z}}'\mathbf{\Sigma}\tilde{\mathbf{Z}} = \sum_{i=1}^r \tilde{z}_i^2 \sim \chi^2(r, \boldsymbol{\mu}'\mathbf{A}\boldsymbol{\mu})$$

Beweis von (3.22) und (3.23)

$$\text{Cov}(\mathbf{CZ}, \mathbf{Z}'\mathbf{A}) = \mathbf{C}\text{Cov}(\mathbf{Z}, \mathbf{Z}')\mathbf{A} = \mathbf{CA} = \mathbf{0}$$

Damit sind $\mathbf{CZ}$ und $\mathbf{Z}'\mathbf{A}$ unabhängig. (NV-Annahme!)

$\Rightarrow \mathbf{CZ}$ und $(\mathbf{Z}'\mathbf{A})(\mathbf{Z}'\mathbf{A})' = \mathbf{Z}'\mathbf{AZ}$ unabh.

qed

$$\text{Cov}(\mathbf{AZ}, \mathbf{Z}'\mathbf{B}) = \mathbf{A}\text{Cov}(\mathbf{Z}, \mathbf{Z}')\mathbf{B} = \mathbf{AB} = \mathbf{0}$$

Damit sind $\mathbf{AZ}$ und $\mathbf{Z}'\mathbf{B}$ unabhängig. (NV-Annahme!)

$\Rightarrow (\mathbf{AZ})'(\mathbf{AZ}) = \mathbf{Z}'\mathbf{AZ}$ und $(\mathbf{Z}'\mathbf{B})(\mathbf{Z}'\mathbf{B})' = \mathbf{Z}'\mathbf{BZ}$ unabh.

qed

Verteilung des KQ-Schätzers unter Normalverteilung

Sei ein multiples Regressionsmodell (2.1) mit (2.5) und $rg(\mathbf{X}) = p'$ gegeben. Für den KQ-Schätzer $\hat{\beta}$ gilt:

$$\hat{\beta} \sim N(\beta, \sigma^2(\mathbf{X}'\mathbf{X})^{-1}) \quad (3.24)$$

$$\hat{\Sigma}_{\hat{\beta}} := \hat{\sigma}^2(\mathbf{X}'\mathbf{X})^{-1} \quad (3.25)$$

$$(n - p') \frac{\hat{\sigma}^2}{\sigma^2} \sim \chi^2(n - p') \quad (3.26)$$

$$\hat{\sigma} \text{ und } \hat{\beta} \text{ sind unabhängig} \quad (3.27)$$

$$\hat{\sigma}_{\hat{\beta}_k} := \sqrt{c_{kk}} \hat{\sigma}, \quad (3.28)$$

(c_{kk} entspr. Diagonalelement von $(\mathbf{X}'\mathbf{X})^{-1}$)

$$\frac{\hat{\beta}_k - \beta_k}{\hat{\sigma}_{\hat{\beta}_k}} \sim t(n - p', 0) \quad (3.29)$$

(vgl. Fahrmeir et al.; S. 119)

(3.24) (Normalverteilung von β) folgt aus Eigenschaften der NV (3.16).

(3.26) folgt aus (3.21), da $\hat{\sigma}^2 = \frac{1}{n-p'} \hat{\epsilon}' \hat{\epsilon} = \frac{1}{n-p'} \mathbf{Y}' \mathbf{Q} \mathbf{Y}$.
 $rg(\mathbf{Q}) = sp(\mathbf{Q})$

(3.27) folgt aus (3.22):

$$\mathbf{C} \in R^{p \times n}, \mathbf{C}\mathbf{A} = \mathbf{0} \implies \mathbf{C}\mathbf{Z} \text{ und } \mathbf{Z}'\mathbf{A}\mathbf{Z} \text{ sind unabh.}$$

mit

$$\begin{aligned}\mathbf{C} &:= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}', \quad \mathbf{A} := \mathbf{Q}, \quad \mathbf{Z} := \mathbf{Y}, \\ \mathbf{C}\mathbf{A} &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Q} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\mathbf{I} - \mathbf{P}) = \\ &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' - (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' = \mathbf{0}\end{aligned}$$

Overall-Test

Sei ein Modell (2.1) mit (2.5) und $rg(\mathbf{X}) = p'$ gegeben. Dann gilt für die mittlere Quadratsummen:

$$F_O = \frac{MSM}{MSE} \sim F(p, n - p', \sigma^{-2} \beta' (\mathbf{Q}_e \mathbf{X})' (\mathbf{Q}_e \mathbf{X}) \beta) \quad (3.30)$$

(3.30) folgt aus (3.21) und (3.23) mit

$$\begin{aligned} MSM &= SSM/p = \mathbf{Y}'(\mathbf{P} - \mathbf{P}_e)\mathbf{Y}/p \\ MSE &= SSE/(n - p') = \mathbf{Y}'\mathbf{QY}/(n - p') \\ \mathbf{Q}(\mathbf{P} - \mathbf{P}_e) &= \mathbf{QP} - \mathbf{QP}_e = \mathbf{0} \end{aligned}$$

Die Verteilung wird zur Konstruktion des folgenden Tests benutzt:

$$H_0^O : \beta_1 = \beta_2 = \dots = \beta_p = 0$$

Lehne H_0^O ab, falls

$$F_O > F_{1-\alpha}(p, n - p') \quad (3.31)$$

Lineare Hypothesen

Es sollen Hypothesen, die sich mit Hilfe linearer Transformationen von β darstellen lassen, betrachtet werden:

$$\mathbf{A} \in R^{a \times (p+1)}, \mathbf{c} \in R^a,$$

$$\mathbf{A}\beta = \mathbf{c} \text{ mit } \text{rg}(\mathbf{A}) = a$$

Beispiele:

$$p = 2 \quad \beta_1 = \beta_2 \quad \leftrightarrow \quad \mathbf{A} = \begin{pmatrix} 0 & 1 & -1 \end{pmatrix}, \mathbf{c} = 0$$

$$p = 4 \quad \beta_3 = \beta_4 = 0 \quad \leftrightarrow \quad \mathbf{A} = \begin{pmatrix} 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{pmatrix}, \mathbf{c} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$p = 4 \quad \beta_2 = 3 \quad \beta_3 + \beta_4 = 1 \quad \leftrightarrow \quad \mathbf{A} = \begin{pmatrix} 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 1 \end{pmatrix}, \mathbf{c} = \begin{pmatrix} 3 \\ 1 \end{pmatrix}$$

(vgl. Fahrmeir et al.; S.130 ff)

Allgemeine lineare Hypothese, Wald-Test

Sei das Modell (2.1) mit (2.5) und $\mathbf{A} \in R^{a \times p'}$, $rg(\mathbf{A}) = a$, $\mathbf{c} \in R^a$ gegeben.

$$V(\mathbf{A}\hat{\boldsymbol{\beta}} - \mathbf{c}) = \sigma^2 \mathbf{A}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{A}' \quad (3.32)$$

$$SSH := (\mathbf{A}\hat{\boldsymbol{\beta}} - \mathbf{c})' (\mathbf{A}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{A}')^{-1} (\mathbf{A}\hat{\boldsymbol{\beta}} - \mathbf{c}) \quad (3.33)$$

$$\sigma^{-2} SSH \sim \chi^2(a, \sigma^{-2} (\mathbf{A}\boldsymbol{\beta} - \mathbf{c})' (\mathbf{A}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{A}')^{-1} (\mathbf{A}\boldsymbol{\beta} - \mathbf{c})) \quad (3.34)$$

$$MSH := \frac{SSH}{a} \quad (3.35)$$

$$\frac{MSH}{MSE} \sim F(a, n - p', \sigma^{-2} (\mathbf{A}\boldsymbol{\beta} - \mathbf{c})' (\mathbf{A}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{A}')^{-1} (\mathbf{A}\boldsymbol{\beta} - \mathbf{c})) \quad (3.36)$$

SSH: Quadratsumme, die die Abweichung von der Hypothese $\mathbf{A}\boldsymbol{\beta} = \mathbf{c}$ beschreibt.

Test nach Wald: $H_0 : \mathbf{A}\boldsymbol{\beta} = \mathbf{c}$. Lehne H_0 ab, falls:

$$TF = MSH/MSE > F_{1-\alpha}(a, n - p') \quad (3.37)$$

Overall-Test und zweiseitiger t-Test

Die Overall-Tests (3.31) ist ein spezieller Wald-Test. Nachweis erfolgt später.

Der mit Hilfe von (3.29) konstruierte zweiseitige Test auf $\beta_k = \beta_k^0$ ist ebenfalls ein Wald-Test.

Der Nachweis erfolgt direkt unter Benutzung von $\mathbf{A} = (0 \cdots 1 \cdots 0)$

Lineare Hypothese und Modell mit Restriktion

Wir betrachten das lineare Modell mit der linearen Restriktion $\mathbf{A}\beta = \mathbf{c}$.
Alle Schätzungen aus diesem Modell werden mit $\hat{\cdot}$ gekennzeichnet.

Wir lösen das Minimierungsproblem:

$$(\mathbf{Y} - \mathbf{X}\beta)'(\mathbf{Y} - \mathbf{X}\beta) \rightarrow \min \quad \text{unter} \quad \mathbf{A}\beta = \mathbf{c}$$

mit der Lagrange-Methode:

$$S(\beta, \lambda) = (\mathbf{Y} - \mathbf{X}\beta)'(\mathbf{Y} - \mathbf{X}\beta) + 2\lambda'(\mathbf{A}\beta - \mathbf{c}).$$

Dabei ist λ der Vektor der Lagrange-Multiplikationen.

Berechnung der Lösung $\hat{\beta}$

$$\frac{\partial S}{\partial \beta} = \mathbf{0} \Leftrightarrow -2\mathbf{X}'\mathbf{Y} + 2\mathbf{X}'\mathbf{X}\hat{\beta} + 2\mathbf{A}'\lambda = \mathbf{0}$$

$$\frac{\partial S}{\partial \lambda} = \mathbf{0} \Leftrightarrow \mathbf{A}\hat{\beta} = \mathbf{c}$$

$$\mathbf{A}'\lambda = \mathbf{X}'\mathbf{Y} - \mathbf{X}'\mathbf{X}\hat{\beta} \quad | \cdot (\mathbf{X}'\mathbf{X})^{-1}$$

$$(\mathbf{X}'\mathbf{X})^{-1}\mathbf{A}'\lambda = \hat{\beta} - \hat{\beta} \quad | \cdot \mathbf{A} (*)$$

$$\Rightarrow \mathbf{A}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{A}'\lambda = \mathbf{A}\hat{\beta} - \mathbf{c} \quad (\mathbf{A}\hat{\beta} = \mathbf{c})$$

$$\Rightarrow \lambda = (\mathbf{A}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{A}')^{-1}(\mathbf{A}\hat{\beta} - \mathbf{c})$$

$$(*) \Rightarrow \hat{\beta} = \hat{\beta} - (\mathbf{X}'\mathbf{X})^{-1}\mathbf{A}'[\mathbf{A}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{A}']^{-1}(\mathbf{A}\hat{\beta} - \mathbf{c})$$

$$\mathbf{w} := (\mathbf{X}'\mathbf{X})^{-1}\mathbf{A}'[\mathbf{A}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{A}']^{-1}(\mathbf{A}\hat{\beta} - \mathbf{c})$$

Darstellung von SSH

$$\begin{aligned}\hat{\hat{\mathbf{Y}}} &= \mathbf{X}\hat{\hat{\boldsymbol{\beta}}} = \hat{\mathbf{Y}} - \mathbf{X}\mathbf{w} \\ \hat{\hat{\boldsymbol{\varepsilon}}} &= \mathbf{Y} - \hat{\hat{\mathbf{Y}}} = \hat{\boldsymbol{\varepsilon}} + \mathbf{X}\mathbf{w} \\ \Rightarrow \hat{\hat{\boldsymbol{\varepsilon}}}'\hat{\hat{\boldsymbol{\varepsilon}}} &= \hat{\boldsymbol{\varepsilon}}'\hat{\boldsymbol{\varepsilon}} + \mathbf{w}'\mathbf{X}'\mathbf{X}\mathbf{w} \quad (\text{da } \mathbf{X}'\hat{\boldsymbol{\varepsilon}} = 0) \\ &= \hat{\boldsymbol{\varepsilon}}'\hat{\boldsymbol{\varepsilon}} + (\mathbf{A}\hat{\boldsymbol{\beta}} - \mathbf{c})'[\mathbf{A}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{A}']^{-1}(\mathbf{A}\hat{\boldsymbol{\beta}} - \mathbf{c}) \\ \Rightarrow SSH &= \hat{\hat{\boldsymbol{\varepsilon}}}'\hat{\hat{\boldsymbol{\varepsilon}}} - \hat{\boldsymbol{\varepsilon}}'\hat{\boldsymbol{\varepsilon}}\end{aligned}$$

Damit haben wir eine andere Möglichkeit, SSH aus den Residuenquadratsummen zu berechnen.

Lineare Hypothese (alternative Durchführung)

Sei das Modell (2.1) mit (2.5) und $\mathbf{A} \in R^{a \times p'}$, $\text{rg}(\mathbf{A}) = a$, $\mathbf{c} \in R^a$ gegeben.

$$H_0 : \mathbf{A}\beta = \mathbf{c}$$

Berechne SSE des Modells und des Modells unter H_0 :

$$SSE = \hat{\varepsilon}'\hat{\varepsilon}$$

$$SSE(H_0) := \hat{\hat{\varepsilon}}'\hat{\hat{\varepsilon}} \quad (3.38)$$

$$SSH = SSE(H_0) - SSE \quad (3.39)$$

$$MSH = SSH/a$$

$$TF := MSH/MSE = \frac{(SSE(H_0) - SSE)/a}{SSE/(n - p')} \quad (3.40)$$

$$TF \sim F(a, n - p') \text{ unter } H_0 \quad (3.41)$$

Das Vorgehen entspricht dem Wald-Test (3.37).

Overall-Test

$$H_0^O : \beta_1 = \beta_2 = \dots = \beta_p = 0$$

Das Modell unter H_0 ist $Y = \beta_0 + \varepsilon$.

$$\begin{aligned}SSE(H_0) &= (\mathbf{Y} - \hat{\hat{\beta}}_0)'(\mathbf{Y} - \hat{\hat{\beta}}_0) = SST \\SSH &= SSE(H_0) - SSE = SSM\end{aligned}$$

Damit entspricht hier der Wald-Test dem Test (3.31).

Weglassen von Einflussgrößen

Lineare Hypothese:

$$H_0 : \beta_k = \beta_{k+1} = \dots = \beta_p = 0$$

Das Modell unter H_0 ist M1:

$$Y = \beta_0 + \beta_1 x_1 + \dots + \beta_{k-1} x_{k-1} + \varepsilon$$

$$SSE(H_0) = SSE(M1)$$

$$SSH = SSE(M1) - SSE$$

→ Vergleich der SSE der beiden Modelle.

Beispiel: Lesetest

Welche Faktoren stehen in Zusammenhang mit den Fehlern bei einem Lesetest?

Daten von Christa Kieferle (Pädagogik, LMU)

180 Kinder aus 8 Klassen (3. und 4. Klassen Grundschule)

Zielgröße:

Anzahl der Fehler bei einem Lesetest

potentielle Einflussgrößen:

Geschlecht, Jahrgang, Leseförderzeit, sonstiges lesen (0=fast nie ,..., 4=oft), Gameboy (0= fast nie ,..., 4=oft), Jahrgang.

$$Y = \beta_0 + \beta_1 * GE + \beta_2 * JG + \beta_3 * LZ + \beta_4 * WOL + \beta_5 * WOG + \beta_6 * WOTV$$

Y: Anzahl der Fehler

GE: Indikator für männlich (= 1 für männlich, 0 sonst)

JG: Indikator für Klassenstufe (=0 für 3. Klasse, 1 für 4.Klasse)

LZ: Lesezeit in der Schule

WOL: Wie oft wird sonst gelesen

WOG: Wie oft wird Gameboy gespielt

WOTV: Wie oft TV

Interpretation der Parameter, z.B β_1 : Geschlechtsunterschied

Annahme: Bei WOL ist der durchschnittliche Unterschied in der Fehlerzahl zwischen den Stufen 0-4 gleich groß. (Änderung um 1 entspricht β_4)

- ① Schätzung des Gesamtmodells
- ② Gibt es einen Zusammenhang zwischen den Variablen WOL, WOG, WOTV und Y?
- ③ Ist der Einfluss von WOG und WOTV auf die Fehlerzahl gleich?
- ④ Gibt es einen Zusammenhang von Lesezeit und WOL und der Fehlerzahl?
- ⑤ Wie lässt die Assoziation zur Lesezeit quantifizieren?

Fragen 2-4 lassen sich als lineare Hypothesen in dem Modell formulieren.
Fragen 1 und 5 betreffen die Schätzung des Modells.

Die maximierte Likelihood des Modells ist:

$$(2\pi)^{-n/2} \cdot \hat{\sigma}^{-n} \cdot \exp \left[- \sum_{i=1}^n \frac{\hat{\varepsilon}_i^2}{2\hat{\sigma}^2} \right]$$

Es folgt (siehe Nachweis $ML = KQ$ aus Kapitel 1)

$$\hat{\sigma}^2 = \frac{\sum \hat{\varepsilon}_i^2}{n} \quad (3.42)$$

$$MaxL = c * \hat{\sigma}^{-n} = c * (SSE/n)^{(-n/2)} \quad (3.43)$$

Likelihood Quotienten-Test

Grundidee des Likelihood-Quotienten-Tests:

Vergleiche (Bilde den Quotienten) maximierte Likelihood des Modells unter H_0 mit maximierter Likelihood ohne H_0

Wir betrachten also den ML - Schätzer mit und ohne die Restriktion $\mathbf{A}\beta = \mathbf{c}$:

$\hat{\hat{\epsilon}}$: Residuen unter dem Modell mit H_0

$\hat{\epsilon}$: Residuen unter dem Modell ohne Einschränkung

Die LQ- Teststatistik lautet dann:

$$\tau_{LQ} = \left(\frac{\hat{\hat{\sigma}}}{\hat{\sigma}} \right)^{-n} = \left(\frac{\hat{\hat{\epsilon}}' \hat{\hat{\epsilon}}}{\hat{\epsilon}' \hat{\epsilon}} \right)^{-n/2} \quad (3.44)$$

Wald-Test ist Likelihood-Quotienten-Test

Sei das Modell (2.1) mit (2.5) und $\mathbf{A} \in R^{a \times p'}$, $rg(\mathbf{A}) = a$, $\mathbf{c} \in R^a$ gegeben.

$$H_0 : \mathbf{A}\beta = \mathbf{c} \quad \text{gegen} \quad H_1 : \mathbf{A}\beta \neq \mathbf{c}$$

Dann ist der Wald-Test zu dem Likelihood-Quotienten-Test äquivalent, d. h. :

Die Testgröße des LQ-Tests ist eine streng monotone Funktion der Testgröße des Wald-Tests:

$$\tau_{LQ} = g \left[\frac{MSH}{MSE} \right] \quad (3.45)$$

Dabei ist g streng monoton.

Damit ist τ_{LQ} eine monotone Funktion der Testgröße des Wald-Tests:

$$\frac{MSH}{MSE} = \frac{(\hat{\hat{\epsilon}}'\hat{\hat{\epsilon}} - \hat{\hat{\epsilon}}'\hat{\hat{\epsilon}})/a}{\hat{\hat{\epsilon}}'\hat{\hat{\epsilon}}/(n - p')} =: \tau_W$$
$$\Rightarrow \left[\tau_W \cdot \frac{a}{(n - p')} + 1 \right]^{-n/2} = \tau_{LQ}$$

Sequentielle und Partielle Quadratsummen

Gegeben sei das Modell (2.1).

Wir betrachten nun Teilmodelle, die durch Nullrestriktionen von Komponenten des Vektors β entstehen sowie deren Residuenquadratsummen.

$$R(\beta_{i1}, \dots, \beta_{ik} | \beta_{j1}, \dots, \beta_{jl}) = SSH = SSE(M1) - SSE(M2) \quad (3.46)$$

M2: Modell, das die Parameter $\beta_{i1}, \dots, \beta_{ik}, \beta_{j1}, \dots, \beta_{jl}$ enthält

M1: Modell, das die Parameter $\beta_{j1}, \dots, \beta_{jl}$ enthält

SSH: Hypothesenquadratsumme zur Hypothese
($\beta_{i1} = \dots = \beta_{ik} = 0$) im Modell M2

Partielle Quadratsummen

Die zu der Hypothese $\beta_k = 0$ gehörigen Quadratsummen bzgl. des Gesamtmodells heißen **partielle Quadratsummen**:

$$R(\beta_k | \beta_0, \dots, \beta_{k-1}, \beta_{k+1}, \dots, \beta_p) = SSE(M_{-k}) - SSE \quad (3.47)$$

M_{-k} : Modell mit $\beta_k = 0$

Beachte: Die partiellen Quadratsummen führen im Allgemeinen zu keiner Zerlegung von SST, d.h.:

$$SST \neq \sum_{k=1}^p R(\beta_k | \beta_0, \dots, \beta_{k-1}, \beta_{k+1}, \dots, \beta_p) + SSE \quad (3.48)$$

Sequentielle Quadratsummen

Wir betrachten die Folge von Modellen:

$$M_0 : \quad \mathbf{Y} = \beta_0 + \varepsilon \quad (3.49)$$

$$M_1 : \quad \mathbf{Y} = \beta_0 + \beta_1 \mathbf{x}_1 + \varepsilon \quad (3.50)$$

...

$$M_p : \quad \mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \varepsilon \quad (3.51)$$

$$R(\beta_k | \beta_0, \dots, \beta_{k-1}) = SSE(M_{k-1}) - SSE(M_k) \quad (3.52)$$

heißen **sequentielle Quadratsummen** und es gilt:

$$SST = \sum_{k=1}^p R(\beta_k | \beta_0, \dots, \beta_{k-1}) + SSE \quad (3.53)$$

Wir betrachten folgende Zerlegung des Modells (2.1):

$$\begin{aligned}\mathbf{Y} &= \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon} \\ \mathbf{Y} &= (\mathbf{X}_1\mathbf{X}_2)(\boldsymbol{\beta}'_1\boldsymbol{\beta}'_2)' + \boldsymbol{\varepsilon} = \mathbf{X}_1\boldsymbol{\beta}_1 + \mathbf{X}_2\boldsymbol{\beta}_2 + \boldsymbol{\varepsilon} \\ \hat{\boldsymbol{\beta}} &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y} = (\hat{\boldsymbol{\beta}}'_1, \hat{\boldsymbol{\beta}}'_2)' \\ \mathbf{Q}_2 &:= \mathbf{I} - \mathbf{X}_2(\mathbf{X}'_2\mathbf{X}_2)^{-1}\mathbf{X}'_2 \\ \mathbf{Y}^* &:= \mathbf{Q}_2\mathbf{Y} \\ \mathbf{X}_1^* &:= \mathbf{Q}_2\mathbf{X}_1 \\ \Rightarrow \hat{\boldsymbol{\beta}}_1 &= \hat{\boldsymbol{\beta}}_1^* = (\mathbf{X}_1^{*'}\mathbf{X}_1^*)^{-1}\mathbf{X}_1^{*'}\mathbf{Y}^*\end{aligned}\tag{3.54}$$

$\mathbf{Y}^*, \mathbf{X}_1^*$: von $\mathbf{X}_2$ bereinigte Variablen

Beweis von (3.54) I

$$\mathbf{Y} = \mathbf{X}_1\beta_1 + \mathbf{X}_2\beta_2 + \epsilon \quad \mathbf{X} = (\mathbf{X}_1 \ \mathbf{X}_2) \quad \beta = \begin{pmatrix} \beta_1 \\ \beta_2 \end{pmatrix}$$

KQ:

$$\mathbf{Y} = \mathbf{X}_1\hat{\beta}_1 + \mathbf{X}_2\hat{\beta}_2 + \hat{\epsilon}$$

$$\mathbf{Q}_2 = \mathbf{I} - \mathbf{P}_2 = \mathbf{I} - \mathbf{X}_2(\mathbf{X}_2'\mathbf{X}_2)^{-1}\mathbf{X}_2'$$

$$\text{Es gilt: } \mathbf{Q}_2\mathbf{Q} = (\mathbf{I} - \mathbf{P}_2)(\mathbf{I} - \mathbf{P}) = \mathbf{I} - \mathbf{P}_2 - \mathbf{P} + \underbrace{\mathbf{P}_2\mathbf{P}}_{\mathbf{P}_2} = \mathbf{I} - \mathbf{P} = \mathbf{Q}$$

(Residuen von Regression auf $(\mathbf{X}_1 \ \mathbf{X}_2)$ und Residuen bzgl. $\mathbf{X}_2$)

$$\text{Analog: } \mathbf{Q}\mathbf{Q}_2 = \mathbf{Q}$$

Beweis von (3.54) II

$$\mathbf{Q}_2 \mathbf{Y} = \mathbf{Q}_2 \mathbf{X}_1 \hat{\beta}_1 + \underbrace{\mathbf{Q}_2 \mathbf{X}_2}_{\mathbf{0}} \hat{\beta}_2 + \underbrace{\mathbf{Q}_2 \hat{\epsilon}}_{\mathbf{Q}_2 \mathbf{Q} \mathbf{Y}}$$

$$\begin{aligned} \Rightarrow \mathbf{Q}_2 \mathbf{Y} &= \mathbf{Q}_2 \mathbf{X}_1 \hat{\beta}_1 + \hat{\epsilon} \\ \mathbf{Y}^* &= \mathbf{X}_1^* \hat{\beta}_1 + \hat{\epsilon} \quad (\text{Bereinigte Variablen}) \end{aligned}$$

$$\mathbf{X}_1^{*'} \hat{\epsilon} = (\mathbf{Q}_2 \mathbf{X}_1)' \hat{\epsilon} = \mathbf{X}_1' \mathbf{Q}_2 \mathbf{Q} \mathbf{Y} = \mathbf{X}_1' \hat{\epsilon} = 0$$

$\Rightarrow \hat{\beta}_1$ ist KQ-Lösung der Regression von $\mathbf{Y}^*$ auf $\mathbf{X}^*$.

Beispiele zur Bereinigung

Mittelwerts-Bereinigung beim einfachen linearen Regressionsmodell

$$\mathbf{X}_2 = (1 \dots 1)'$$

$$\mathbf{X}_1 = (x_1 \dots x_n)'$$

$$\mathbf{Y}^* = Y - \bar{y}$$

$$\mathbf{X}_1^* = x - \bar{x}$$

$$(\mathbf{X}'^* \mathbf{X}^*)^{-1} \mathbf{X}'^* \mathbf{Y}^* = S_x^{-2} S_{xy}$$

z.B.: Geschlechtseffekt, Trendbereinigung

Der Partial leverage plot


Wir betrachten den Fall einer Variablen x_1 und bezeichnen die Matrix der übrigen Variablen mit X_2 . Die Residuen der Regressionen von Y und x_1 aus X_2 bezeichnen wir mit Y^* bzw. x_1^* (Bereinigte Daten). Ziele:

- Identifizierung des Beitrags einer Variablen in der multiplen Regression
- Aufdecken von Ausreißern oder einflussreichen Beobachtungen
- Überprüfung der Modellannahmen

Bespiel Lesedaten

Partial leverage plot zum Zusammenhang zwischen Lesezeit und Fehlerzahl

Bereinigung bezüglich aller anderen Variablen



Beispiel Lesedaten: Bereinigung Geschlechtseffekt

Zielgröße : Anzahl der Fehler bei Test

Einflussgrößen : Geschlecht, Alter, Leseverhalten, Fernsehverhalten, etc.

Regression auf binäre Variable Geschlecht entspricht
Mittelwertsschätzung

Bereinigung nach Geschlecht: Abziehen des jeweiligen
Gruppenmittelwertes

In Modell (2.1) betrachten wir eine weitere Beobachtung mit bekanntem Vektor der x -Werte $\mathbf{x}_{n+1}$ und zugehörigem, unbekanntem Y_{n+1} . Der Prognosewert von Y_{n+1} ist gegeben durch

$$\hat{Y}_{n+1} = \mathbf{x}'_{n+1} \hat{\beta} \quad (3.55)$$

Für den Erwartungswert und die Varianz des Prognosefehlers gilt:

$$E \left[\hat{Y}_{n+1} - Y_{n+1} \right] = 0 \quad (3.56)$$

$$V \left[\hat{Y}_{n+1} - Y_{n+1} \right] = \sigma^2 (1 + \mathbf{x}'_{n+1} (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_{n+1}) \quad (3.57)$$

Der Nachweis verläuft analog zum einfachen linearen Modell unter Berücksichtigung von:

$$V(\hat{\beta}) = \sigma^2 (\mathbf{X}'\mathbf{X})^{-1}$$

Prognoseintervalle und Konfidenzintervalle

Das Prognoseintervall für eine zukünftige Beobachtung y_{n+1} bei gegebenem $\mathbf{x}_{n+1}$ erhält man mit Hilfe der Normalverteilung von $\hat{\beta}$ und durch Standardisieren:

$$[\hat{Y}_{n+1} - \hat{\sigma}_{\hat{Y}_{n+1}} t_{1-\alpha/2}(n-p'); \hat{Y}_{n+1} + \hat{\sigma}_{\hat{Y}_{n+1}} t_{1-\alpha/2}(n-p')] \quad (3.58)$$

$$\text{mit } \hat{\sigma}_{\hat{Y}_{n+1}}^2 = \hat{\sigma}^2 (1 + \mathbf{x}_{n+1}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_{n+1})$$

Das Konfidenzintervall für den Erwartungswert μ_{n+1} einer zukünftige Beobachtung y_{n+1} bei gegebenem $\mathbf{x}_{n+1}$ ist:

$$[\hat{Y}_{n+1} - \hat{\sigma}_{\hat{\mu}_{n+1}} t_{1-\alpha/2}(n-p'); \hat{Y}_{n+1} + \hat{\sigma}_{\hat{\mu}_{n+1}} t_{1-\alpha/2}(n-p')] \quad (3.59)$$

$$\text{mit } \hat{\sigma}_{\hat{\mu}_{n+1}}^2 = \hat{\sigma}^2 (\mathbf{x}_{n+1}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_{n+1})$$

(vgl. Fahrmeir et al.; S.152)

- Prognoseintervalle enthalten die Zufallsschwankung durch den Störterm ε_{n+1} **und** die Unsicherheit bezüglich der Modellparameter
- Die entsprechenden Konfidenzintervalle enthalten nur die Unsicherheit bezüglich der Modellparameter. Sie können gut zur Darstellung der Modellschätzung verwendet werden.
- Um den geschätzten Effekt einer Einflussgröße x_1 darzustellen, werden die anderen Einflussgrößen auf einen festen Wert (z.B. Modus, Median oder Mittelwert) gesetzt. Dann wird der Zusammenhang von $x_{1,n+1}$ und $\hat{Y}_{n+1}$ zusammen mit den entsprechenden Konfidenzintervallen geplottet. (R-Paket: effects)

Das Gauss-Markov-Theorem

Sei das Modell

$$\begin{aligned}\mathbf{Y} &= \mathbf{X}\beta + \varepsilon, \quad \text{rg } \mathbf{X} = p' \\ E(\varepsilon) &= \mathbf{0} \\ V(\varepsilon) &= \sigma^2 \mathbf{I}\end{aligned}$$

gegeben.

Dann ist der KQ-Schätzer $\hat{\beta}$ unter den erwartungsternen linearen Schätzern derjenige mit der kleinsten Varianz: $\hat{\beta}$ ist BLUE-Schätzer (**b**est **l**inear **u**nbiased **e**stimator).

Ist $\tilde{\beta}$ ein weiterer Schätzer von β mit $E(\tilde{\beta}) = \beta$ und $\tilde{\beta} = \mathbf{C}\mathbf{Y}$, so gilt:

$$V(\tilde{\beta}) \geq V(\hat{\beta})$$

$$V(\tilde{\beta}) \geq V(\hat{\beta}) \Leftrightarrow V(\tilde{\beta}) = V(\hat{\beta}) + \mathbf{M} \text{ mit } \mathbf{M} \text{ positiv semidefinit.}$$

(vgl. Fahrmeir et al.; S. 187)

Konsistenz des KQ-Schätzers I

Sei das Modell (2.1) - (2.4) gegeben. Wir betrachten nun das Modell mit steigendem Stichprobenumfang n . Da die Einflussgrößen fest sind, gehen wir von einer gegebenen Folge x_n der Einflussgrößen aus.

Sei zu jedem $n > p'$

$\mathbf{X}_n$: Designmatrix, die aus den ersten n Beobachtungen besteht

$\hat{\beta}^{(n)}$: KQ- Schätzer aus den ersten n Beobachtungen

Vor.: $\mathbf{X}_n$ hat vollen Rang für alle $n \geq p$.

$$\lim_{n \rightarrow \infty} (\mathbf{X}_n' \mathbf{X}_n)^{-1} = 0.$$

Konsistenz des KQ-Schätzers II

Dann folgt die schwache Konsistenz des KQ-Schätzers (Konvergenz in Wahrscheinlichkeit):

$$\hat{\beta}^{(n)} \xrightarrow{P} \beta. \quad (3.60)$$

Sind die Störgrößen zusätzlich identisch verteilt, so folgt die starke Konsistenz (fast sichere Konvergenz)

$$\hat{\beta}^{(n)} \xrightarrow{\text{f.s.}} \beta. \quad (3.61)$$

(vgl. Fahrmeir et al.; S.133)

Asymptotische Normalität des KQ-Schätzers

Sei das Modell (2.1) - (2.4) gegeben.

Sei zu jedem $n > p'$

$\mathbf{X}_n$: Designmatrix, die aus den ersten n Beobachtungen besteht
 $\hat{\beta}^{(n)}$: KQ- Schätzer aus den ersten n Beobachtungen

Vor.: $\mathbf{X}_n$ hat vollen Rang für alle $n \geq p$

$$\lim_{n \rightarrow \infty} \max_{1 \leq i \leq n} \mathbf{x}_i' (\mathbf{X}_n' \mathbf{X}_n)^{-1} \mathbf{x}_i = 0.$$

Dann folgt die asymptotische Normalität von β

$$\sigma^{-1} (\mathbf{X}_n' \mathbf{X}_n)^{1/2} (\hat{\beta}^{(n)} - \beta) \xrightarrow{d} N(0, \mathbf{I}). \quad (3.62)$$

Die asymptotische Normalität gilt auch, wenn man in (3.62) die unbekannte Varianz σ durch den Schätzer $\hat{\sigma}_n$ ersetzt. Man kann (3.62) zur Konstruktion von Konfidenzintervallen und zum Testen der linearen Hypothese nutzen. Es gilt:

$$\hat{\beta}^{(n)} \overset{a}{\sim} N(\beta, \hat{\sigma}_n^2 (\mathbf{X}_n' \mathbf{X}_n)^{-1})$$

Statt der t-Verteilung verwendet man die Normalverteilung, was für große n aber praktisch keinen Unterschied macht.

Auch die F-Verteilung für den Test der linearen Hypothese entspricht für große n der χ^2 -Verteilung.