

5. Diskrete Einflußgrößen: Dummy- und Effektkodierung, Mehrfaktorielle Varianzanalyse

Bei der ANOVA geht es um den Vergleich von Mittelwerten.

Die einfaktorielle Varianzanalyse hat die primäre Fragestellung:

Sind die Mittelwerte von verschiedenen Gruppen gleich?

Diese Frage lässt sich als lineares Modell darstellen. Wir verwenden eine diskrete Variable, die die Gruppenzugehörigkeit beschreibt.

Wir betrachten ein nominales Merkmal C mit K Ausprägungen.

a) Einfache Dummy-Kodierung

$$Z_k(C) = \begin{cases} 1 & \text{für } C = k; \\ 0 & \text{für } C \neq k; \end{cases} \quad k = 1, \dots, K \quad (4.1)$$

b) Effekt-Kodierung

$$Z_k^e(C) = \begin{cases} 1 & \text{für } C = k; \\ 0 & \text{für } C \neq k; C \neq K \\ -1 & \text{für } C = K; \end{cases} \quad k = 1, \dots, K-1; \quad (4.2)$$

(vgl. Fahrmeir et al.; S. 109)

Gegeben sei eine nominale Einflussgröße C mit K Ausprägungen (Gruppen). Der Zielgrößenvektor $\mathbf{Y}$ wird in die K Gruppen mit jeweils n_k Beobachtungen aufgeteilt:

$$\mathbf{Y} = (Y_{11}, \dots, Y_{1n_1}, Y_{21}, \dots, Y_{Kn_K})'$$

a) Mittelwertsmodell:

$$Y_{kl} = \mu_k + \varepsilon_{kl} \quad l = 1, \dots, n_k; \quad k = 1, \dots, K$$

$$\mathbf{Y} = (Z_1(C) \dots Z_K(C)) \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_K \end{pmatrix} + \boldsymbol{\varepsilon} \quad (4.3)$$

Beispiel

Sei X die Design-Matrix für $K = 3$ Gruppen mit je $n_k = 2$ Beobachtungen pro Gruppe.

Die entsprechende Regressionsgleichung lautet:

$$\begin{pmatrix} Y_{11} \\ Y_{12} \\ Y_{21} \\ Y_{22} \\ Y_{31} \\ Y_{32} \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} \mu_1 \\ \mu_2 \\ \mu_3 \end{pmatrix} + \begin{pmatrix} \varepsilon_{11} \\ \varepsilon_{12} \\ \varepsilon_{21} \\ \varepsilon_{22} \\ \varepsilon_{31} \\ \varepsilon_{32} \end{pmatrix}$$

b) Effekt-Kodierung:

$$Y_{kl} = \mu + \tau_k + \varepsilon_{kl}; \quad \sum_{k=1}^K \tau_k = 0$$

$$\mathbf{Y} = (e \ Z_1^e(C) \dots Z_{K-1}^e(C)) \begin{pmatrix} \mu \\ \tau_1 \\ \vdots \\ \tau_{K-1} \end{pmatrix} + \varepsilon \quad (4.4)$$

Design-Matrix $\mathbf{X}$ für $K = 3$
Gruppen mit je $n_k = 2$
Beobachtungen pro Gruppe.

$$\mathbf{X} = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 0 & 1 \\ 1 & -1 & -1 \\ 1 & -1 & -1 \end{pmatrix}$$

c) Modell mit Referenzkategorie K :

$$Y_{kl} = \mu_K + \tau_k + \varepsilon_{kl}, \quad \tau_K = 0;$$

$$\mathbf{Y} = (e \ Z_1(C) \dots Z_{K-1}(C)) \begin{pmatrix} \mu_K \\ \tau_1 \\ \vdots \\ \tau_{K-1} \end{pmatrix} + \varepsilon \quad (4.5)$$

Design-Matrix $\mathbf{X}$ für 3 Gruppen
mit je 2 Beobachtungen pro
Gruppe:

$$\mathbf{X} = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 0 & 1 \\ 1 & 0 & 0 \\ 1 & 0 & 0 \end{pmatrix}$$

Nullhypothesen zum Test auf „Effekt von C“

a) $H_0 : \mu_1 = \mu_2 = \dots = \mu_K$

b) $H_0 : \tau_1 = \tau_2 = \dots = \tau_{K-1} = 0$

c) $H_0 : \tau_1 = \tau_2 = \dots = \tau_{K-1} = 0$

Zusammenhang zwischen Kodierungen

Mittelwertsmodell: $\mu_1, \dots, \mu_K$ kein Intercept

Effektkodierung: $\mu = \frac{1}{K} \sum_{k=1}^K \mu_k$ $\Leftrightarrow$ Intercept

$$\begin{aligned} \tau_k &= \mu_k - \mu \\ \Leftrightarrow \mu_k &= \mu + \tau_k \end{aligned} \quad \begin{array}{l} \text{„Unterschied zum} \\ \text{Gesamtmittel“} \end{array}$$

Referenzkodierung: $\mu = \mu_K$ $\Leftrightarrow$ Intercept

$$\begin{aligned} \tau_k &= \mu_k - \mu_K \\ \Leftrightarrow \mu_k &= \mu_K + \tau_k \end{aligned} \quad \begin{array}{l} \text{„Unterschied zur} \\ \text{Referenz“} \end{array}$$

- Alle 3 Kodierungen führen zu gleicher Modellanpassung (R^2).
- Parameter haben unterschiedliche Interpretation.
- Parameter und deren Schätzungen sind aus verschiedenen Varianten direkt ineinander überführbar.
- Modelle sind erweiterbar mit zusätzlichen Einflussgrößen.

Modell der zweifaktoriellen Varianzanalyse

Wir betrachten zwei diskrete Einflussgrößen C und D mit K_1 bzw. K_2 Ausprägungen. Man spricht dann von einer zweifaktoriellen Varianzanalyse mit einem K_1 -stufigen und einem K_2 -stufigen Faktor. Hier ist die Mittelwertsdarstellung nicht möglich.

a) Modell mit einfachen Effekten (Effektdarstellung)

$$\mathbf{Y} = (e \ Z_1^e(C) \dots Z_{K_1-1}^e(C) Z_1^e(D) \dots Z_{K_2-1}^e(D)) \begin{pmatrix} \mu \\ \tau_1 \\ \vdots \\ \tau_{K_1-1} \\ \gamma_1 \\ \vdots \\ \gamma_{K_2-1} \end{pmatrix} + \varepsilon \quad (4.6)$$

Test auf Effekt von C : $H_0 : \tau_1 = \dots = \tau_{K_1-1} = 0$

Test auf Effekt von D : $H_0 : \gamma_1 = \dots = \gamma_{K_2-1} = 0$

Interpretation:

τ_k, γ_l Abweichung vom Gesamtmittel der Kategorien

Beispiel: Designmatrix

Gegeben sei ein Modell mit einem zweistufigen und einem dreistufigen Faktor und jeweils zwei Beobachtungen pro Faktorkombination:

$$\mathbf{X} = \begin{pmatrix} 1 & 1 & 1 & 0 \\ 1 & 1 & 1 & 0 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & -1 & -1 \\ 1 & 1 & -1 & -1 \\ 1 & -1 & 1 & 0 \\ 1 & -1 & 1 & 0 \\ 1 & -1 & 0 & 1 \\ 1 & -1 & 0 & 1 \\ 1 & -1 & -1 & -1 \\ 1 & -1 & -1 & -1 \end{pmatrix}$$

Beispiel: 2 kategoriale Einflussgrößen

$$\mu = 1$$


$$\text{Faktor A (2-stufig): } \tau_1 = 2 \quad \Rightarrow \tau_2 = -2$$

$$\text{Faktor B (3-stufig): } \gamma_1 = 1, \gamma_2 = 2 \quad \Rightarrow \gamma_3 = -3$$

Berechnung der Mittelwerte:

Faktor A	Faktor B	MW
1	1	$1 + 2 + 1 = 4$
1	2	$1 + 2 + 2 = 5$
1	3	$1 + 2 - 3 = 0$
2	1	$1 - 2 + 1 = 0$
2	2	$1 - 2 + 2 = 1$
2	3	$1 - 2 - 3 = -4$

Graphische Darstellung



Verlauf parallel mit
Abstand $\tau_1 - \tau_2$

Darstellung mit Referenz-Kodierung

$$\mathbf{Y} = (e \ Z_1(C) \dots Z_{K_1-1}(C) Z_1(D) \dots Z_{K_2-1}(D)) \begin{pmatrix} \mu \\ \tau_1 \\ \vdots \\ \tau_{K_1-1} \\ \gamma_1 \\ \vdots \\ \gamma_{K_2-1} \end{pmatrix} + \epsilon \quad (4.7)$$

Interpretation von τ_k, γ_l :
Abweichung von der Referenzkategorie

Beispiel: Designmatrix

Gegeben sei ein Modell mit einem zweistufigen und einem dreistufigen Faktor und jeweils zwei Beobachtungen pro Faktorkombination:

$$\mathbf{X} = \begin{pmatrix} 1 & 1 & 1 & 0 \\ 1 & 1 & 1 & 0 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 \end{pmatrix}$$

Interaktion ist ein wichtiger Begriff bei der Modellierung.

Bedeutung: Der Einfluss einer Variablen hängt von dem Wert einer anderen Variablen ab.

Beispiele für Interaktionen bei zwei Einflussgrößen:

- Die Wirkung des Medikaments ist bei Männern anders als bei Frauen
- Der Geschlechtsunterschied in der Lebenszufriedenheit ist abhängig vom Alter
- Die Wirkung des Lesetrainings ist bei guten Schülern geringer als bei schwachen Schülern

Andere Begriffe: Moderation (Psychologie), Synergieeffekte

Der Begriff der Interaktion ist zu unterscheiden von dem Zusammenhang (Korrelation, Multikollinearität) zwischen zwei Einflussgrößen! Bei der Interaktion gibt es einen direkten Bezug zu der Zielgröße

(vgl. Fahrmeir et al.; S. 109 ff)

Modell mit Interaktion

Interaktionen lassen sich durch Aufnahme aller Produktterme $Z_k^e(C)Z_l^e(D)$ modellieren:

$$E(Y) = (e, Z_1^e(C) \dots Z_{K_2-1}^e(D), Z_1^e(C)Z_1^e(D) \dots Z_{K_1-1}^e(C)Z_{K_2-1}^e(D)) \begin{pmatrix} \mu \\ \tau_1 \\ \vdots \\ \gamma_{K_2-1} \\ (\tau\gamma)_{11} \\ \vdots \\ (\tau\gamma)_{K_1-1, K_2-1} \end{pmatrix}$$

Test auf Interaktion:

$$H_0 : (\tau\gamma)_{11} = \dots = (\tau\gamma)_{K_1-1, K_2-1} = 0$$

Beispiel

Design-Matrix **X** für 2-Faktor Modell mit einem zweistufigen und einem dreistufigen Faktor: (jeweils eine Beobachtung pro Merkmalskombination).

Effektkodierung:

$$\mathbf{X}\boldsymbol{\beta} = \begin{pmatrix} 1 & 1 & 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 1 & 0 & 1 \\ 1 & 1 & -1 & -1 & -1 & -1 \\ 1 & -1 & 1 & 0 & -1 & 0 \\ 1 & -1 & 0 & 1 & 0 & -1 \\ 1 & -1 & -1 & -1 & 1 & 1 \end{pmatrix} \cdot \begin{pmatrix} \mu \\ \tau_1 \\ \gamma_1 \\ \gamma_2 \\ (\tau\gamma)_{11} \\ (\tau\gamma)_{12} \end{pmatrix}$$

Effekt-Kodierung mit Interaktion

Darstellung mit allen Parametern

$$Y_{kl} = \mu + \tau_k + \gamma_l + (\tau\gamma)_{kl} + \varepsilon_{kl} \quad (4.8)$$

$$\sum_{k=1}^{K_1} \tau_k = 0$$

$$\sum_{l=1}^{K_2} \gamma_l = 0$$

$$\sum_{k=1}^{K_1} (\tau\gamma)_{kl} = 0 \text{ für } l = 1 \dots K_2$$

$$\sum_{l=1}^{K_2} (\tau\gamma)_{kl} = 0 \text{ für } k = 1 \dots K_1$$

Interpretation der Parameter

τ_k : Unterschied von Kategorie k zu Gesamtmittel

γ_l : Unterschied von Kategorie l zu Gesamtmittel

$(\tau\gamma)_{kl}$: Unterschied von Zelle (kl) zum Wert
unter Berücksichtigung der Basiseffekte

- Eine Interpretation ist am besten möglich durch die grafische Darstellung der geschätzten Effekte, z.B. mit Effectplots in R.
- Bei der Effektkodierung ist die Interpretation der Basiseffekte in vielen Fällen hilfreich.

Beispiel: 2 kategoriale Einflussgrößen mit Interaktion

$$\mu = 1$$

$$\text{Faktor A (2-stufig): } \tau_1 = 2 \quad \Rightarrow \tau_2 = -2$$


$$\text{Faktor B (3-stufig): } \gamma_1 = 1, \gamma_2 = 2 \quad \Rightarrow \gamma_3 = -3$$

$$\begin{aligned} \text{Interaktion: } (\tau\gamma)_{11} &= -2 & \Rightarrow (\tau\gamma)_{21} &= 2 \\ (\tau\gamma)_{12} &= 0 & \Rightarrow (\tau\gamma)_{22} &= 0 \\ & \Rightarrow (\tau\gamma)_{13} = 2 & \Rightarrow (\tau\gamma)_{23} &= -2 \end{aligned}$$

Berechnung der Mittelwerte:

Faktor A	Faktor B	MW
1	1	$1 + 2 + 1 - 2 = 2$
1	2	$1 + 2 + 2 + 0 = 5$
1	3	$1 + 2 - 3 + 2 = 2$
2	1	$1 - 2 + 1 + 2 = 2$
2	2	$1 - 2 + 2 + 0 = 1$
2	3	$1 - 2 - 3 - 2 = -6$

Grafische Darstellung



Verlauf unterschiedlich
⇔ Interaktion

Interaktion mit Referenzkodierung

Modell mit einem K_1 -stufigen und einem K_2 -stufigen Faktor. Darstellung mit allen Parametern

$$Y_{kl} = \mu + \tau_k + \gamma_l + (\tau\gamma)_{kl} + \varepsilon_{kl}; \quad (4.9)$$

$$\tau_{K_1} = 0$$

$$\gamma_{K_2} = 0$$

$$(\tau\gamma)_{K_1 l} = 0 \text{ für } l = 1 \dots K_2$$

$$(\tau\gamma)_{k K_2} = 0 \text{ für } k = 1 \dots K_1$$

Interpretation der Parameter:

- τ_k : Unterschied von Kategorie k zur Referenz für Faktor 2 = Referenz
- γ_l : Unterschied von Kategorie l zur Referenz, wenn Faktor 1 = Referenz
- $(\tau\gamma)_{kl}$: Unterschied von Zelle (kl) zur jeweiligen Referenz unter Berücksichtigung der Basiseffekte

Design-Matrix $\mathbf{X}$ für 2-Faktor Modell mit einem zweistufigen und einem dreistufigen Faktor: (jeweils eine Beobachtung pro Merkmalskombination).

Referenzkodierung:

$$\mathbf{X}\boldsymbol{\beta} = \begin{pmatrix} 1 & 1 & 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 1 & 0 & 1 \\ 1 & 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 \end{pmatrix} \cdot \begin{pmatrix} \mu \\ \tau_1 \\ \gamma_1 \\ \gamma_2 \\ (\tau\gamma)_{11} \\ (\tau\gamma)_{12} \end{pmatrix}$$

Erweiterung auf Kombination von diskreten und stetigen Merkmalen (Kovarianzanalyse)

Beispiel für Design-Matrix $\mathbf{X}$ für $K = 3$ Gruppen mit je $n_k = 2$ Beobachtungen pro Gruppe und stetigem Merkmal x :

$$\mathbf{X} = \begin{pmatrix} 1 & 0 & 0 & x_1 \\ 1 & 0 & 0 & x_2 \\ 0 & 1 & 0 & x_3 \\ 0 & 1 & 0 & x_4 \\ 0 & 0 & 1 & x_5 \\ 0 & 0 & 1 & x_6 \end{pmatrix} \quad \boldsymbol{\beta} = \begin{pmatrix} \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \beta_4 \end{pmatrix}$$

Interpretation:

In den drei Gruppen ergeben sich drei parallele Geraden mit Achsenabschnitt α_i und Steigung β_4 .

(vgl. Fahrmeir et al.; S. 100)

Erweiterung auf Geraden mit versch. Steigung

Modell:

$$Y_{kl} = \alpha_k + \beta_k X_{kl} + \varepsilon_{kl} \quad (4.10)$$

Matrixdarstellung (3 Gruppen, 2 Beobachtungen pro Gruppe)

$$\mathbf{X} = \begin{pmatrix} 1 & 0 & 0 & x_1 & 0 & 0 \\ 1 & 0 & 0 & x_2 & 0 & 0 \\ 0 & 1 & 0 & 0 & x_3 & 0 \\ 0 & 1 & 0 & 0 & x_4 & 0 \\ 0 & 0 & 1 & 0 & 0 & x_5 \\ 0 & 0 & 1 & 0 & 0 & x_6 \end{pmatrix} \quad \beta = \begin{pmatrix} \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \beta_1 \\ \beta_2 \\ \beta_3 \end{pmatrix}$$

Interaktion bedeutet Steigungen verschieden.

Test auf Interaktion: $\beta_1 = \beta_2 = \beta_3$

Darstellung mit Referenzkodierung

Modell:

$$Y_{kl} = \alpha_3 + \alpha_k + \beta_3 X_{kl} + \beta_k X_{kl} + \varepsilon_{kl} \quad (k = 1, 2)$$

$$Y_{kl} = \alpha_3 + \beta_3 X_{kl} + \varepsilon_{kl} \quad (k = 3)$$

Matrixdarstellung (3 Gruppen 2 Beobachtungen pro Gruppe)

$$\mathbf{X} = \begin{pmatrix} 1 & 1 & 0 & x_1 & x_1 & 0 \\ 1 & 1 & 0 & x_2 & x_2 & 0 \\ 1 & 0 & 1 & x_3 & 0 & x_3 \\ 1 & 0 & 1 & x_4 & 0 & x_4 \\ 1 & 0 & 0 & x_5 & 0 & 0 \\ 1 & 0 & 0 & x_6 & 0 & 0 \end{pmatrix} \boldsymbol{\beta} = \begin{pmatrix} \alpha_3 \\ \alpha_1 \\ \alpha_2 \\ \beta_3 \\ \beta_1 \\ \beta_2 \end{pmatrix}$$

Interaktion bedeutet Steigungen verschieden.

Test auf Interaktion: $\beta_1 = \beta_2 = 0$

Typen von Quadratsummen

In der Literatur unterscheidet man 3 Typen von Quadratsummen:

Typ1 Sequentielle Quadratsummen

Typ2 Partielle Quadratsummen ohne höhere Interaktionsterme

Typ3 Partielle Quadratsummen

Beispiel mit Effekten X_1 X_2 X_3 $X_1 \cdot X_2$ $X_1 \cdot X_3$ $X_2 \cdot X_3$ $X_1 \cdot X_2 \cdot X_3$

Effekt	Variablen im Modell bei		
	Typ1	Typ3	Typ2
X_1	-	alle anderen	X_2 X_3 $X_2 \cdot X_3$
X_2	X_1	alle anderen	X_1 X_3 $X_1 \cdot X_3$
$X_1 \cdot X_2$	X_1 X_2 X_3	alle anderen	X_1 X_2 X_3 $X_1 \cdot X_3$ $X_2 \cdot X_3$
$X_1 \cdot X_2 \cdot X_3$	alle anderen	alle anderen	alle anderen

Beachte: Falls Interaktionen vorhanden sind, sind die einfachen Koeffizienten schwer direkt interpretierbar!

Beispiel: Vorher-Nachher Vergleich

X1 : Blutwert zum Zeitpunkt 1

X2 : Blutwert zum Zeitpunkt 2

Z : Gruppenzugehörigkeit (0= Placebo / 1= Verum)
oder auch allgemeine Gruppierungsvariable

Fragestellung: Gibt es einen Unterschied zwischen den Gruppen?

Variante 1: Betrachte Differenzen $X2 - X1 = D$ und
führe 2 Stichproben t-Test durch.
Vorteil: Einfach und leicht interpretierbar

Variante 2: Regression $X2 = \beta_0 + \beta_1 X1 + \gamma * Z + \epsilon$
Teste die Nullhypothese: $H_0 : \gamma = 0$
Vorteil: „Regression to the mean“ und mögliche Abhängigkeit
der Differenz vom Anfangswert werden berücksichtigt.