

6. Metrische Einflußgrößen: Interaktionen, Polynomiale Regression, Trigonometrische Polynome, Regressionssplines, Transformationen.

Interaktionen bei metrischen Variablen

Gegeben sei ein Modell mit zwei metrischen Variablen x_1 und x_2 :

$$E(Y) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 \cdot x_2$$

Interpretation durch die Darstellung

$$E(Y) = \beta_0 + \beta_1 x_1 + (\beta_2 + \beta_3 x_1) x_2$$

oder:

$$E(Y) = \beta_0 + \beta_2 x_2 + (\beta_1 + \beta_3 x_2) x_1$$

Beachte: Die Parameter β_1 und β_2 geben die Steigung bei $x_2 = 0$ bzw. $x_1 = 0$ an. Häufig sind diese nicht sinnvoll interpretierbar. Bei zentrierten Variablen ergeben sie die Steigung bei dem jeweiligen Mittelwert der anderen Variablen.

Behandlung von metrischen Einflussgrößen I

- ❶ Einfach linear:

$$E(Y) = \beta_0 + \beta_1 x$$

- ❷ Transformiert:

$$E(Y) = \beta_0 + \beta_1 T(x)$$

Beachte: Andere Interpretation von β_1 z.B.:

Logarithmisch:	$T(x) = \ln(x)$
Logarithmisch mit Nullpunkt-Erhaltung:	$T(x) = \ln(1 + x)$
Exponentiell mit bekanntem c :	$T(x) = x^c$

③ Als Polynom:

$$E(Y) = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \dots \beta_k x^k$$

Problem: Bestimmung von k

Mögliche Lösung: Tests auf $\beta_1 = \dots = \beta_k = 0$

→ Verwende Sequentielle Quadratsummen

(vgl. Fahrmeir et al.; S. 431)

- ④ als stückweise konstante Funktion

$$E(Y) = \begin{cases} \beta_0 & \text{für } x \leq x_0 \\ \beta_1 & \text{für } x_0 < x < x_1 \\ \vdots & \\ \beta_h & \text{für } x > x_{h-1} \end{cases}$$

Dies entspricht der Kategorisierung der x -Variablen.

Bei x -Variablen, die nur wenige Werte haben, kann das Modell zur Überprüfung der Linearität benutzt werden.

Behandlung von metrischen Einflussgrößen IV

- ⑤ als stückweise lineare Funktion:

$$E(Y) = \beta_0 + \beta_1 x + \beta_2(x - g_1)_+ + \beta_3(x - g_2)_+ + \dots \beta_h(x - g_k)_+$$

mit bekannten Bruchpunkten (Knoten) g_k und $t_+ = \max(t, 0)$

- ⑥ als Regressionsspline:

$$E(Y) = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \beta_4(x - g_1)_+^3 + \beta_5(x - g_2)_+^3$$

Ein Polynom 3. Grades ist 2x stetig differenzierbar, da x^3 2x stetig differenzierbar in 0 ist. (Bekannte Knoten g_k)

- 7 als fraktionale Polynome:

Beispiel: Grad $(-2,2)$

$$E(Y) = \beta_0 + \beta_1 x^{-2} + \beta_2 x^{-1} + \beta_3 x^{-0.5} + \beta_4 \ln(x) + \beta_5 x^{0.5} + \beta_6 x + \beta_7 x^2$$

Flexible Darstellung mit Strategien zur Selektion (Sauerbrei et al.,
Uni Freiburg)

Behandlung von metrischen Einflussgrößen VI

- 8 als trigonometrische Polynome zur Modellierung von periodischen Termen (Saisonfigur):

Beispiel:

$$E(Y) = \beta_0 + \beta_1 \sin\left(\frac{2\pi}{T} \cdot x\right) + \beta_2 \cos\left(\frac{2\pi}{T} \cdot x\right) + \beta_3 \sin\left(\frac{2\pi}{T} \cdot 2x\right) + \beta_4 \cos\left(\frac{2\pi}{T} \cdot 2x\right)$$

T: Periodenlänge, x: Zeit

Alternative: Saison-Dummy (Indikator) Variablen

Beachte:

$$A_1 * \cos(x) + A_2 * \sin(x) = A_3 * \sin(x + \phi)$$

Allgemeiner Ansatz mit Basisfunktionen

Bekannte Basisfunktionen: $B_1, B_2, B_3, \dots$

$$E(Y) = \beta_0 + \beta_1 B_1(x) + \beta_2 B_2(x) + \beta_3 B_3(x) + \dots$$

- Oben vorgestellte Ansätze besitzen diese allgemeine Darstellung
- Mit bestimmten Basisfunktionen und geeigneter Schätzung lässt sich bei hoher Flexibilität beinahe jeder nichtlineare Zusammenhang adäquat **datengesteuert** schätzen, z.B. P-Splines (*penalized B-splines*); (siehe Veranstaltung Generalisierte Lineare Modelle)

Beispiel: Trendmodell für die Populationsgröße von Füchsen in Baden Württemberg

Gegeben:

So genannte Jagdstrecken t

Y : Anzahl der geschossenen Füchse als Indikator für die Populationsgröße

Modelle:

$$\ln(Y) = \beta_0 + \beta_1 t + \beta_2 t^2$$

$$\ln(Y) = \beta_0 + \beta_1 t + \beta_2 t^2 + \beta_3 t^3 + \beta_4 (t - 70)_+^3 + \beta_5 (t - 85)_+^3$$

etc.

Versuchen Sie eine Modellierung von $\ln$ (Hase)

Multiples Testen und simultane Konfindenzbereiche

Häufig werden bei multiplen linearen Modellen mehrere Tests durchgeführt oder für mehrere Parameter Konfidenzintervalle bestimmt. Dann ist die Wahrscheinlichkeit, dass mindestens eine falsche Entscheidung getroffen wird, höher als das (lokale) Niveau der einzelnen Tests.

Abhilfe: multiple Testprozeduren

Gegeben: Hypothesen $H_{0,1}, \dots, H_{0,k}$

z.B.: $H_{0,1} : \tau_1 = 0$, $H_{0,2} : \tau_2 = 0$ usw.

lokales Niveau: Einzelniveau der Tests

globales Niveau: Wahrscheinlichkeit, dass mindestens eine Nullhypothese abgelehnt wird, obwohl alle Nullhypothesen gelten.

multiples Niveau: Wahrscheinlichkeit, dass mindestens eine Nullhypothese fälschlicherweise abgelehnt wird $< \alpha$.

- **Bonferroni:** Allgemeine Methode für m Tests, die sehr allgemein anwendbar ist
- **Scheffe:** Allgemeine Methode im linearen Modell für eine große Anzahl von Hypothesen bzw. Parametern
- **Tukey, Hothorn et al.:** Methode nach dem Multiple-Range-Prinzip bzw. nach Maximum-Prinzip.
- **Abschlussprozeduren:** Für Testsysteme häufig mächtiger als andere Prozeduren : Wichtig im Fall des Vergleichs von 3 Gruppen

Andere Verfahren halten das multiple Niveau nicht und sollten daher eher gemieden werden, wie z.B.: Duncan multiple Range, Fisher LSD, Newman-Keuls.

Verwende bei k vorab festgelegten Tests jeweils das lokale

Signifikanzniveau $\alpha_I = \alpha/k$

Die Eigenschaften folgen unmittelbar aus der Bonferroni-Ungleichung.

$$P\left(\bigcup E_i\right) \leq \sum P(E_i)$$

Eigenschaften:

- Sehr allgemein anwendbar
- Einfach durchführbar
- Hält multiples Niveau
- ungeeignet bei sehr vielen Tests (Power gering)

Sei das Modell (2.1) mit NV-Annahme (2.5) gegeben.
Dann ist

$$\left\{ \beta \mid (\beta - \hat{\beta})'(\mathbf{X}'\mathbf{X})(\beta - \hat{\beta}) \leq p' \hat{\sigma}^2 F_{1-\alpha}(p', n - p') \right\} \quad (5.1)$$

eine Konfidenzregion für β .

Entsprechendes gilt für lineare Transformationen $\gamma = \mathbf{A}\beta$:

$$\left\{ \gamma \mid (\gamma - \hat{\gamma})' \widehat{V(\hat{\gamma})}^{-1} (\gamma - \hat{\gamma}) < \dim \gamma \cdot F_{1-\alpha}(\dim(\gamma), n - p') \right\}$$

ist Konfidenzregion zum Sicherheitsniveau $1 - \alpha$.

Konfidenzintervalle nach Scheffe

Sei Modell (2.1) mit NV-Annahme (2.5) gegeben.
Dann sind

$$\hat{\beta}_j \pm \sqrt{p' F_{1-\alpha}(p', n - p')} \hat{\sigma}_{\hat{\beta}_j} \quad (5.2)$$

für die Parameter β_j und

$$\hat{\gamma} \pm \sqrt{p' F_{1-\alpha}(p', n - p')} \hat{\sigma}_{\hat{\gamma}}$$

für beliebige Linearkombinationen $\gamma = a'\beta$ simultane Konfidenzintervalle.

Strategie mit Maximum-Statistiken

Tests nach **Tuckey** und **Horthorn et al.**:

Wir betrachten simultane Hypothesen der Form $\mathbf{A}\beta = \mathbf{0}$ mit den einzelnen studentisierten Komponenten (Zeilen)

$$\mathbf{T}_i = \mathbf{d}'_i \beta / \hat{\sigma}_{\mathbf{d}'_i \beta}, i = 1, \dots, a$$

$$Q = \max |\mathbf{T}_i|$$

Sei $Q(n - p', \mathbf{R})$ die Verteilung des Maximums von t -Verteilungen mit Korrelationsmatrix $\mathbf{R}$.

$$P(Q \leq q) = 1 - \alpha$$

$$\implies P(\max_i |\mathbf{T}_i| \leq q) = 1 - \alpha$$

$$\implies P(\forall i : |\mathbf{T}_i| \leq q) = 1 - \alpha$$

$$P(\forall i : \mathbf{d}'_i \beta \in [-q \hat{\sigma}_{\mathbf{d}'_i \beta}; +q \hat{\sigma}_{\mathbf{d}'_i \beta}]) = 1 - \alpha$$

d.h. wir erhalten **simultane** KIs zum Konfidenzniveau $1 - \alpha$

- Das Vorgehen ist sehr allgemein auf (asymptotisch) normalverteilte Teststatistiken anwendbar.
- Umsetzung im R-package multcomp: inclusive Angaben von entsprechenden p-Werten.
- siehe Artikel: *Simultaneous inference in general parametric models*; Hothorn, T; Bretz, F; Westfall, P.; BIOMETRICAL JOURNAL; 50; 346-363; 2008. **über 9000 mal zitiert (2024)**