

7. Modelldiagnose

Probleme bei der Regression und Diagnose

Gegeben sei das multiple Regressionsmodell (2.1) und (2.5):

$$\mathbf{Y} = \mathbf{X}\beta + \varepsilon$$

$$\varepsilon \sim N(\mathbf{0}, \sigma^2 \mathbf{I})$$

Es geht darum, herauszufinden, ob das Modell zur Analyse der jeweiligen Daten geeignet ist.

Da sich die Modellannahmen auf die Störterme beziehen, werden typischerweise die Residuen betrachtet.

Beachte, dass sich die Annahmen nicht auf die Randverteilung von $\mathbf{Y}$ beziehen.

Verschiedene Typen von Residuen

Beachte: Die Residuen ergeben sich aus den (unbekannten) Störtermen ε durch

$$\hat{\varepsilon} = \mathbf{Q}\varepsilon = (\mathbf{I} - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}')\varepsilon = (\mathbf{I} - \mathbf{P})\varepsilon.$$

Daher gilt:

$$\text{Var}(\hat{\varepsilon}_i) = q_{ii}\sigma^2 \quad (6.1)$$

Beispiel:

$$\mathbf{X} := \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{bmatrix} \quad \mathbf{Q} := \begin{bmatrix} 2/5 & -2/5 & -1/5 & 0 & 1/5 \\ -2/5 & \frac{7}{10} & -1/5 & -1/10 & 0 \\ -1/5 & -1/5 & 4/5 & -1/5 & -1/5 \\ 0 & -1/10 & -1/5 & \frac{7}{10} & -2/5 \\ 1/5 & 0 & -1/5 & -2/5 & 2/5 \end{bmatrix}$$

$$r_i := \frac{\hat{\varepsilon}_i}{\hat{\sigma} \sqrt{q_{ii}}} \quad i = 1, \dots, n \quad (6.2)$$

$q_{ii} = 1 - h_{ii}$: Elemente der Residualmatrix **Q**

Es gilt:

$$\begin{aligned} \frac{1}{n} &\leq h_{ii} \leq 1 & \sum h_{ii} &= p' \\ \Rightarrow 0 &\leq q_{ii} \leq 1 - \frac{1}{n} & \sum q_{ii} &= n - p' \end{aligned}$$

Problem: Bei der Schätzung von σ geht das Residuum mit ein.
Dies kann insbesondere bei kleinen Stichproben ein Problem sein.

Daher definiert man:

$$r_i^* := \frac{\hat{\varepsilon}_i}{\hat{\sigma}_{(i)}\sqrt{q_{ii}}} \quad i = 1, \dots, n \quad (6.3)$$

$\hat{\sigma}_{(i)}$:= Schätzung von σ **ohne** die Beobachtung i .

Kreuzvalidierungs-Residuen

$$e_{(i)} := y_i - \mathbf{x}_i' \hat{\boldsymbol{\beta}}_{(i)} \quad (6.4)$$

$\hat{\boldsymbol{\beta}}_{(i)}$: Schätzung von $\boldsymbol{\beta}$ ohne Beobachtung i

$$PRESS := \sum_{i=1}^n e_{(i)}^2$$

(PRESS: Predicted Residual Sum of Squares)

Es gilt:

$$e_{(i)} = \hat{\varepsilon}_i / q_{ii} \quad (6.5)$$

$$\text{Var}(e_{(i)}) = \frac{1}{q_{ii}} \sigma^2 > \sigma^2 \quad (6.6)$$

Die Gleichung (6.5) ist ein wesentliches Hilfsmittel, um die Kreuzvalidierungsresiduen effizient zu berechnen.

Beweis von (6.5)

Lemma

Sei A eine invertierbare Matrix, b ein Vektor λ ein Skalar. Für $\lambda \neq -\frac{1}{b'A^{-1}b}$ gilt:

$$(A + \lambda bb')^{-1} = A^{-1} - \left(\frac{\lambda}{1 + \lambda b'A^{-1}b} \right) A^{-1}bb'A^{-1} \quad (6.7)$$

Nachweis durch Nachrechnen

$$\left\{ A^{-1} - \left(\frac{\lambda}{1 + \lambda b'A^{-1}b} \right) A^{-1}bb'A^{-1} \right\} (A + \lambda bb') = I.$$

Beweis II

Wir zeigen zunächst

$$\hat{\beta} - \hat{\beta}_{(i)} = \left(\frac{\hat{\varepsilon}_i}{1 - h_{ii}} \right) (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_i \quad (6.8)$$

$$\left(\mathbf{X}'_{(i)} \mathbf{X}_{(i)} \right)^{-1} \mathbf{x}_i = \left(\frac{1}{1 - h_{ii}} \right) (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_i \quad (6.9)$$

Wir nutzen $\sum_{j=1}^n \mathbf{x}_j \mathbf{x}_j' = \mathbf{X}'\mathbf{X}$ und obiges Lemma

$$\begin{aligned} \left(\mathbf{X}'_{(i)} \mathbf{X}_{(i)} \right)^{-1} &= (\mathbf{X}'\mathbf{X} - \mathbf{x}_i \mathbf{x}_i')^{-1} \\ &= (\mathbf{X}'\mathbf{X})^{-1} + \frac{(\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_i \mathbf{x}_i' (\mathbf{X}'\mathbf{X})^{-1}}{1 - \mathbf{x}_i' (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_i} \end{aligned}$$

Es gilt also :

$$\begin{aligned} \left(\mathbf{X}'_{(i)} \mathbf{X}_{(i)} \right)^{-1} \mathbf{x}_i &= (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_i + (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_i \left(\frac{\mathbf{x}_i' (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_i}{1 - \mathbf{x}_i' (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_i} \right) \\ &= \left(\frac{1}{1 - h_{ii}} \right) (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_i \end{aligned}$$

aus den Normalengleichungen folgt

$$\mathbf{X}'\mathbf{X}\hat{\beta} = \mathbf{X}'\mathbf{y}$$

$$\left(\mathbf{X}'_{(i)}\mathbf{X}_{(i)} + x_i x_i'\right) \hat{\beta} = \mathbf{X}'_{(i)}y_{(i)} + x_i y_i$$

Multiplikation mit $\left(\mathbf{X}'_{(i)}\mathbf{X}_{(i)}\right)^{-1}$:

$$\left\{ I + \left(\mathbf{X}'_{(i)}\mathbf{X}_{(i)}\right)^{-1} x_i x_i' \right\} \hat{\beta} = \hat{\beta}_{(i)} + \left(\mathbf{X}'_{(i)}\mathbf{X}_{(i)}\right)^{-1} x_i \left(x_i' \hat{\beta} + \hat{\varepsilon}_i\right)$$

$$\hat{\beta} = \hat{\beta}_{(i)} + \left(\mathbf{X}'_{(i)}\mathbf{X}_{(i)}\right)^{-1} x_i \hat{\varepsilon}_i$$

$$= \hat{\beta}_{(i)} + (\mathbf{X}'\mathbf{X})^{-1} x_i \frac{\hat{\varepsilon}_i}{1 - h_{ii}}$$

wobei die letzte Gleichung aus (6.9) folgt.

Aus (6.8) ergibt sich:

$$\begin{aligned}\hat{\varepsilon}_i &= y_i - x_i' \hat{\beta} \\ &= y_i - x_i' \hat{\beta}_{(i)} - x_i' (\mathbf{X}'\mathbf{X})^{-1} x_i \frac{\hat{\varepsilon}_i}{1 - h_{ii}} = e_{(i)} - \frac{h_{ii}}{1 - h_{ii}} \hat{\varepsilon}_i\end{aligned}$$

Es folgt

$$e_{(i)} = \frac{\hat{\varepsilon}_i}{1 - h_{ii}} = \frac{\hat{\varepsilon}_i}{q_{ii}}$$

qed

Bei Zeitreihen verwendet man häufig:

$$\omega_i := \frac{y_i - \mathbf{x}'_i \hat{\boldsymbol{\beta}}_{[i-1]}}{\sqrt{1 - \mathbf{x}'_i (\mathbf{X}'_{[i-1]} \mathbf{X}_{[i-1]})^{-1} \mathbf{x}_i}} \quad i = p' + 1, \dots, n \quad (6.10)$$

$\hat{\boldsymbol{\beta}}_{[i-1]}$: Schätzung von $\boldsymbol{\beta}$ aus den ersten $i - 1$ Beobachtungen

$\mathbf{X}_{[i-1]}$: $\mathbf{X}$ -Matrix der ersten $i - 1$ Beobachtungen

Die Störterme ε_i sind nicht normalverteilt

Ursachen: Die Y-Variable stellt eine Zählgröße, eine Überlebenszeit, oder einen Anteil dar. Y ist nicht-negativ etc.

Folgen: Der KQ-Schätzer $\hat{\beta}$ ist immer noch erwartungstreuer Schätzer mit kleinster Varianz. Der F-Test ist i. a. robust. Problematisch sind insbesondere bei kleinen Stichprobenumfängen die Konfidenzintervalle der Parameter. Außerdem sind die Prognoseintervalle nicht mehr gültig, da hierbei die NV-Annahme besonders eingeht.

Diagnose: Schiefe und Kurtosis der Verteilung der Residuen, Normal-Plots der Residuen

Therapie: Transformationen der Y-Variablen, Verwendung von generalisierten linearen Modellen

Heterogene Varianzen

Die Varianz der Störterme ε_i ist von i abhängig.

Ursachen: Y Zählraten, Anteile. Gruppierte Daten führen zu verschiedenen Residualvarianzen innerhalb der Gruppen. Multiplikative Fehlerstruktur, d. h. σ_i ist abhängig von der Größe von Y_i .

Folgen: Der Schätzer für β ist erwartungstreu, aber er hat nicht mehr die kleinste Varianz; Konfidenzintervalle und Tests für β sind nicht mehr korrekt.

Diagnose: Residualplot der $\hat{\varepsilon}_i$ auf $\hat{Y}_i$; Berechnung der Residualvarianzen in den einzelnen Gruppen (bei gruppierten Daten).

Therapie: Transformation der Y -Variable; Gewichtete KQ-Schätzung.

(vgl. Fahrmeir et al.; S. 183)

Korrelation zwischen den Störtermen

Es gilt $\text{Cov}(\varepsilon_i, \varepsilon_j) \neq 0$ für einige $i \neq j$.

Ursachen: Zeitreihenstruktur oder räumliche Struktur der Daten führen zu positiver Korrelation von aufeinander folgenden (bzw. nahen) Beobachtungen. Residuen bei gruppierten Beobachtungen, bei denen die Gruppenzugehörigkeit nicht zusätzlich modelliert wird, sind häufig positiv korreliert.

Folgen: Der Schätzer von β bleibt erwartungstreu, aber nicht mit geringster Varianz; Bias bei der Varianzschätzung führt zu fehlerhaften Konfidenzintervallen und zu Problemen bei den F-Tests.

Diagnose: Analyse der Zeitreihenstruktur der Residuen, z.B. mit Durbin–Watson–Test; Plots der Residuen gegen die Zeit; Plots von $\hat{\varepsilon}_i$ gegen $\hat{\varepsilon}_{i-1}$.

Therapie: Verwendung von Zeitreihenmethoden; Einbeziehung von Trend und Saison; Gewichtete KQ-Methode .

(vgl. Fahrmeir et al.; S. 191-195)

Durbin-Watson-Test

Um zu testen, ob die Störterme ε_i und ε_{i-1} korreliert sind, benutzt man folgende Testgröße:

$$d := \frac{\sum_{i=2}^n (\hat{\varepsilon}_i - \hat{\varepsilon}_{i-1})^2}{\sum_{i=1}^n \hat{\varepsilon}_i^2} \approx 2(1 - \hat{\rho})$$

$\hat{\rho}$: Korrelation zwischen $\hat{\varepsilon}_i$ und $\hat{\varepsilon}_{i-1}$

$H_0: \rho = 0$

Lehne H_0 ab, falls $d \in [0, d_l]$ oder $d \in [4 - d_l, 4]$.

H_0 nicht ablehnen wenn $d \in [d_u, 4 - d_u]$

(d_l, d_u sind von p und n abhängige, feste Werte).

Kleine Werte von d : positives ρ

Große Werte von d : negatives ρ

$d \approx 2 \longrightarrow$ keine Autokorrelation

(vgl. Fahrmeir et al.; S. 195-197)

Ausreißer und Punkte mit starkem Einfluss

Einflussreiche Beobachtungen (high leverage points) sind in den X-Werten weit vom Zentrum der Daten entfernt.

Ausreißer haben dem Betrag nach sehr große Störterme.

Ursachen: Falsche Erhebung; Beobachtung gehört nicht zur Grundgesamtheit; Besonderheiten bei einzelner Untersuchungseinheit.

Folgen: Einflussreiche Beobachtungen wirken stark auf die Schätzung von β . Ausreißer können zu erheblicher Verzerrung der Schätzung von β führen. Dies gilt besonders für Ausreißer, die gleichzeitig high leverage points sind.

Diagnose: Analyse der Diagonalelemente der Hat-Matrix $\mathbf{P}$ zum Auffinden von high leverage points; Verschiedene Residuenplots zur Ausreißeranalyse; Influence-Statistiken.

Therapie: Fehlerhafte Daten weglassen (Sensitivitätsanalyse); Robuste Regression; Gewichtete Regression.

(vgl. Fahrmeir et al.; S. 160,161,164)

Wichtige Einflussmaße: Leverage

Das i -te Diagonalelement der Hat-Matrix $\mathbf{P}$

$$h_{ii} := \mathbf{x}_i'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_i \quad (6.11)$$

heißt **Leverage** der Beobachtung $\mathbf{x}_i$.

Es gilt:

$$\frac{1}{n} \leq h_{ii} \leq 1$$

Normalwert: $h_{ii} = \frac{p'}{n}$

großer Wert: $h_{ii} > \frac{2p'}{n}$

(vgl. Fahrmeir et al.; S.165)

Cook's Distanz:

$$D_i = \frac{(\hat{\beta}_{(i)} - \hat{\beta})'(\mathbf{X}'\mathbf{X})(\hat{\beta}_{(i)} - \hat{\beta})}{\hat{\sigma}^2 p'} \quad (6.12)$$

$\hat{\beta}_{(i)}$: Schätzung von β ohne Beobachtung i

Es gilt:

$$D_i = \underbrace{\frac{r_i^2}{p'}}_{\text{Residuen}} \cdot \underbrace{\frac{h_{ii}}{1 - h_{ii}}}_{\text{Leverage}} \quad (6.13)$$

$$D_i = \frac{(\hat{\mathbf{Y}}_{(i)} - \hat{\mathbf{Y}})'(\hat{\mathbf{Y}}_{(i)} - \hat{\mathbf{Y}})}{p' \hat{\sigma}^2} \quad (6.14)$$

Cook's Distanz wird im Vergleich mit den Beobachtungen interpretiert.

(vgl. Fahrmeir et al.; S. 165)

Regressionsgleichung ist nicht korrekt

Die Gleichung $\mathbf{Y} = \mathbf{X}\beta + \varepsilon$ ist fehlerhaft.

Ursachen: Variablen wurden weggelassen oder überflüssigerweise in das Modell einbezogen; Der Zusammenhang ist nicht linear; Interaktionen werden nicht in das Modell einbezogen.

Folgen: Systematische Fehler bei der Schätzung der Modellparameter und bei der Prognose; **Dennoch:** Modellschätzung liefert häufig brauchbare Näherung.

Diagnose: Residuenplots $\hat{\varepsilon}_i$ gegen $\hat{y}_i$; F-Tests auf Einfluss von weiteren Variablen; Interaktionen; Polynomterme höherer Ordnung, etc.

Therapie: Modellerweiterung; Transformationen der Einflussgrößen; Variablenselektionsverfahren.

Partial Leverage Plot

$\mathbf{y}^*$ auf $\mathbf{x}_k^*$ mit

$$\mathbf{y}^* := \mathbf{Q}_{(k)} \mathbf{y}$$

$$\mathbf{x}_k^* := \mathbf{Q}_{(k)} \mathbf{x}_k$$

$\mathbf{Q}_{(k)}$: $\mathbf{Q}$ -Matrix der Einflussgrößen **ohne** Variable k

$\implies$ Darstellung des Zusammenhangs zwischen $\mathbf{y}$ und der Einflussgröße $\mathbf{x}_k$ unter Berücksichtigung der übrigen Einflussgrößen

Die Spalten von $\mathbf{X}$ sind (annähernd) linear abhängig.

Ursachen: Hohe Korrelation zwischen den Einflussgrößen; Ungünstiges Versuchs-Design; Codierung von diskreten Variablen.

Folgen: Ungenaue Schätzung von β , häufig sogar falsches Vorzeichen;
Aber: Konfidenzintervalle korrekt und damit entsprechend groß.

Diagnose: Analyse der Matrix $(\mathbf{X}'\mathbf{X})$ und der Korrelationsmatrix der metrischen Einflussgrößen.

Therapie: Zusammenfassen bzw. Weglassen von Einflussgrößen;
Verwendung von anderen Schätzmethoden, z.B.: Ridge-Regression.

(vgl. Fahrmeir et al.; S. 157)

a) Konditionszahl

$$K(\mathbf{X}) := \sqrt{\frac{\lambda_{\max}}{\lambda_{\min}}} \quad (6.15)$$

$\lambda_{\min}, \lambda_{\max}$: minimaler, bzw. maximaler Eigenwert von $\mathbf{X}'\mathbf{X}$

b) Varianz Inflationsfaktor

$$\text{VIF}_j := \frac{1}{1 - R_j^2} \quad (6.16)$$

R_j^2 : Bestimmtheitsmaß der Regression von $\mathbf{x}_j$ auf die übrigen $\mathbf{x}$
Es gilt für die Varianz von β_j :

$$\sigma_{\hat{\beta}_j} = \frac{\sigma^2}{(\mathbf{x}_j - \bar{\mathbf{x}}_j)'(\mathbf{x}_j - \bar{\mathbf{x}}_j)} \text{VIF}_j \quad (6.17)$$

Beachte: VIF ist auch für kategoriale Variablen geeignet.

(vgl. Fahrmeir et al.; S. 157,158)

Ursachen: Messfehler im engeren Sinne (Messgerät) und im weiteren Sinne (z.B. falsche Beantwortung von Fragen).

Folgen: Bei additivem Messfehler in x meist systematische betragsmäßige Unterschätzung der zu den fehlerhaft gemessenen Größen gehörigen β_i ; Geringere Power der entsprechenden F-Tests.

Diagnose: Mehrfach-Messungen der entsprechenden Größen

Therapie: Verwendung von Korrektur-Verfahren $\longrightarrow$ Theorie der Fehler-in-den-Variablen-Modelle