

10. Das logistische Regressionsmodell

Fragestellung

Bisher: Metrische (bedingt normalverteilte) Zielgröße

Jetzt: Zielgröße binär:

$$Y_i = \begin{cases} 1, & \text{Ereignis} \\ 0, & \text{kein Ereignis} \end{cases}$$



Beispiele

- Y: Auftreten einer Krankheit in einem bestimmten Zeitraum (Ja/Nein), X: Exposition, Geschlecht, Alter, etc.
- Y: Kreditwürdigkeit (Ja/Nein), X: Personenmerkmale
- Y: Präferenz für eine Partei, X: Persönlichkeitsmerkmale
- Y: Bestehen eines Tests, X: Lehrmethode, Geschlecht, etc.
- Y: Ausfall eines Maschinenteils (Ja/Nein), X: Belastung

→ Man interessiert sich dafür, wie Einflussgrößen X mit dem Erwartungswert/der Wahrscheinlichkeit für ein Ereignis zusammenhängen

Beispiel Bauteile



960 Bauteile wurden unterschiedlichen Belastungen ausgesetzt
Y: Bauteil versagt (Ja/Nein), x: Belastungsgrad



Beispiel Bauteile

Schätzung des Erwartungswertes mit linearem Modell

$$E(Y_i|x_i) = \beta_0 + \beta_1 x_i$$



- Kann auch Werte außerhalb des gültigen Wertebereichs $[0, 1]$ liefern
- Schlechte Approximation an den Rändern des Wertebereichs von x

Das logistische Regressionsmodell

Y_i : binäre Zielgröße, $i = 1, \dots, n$ unabhängig (bei gegebenem, festem $\mathbf{x}_i$)
 $\mathbf{x}_i$: Vektor der Einflussgrößen

$$Y_i \sim \text{Ber}(\pi_i) \quad (9.1)$$

$$\pi_i = E(Y_i | \mathbf{x}_i) = P(Y_i = 1 | \mathbf{x}_i) = G(\eta_i = \mathbf{x}_i' \boldsymbol{\beta}) \quad (9.2)$$

$$\ln \frac{\pi_i}{1 - \pi_i} = \eta_i = \mathbf{x}_i' \boldsymbol{\beta} \quad (9.3)$$

$$G(\eta) = (1 + \exp(-\eta))^{-1} \quad (9.4)$$

Bezeichnungen:

$\ln \frac{\pi_i}{1 - \pi_i}$	:	„Logarithmierte Chance“ oder Log-odds
$\eta_i = \mathbf{x}_i' \boldsymbol{\beta} = \beta_0 + \dots + \beta_p x_p$	:	linearer Prädiktor
Funktion G	:	Response-Funktion (Inverse Link-Funktion)

(vgl. Fahrmeir et al.; S. 270-273)

Die Wahl von G (Verteilungsfunktion der logistischen Verteilung) als Responsefunktion ermöglicht folgende Interpretation:

Einfaches Modell:

$$P(Y = 1|x_1) = G(\beta_0 + \beta_1 * x_1)$$

$$P(Y = 1|x_1 + 1) = G[\beta_0 + \beta_1 * (x_1 + 1)]$$

$$\frac{P(Y = 1|x_1 + 1)/(1 - P(Y = 1|x_1 + 1))}{P(Y = 1|x_1)/(1 - P(Y = 1|x_1))} = \exp(\beta_1)$$

$$\ln \frac{P(Y = 1|x_1 + 1)}{1 - P(Y = 1|x_1 + 1)} - \ln \frac{P(Y = 1|x_1)}{1 - P(Y = 1|x_1)} = \beta_1$$

Interpretation

Das logistische Regressionsmodell nimmt einen linearen Zusammenhang zwischen den „Log-odds“ von Y und den Einflussgrößen x an.

Interpretation: Die folgenden Aussagen gelten für eine Einflussgröße x_k bei Festhalten aller anderen Einflussgrößen

- Erhöht sich x_k um eine Einheit, so ändert sich die logarithmierte Chance von Y um β_k .
- Wenn x_k um eine Einheit steigt, so ändert sich die Chance von Y um den Faktor $\exp(\beta_k)$.
- Das Odds Ratio (Chancenverhältnis) zwischen Y bei x_k und Y bei $x_k + 1$ ist $\exp(\beta_k)$.

W'keit	0.01	0.05	0.1	0.3	0.4	0.5	0.6	0.7	0.9	0.95	0.99
Odds	1/99	1/19	1/9	3/7	2/3	1	1.5	7/3	9	19	99
Log odds	-4.6	-2.9	-2.2	-0.85	-0.41	0	0.41	0.85	2.2	2.9	4.6

(vgl. Fahrmeir et al.; S. 287)

Die Varianten des multiplen linearen Regressionsmodells lassen sich direkt auf das logistische Modell übertragen:

- Behandlung von Gruppenvergleichen (ANOVA) mit Hilfe von Indikatorvariablen
- Behandlung von diskreten Einflussgrößen mit Hilfe verschiedener Codierungen, Interaktionen, etc.
- Behandlung von stetigen Einflussgrößen (Polynome, Splines, etc.)

Beachte:

Beim logistischen Modell „fehlt“ der Varianz-Parameter σ ,
da $\text{Var}(Y) = E(Y) * [1 - E(Y)]$

Weiter ist keine Verteilungsannahme nötig, da Y immer Bernoulli-verteilt ist.

Logistische Regression als Klassifikationsproblem

- Die Prognose in der logistischen Regression entspricht einem Klassifikationsproblem mit 2 Gruppen.
- Analogien zu Verfahren der Diskriminanzanalyse
- Diskriminanzregeln aus logistischer Regression möglich

ML-Schätzung im logistischen Regressionsmodell

Sei das Modell (9.2)–(9.4) gegeben.

$$\hat{\beta}_{ML} := \arg \max L(\beta) = \arg \max \ln L(\beta) \quad (9.5)$$

$$L(\beta) = \prod_{i=1}^n G(\mathbf{x}'_i \beta)^{Y_i} (1 - G(\mathbf{x}'_i \beta))^{1-Y_i} \quad (9.6)$$

$$\ln L(\beta) = \sum_{i=1}^n Y_i \ln(G(\mathbf{x}'_i \beta)) + (1 - Y_i) \ln(1 - G(\mathbf{x}'_i \beta)) \quad (9.7)$$

Ableiten nach β und Null setzen liefert unter Benutzung von $G' = G(1 - G)$ die Score-Gleichungen für $\hat{\beta}_{ML}$.

$$s(\hat{\beta}_{ML}) := \sum_{i=1}^n (Y_i - G(\mathbf{x}'_i \hat{\beta}_{ML})) \mathbf{x}_i = 0. \quad (9.8)$$

Eigenschaften des ML-Schätzers

Die allgemeine Theorie der Maximum-Likelihood-Schätzung liefert folgendes:

Für $n \rightarrow \infty$ gilt unter Regularitätsbedingungen:

$$\hat{\beta}_{ML} \rightarrow N(\beta, F^{-1}(\beta)) \quad (9.9)$$

$$F(\beta) = \mathbf{X}' D(\beta) \mathbf{X} \quad (9.10)$$

$$D(\beta) = \text{diag}\{(G(\mathbf{x}'_i \beta)(1 - G(\mathbf{x}'_i \beta)))\} \quad (9.11)$$

$$\hat{\beta}' F(\beta) \hat{\beta} \rightarrow \chi^2(p') \quad (9.12)$$

- Die asymptotische Varianzmatrix ergibt sich als Inverse der Fischer-Information (negative Ableitung der Score-Funktion)
- Die asymptotische Varianzmatrix entspricht auch der Varianzmatrix aus der gewichteten (heteroskedastischen) Regression, da $\text{Var}(Y) = D(\beta) = \text{diag}(G(\mathbf{x}'_i \beta)(1 - G(\mathbf{x}'_i \beta)))$
- Die numerische Berechnung des ML-Schätzers erfolgt nach der Methode der „iterierten, gewichteten Methode der kleinsten Quadrate“ (IWLS Iteratively Weighted Least Squares).

Existenz und Eindeutigkeit des ML-Schätzers im logistischen Modell

Eindeutigkeit:

Da die Likelihood-Funktion konkav ist, ist die Lösung der Score-Gleichung immer eindeutig

Existenz:

Der ML- Schätzer existiert $\iff$ Die Werte 0 und 1 sind nicht linear trennbar, d.h. es existiert kein α mit $Y = 1$ für $\mathbf{x}'\alpha > 0$ und $Y = 0$ für $\mathbf{x}'\alpha < 0$.

Im Fall der Nicht-Existenz geht mindestens eine Komponente gegen ∞ .
Im einfachen Modell bedeutet die Bedingung, dass $Y=1$ für $x > c$ und $Y=0$ für $x < c$.

Inferenz im logistischen Regressionsmodell

Beachte:

Alle Aussagen gelten - im Gegensatz zum linearen Regressionsmodell - nur asymptotisch, d.h. für hinreichend großen Stichprobenumfang

Wald-Konfidenzintervalle:

Wir benutzen die asymptotische Normalität und erhalten folgende Konfidenzintervalle für β zum Niveau α :

$$\hat{\beta}_k \pm \hat{\sigma}_{\hat{\beta}_k} z_{1-\alpha/2}$$

$$\hat{\sigma}_{\hat{\beta}_k} = \sqrt{c_{kk}} \text{ (k-tes Diagonalelement der Matrix } F^{-1}(\hat{\beta}))$$

Für die Odds-ratios $\exp(\beta_k)$ erhält man transformierte Konfidenzintervalle zum Niveau α :

$$\exp \left[\hat{\beta}_k \pm \hat{\sigma}_{\hat{\beta}_k} z_{1-\alpha/2} \right]$$

Da kein Varianzparameter zu schätzen ist, kommt die t -Verteilung hier nicht vor.

Wald-Test für die lineare Hypothese

Sei das logistische Regressionsmodell (9.1)–(9.4) gegeben.

$H_0 : \mathbf{A}\boldsymbol{\beta} = \mathbf{c}$ mit $\text{rg}(\mathbf{A}) = a$.

Analog zum linearen Modell wird folgende quadratische Form betrachtet:

$$W = (\mathbf{A}\hat{\boldsymbol{\beta}} - \mathbf{c})'(\mathbf{A}\mathbf{F}^{-1}(\hat{\boldsymbol{\beta}})\mathbf{A}')^{-1}(\mathbf{A}\hat{\boldsymbol{\beta}} - \mathbf{c})$$

W heißt Wald-Statistik.

Aus der asymptotischen Normalität folgt unmittelbar:

$$W \underset{\sim}{\stackrel{\text{as}}{\sim}} \chi^2(a)$$

Mit dieser Statistik lässt sich die allgemeine lineare Hypothese testen.

(vgl. Fahrmeir et al.; S. 285–287)

Likelihood-Quotienten-Test für die lineare Hypothese

Gegeben sei das logistische Regressionsmodell (9.2)–(9.4).

$H_0 : \mathbf{A}\beta = \mathbf{c}$ mit $\text{rg}(\mathbf{A})=a$.

Wir definieren folgende Teststatistik:

$$LQ = -2 \left\{ \ln L(\hat{\hat{\beta}}) - \ln L(\hat{\beta}) \right\}$$
$$\hat{\hat{\beta}} : \text{ML-Schätzer unter } H_0$$

Aus der allgemeinen Theorie von Likelihood-Quotienten-Tests folgt, dass unter H_0 gilt:

$$LQ \underset{\sim}{\text{as}} \chi^2(a)$$

Beachte: Der LQ -Test ist mit dem Wald-Test für endliche Stichproben nicht äquivalent. Äquivalenz gilt nur asymptotisch.

Likelihood-Quotienten-Konfidenzintervalle

Mit Hilfe des LQ -Tests lassen sich auch Konfidenzintervalle zum Niveau α konstruieren:

$$KI := \{\tilde{\beta}_k | H_0 : \beta_k = \tilde{\beta}_k \text{ wird mit LQ-Test zum Niveau } \alpha \text{ nicht abgelehnt}\}$$

Überprüfung der Modellgüte

- Viele Vorschläge für R^2
- Residuen wenig geeignet
- Gruppierte Daten ermöglichen Residualanalyse
- Strategie: Betrachte Modellerweiterungen
- Kreuzvalidierung für Prognosegüte

Gute Methode für Goodness of fit und Vorhersagekraft

Allgemein:

$Y = 1 \longrightarrow$ Ausfall (krank)

$Y = 0 \longrightarrow$ kein Ausfall (gesund)

In der medizinischen Literatur ist das Testergebnis m :

$$\hat{Y}_i = 1 \Leftrightarrow m_i \geq c \quad (9.13)$$

c ist dabei ein Grenzwert.

Richtig Positiv = Sensitivität:

$$P(\hat{Y} = 1|Y = 1) = P(m \geq c|Y = 1) = S_1(c) = 1 - F_1(c) \quad (9.14)$$

$S_1(c)$ stellt die Survivorfunktion dar, $F_1(c)$ die Verteilungsfunktion.


Falsch Positiv = 1 - Spezifität:

$$P(\hat{Y} = 1|Y = 0) = P(m \geq c|Y = 0) = S_0(c) \quad (9.15)$$

$$(9.16)$$

Die ROC-Kurve besteht aus den Punkten $(S_0(c), S_1(c))$.

Beispiel für ROC-Kurve



Logistische Regression und ROC-Kurve

$$m_i = G(\mathbf{x}_i' \beta)$$

$$m_i = \mathbf{x}_i' \beta$$

Beachte die Invarianz der ROC-Kurve bzgl. monotoner Funktionen! Die Verteilung von F_0, F_1 bzw. S_0, S_1 kann aus den Daten geschätzt werden
 $\Rightarrow$ ROC-Kurve

Alternative: Schätze F_0, F_1 bzw. S_0, S_1 aus Validierungsdaten.

Maß zur Bewertung der Kurve: AUC

$$AUC = \int_{t=0}^1 ROC(t) dt \quad (9.17)$$

Dies stellt die Fläche unter der Kurve dar.

Es gilt:

$$AUC = P(m_1 \leq m_0) \quad (9.18)$$

m_1 ist dabei aus der Verteilung $m|Y = 1$

m_0 ist dabei aus der Verteilung $m|Y = 0$

Daher ist das empirische AUC:

$$\widehat{AUC} = \frac{N_c}{N} \quad (9.19)$$

Dabei bezeichnet N_c die Anzahl der konkordanten Paare und N die Anzahl der Paare mit unterschiedlichem Y .

Die logistische Regression für Fall-Kontroll-Studien

Sei in der Grundgesamtheit folgende Beziehung gegeben:

$$P_0(Y = 1|X = x) = G(\alpha + \beta x) \quad (9.20)$$

mit $G(t) = (1 + \exp(-t))^{-1}$

X: Exposition

Y: Erkrankung

Es wird nun aus der GG gezogen:

n_1 : Fälle ($Y = 1$) und n_2 : Kontrollen ($Y = 0$)

Gesucht ist

$$P_S(Y = 1|X = x) \quad (9.21)$$

Mit P_S werden die Wahrscheinlichkeiten (Dichten) in der Stichprobe bezeichnet, mit P_0 die in der GG.

Berechnung von P_S I

$$\begin{aligned} P_S(Y = 1|X = x) &= \frac{P_S(Y = 1, X = x)}{P_S(X = x)} = \\ &= \frac{P_S(Y = 1)P_S(X = x|Y = 1)}{P_S(Y = 1)P_S(X = x|Y = 1) + P_S(Y = 0)P_S(X = x|Y = 0)} = \\ &= \frac{c_1 P_0(X = x|Y = 1)}{c_1 P_0(X = x|Y = 1) + c_2 P_0(X = x|Y = 0)} \end{aligned}$$

Die letzte Identität gilt wegen

$$P_0(X = x|Y = 1) = P_S(X = x|Y = 1) \quad (9.22)$$

und mit $c_1 = \frac{n_1}{n_1 + n_2}$ und $c_2 = \frac{n_2}{n_1 + n_2}$

$$c_1 P_0(X = x|Y = 1) = \frac{c_1}{P_0(Y = 1)} P_0(X = x) P_0(Y = 1|X = x)$$

$$c_2 P_0(X = x|Y = 0) = \frac{c_2}{P_0(Y = 0)} P_0(X = x) P_0(Y = 0|X = x)$$

Berechnung von P_S II

Mit $\frac{c_1}{P_0(Y=1)} = d_1$ und $\frac{c_2}{P_0(Y=0)} = d_2$ folgt:

$$\begin{aligned}P_S(Y=1|X=x) &= \frac{d_1 P(Y=1|X=x)}{d_1 P(Y=1|X=x) + d_2 (1 - P(Y=1|X=x))} \\&= \frac{1}{1 + \frac{d_2}{d_1} \frac{1 - G(\alpha + \beta x)}{G(\alpha + \beta x)}} \\&= \frac{1}{1 + \exp(-\alpha - \ln(\frac{d_1}{d_2}) - \beta x)}\end{aligned}$$

Die letzte Gleichung folgt aus $\frac{1 - G(t)}{G(t)} = \frac{1}{G(t)} - 1 = \exp(-t)$.

Berechnung von P_S III

Insgesamt gilt

$$P_S(Y = 1|X = x) = G\left(\alpha + \ln\left(\frac{d_1}{d_2}\right) + \beta x\right) \quad (9.23)$$

Die Auswertung bezüglich β kann also auch bei Fall- Kontrollstudien durch eine logistische Regression erfolgen. Der Parameter α in der Grundgesamtheit kann dabei nicht geschätzt werden.

- Die logistische Regression ist ein vielseitiges Werkzeug zur Modellierung binärer Ergebnisse.
- Anwendung in vielen Bereichen.
- Viele Techniken aus dem linearen Modell können übernommen werden (z.B. Indikatorvariablen, Splines, Testen von linearen Hypothesen).
- Es gibt enge Beziehungen zu Klassifikationsverfahren.
- Zu beachten ist die Interpretation auf der Log-Odds-Skala.