




11. Variablenselektion

Modellwahl: Zielsetzung der Modellierung




- a) gute Beschreibung des Verhaltens der Zielgröße
- b) Vorhersage zukünftiger Werte der Zielgröße und Schätzung des Mittels der Zielgröße
- c) Extrapolation auf Bereiche außerhalb der X -Daten
- d) Schätzung von Parametern
- e) Kontrolle eines Prozesses durch Variation des Inputs
→ Kausalität nötig
- f) Entwicklung realistischer Modelle für einen Prozess
→ Kausalität nötig



Underfitting




Overfitting



Underfitting

Overfitting



Allgemein: „Tradeoff“ zwischen Modell-Genauigkeit (R^2) und Einfachheit.

Viele Variablen $\rightarrow R^2$ steigt
 $\rightarrow$ Komplexität nimmt zu

a) b) Modellgenauigkeit wichtig

$\rightarrow$ viele Variablen
 $\rightarrow$ Kausale Beziehung nicht nötig „Variable enthält Information“

c) Extrapolation

$\rightarrow$ Kausalität

d) Bias durch Weglassen von Variablen

Erhöhung der Varianz von Schätzern durch überflüssige Variablen

Beachte: Interpretation der Regressionskoeff. „bei Festhalten der anderen Variablen“.

→ Einschränkung durch viele Kovariablen.

e) Kontrolle

→ Kausalität erforderlich

Realistische Beschreibung

→ Sparsames klares Modell

Kein Verfahren kann (zunächst bei den Zielen (c, d, e, f))
das Fachwissen ersetzen

→ Verfahren eher explorativ

Bei der Prognose können bei größeren Datenmengen
Variablenselektionsverfahren sehr effizient sein.

❶ Diskrete Variablen bereiten zusätzliche Probleme:

Gleiches gilt für Interaktionseffekte.

Es gibt „Regeln“ z.B.,

- a) Interaktionen nicht ohne Haupteffekte ins Modell
- b) Effekte von kategoriellen Variablen nur als Ganzes ins Modell

Andere Möglichkeit: Verwenden von Indikator-Variablen

→ Indikator-Variablen, die nicht im Modell sind, entsprechen der gemeinsamen Referenzkategorie

❷ Multikollinearität kann ein erhebliches Problem sein.

→ Korrelation der Kandidaten-Einflussgrößen analysieren

❸ Transformation, quadratische Terme liefern weitere Möglichkeiten

(vgl. Fahrmeir et al.; S. 151)

Maße für die Modellgüte I

Gegeben sei das lineare Modell $Y = X\beta + \varepsilon$

a) **Bestimmtheitsmaß:**

$$R^2 = \frac{SSM}{SST} = 1 - \frac{SSE}{SST} \quad (10.1)$$

b) **Adjustiertes Bestimmtheitsmaß:**

$$R_{adj}^2 := 1 - \frac{MSE}{MST} = 1 - \frac{\hat{\sigma}^2}{SST/(n-1)} \quad (10.2)$$

(vgl. Fahrmeir et al.; S. 147, 148)

c) Akaikes Informationskriterium

$$\begin{aligned} AIC &:= -2\log(l(\hat{\beta}, \hat{\sigma})) + 2(p' + 1) = \\ &= \ln(\text{SSE}) - n \ln(n) + 2(p' + 1) + \text{const} \end{aligned} \quad (10.3)$$

Ausgleich zwischen Anpassung (SSE) und Komplexität ($2p'$)

d) Schwarz'sches Bayes-Kriterium BIC

$$\text{SBC} = n \ln(\text{SSE}) + \ln(n)p' - n \ln(n) \quad (10.4)$$

Komplexität wird stärker gewichtet als bei AIC


(vgl. Fahrmeir et al.; S. 148)

Verwende Schätzung der Prognosegüte eines Modells als Kriterium
k-fache Kreuzvalidierung

- 1 Teile den Datensatz in k Teile von etwa gleicher Grösse
- 2 Verwende den ersten Datensatz als Validierungs-Datensatz und die übrigen zur Schätzung
- 3 Berechne Summe der quadratischen Vorhersagefehler (oder anderes Abweichungsmaß) für den ersten Datensatz
- 4 Analoge Berechnung für die übrigen $k-1$ Teile, d.h. es wird jeder Teildatensatz als Validierungsdatensatz verwendet.
- 5 Kreuzvalidierungsscore ergibt sich als Summe der k einzelnen Quadratsummen

Sonderfall: n Gruppen (einfache Kreuzvalidierung)

(vgl. Fahrmeir et al.; S. 149)



Variablenselektionsverfahren I

Gegeben ist eine Zielgröße Y und mehrere mögliche Einflussgrößen $x_k, k = 1, \dots, K$. Gesucht ist ein möglichst gutes Modell

$$Y = \beta_0 + \sum_{j=1}^L \beta_j x_{k_l},$$

wobei die $x_{k_l}, l = 1, \dots, L$ ausgewählt werden sollen.

❶ Auswahl nach einem Kriterium

Wähle aus allen möglichen 2^k Modellen das Modell mit optimalem Kriterium C aus. C ist in der Regel ein Kriterium aus (10.1) - (10.4).

② Vorwärtsselektion

- a) Wähle im Anfangsschritt das Modell $Y = \beta_0$.
- b) Im ersten Schritt wird die Variable in das Modell aufgenommen, die zu dem höchsten R^2 führt.
- c) In den weiteren Schritten wird jeweils eine Einflussgröße in das Modell zusätzlich aufgenommen. Es wird jeweils die Variable, die zu dem höchsten R^2 des resultierenden Modells führt, aufgenommen.
- d) **Stoppregel:** Die Prozedur wird beendet, falls ein bestimmtes Zielkriterium erfüllt ist, z.B. AIC

3 Rückwärts-Selektion

- a) Wähle im Anfangsschritt das volle Modell $Y = \sum_{k=0}^K \beta_k x_k$
- b) In den weiteren Schritten wird jeweils eine Einflussgröße aus dem Modell genommen. Es wird jeweils die Einflussgröße, die zu dem höchsten R^2 des resultierenden Modells führt, ausgeschlossen.
- c) **Stoppregel:** Nach Erfüllung eines bestimmtem Zielkriteriums, z.B. AIC.



4 Schrittweise Selektion:

Kombination aus Vorwärts- und Rückwärtsselektion. Es werden jeweils abwechselnd eine Vorwärtsselektion und eine Rückwärtsselektion mit geeignetem Stoppkriterium durchgeführt.

(vgl. Fahrmeir et al.; S. 151)

Folgen von Variablenselektion

- Überschätzung von R^2
- Überschätzung der Regressionskoeffizienten
- P-Werte und Konfidenzintervalle sind nicht valide
- Instabilität des Modells




Abschließende Bemerkungen

- Möglichst inhaltlich sparsames (Maximal-)–Modell vorgeben
- Strategie bei zentraler Einflussgröße:
 - Variablenselektion für „Confounder“-Modell ohne zentrale Einflussgröße
 - Test auf Effekt der zentralen Einflussgröße mit dem gewählten Confounder-Modell
- Prognoseintervalle etc. mit Kreuzvalidierung (evtl. unter Einbeziehung der Selektion)


Welche Variablen sollen in das Modell ?

Confounder




Confounder: Ja

Mediator



Mediator: Möglich, Interpretation ändert sich


Collider



Collider: Nein

- Es wurden in den letzten Jahren Methoden entwickelt, die Modellschätzung und Variablenselektion simultan erreichen, z.B. LASSO und Boosting-Verfahren; siehe Vorlesung Generalisierte Regression.
- Es gibt in der Regel nicht einfach ein bestes Modell, sondern mehrere passende Modelle. Bayes-Verfahren ermöglichen Inferenz dazu durch Berechnung von Wahrscheinlichkeiten für bestimmte Modelle.
- Eine Strategie in der Inferenz und Prognose besteht in dem sog. Model- Averaging: Man bestimmt Prognosen aus mehreren Modellen als gewichtetes Mittel der Einzel-Prognosen.
- Es wurden in den letzten Jahren einige Strategien zur Inferenz nach Modellwahl entwickelt: **Post Selection Inferenz**;

Explanatory modeling



Predictive modeling

