

NAME: _____

Aufgabe 1

(ca. 29min)

Statistikstudent Severin sterben ständig seine Basilikumpflanzen. Seit Jahren schaut er, wie lange es dauert bis seine Pflanze stirbt und verändert dabei die Variablen *Wassermenge* und *Standort*.

Variable	Ausprägungen
Wassermenge	50, 100, 150 [mL/Tag]
Standort	Fensterbank, Tisch
Ueberlebenszeit	7 - 45 [Tage]

Er rechnet nun folgendes *Modell 1a* in R, um die idealen Bedingungen für ein möglichst langes Überleben des Basilikums zu finden.

Modell 1a

```
> modell.1a <- lm(Ueberlebenszeit ~ Standort + Wassermenge,
data = dat_basil)
> summary(modell.1a)
Call:
lm(formula = Ueberlebenszeit ~ Standort + Wassermenge,
data = dat_basil)
Residuals:
    Min       1Q   Median       3Q      Max
-11.068  -6.059  -2.877   8.812  15.447
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    17.00000     2.00021   8.499 7.16e-14 ***
StandortTisch -10.00000     1.41436  -7.070 1.21e-10 ***
Wassermenge     0.10000     0.01732   5.773 6.52e-08 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 7.747 on 117 degrees of freedom
Multiple R-squared:  0.4,      Adjusted R-squared:  0.3897
F-statistic: 38.99 on 2 and 117 DF,  p-value: 1.056e-13
```

(a) Interpretieren Sie den Koeffizienten *Wassermenge*.

NAME: _____

- (b) Berechnen Sie die erwartete Überlebensdauer auf dem Standort *Tisch* bei einer Wassermenge von 2000 mL/Tag.

- (c) Bewerten Sie die Interpretierbarkeit der erwarteten Überlebensdauer auf dem Standort *Tisch* bei einer Wassermenge von 2000 mL/Tag.

Im nächsten Schritt möchte Severin herausfinden, ob es eine Interaktion zwischen der Wassermenge und dem Standort gibt und rechnet dazu *Modell 1d*.

Modell 1d

```
> modell.1d <- lm(Ueberlebenszeit ~ Standort * Wassermenge,
data = dat_basil)
> summary(modell.1d)
```

Call:
lm(formula = Ueberlebenszeit ~ Standort * Wassermenge,
data = dat_basil)

Residuals:

Min	1Q	Median	3Q	Max
-11.094	-6.054	-2.903	8.812	15.447

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	17.00000	2.65740	6.397	3.46e-09 ***
StandortTisch	-10.00000	3.75813	-2.661	0.0089 **
Wassermenge	0.10000	0.02460	4.065	8.79e-05 ***
StandortTisch:Wassermenge	-0.01000	0.03479	-0.287	0.7743

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 7.78 on 116 degrees of freedom
Multiple R-squared: 0.4, Adjusted R-squared: 0.3844
F-statistic: 25.77 on 3 and 116 DF, p-value: 7.547e-13

NAME: _____

(d) Interpretieren Sie den Effekt der *Wassermenge* auf dem Standort *Tisch* von *Modell 1d*.

(e) Severin führt nun folgenden R-Code aus.

```
> anova(modell.1a, modell.1d)
Analysis of Variance Table

Model 1: Ueberlebenszeit ~ Standort + Wassermenge
Model 2: Ueberlebenszeit ~ Standort * Wassermenge
  Res.Df    RSS Df Sum of Sq    F Pr(>F)
1     117 7021.5
2     116 7021.4  1  0.054493 9e-04 0.9761
```


i) Geben Sie die zugehörige Nullhypothese an.

ii) Kann die Nullhypothese zum Signifikanzniveau von 5% abgelehnt werden? Begründen Sie kurz.

NAME: _____

iii) Welche Schlussfolgerung ziehen Sie daraus?

(f) Ein Diagnostik-Plot könnte wie folgt aussehen.



i.) Geben Sie an, welche Modellannahme verletzt sein könnte und nennen Sie **KURZ** die Begründung, warum Sie dies vermuten.

ii.) Geben Sie eine Lösungsmöglichkeit an.

NAME:

Modell 1g

```
> modell.1g <- lm(Ueberlebenszeit ~ Standort + Wassermenge_fakt,
data = dat_basil)
> summary(modell.1g)
```

Call:
lm(formula = Ueberlebenszeit ~ Standort + Wassermenge_fakt,
data = dat_basil)

Residuals:

Min	1Q	Median	3Q	Max
-6.8823	-1.6865	0.0699	1.7225	7.4049

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	17.0000	0.5019	33.87	<2e-16 ***
StandortTisch	-10.0000	0.5019	-19.92	<2e-16 ***
Wassermenge_fakt100	20.0000	0.6147	32.54	<2e-16 ***
Wassermenge_fakt150	10.0000	0.6147	16.27	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.749 on 116 degrees of freedom
Multiple R-squared: 0.9251, Adjusted R-squared: 0.9231
F-statistic: 477.5 on 3 and 116 DF, p-value: < 2.2e-16

- (g) Im Vergleich zu *Modell 1a* ist in *Modell 1g* nun die Variable *Wassermenge_fakt* statt *Wassermenge* verwendet worden. Was wurde inhaltlich getan?

Hinweis: Severin hat nur die Wassermenge 50, 100 und 150 mL/Tag ausprobiert.

- (h) Interpretieren Sie die Regressionskoeffizienten zur Variable *Wassermenge_fakt* in *Modell 1g*.

NAME: _____


Im letzten Schritt rechnet Severin noch ein Modell *Modell 1i*.

Modell 1i

```
> modell.1i <- lm(Ueberlebenszeit ~ Standort * Wassermenge_fakt,  
data = dat_basil)
```

(i) Wie viele Regressionskoeffizienten hat das *Modell 1i*?

(j) Der Effektplot für *Modell 1i* sieht wie folgt aus:



Begründen Sie anhand der Grafik, ob es Indizien für einen Interaktionseffekt gibt und begründen Sie kurz.

=0 PUNKTE

NAME:

Aufgabe 2

(ca. 32min)

Nehmen Sie an, dass Sie die Assoziation zwischen drei Düngersorten und dem Wachstum (in cm) einer Staudenpflanzensorte zwischen der ersten und vierten Woche nach Keimung analysieren möchten.

Wir beobachten insgesamt 300 Samen in unserer Studie. 75 Samen werden mit dem ersten Dünger gedüngt (Treatment 1), 75 Samen werden mit dem zweiten Dünger gedüngt (Treatment 2), 75 Samen werden mit dem dritten Dünger gedüngt (Treatment 3) und 75 Samen werden als Kontrolle ohne Behandlung beobachtet.

- a) Die Assoziation zwischen Wachstum und Düngermittelsorte soll mit Hilfe eines linearen Regressionsmodells geschätzt werden. Wir nehmen an, dass die Düngermittelsorte mit einer Referenzkodierung in das Modell aufgenommen wird. Schreiben Sie die Modellgleichung aus. Sie dürfen in diesem Fall die Verteilungsannahmen auslassen. Definieren Sie die Ausprägungen der Kovariablen.

NAME:

- b) Stellen Sie sich nun vor, dass Sie anstatt der Referenzkodierung eine Effektkodierung wählen. Skizzieren Sie hierfür eine dementsprechende Designmatrix. Geben Sie an welche Zeilen und welche Spalten welchem Dünger entsprechen. (Hinweis: Sie müssen **NICHT** 300 Zeilen ausschreiben. Kürzen Sie die Skizze Ihrer Designmatrix so viel wie möglich.)



NAME: _____

- c) Nehmen Sie an, dass Sie nun das Modell beschrieben in Aufgabe 2b) in R gefittet haben und dass Sie nun den folgenden Output bekommen.

Modell 2c

```
Call:
lm(formula = y ~ Treatment, data = Xdata, contrasts
= list(Treatment = "contr.sum"))
```

Coefficients:

(Intercept)	Treatment1	Treatment2	Treatment3
5.7524	0.2886	3.1414	-2.7460

Hier beschreibt XData den oben beschriebenen Datensatz. "y" ist hier die Responsevariable, die für das Wachstum steht, und die Treatmentvariable steht für die jeweilige Behandlung der Pflanzen.

- i) Nutzen Sie den Output des Modells 2c, um für alle drei Düngersorten jeweils das durchschnittliche Wachstum der Pflanzen per Hand zu berechnen.

- ii) Nehmen Sie an, dass Sie mit Hilfe eines F-Tests testen möchten, ob mindestens einer der Düngervarianten einen signifikanten Wachstumsunterschied zur Kontrollgruppe aufweist. Stellen Sie dafür die passenden Hypothesen und Test-Statistik auf. (**Sie müssen den Test hier nicht durchführen.**)

NAME: _____

- iii) Im folgenden sehen Sie, dass eine ANOVA in R genutzt wurde, um einen F-Test durchzuführen. Hier fehlen jedoch noch vier Felder; hier mit “a?”, “b?”, “c?” und “d?” gekennzeichnet. Vervollständigen Sie den Output. (Hinweis: Geben Sie bei Ihrer Antwort klar an, welches Feld Sie jeweils vervollständigen.)

```
Analysis of Variance Table

Response: y
      Df Sum Sq Mean Sq F value    Pr(>F)
Treatment  a?      b?      d?  726.75 < 2.2e-16 ***
Residuals 296      c?      0.62
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.'
0.1 ' ' 1
```


- iv) Nutzen Sie Ihre Antwort aus der vorherigen Frage, um das adjustierte R^2 für das Modell auszurechnen. Als Ersatzlösung dürfen Sie stattdessen auch 1500 als Streuung des Modells annehmen und 200 als Residualstreuung.

NAME: _____

- v) Diskutieren Sie kurz, ob in dieser Aufgabe ein R^2 oder ein adjustiertes R^2 als Bestimmtheitsmaß zu bevorzugen wäre. (*Hinweis:* Wir suchen nach jeweils einem Argument für **beide** Bestimmtheitsmaße.)



- d) Es wird angenommen, dass die Fehler ϵ_i unabhängig und identisch verteilt sind. Welche asymptotischen Eigenschaften besitzt die KQ-Schätzung? Wann werden diese benötigt?



NAME:

- e) Beschreiben Sie kurz, wann eine gewichtete KQ-Schätzung einer ungewichteten KQ-Schätzung vorzuziehen wäre.

- f) Erläutern Sie, anhand einer der oben aufgeführten Modelle, oder einer generellen Form des Multiplen Normalen Linearen Modells, wie eine Transformation des Modells in einer gewichteten KQ-Schätzung aussehen würde.

=0 PUNKTE

NAME: _____

Aufgabe 3

(ca. 29min)

Bei einer Studie zu COVID-19 wird das Überleben der Infizierten nach 60 Tagen betrachtet. Es soll die Assoziation des Überlebens zum Alter (Alt; 3 Altersgruppen: 60-64, 75-79 und 90+) und zum Impfstatus (impfst; *geboostert* und *ungeimpft*) analysiert werden.

Als Zielgröße wird die Variable *vst* benutzt ($vst = 1$ entspricht verstorben, $vst = 0$ entspricht überlebt). Dazu wurden insgesamt 2 Modelle angepasst.

- (a) Interpretieren Sie für folgendes Modell (*Modell 4a*) die geschätzten Koeffizienten von dem Impfstatus. Benutzen Sie hierzu die Odds Ratios.

Modell 4a

```
Call:
glm(formula = vst ~ Alt + impfst, family = binomial, data = datac)

Deviance Residuals:
    Min       1Q   Median       3Q      Max
-0.6359  -0.0707  -0.0306  -0.0306   3.9156

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)    -7.6653     0.1863  -41.15  <2e-16 ***
Alt75-79         2.7650     0.2009   13.76  <2e-16 ***
Alt90+          4.4949     0.1875   23.97  <2e-16 ***
impfstungeimpft  1.6746     0.1087   15.40  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 4375.7  on 47344  degrees of freedom
Residual deviance: 3107.0  on 47341  degrees of freedom
AIC: 3115

Number of Fisher Scoring iterations: 9
```

NAME:



- (b) Berechnen Sie für die den Koeffizienten von *Alt75-79* das Konfidenzintervall zum Niveau $\alpha = 0.05$, sowohl für die log-Odds als auch für die Odds.



NAME: _____

- (c) Für den Koeffizienten des Impfstatus (*impfstungeimpft*) ist der Wert 0 nicht im 95%-Konfidenzintervall enthalten. Was bedeutet das für einen ungerichteten Hypothesentest des Odds Ratios des Impfstatus mit Nullhypothese $H_0: \text{Odds Ratio} = 1$ und Gegenhypothese $H_1: \text{Odds Ratio ungleich } 1$ zum Niveau $\alpha = 0.05$? Begründen Sie kurz.

- (d) Geben Sie für *Modell 4a* die Struktur- und Verteilungsannahme an. Spezifizieren Sie explizit den linearen Prädiktor sowie die Response- und Link-Funktion.

NAME:

(e) Nun wird ein weiteres Modell (*Modell 4e*) geschätzt:**Modell 4e**

```
Call:
glm(formula = vst ~ Alt + impfst + Alt * impfst, family = binomial,
    data = datac)

Deviance Residuals:
    Min       1Q   Median       3Q      Max
-0.5849  -0.0774  -0.0255  -0.0255   4.0074

Coefficients:
                Estimate Std. Error z value Pr(>|z|)
(Intercept)      -8.0293     0.3333  -24.089  < 2e-16 ***
Alt75-79           2.7653     0.3718   7.437 1.03e-13 ***
Alt90+             5.0575     0.3466  14.590  < 2e-16 ***
impfstungeimpft    2.2189     0.3910   5.675 1.39e-08 ***
Alt75-79:impfstungeimpft 0.1069     0.4425   0.242  0.8091
Alt90+:impfstungeimpft -0.9262     0.4143  -2.235  0.0254 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 4375.7  on 47344  degrees of freedom
Residual deviance: 3086.9  on 47339  degrees of freedom
AIC: 3098.9

Number of Fisher Scoring iterations: 10
```

(f) Welche zusätzliche Fragestellung wird in Modell 4e, im Vergleich zu Modell 4a, bearbeitet? Erklären Sie.

NAME: _____

- (g) Vergleichen Sie die Ergebnisse von Modell 4a und Modell 4e inhaltlich im Hinblick auf Alters- und Impfstatus-Effekte. Welches Modell ist zu bevorzugen? Begründen Sie.

- (h) Die zugehörige ANOVA zu Modell 4e ist:

Analysis of Deviance Table (Type II tests)

Response: vst

	LR	Chisq	Df	Pr(>Chisq)
Alt	1044.93	2	< 2.2e-16	***
impfst	231.22	1	< 2.2e-16	***
Alt:impfst	20.13	2	4.254e-05	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

- (i) Welches Modell ist zu bevorzugen? Begründen Sie kurz.

=0 PUNKTE