

NAME: _____

Aufgabe 1

(ca. 17min)

Ein Krankenhaus untersucht Faktoren, die die Zufriedenheit von PatientInnen (Zufriedenheit) beeinflussen könnten. Die Zufriedenheit wird über einen standardisierten Fragebogen auf einer Skala von 1 (sehr unzufrieden) bis 5 (sehr zufrieden) erfasst.

Als mögliche Einflussfaktoren werden die Variablen Aufenthalt und Therapien betrachtet. Die Variable Aufenthalt gibt die Dauer des Krankenhausaufenthalts in Tagen an. Die binäre Variable Therapien mit den Ausprägungen NurEine und Mehrere gibt an, ob ein Patient nur eine oder mehrere unterschiedliche Therapien im Krankenhaus erhalten hat.

Im Folgenden ist der R-Output eines multiplen linearen Regressionsmodells für einen Datensatz mit 20 PatientInnen (Modell 1.1) gegeben:

Modell 1.1

```
Call:
lm(formula = Zufriedenheit ~ Aufenthalt + Therapien, data = daten)

Residuals:
Min      1Q  Median      3Q      Max
-1.5    -0.5       0     0.4     1.6

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)       4.50      0.10   45.00  <0.00001 ***
Aufenthalt        -0.05      0.01   -5.00  <0.00001 ***
TherapienMehrere  -0.20      0.05   -4.00  <0.00001 ***

Residual standard error: 0.6 on 17 degrees of freedom
Multiple R-squared:  0.35,    Adjusted R-squared:  0.33
F-statistic: 39 on 2 and 17 DF,  p-value: < 0.00001
```


(a) Stellen Sie anhand des R-Outputs die Modellgleichung zu Modell 1.1 auf.

NAME:

(b) Interpretieren Sie die Koeffizienten der Variablen Aufenthalt und Therapien.



(c) Ein Patient hatte einen Krankenhausaufenthalt von sieben Tagen und benötigte drei Therapien. Wie hoch ist die erwartete Zufriedenheit dieses Patienten gemäß Modell 1.1?



NAME:

- (d) Es ist zweifelhaft, ob der Zusammenhang zwischen der Dauer des Aufenthalts und der Zufriedenheit linear ist. Nennen und beschreiben Sie zwei sinnvolle Modifikationen des Modells, mit deren Hilfe die Linearität überprüft werden kann.

- (e) Beschreiben Sie eine Möglichkeit, wie die Normalverteilungsannahme bei einem linearen Modell überprüft werden kann. Welche Problematik könnte sich bei Modell 1.1 bezüglich dieser Annahme ergeben?

=0 PUNKTE

NAME: _____

Aufgabe 2

(ca. 14min)

Im Jahr 2018 wurde im Rahmen einer Umfrage zum Reiseverhalten in Deutschland bei 1000 Personen unter anderem die Entfernung des Reiseziels vom Wohnort bei der wichtigsten Reise des Jahres (Reisedistanz) erhoben.

Bei der Analyse der Daten wurde ein lineares Regressionsmodell (Modell 2.1) geschätzt, das die Reisedistanz in Abhängigkeit des Alters (Alter), des monatlichen Nettoeinkommens in 1000 € (Einkommen) und des Bildungsniveaus (Bildung) beschreibt. Das Bildungsniveau wurde hierzu in drei Kategorien niedrig (kein Schulabschluss, Hauptschulabschluss), mittel (Mittlere Reife) und hoch (Abitur, Hochschulabschluss) eingeteilt.

Nachfolgend sind die zugehörige Modellgleichung auf Beobachtungsebene sowie ein Effektplot der Variable Einkommen getrennt nach den Bildungsniveaus für eine 30-jährige Person gegeben:


Modell 2.1

$$\text{Reisedistanz}_i = \beta_0 + \beta_1 \text{Alter}_i + \beta_2 \text{Einkommen}_i + \beta_3 \text{Bildung}_{\text{mittel},i} + \beta_4 \text{Bildung}_{\text{hoch},i} + \varepsilon_i$$

mit $\varepsilon_i \stackrel{iid}{\sim} \mathbb{N}(0, \sigma^2)$,

$$\text{Bildung}_{\text{mittel},i} = \begin{cases} 1 & \text{für Bildung}_i = \text{mittel} \\ 0 & \text{für Bildung}_i \neq \text{mittel}, \end{cases}$$

$$\text{Bildung}_{\text{hoch},i} = \begin{cases} 1 & \text{für Bildung}_i = \text{hoch} \\ 0 & \text{für Bildung}_i \neq \text{hoch}, \end{cases}$$



NAME: _____

- (a) Geben Sie die Referenzkategorie der Variable Bildung an und begründen Sie, warum diese eine sinnvolle Wahl darstellt.

- (b) Bestimmen Sie anhand des Effektplots die geschätzten Koeffizienten $\hat{\beta}_0$, $\hat{\beta}_2$, $\hat{\beta}_3$ und $\hat{\beta}_4$, wobei $\hat{\beta}_1 = -0.0076$ als bekannt vorausgesetzt wird.

- (c) Basierend auf Modell 2.1 soll nun in einem linearen Hypothesentest der Form $\mathbf{A}\beta = \mathbf{c}$ die Nullhypothese überprüft werden, dass der Effekt für die Kategorie mittel im Vergleich zur Referenzkategorie doppelt so groß ist wie für die Kategorie hoch. Geben Sie für diesen Test die Hypothesen, die Matrizen $\mathbf{A}$ und $\mathbf{c}$ sowie die Verteilung der Teststatistik an.

NAME:

=0 PUNKTE

NAME: _____

Aufgabe 3

(ca. 30min)

Im Rahmen dieser Aufgabe soll die Mortalität (pro 100 000 Einwohner) in Metropolregionen in den USA in Abhängigkeit von bis zu 15 Kovariablen modelliert werden. Hierfür wird ein Datensatz verwendet, der 1973 von McDonald und Schwing veröffentlicht wurde.

- (a) Zunächst wird ein lineares Modell geschätzt, bei dem alle 15 möglichen Einflussgrößen berücksichtigt werden. Interpretieren Sie das R^2 anhand des folgenden gekürzten R-Outputs.

```
Call:
lm(formula = MORT ~ ., data = Schmutz)

Residuals:
    Min       1Q   Median       3Q      Max
-68.066 -18.017   0.912  19.224  86.961

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.764e+03   4.373e+02   4.034 0.000215 ***
PREC         1.905e+00   9.237e-01   2.063 0.045071 *
JANT        -1.938e+00   1.108e+00  -1.748 0.087413 .
...
HUMID         1.068e-01   1.169e+00   0.091 0.927644
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 34.93 on 44 degrees of freedom
Multiple R-squared:  0.7649,    Adjusted R-squared:  0.6847
F-statistic: 9.542 on 15 and 44 DF,  p-value: 2.193e-09
```

NAME:

- (b) Der folgende R-Code führt vier verschiedene schrittweise Variablenselektionsverfahren zur Modellierung der Mortalität durch. Die Ergebnisse werden in den Objekten Selektion_1, Selektion_2, Selektion_3 und Selektion_4 gespeichert.

```
Volles_Modell <- lm(MORT ~ ., data = SCHMUTZ)
Null_Modell <- lm(MORT ~ 1, data = Schmutz)
scope_schmutz <- list(upper = Volles_Modell, lower = Null_Modell)
Selektion_1 <- stepAIC(Null_Modell, scope = scope_schmutz,
                      direction = "forward", k = log(nrow(Schmutz)))
Selektion_2 <- stepAIC(Volles_Modell, scope = scope_schmutz,
                      direction = "backward")
Selektion_3 <- stepAIC(Null_Modell, scope = scope_schmutz,
                      direction = "both")
Selektion_4 <- stepAIC(Volles_Modell, scope = scope_schmutz,
                      direction = "both", k = log(nrow(Schmutz)))
```

- (i) Bestimmen Sie für jedes der vier Variablenselektionsverfahren, welches Selektionskriterium und welche Selektionsmethode verwendet wurden. Geben Sie auch jeweils an, ob das Verfahren mit dem Nullmodell oder dem vollen Modell gestartet wurde.

NAME: _____

- (ii) Begründen Sie, ohne die Ergebnisse der Variablenselektion zu kennen, welches der vier Verfahren wahrscheinlich zum kleinsten Modell führen wird.

- (iii) Verwenden Sie den folgenden R-Code, um zu begründen, welche der vier Variablenselektionsverfahren zur Prognose neuer Datenpunkte ausgewählt werden würden.

```
##### Dimensionen der neuen Daten #####
dim(Neu_Daten)
# 100 Reihen, 16 Spalten


##### Funktion zur Berechnung des Root Mean Squared Error #####
RMSE <- function(Y, Y_pred){
  RMSE <- sqrt(sum((Y - Y_pred)^2))
  return(RMSE)
}

##### Prognose der Mortalität anhand der vier #####
##### Variablenselektionsverfahren für die neuen Daten #####
Predict_1 <- predict(Selektion_1, newdata = Neu_Daten)
Predict_2 <- predict(Selektion_2, newdata = Neu_Daten)
Predict_3 <- predict(Selektion_3, newdata = Neu_Daten)
Predict_4 <- predict(Selektion_4, newdata = Neu_Daten)


##### Auflistung der berechneten RMSEs #####
RMSE_SELEKTION <- cbind("Selektion_1"= RMSE(Neu_Daten$MORT, Predict_1),
                        "Selektion_2"= RMSE(Neu_Daten$MORT, Predict_2),
                        "Selektion_3"= RMSE(Neu_Daten$MORT, Predict_3),
                        "Selektion_4"= RMSE(Neu_Daten$MORT, Predict_4))
RMSE_SELEKTION

      Selektion_1 Selektion_2 Selektion_3 Selektion_4
[1,]      231.6872      431.1707      231.6872      431.1707
```


NAME:



- (iv) Geben sie einen Grund an, warum sich für zwei verschiedene Variablenselektionsverfahren die gleichen RMSEs ergeben können.



- (c) Beschreiben Sie je einen möglichen Vor- und Nachteil einer schrittweisen Variablenselektion gegenüber der Best Subset-Methode.



NAME:

- (d) Stellen Sie sich nun vor, dass ein schrittweises Variablenselektionsverfahren mit dem R^2 als Selektionskriterium durchgeführt wird. Begründen Sie, wie viele Variablen durch dieses Selektionsverfahren ausgewählt werden würden.



=0 PUNKTE





NAME:

Aufgabe 4

(ca. 15min)

Die folgenden Aufgabenstellungen stellen offene Fragen dar, die in Textform beantwortet werden sollen. Achten Sie dabei insbesondere darauf, dass Sie Ihre *eigenen* Worte verwenden.

- (a) Im Folgenden sind vier Standarddiagnostikgrafiken zu einem linearen Regressionsmodell der Form $y = X\beta + \varepsilon$ mit $\varepsilon \sim N(0, \sigma^2 I)$ gegeben. Beurteilen Sie die Varianzhomogenitäts- und Normalverteilungsannahme des Modells und gehen Sie außerdem darauf ein, ob Ausreißer und einflussreiche Beobachtungen vorliegen. Begründen Sie Ihre Aussagen anhand der passenden Grafiken.



NAME:

- (b) Beschreiben Sie die Problematik der Kollinearität bei einem multiplen linearen Regressionsmodell. Warum ist es wichtig, das Modell diesbezüglich zu überprüfen und ggf. Anpassungen vorzunehmen?

NAME:

- (c) Erläutern Sie den Unterschied zwischen einem Konfidenz- und einem Prognoseintervall für die Prognose $\hat{y}_{n+1}$ einer neuen Beobachtung anhand eines linearen Modells der Form $y = X\beta + \varepsilon$ mit $\varepsilon \sim N(0, \sigma^2 I)$. Welches der beiden Intervalle ist breiter?



=0 PUNKTE

NAME: _____

Aufgabe 5

(ca. 28min)

Credit Scoring ist ein Bereich der Datenanalyse, der häufig im Bankenwesen eingesetzt wird. Ziel ist es, anhand verschiedener personenspezifischer Merkmale (z.B. Alter) sowie Merkmale zur finanziellen Lage (z.B. Einkommen, Hauseigentum) und zur Kredithistorie (z.B. Anzahl Probleme in der Vergangenheit) auf die Kreditwürdigkeit von Bewerbern zu schließen.

Im Folgenden wird ein Datensatz zu 1319 Personen betrachtet, für die zusammen mit weiteren Variablen die Information erhoben wurde, ob ihr Antrag für eine Kreditkarte akzeptiert wurde. Anhand des Datensatzes soll untersucht werden, auf welche Weise die verschiedenen Einflussgrößen auf die Bewilligung einer Kreditkarte durch die Bank wirken.

Im Rahmen der Aufgabe werden die folgenden Variablen betrachtet:

Variable	Beschreibung
card	Bewilligung einer Kreditkarte (0 = nein, 1 = ja)
age	Alter in Jahren
income	Jährliches Bruttoeinkommen in 10 000 USD
owner	Eigentümer eines Hauses (no = nein, yes = ja)
selfemp	Selbstständige Beschäftigung (no = nein, yes = ja)
reports	Anzahl problematischer finanzieller Interaktionen in der Vergangenheit
expenditure	Durchschnittliche monatliche Kreditkartenausgaben in USD

Zur Beantwortung der Fragestellung wird das folgende Modell (Modell 3.1) angepasst:

Modell 3.1

```
Call:
glm(formula = card ~ age + income + owner + selfemp + reports,
     family = "binomial", data = CreditCard)
```

Deviance Residuals:

Min	1Q	Median	3Q	Max
-2.5968	0.3054	0.4742	0.6230	2.5614

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	1.292466	0.288622	4.478	7.53e-06	***
age	-0.010813	0.008544	-1.266	0.205681	
income	0.221742	0.061325	3.616	0.000299	***
owneryes	0.699776	0.182865	3.827	0.000130	***
selfempyes	-0.672782	0.281205	-2.392	0.016734	*
reports	-1.335038	0.112599	-11.857	< 2e-16	***


Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

NAME:

- (a) Geben Sie anhand des R-Outputs zu Modell 3.1 den linearen Prädiktor, die Responsefunktion und die Verteilung der Zielvariable (gegeben die Kovariablen) an.

A large empty rectangular box intended for the student's answer to question (a).

- (b) Interpretieren Sie die geschätzten Koeffizienten der Variablen `income` und `owner` auf Ebene der Odds.

A large empty rectangular box intended for the student's answer to question (b).

NAME:

- (c) Wie hoch ist gemäß Modell 3.1 die Chance auf die Bewilligung einer Kreditkarte für eine selbstständige Antragstellerin mit 40 000 USD Jahreseinkommen im Vergleich zu einer angestellten Antragstellerin mit 30 000 USD Jahreseinkommen, wenn alle anderen Variablen bei beiden Frauen gleich sind?

NAME: _____

- (d) Das Modell wird nun um die Variable `expenditure` (monatliche Kreditkartenausgaben) ergänzt, so dass sich der untenstehende Modelloutput (Modell 3.2) ergibt. Vergleichen Sie den Output mit dem Output zu Modell 3.1. Erklären Sie die Problematik, die sich bezüglich der Variable `expenditure` ergibt.

Modell 3.2:

```
Call:
glm(formula = card ~ age + income + owner + selfemp + reports +
     expenditure, family = "binomial", data = CreditCard)

Deviance Residuals:
    Min       1Q   Median       3Q      Max
-0.8733   0.0000   0.0000   0.0000   2.6262

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)  -2.60440    0.78169  -3.332 0.000863 ***
age           0.02461    0.02071   1.188 0.234741
income       -0.13124    0.16555  -0.793 0.427930
owneryes      0.35693    0.55544   0.643 0.520480
selfempyes    0.47604    0.69672   0.683 0.494438
reports      -2.13303    0.95188  -2.241 0.025036 *
expenditure  35.19398   173.28833   0.203 0.839061
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

NAME: _____

- (e) Die folgende Tabelle gibt für einen Validierungsdatensatz mit fünf Antragstellern die anhand von Modell 3.1 prognostizierten Wahrscheinlichkeiten für eine Bewilligung einer Kreditkarte an.

Antragsteller	1	2	3	4	5
$P(\text{card} = 1 x)$	0.96	0.89	0.61	0.53	0.07
card	Ja	Ja	Nein	Ja	Nein

- (i) Zeichnen Sie die ROC-Kurve für diesen Datensatz. Geben Sie die hierfür berechneten Punkte im Koordinatensystem an.

- (ii) Berechnen Sie den AUC-Wert.

=0 PUNKTE