

Vorlesung: Lineare Modelle

Sabine Hoffmann

Danke an Helmut Küchenhoff für das Bereitstellen der Folien

Institut für Statistik, LMU München

SoSe 2025

Termine und Informationen

Homepage: <https://moodle.lmu.de/course/view.php?id=40188>

Vorlesung:

Sabine Hoffmann

Montag, 12.15 - 13.45 Schellingstraße 3, S 001

Dienstag, 12.15 - 13.45 Hauptgebäude, A 120

Übung:

Conni Gruber, Christina Sauer

Gruppe 1: Dienstag, 10.15 - 11.45 Hauptgebäude, A 120

Gruppe 2: Donnerstag, 14.15 - 15.45 Hauptgebäude, A 120

Beginn: 6.05. bzw. 8.05., 14-tägig

Tutorium:

Eugen Gorich

Montag, 12.15 - 13.45 Schellingstraße 3, S 001

Beginn: 5.05., 14-tägig

- Präsenzvorlesung
- Folien werden bereit gestellt
- Ergänzend Videos aus 2021 von Helmut Küchenhoff

- Übungsblätter werden ins Netz gestellt. Sie sollten selbstständig oder in Gruppen bearbeitet werden (ohne Abgabe)
- Lösungen zu den Blättern werden von den Übungsleitern erläutert.
- Videos zu den Übungen teilweise im Netz

- Zusätzliche Aufgaben werden ins Netz gestellt
- Besprechung wöchentlich

Bitte beteiligen Sie sich aktiv an der Veranstaltung.

L. Fahrmeir, Th. Kneib, S. Lang, B. Marx:
Regression

Models, Methods and Applications

Springer-Verlag 2013

in der Bibliothek online verfügbar

J. Faraway:

Linear Models with R

Extending the Linear Model with R


Thomas Nagler:

Methoden der Linearen Algebra in der Statistik Vorlesungsskript

1. Einführung und Beispiele


Sir Francis Galton

Sir Francis Galton (1822-1911): „Regression toward mediocrity in hereditary stature“



(vgl. Fahrmeir et al.; S. 1)

Der Begriff Regression



Zusammenhang zwischen Größe der Eltern und der ihrer Kinder

$$E(Y) = \bar{Y} + 0.65(x - \bar{x})$$


$$E(Y) = 24 + 0.65x$$

Y: Größe des Kindes x: Größe der Eltern

(vgl. Fahrmeir et al.; S. 2,3)

Gibt es eine Midlife - Crisis ?

Daten über die Zufriedenheit von Personen:



$$E(Y_t) = \beta_0 + \beta_1 x_{1t} + \beta_2 x_{2t} + \beta_3 \log(x_{3t}) + \beta_4 x_{4t} + \dots + f(\text{Alter})$$

x-Variablen: Gehalt, Geschlecht, Gesundheitsstatus etc.

→ **multiple lineare Regression, Splines**

Wirksamkeit der Umweltzone

$$E(NOX_t) = \mu(LEZ(t)) + \beta_1 * temp + ...$$

$\mu(LEZ(t))$: Belastung bei der Umweltzone Stufe 0,1,2,3

Zielgröße: NOX_t : Stündliche Werte von Stickoxiden
→ **Kovarianzanalyse**

Zusammenhang zwischen Lesefähigkeit und Lehrmethode

$$E(Y_{ij}) = \beta_0 + \beta_1 x_{1ij} + \alpha_j$$

Y_{ij} : Lesefähigkeit von Schüler/in i in Klasse j

x_{1ij} : Zahl der Förderstunden

α_j : Klasseneffekt

→ **Gemischtes lineares Modell**

Zusammenhang zwischen dem Auftreten von Chronischer Bronchitis (CBR) und Staubbelastung am Arbeitsplatz

Studie: 1246 Arbeitnehmer

$$P(Y_i = 1) = G(\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 IR_i)$$

Variablen:

Y : Indikator für CBR

x_1 : Staubkonzentration am Arbeitsplatz

x_2 : Dauer der Exposition

IR : Rauchstatus (ja/nein)

→ **Logistisches Regressionsmodell**

- Wir wollen einen Zusammenhang zwischen einer Zielgröße Y und Einflussgrößen x modellieren
- Ziele sind Verstehen, Nachweisen, Prognostizieren
- *Supervised learning*: Wir lernen aus den Daten den Zusammenhang zwischen x und Y
- Zusammenhänge können sehr komplex sein. Daher sind die Methoden auch komplex.

(vgl. Fahrmeir et al.; S. 21)

Inhalt der Vorlesung (1)

- 1 Einführung und Beispiele
- 2 Das einfache lineare Regressionsmodell
- 3 Das multiple lineare Regressionsmodell
- 4 Quadratsummenzerlegung und statistische Inferenz im multiplen linearen Regressionsmodell
- 5 Diskrete Einflußgrößen: Dummy- und Effektkodierung, Mehrfaktorielle Varianzanalyse

Inhalt der Vorlesung (2)

- 6 Metrische Einflußgrößen: Interaktionen, Polynomiale Regression, Trigonometrische Polynome, Regressionssplines, Transformationen.
- 7 Modelldiagnose
- 8 Das allgemeine lineare Modell: Gewichtete KQ-Methode, Autokorrelierte und heteroskedastische Störterme
- 9 Das gemischte lineare Regressionsmodell („Linear mixed Model“)
- 10 Das logistische Regressionsmodell
- 11 Variablenselektion

2. Das einfache lineare Regressionsmodell

Das einfache lineare Regressionsmodell

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i; \quad i = 1, \dots, n \quad (1.1)$$

$$E(\varepsilon_i) = 0 \quad (1.2)$$

$$V(\varepsilon_i) = \sigma^2 \quad (1.3)$$

$$\{\varepsilon_i \mid i = 1, \dots, n\} \quad \text{stoch. unabhängig} \quad (1.4)$$

$$\varepsilon_i \sim N(0, \sigma^2) \quad (1.5)$$

Y_i : Zielgröße (Zufallsgröße), abhängige Variable

x_i : **feste** bekannte Einflussgröße, unabhängige Variable


ε_i : Zufallsfehler

$\beta_0, \beta_1, \sigma^2$: unbekannte Parameter


n : Anzahl der Beobachtungen

(vgl. Fahrmeir et al.; S. 24, 73-76)


Wahl der Kostenfunktion



Wahl der Kostenfunktion: Absolute Distanz



Wahl der Kostenfunktion: Quadratische Distanz



KQ-Methode: Gauss und Legendre

Erste Veröffentlichung durch Legendre (1805)

Asteroiden-Daten : Gauß (1795 (?))



Wir betrachten Modell (1.1).

Dann heißt


$$(\hat{\beta}_0, \hat{\beta}_1) = \arg \min_{\beta_0, \beta_1} \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i)^2 \quad (1.6)$$

KQ-Schätzer (Schätzer nach der Methode der kleinsten Quadrate) und


$$\hat{\varepsilon}_i := Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i \quad \text{heißen } \mathbf{Residuen}. \quad (1.7)$$

(vgl. Fahrmeir et al.; S. 105-108)


Schätzung: Kleinste Quadrate




Schätzung: Kleinste Quadrate



Schätzung: Kleinste Quadrate



Vergleich mit absoluter Distanz



Existenz und Berechnung des KQ-Schätzers

Der KQ-Schätzer **existiert** und ist **eindeutig**, (falls $\sum_{i=1}^n (x_i - \bar{x})^2 \neq 0$):

$$\hat{\beta}_1 = \frac{S_{xY}}{S_x^2} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(Y_i - \bar{Y})}{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2} \quad (1.8)$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{x}. \quad (1.9)$$

Beweis:

Durch Differenzieren von (1.6) erhält man $(\hat{\beta}_0, \hat{\beta}_1)$ als Lösung der Normalgleichungen

$$\sum_{i=1}^n \hat{\varepsilon}_i = 0 \quad (1.10)$$

$$\sum_{i=1}^n \hat{\varepsilon}_i x_i = 0 \quad (1.11)$$

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i; \quad i = 1, \dots, n$$
$$E(Y_i | x_i) = \beta_0 + \beta_1 x_i$$

Systematische Komponente: $\beta_0 + \beta_1 x_i$

- Zentrale Größe ist der Steigungsparameter β_1

Wenn x um eine Einheit steigt, dann steigt Y **im Durchschnitt** um β_1 Einheiten

Die Größe von β_1 hängt von der Einheit von x ab. Sie kann also nur in Zusammenhang mit x interpretiert werden.

- Interpretation des Achsenabschnitts β_0 :

Erwartungswert von Y bei $x=0$ (In vielen Fällen irrelevant)

Interpretation der Modellparameter II

$$\begin{aligned}Y_i &= \beta_0 + \beta_1 x_i + \varepsilon_i; \quad i = 1, \dots, n \\E(Y_i | x_i) &= \beta_0 + \beta_1 x_i\end{aligned}$$

Stochastische Komponente : Störterm ε

Interpretation des Parameters σ :

- Standardabweichung des Störterms
- Maß für die durchschnittliche Abweichung der Y -Werte von der Regressionsgeraden

Eigenschaften des KQ-Schätzers I

Gegeben sei Modell (1.1) mit Annahme (1.2).

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i; \quad i = 1, \dots, n \quad (1.1)$$

$$E(\varepsilon_i) = 0 \quad (1.2)$$

❶ Dann ist $(\hat{\beta}_0, \hat{\beta}_1)$ ein **erwartungstreuer** Schätzer für (β_0, β_1) :

$$E(\hat{\beta}_0, \hat{\beta}_1) = (\beta_0, \beta_1). \quad (1.12)$$

Eigenschaften des KQ-Schätzers II

- 2 Für die **Varianzen** von $(\hat{\beta}_0, \hat{\beta}_1)$ gilt unter den Annahmen (1.3), (1.4):

$$V(\varepsilon_i) = \sigma^2 \quad (1.3)$$

$$\{\varepsilon_i \mid i = 1, \dots, n\} \quad \text{stoch. unabhängig} \quad (1.4)$$

$$V(\hat{\beta}_1) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} = \sigma^2 / nS_x^2 \quad (1.13)$$

$$V(\hat{\beta}_0) = \sigma^2 \left[\frac{\sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right] = \sigma^2 \left[\frac{1}{n} + \frac{\bar{x}^2}{nS_x^2} \right] \quad (1.14)$$

Eigenschaften des KQ-Schätzers III

- ③ Unter der NV-Annahme (1.5):

$$\varepsilon_i \sim N(0, \sigma^2) \quad (1.5)$$

ist der KQ-Schätzer $(\hat{\beta}_0, \hat{\beta}_1)$ gleichzeitig der **ML-Schätzer**.

Beweis des Satzes I

- ① Es ist zu beachten, dass die x_i fest sind und dass die einzige stochastische Komponente des Modells ε_i ist.

$$\begin{aligned} E(\hat{\beta}_1) &= E \left[\frac{\sum_{i=1}^n (Y_i - \bar{Y})(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \right] \\ &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n E[(\beta_0 + \beta_1 x_i + \varepsilon_i - \beta_0 - \beta_1 \bar{x} - \bar{\varepsilon})(x_i - \bar{x})] \\ &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n [(\beta_0 + \beta_1 x_i + E[\varepsilon_i] - \beta_0 - \beta_1 \bar{x} - E[\bar{\varepsilon}])(x_i - \bar{x})] \\ &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n \beta_1 (x_i - \bar{x})(x_i - \bar{x}) = \beta_1 \end{aligned}$$

$$E(\hat{\beta}_0) = E[\bar{Y} - \hat{\beta}_1 \bar{x}] = E[\beta_0 + \beta_1 \bar{x} + \bar{\varepsilon}] - \beta_1 \bar{x} = \beta_0$$

- ② Übung

Beweis des Satzes II

- 3 Die Likelihood von Beobachtungen (y_i, x_i) lautet:

$$L(y_1, \dots, y_n, x_1, \dots, x_n) = \prod_{i=1}^n \left(\sqrt{2 * \pi * \sigma^2} \right)^{-1} \exp \left[-\frac{[\varepsilon_i(\beta_0, \beta_1)]^2}{2\sigma^2} \right]$$

$$\ln L(y_1, \dots, y_n, x_1, \dots, x_n) = -n/2 * \ln(\sigma^2 * 2 * \pi) - \frac{1}{2\sigma^2} \sum_{i=1}^n \varepsilon_i^2$$

Da die Parameter β_0 und β_1 nur in $\sum_{i=1}^n \varepsilon_i^2$ vorkommen, entspricht die Maximierung von $\ln(L(y_i, x_i))$ der Minimierung von $\sum_{i=1}^n \varepsilon_i^2$. Damit entspricht die KQ-Methode der ML-Methode.

Als ML-Schätzung von σ^2 ergibt sich nach Einsetzen von $\hat{\varepsilon}_i := \varepsilon_i(\hat{\beta}_0, \hat{\beta}_1)$:

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n \hat{\varepsilon}_i^2$$

Dieser Schätzer ist nicht erwartungstreu. Daher wird er selten verwendet.

Schätzung von σ^2 und Konfidenzintervalle für β_0 und β_1 I

Gegeben sei das Modell (1.1) bis (1.4).

➊ Dann ist

$$\hat{\sigma}^2 := \frac{1}{n-2} \sum_{i=1}^n \hat{\varepsilon}_i^2 = \frac{1}{n-2} \sum_{i=1}^n (Y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i))^2 \quad (1.15)$$

ein **erwartungstreuer** Schätzer für σ^2 .

Schätzung von σ^2 und Konfidenzintervalle für β_0 und β_1 II

- ② Unter der Normalverteilungsannahme (1.5) gilt:

$$\frac{1}{\sigma^2} \sum_{i=1}^n \hat{\varepsilon}_i^2 \sim \chi_{n-2}^2 \quad (1.16)$$

$$(\hat{\beta}_0, \hat{\beta}_1) \text{ und } \hat{\sigma}^2 \quad \text{stoch. unabhängig} \quad (1.17)$$

Schätzung von σ^2 und Konfidenzintervalle für β_0 und β_1 III

- 3 Unter (1.5) gilt für die Schätzer $\hat{\beta}_1$ und $\hat{\beta}_0$:

$$\frac{\hat{\beta}_1 - \beta_1}{\hat{\sigma}_{\hat{\beta}_1}} \sim t_{n-2} \text{ mit } \hat{\sigma}_{\hat{\beta}_1} := \sqrt{\frac{\hat{\sigma}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}} \quad (1.18)$$

$$\frac{\hat{\beta}_0 - \beta_0}{\hat{\sigma}_{\hat{\beta}_0}} \sim t_{n-2} \text{ mit } \hat{\sigma}_{\hat{\beta}_0} := \sqrt{\hat{\sigma}^2 \left[\frac{\sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right]} \quad (1.19)$$

- ④ Konfidenzintervalle zum Niveau $1 - \alpha$ für β_1 und β_0 unter Normalverteilungsannahme (1.5):

$$[\hat{\beta}_1 - \hat{\sigma}_{\hat{\beta}_1} t_{1-\alpha/2}(n-2); \hat{\beta}_1 + \hat{\sigma}_{\hat{\beta}_1} t_{1-\alpha/2}(n-2)] \quad (1.20)$$

$$[\hat{\beta}_0 - \hat{\sigma}_{\hat{\beta}_0} t_{1-\alpha/2}(n-2); \hat{\beta}_0 + \hat{\sigma}_{\hat{\beta}_0} t_{1-\alpha/2}(n-2)] \quad (1.21)$$

$t_{1-\alpha/2}(n-2)$: $1 - \alpha/2$ -Quantil der $t(n-2)$ -Verteilung

Teil I und **Teil II** später als Spezialfall im multiplen Regressionsmodell

Teil III:

$$\text{Def. t-Verteilung: } \left. \begin{array}{l} Z \sim N(0, 1) \\ W \sim \chi_n^2 \\ Z, W \text{ unabh.} \end{array} \right\} \frac{Z}{\sqrt{\frac{W}{n}}} \sim t_n$$

$$\hat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{\sum (x_i - \bar{x})^2}\right), \text{ da } \hat{\beta}_1 = \sum \frac{x_i - \bar{x}}{\sum (x_i - \bar{x})^2} Y_i \sim NV$$

(Summe von unabh. NV ZG)

Aus der Def. der t-Vert. und Teil II $\Rightarrow$ Behauptung

Teil IV:

Standard-Konstruktion von Konfidenzintervallen

Beispiel: Analyse von Daten aus Reihengräbern in Wenigumstadt

Fragestellung: Zusammenhang zwischen Alter (zum Todeszeitpunkt) und Knochenbälkchendicke des 4. Lendenwirbels

Im Zentrum der Interpretation stehen

- die Parameterschätzung von β_1 ,
- die Schätzung der durchschnittlichen Abweichung von der Regressionsgeraden und
- das Bestimmtheitsmaß R^2 .

Probleme:

- Messfehler
- sehr kleine Werte
- Zufälligkeit der x_i

Quadratsummenzerlegung I

Gegeben sei das Modell (1.1). Dann gilt:

1

$$\underbrace{\sum_{i=1}^n (Y_i - \bar{Y})^2}_{\text{SST}} = \underbrace{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}_{\text{SSE}} + \underbrace{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}_{\text{SSM}} \quad (1.22)$$

mit den **angepassten Größen** $\hat{Y}_i := \hat{\beta}_0 + \hat{\beta}_1 x_i$ (1.23)

SST:	Gesamtstreuung von Y	Sum of Squares Total
SSE:	Streuung der Residuen	Sum of Squares Error
SSM:	Streuung, die das Modell erklärt	Sum of Squares Model

Quadratsummenzerlegung II

2

$$R^2 = \frac{SSM}{SST} = 1 - \frac{SSE}{SST} \quad (1.24)$$

heißt **Bestimmtheitsmaß**.

Es gilt

$$R^2 = r_{xY}^2. \quad (1.25)$$

$r_{xY} :=$ Korrelationskoeffizient nach Bravais-Pearson.

Bemerkung

Zu den obigen Quadratsummen wird üblicherweise die Zahl der Freiheitsgrade angegeben. Sie bezeichnet die Anzahl der frei bestimmbaren Summanden der obigen Quadratsummen (bei geg. x_i)

bei SST: $\sum(Y_i - \bar{Y}) = 0$
 $\Rightarrow$ **df=n-1**

bei SSE: NGL liefern 2 Restriktionen
 $\Rightarrow$ **df=n-2** ($\sum \hat{\varepsilon}_i = 0$; $\sum \hat{\varepsilon}_i x_i = 0$)

bei SSM: $\sum(\hat{Y}_i - \bar{Y})^2 = \sum(\hat{\beta}_0 + \hat{\beta}_1 x_i - \bar{Y})^2 = \sum(\hat{\beta}_1(x_i - \bar{x}))^2$
 $\Rightarrow$ **df=1** (durch Wählen von 1 Y-Wert liegt $\hat{\beta}_1$ fest)

Beweis von 1):

$$\begin{aligned}\sum (Y_i - \bar{Y})^2 &= \sum (Y_i - \hat{Y}_i + \hat{Y}_i - \bar{Y})^2 \\ &= \sum (Y_i - \hat{Y}_i)^2 + \sum (\hat{Y}_i - \bar{Y})^2 + 2 \underbrace{\sum (Y_i - \hat{Y}_i)(\hat{Y}_i - \bar{Y})}_C\end{aligned}$$

$$C = \sum \hat{\varepsilon}_i(\hat{\beta}_0 + \hat{\beta}_1 x_i - \bar{Y}) = 0$$

Interpretation von R^2

R^2 ist das zentrale Maß der Anpassungsgüte der Regression

- R^2 beschreibt den Anteil der Varianz von Y , die durch x erklärt wird.
- R ist invariant gegenüber linearen Skalentransformationen
- R ist symmetrisch bzgl. x und Y .
- Vorsicht: R^2 hängt auch von der Streuung von x in der Stichprobe ab.

In Modell (1.1) mit (1.2) - (1.4) betrachten wir eine weitere Beobachtung x_{n+1} mit zugehörigem unbekanntem Y_{n+1} . Der Prognosewert von Y_{n+1} ist gegeben durch

$$\hat{Y}_{n+1} = \hat{\beta}_0 + \hat{\beta}_1 x_{n+1} \quad (1.26)$$

Für den Erwartungswert und die Varianz des Prognosefehlers gilt:

$$E \left[\hat{Y}_{n+1} - Y_{n+1} \right] = 0 \quad (1.27)$$

$$V \left[\hat{Y}_{n+1} - Y_{n+1} \right] = \sigma^2 \left[1 + \frac{1}{n} + \frac{(x_{n+1} - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right] \quad (1.28)$$

Prognoseintervall für Y_{n+1} zum Niveau $1 - \alpha$:

$$[\hat{Y}_{n+1} - \hat{\sigma}_{\hat{Y}_{n+1}} t_{1-\alpha/2}(n-2); \hat{Y}_{n+1} + \hat{\sigma}_{\hat{Y}_{n+1}} t_{1-\alpha/2}(n-2)] \quad (1.29)$$

$$\text{mit } \hat{\sigma}_{\hat{Y}_{n+1}}^2 = \hat{\sigma}^2 \left[1 + 1/n + (x_{n+1} - \bar{x})^2 / \left(\sum_{i=1}^n (x_i - \bar{x})^2 \right) \right] \quad (1.30)$$

- ① Alle Aussagen gelten nur unter der zentralen Modellannahme des linearen Zusammenhangs von $E(Y)$ und x .
- ② Transformationen sind grundsätzlich möglich. Zu beachten sind dann die geänderte Interpretation der Modellparameter und der Modellannahmen. Insbesondere ist

$$E[g(Y)] \neq g[E(Y)]$$

- ③ Das lineare Modell ist in vielen Beispielen eine sinnvolle Näherung

Lineares Modell als sinnvolle Annäherung I

Gegeben sei ein quadratisches Modell:

$$Y_i = x_i^2 + \epsilon \text{ mit } E(\epsilon) = 0, \quad x_1 = 0, x_2 = 1, x_3 = 2 \text{ und } y_1, y_2, y_3$$


Angenommen wird aber ein lineares Modell:

$$Y_i = \beta_0 + \beta_1 x_i + \epsilon$$

→ **KQ-Schätzung**

Lineares Modell als sinnvolle Annäherung II

$$\begin{aligned}E(\hat{\beta}_1) &= \frac{\sum_{i=1}^3 (x_i - \bar{x})E(Y_i - \bar{Y})}{\sum_{i=1}^3 (x_i - \bar{x})^2} \\&= \frac{1}{2} (-1E(Y_1 - \bar{Y}) + 1E(Y_3 - \bar{Y})) \\&= \frac{1}{2} \left(-(0 - \frac{5}{3}) + (4 - \frac{5}{3}) \right) = 2 \\E(\hat{\beta}_0) &= E(\bar{Y} - \hat{\beta}_1 \bar{x}) = \frac{5}{3} - 2 \cdot 1 = -\frac{1}{3}\end{aligned}$$



Lineares Modell als sinnvolle Annäherung III

Je nachdem, wie die x -Werte (unter Annahme der Richtigkeit des quadratischen Modells) liegen, bekommt man eine andere Regressionsgerade (bei Annahme eines linearen Zusammenhangs).

- Näherung im Bereich $[0, 2]$ ist akzeptabel (abhängig von der Größe des Störterms).
- Prognose außerhalb von $[0, 2]$ ergibt falsche Ergebnisse. Auch das Prognose-Intervall ist vollkommen falsch. z.B. $x = -1$ ergibt Erwartungswert der Prognose von $\hat{Y} = -2\frac{1}{3}$, obwohl $E(Y|x = -1) = 1$ richtig ist.

3. Das multiple lineare Regressionsmodell

Modelldefinition

$$Y_i = \underbrace{\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip}}_{\mathbf{x}_i' \boldsymbol{\beta}} + \varepsilon_i; \quad i = 1, \dots, n$$
$$\mathbf{x}_i' = (1, x_{i1}, \dots, x_{ip})$$

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon} \quad (2.1)$$

mit

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix} \quad \mathbf{X} = \begin{pmatrix} 1 & x_{11} & \cdots & x_{1p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \cdots & x_{np} \end{pmatrix} \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \vdots \\ \beta_p \end{pmatrix} \quad \boldsymbol{\varepsilon} = \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

$$\begin{aligned} E(\varepsilon_i) &= 0 \\ E(\boldsymbol{\varepsilon}) &= \mathbf{0} \end{aligned} \tag{2.2}$$

$$V(\varepsilon_i) = \sigma^2 \tag{2.3}$$

$$\{\varepsilon_i \mid i = 1, \dots, n\} \quad \text{unabh.} \tag{2.4}$$

$$\text{Aus (2.3), (2.4) folgt: } V(\boldsymbol{\varepsilon}) = \sigma^2 \mathbf{I}$$

$$\varepsilon_i \sim N(0, \sigma^2) \text{ und (2.4)}$$

$$\boldsymbol{\varepsilon} \sim N(\mathbf{0}, \sigma^2 \mathbf{I}) \tag{2.5}$$

Y: Zufallsvektor der Zielgröße

X: feste Design-Matrix (Matrix der Einflussgrößen)

β : Vektor der Regressionsparameter

ε : Störgrößen

(vgl. Fahrmeir et al.; S. 75,76)

- Lineare Abhängigkeit von den Einflussgrößen
- Steigt x_k um eine Einheit, so steigt Y im Erwartungswert um β_k Einheiten, wenn alle anderen x -**Variablen festgehalten werden**
 - Linearer Zusammenhang bei Festhalten der übrigen Variablen
 - β_k charakterisiert den Einfluss von x_k unter Berücksichtigung der übrigen Variablen („Confounder-Korrektur“)

Wir betrachten Modell (2.1). Dann heißt

$$\hat{\beta} = \arg \min_{\beta} \underbrace{(\mathbf{Y} - \mathbf{X}\beta)'(\mathbf{Y} - \mathbf{X}\beta)}_{\sum_{i=1}^n (Y_i - \mathbf{x}'_i \beta)^2} \quad (2.6)$$

KQ-Schätzer.

$$\hat{\varepsilon}_i := Y_i - \mathbf{x}'_i \hat{\beta} \quad (2.7)$$

Es gilt für $(\mathbf{X}'\mathbf{X})$ invertierbar: $\hat{\beta}$ **existiert**, ist **eindeutig** und

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{Y}. \quad (2.8)$$

Der KQ-Schätzer erfüllt die Normalgleichungen:

$$\mathbf{X}'\hat{\varepsilon} = \mathbf{0} \quad (2.9)$$

(vgl. Fahrmeir et al.; S.104-107)

- ➊ Ableiten und Nullsetzen, vergl. Fahrmeir et al.; S.117-119)
- ➋ Mit Hilfe linearer Algebra und Projektionen: vergl. Skript Thomas Nagler Kapitel 5.8.

Produktsummenmatrix

Die Matrix $\mathbf{X}'\mathbf{X}$ heißt Produktsummenmatrix.

Es gilt:

$$\mathbf{X}'\mathbf{X} = \begin{pmatrix} n & \sum x_{i1} & \cdots & \sum x_{ip} \\ \sum x_{i1} & \sum x_{i1}^2 & \cdots & \sum x_{i1}x_{ip} \\ \vdots & \vdots & \ddots & \vdots \\ \sum x_{ip} & \cdots & \cdots & \sum x_{ip}^2 \end{pmatrix} \quad (2.10)$$

Eigenschaften des KQ-Schätzers

Sei das Modell (2.1) mit (2.2) gegeben.

- ❶ Der KQ-Schätzer ist **erwartungstreu**:

$$E(\hat{\beta}) = \beta \quad (2.11)$$

- ❷ Für die Varianz-Kovarianz-Matrix von $\hat{\beta}$ gilt unter (2.3) und (2.4):

$$V(\hat{\beta}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1} \quad (2.12)$$

- ❸ Unter (2.5) gilt:

$$\hat{\beta} \sim N(\beta, \sigma^2(\mathbf{X}'\mathbf{X})^{-1}) \quad (2.13)$$

Hat-Matrix und Residualmatrix

Sei das Modell (2.1) mit einer Designmatrix $\mathbf{X}$ mit $rg(\mathbf{X}) = p + 1$ gegeben. Es gilt:

$$\hat{\mathbf{Y}} = \underbrace{\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}}_{\hat{\boldsymbol{\beta}}} \quad (2.14)$$

$$\mathbf{P} := \underbrace{\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'}_{n \times n} \quad (2.15)$$


$$\hat{\boldsymbol{\varepsilon}} = \mathbf{Y} - \hat{\mathbf{Y}} = \underbrace{(\mathbf{I} - \mathbf{P})\mathbf{Y}}_{\mathbf{Q}} \quad (2.16)$$

$$\mathbf{Q} := \mathbf{I} - \mathbf{P} \quad (2.17)$$

(vgl. Fahrmeir et al.; S. 120)

Geometrische Interpretation

Wir betrachten den Vektorraum $\mathbb{R}^n$. Die Größen $\mathbf{Y}$ und $\mathbf{x}$ sind Vektoren. Die KQ-Schätzung ist eine orthogonale Projektion auf den von den $\mathbf{x}$ -Vektoren aufgespannten Unterraum:



(vgl. Nagler Kap. 5)

Eigenschaften von P und Q

P heißt **Hat-Matrix** ($\hat{Y} = PY$), Q **Residualmatrix**. P und Q sind Projektionsmatrizen und zueinander orthogonal:

$$P' = P, P^2 = P \quad (2.18)$$

$$Q' = Q, Q^2 = Q \quad (2.19)$$

$$PQ = QP = 0 \quad (2.20)$$

(vgl. Fahrmeir et al.; S. 108)

- Beweis durch Nachrechnen (benutze $(\mathbf{AB})' = \mathbf{B}'\mathbf{A}'$)
- Bedeutung von $\mathbf{P}^2 = \mathbf{P}$:
zweimaliges Anwenden der Regression führt zum gleichen Ergebnis
- Bedeutung von $\mathbf{PQ} = \mathbf{0}$:
Regression von Residuen liefert $\hat{y} = 0$.

Für die Varianz-Kovarianz-Matrizen von $\hat{\mathbf{Y}}$ bzw. $\hat{\varepsilon}$ gilt:

$$V(\hat{\mathbf{Y}}) = \sigma^2 \mathbf{P} \quad (2.21)$$

$$V(\hat{\varepsilon}) = \sigma^2 \mathbf{Q} \quad (2.22)$$

$$\text{da } \hat{\varepsilon} = \mathbf{Q}\varepsilon \quad (2.23)$$

Erwartungstreue Schätzung von σ^2

Gegeben sei das Modell (2.1) mit (2.2) bis (2.4).

Dann ist:

$$\hat{\sigma}^2 = \frac{1}{n - (p + 1)} \hat{\varepsilon}' \hat{\varepsilon} = \frac{1}{n - (p + 1)} \sum \hat{\varepsilon}_i^2 \quad (2.24)$$

ein erwartungstreuer Schätzer für σ^2 .

$$\begin{aligned}E(\hat{\varepsilon}'\hat{\varepsilon}) &= E(\varepsilon'\mathbf{Q}'\mathbf{Q}\varepsilon) = E\left(\sum_{i=1}^n \sum_{j=1}^n q_{ij}\varepsilon_i\varepsilon_j\right) \\&= \sum_{i=1}^n E(\varepsilon_i^2)q_{ii} + 0 = \sigma^2 * sp(\mathbf{Q}) \\&= \sigma^2 * (n - sp(\mathbf{P})) = \sigma^2 * (n - (p + 1)) \\\\sp(\mathbf{P}) &= sp(\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}') = sp((\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}) = sp(\mathbf{I}_{p+1})\end{aligned}$$

Bemerkung:

Für Projektionsmatrizen gilt allgemein: $sp(\mathbf{P}) = rg(\mathbf{P})$

Beispiel: Lesetest

Welche Faktoren stehen in Zusammenhang mit den Fehlern bei einem Lesetest ?

Daten von Christa Kieferle (Pädagogik, LMU)

180 Kinder aus 8 Klassen (3. und 4. Klassen Grundschule)

Zielgröße:

Anzahl der Fehler bei einem Lesetest

potentielle Einflussgrößen:

Geschlecht, Jahrgang, Leseförderzeit, sonstiges Lesen, Gameboy ,
Jahrgang.

$$E(Y) = \beta_0 + \beta_1 * GE + \beta_2 * JG + \beta_3 * LZ + \beta_4 * WOL + \beta_5 * WOG + \beta_6 * WOTV$$

Y:	Anzahl der Fehler
GE:	Indikator für männlich (= 1 für männlich, 0 sonst)
JG:	Indikator für Klassenstufe (=1 für 3. Klasse, 0 für 4.Klasse)
LZ:	Lesezeit in der Schule
WOL:	Wie oft wird sonst gelesen
WOG:	Wie oft wird Gameboy gespielt
WOTV:	Wie oft TV

Interpretation der Parameter, z.B β_1 : Geschlechtsunterschied

Annahme:

Bei WOL ist der durchschnittliche Unterschied in der Fehlerzahl zwischen den Stufen 1-5 gleich groß. (Änderung um 1 entspricht β_4)

4. Quadratsummenzerlegung und statistische Inferenz im multiplen linearen Regressionsmodell

Quadratsummenzerlegung

Gegeben sei das Modell (2.1) mit Design-Matrix $\mathbf{X}$ und

$$\text{rg}(\mathbf{X}) = p + 1 =: p'. \quad (3.1)$$


Dann gilt:

$$\underbrace{(\mathbf{Y} - \bar{\mathbf{Y}})'(\mathbf{Y} - \bar{\mathbf{Y}})}_{SST} = \underbrace{(\mathbf{Y} - \hat{\mathbf{Y}})'(\mathbf{Y} - \hat{\mathbf{Y}})}_{SSE} + \underbrace{(\hat{\mathbf{Y}} - \bar{\mathbf{Y}})'(\hat{\mathbf{Y}} - \bar{\mathbf{Y}})}_{SSM} \quad (3.2)$$

Interpretation:

- SST : Gesamt-Streuung, (korrigierte) Gesamt-Quadratsumme, “Total”
- SSE : Fehler-Quadratsumme, “Error”
- SSM : Modell-Quadratsumme, “Model”

Quadratsummenzerlegung



(vgl. Fahrmeir et al.; S. 122) und Nagler, Kap. 5

Zerlegung ohne Absolutglied

Die Zerlegung (3.2) setzt ein Absolutglied in der Regression voraus.

Weitere Zerlegung, die nicht notwendig ein Absolutglied in der Regression voraussetzt:

$$\underbrace{\mathbf{Y}'\mathbf{Y}}_{SST^*} = \underbrace{(\mathbf{Y} - \hat{\mathbf{Y}})'(\mathbf{Y} - \hat{\mathbf{Y}})}_{SSE} + \underbrace{\hat{\mathbf{Y}}'\hat{\mathbf{Y}}}_{SSM^*} \quad (3.3)$$

- SST^* : Nicht korrigierte Gesamt-Quadratsumme
Erfasst auch Abweichungen von $Y = 0$ und nicht nur von $\bar{Y}$.
- SSE : Fehler-Quadratsumme, wie bei (3.2)
- SSM^* : Nicht korrigierte Modell-Quadratsumme

Nachweis der Quadratsummenzerlegung (3.3)

$$\begin{aligned} \mathbf{Y}'\mathbf{Y} &= \mathbf{Y}'\mathbf{I}\mathbf{Y} \\ &\stackrel{2.17}{=} \mathbf{Y}'(\mathbf{Q} + \mathbf{P})\mathbf{Y} \\ &= \mathbf{Y}'\mathbf{Q}\mathbf{Y} + \mathbf{Y}'\mathbf{P}\mathbf{Y} \\ &\stackrel{2.18}{=} \mathbf{Y}'\mathbf{Q}'\mathbf{Q}\mathbf{Y} + \mathbf{Y}'\mathbf{P}'\mathbf{P}\mathbf{Y} \\ &= \hat{\boldsymbol{\epsilon}}'\hat{\boldsymbol{\epsilon}} + \hat{\mathbf{Y}}'\hat{\mathbf{Y}} \quad \text{qed} \end{aligned}$$

P und **Q** sind Projektionsmatrizen.

Nachweis der Quadratsummenzerlegung (3.2) I

Wir definieren:

$$\mathbf{P}_e = \mathbf{e}(\mathbf{e}'\mathbf{e})^{-1}\mathbf{e}', \quad \mathbf{Q}_e = \mathbf{I} - \mathbf{P}_e \text{ mit } \mathbf{e} = (1, 1, \dots, 1)'. \quad (3.4)$$

$\mathbf{P}_e$ entspricht der Regression auf eine Konstante ($E(\mathbf{Y}) = \beta_0$).

$$\mathbf{P}_e \mathbf{Y} = \bar{\mathbf{Y}} \quad (\text{„Mittelwert bilden“})$$

$$\mathbf{Q}_e \mathbf{Y} = \mathbf{Y} - \bar{\mathbf{Y}} \quad (\text{„Mittelwertsbereinigung“})$$

$\mathbf{P}_e$, $\mathbf{Q}_e$ sind dabei auch idempotent mit denselben Eigenschaften wie $\mathbf{P}$ und $\mathbf{Q}$.

$$\begin{aligned} (\mathbf{Y} - \bar{\mathbf{Y}})'(\mathbf{Y} - \bar{\mathbf{Y}}) &= \mathbf{Y}'\mathbf{Q}_e'\mathbf{Q}_e\mathbf{Y} = \mathbf{Y}'\mathbf{Q}_e\mathbf{Y} \\ &= \mathbf{Y}'\mathbf{Q}_e(\mathbf{Q} + \mathbf{P})\mathbf{Y} = \mathbf{Y}'\mathbf{Q}_e\mathbf{Q}\mathbf{Y} + \mathbf{Y}'\mathbf{Q}_e\mathbf{P}\mathbf{Y} \\ &\stackrel{(*)}{=} \dots \end{aligned}$$

Nachweis der Quadratsummenzerlegung (3.2) II

$$(*) \quad \mathbf{Q}_e \mathbf{QY} = \mathbf{Q}_e \hat{\mathbf{e}} = \hat{\mathbf{e}} = \mathbf{QY}$$

↑

„Residuen haben Mittelwert 0“

$$\begin{aligned} (*) \quad \mathbf{Q}_e \mathbf{PQ}_e \mathbf{PY} &= \mathbf{Q}_e \mathbf{PQ}_e \hat{\mathbf{Y}} = \mathbf{Q}_e \mathbf{P}(\hat{\mathbf{Y}} - \bar{\mathbf{Y}}) \\ &= \mathbf{Q}_e \mathbf{P}\hat{\mathbf{Y}} - \mathbf{Q}_e \mathbf{P}\bar{\mathbf{Y}} = \mathbf{Q}_e \hat{\mathbf{Y}} - \mathbf{Q}_e \bar{\mathbf{Y}} = \mathbf{Q}_e \hat{\mathbf{Y}} - \mathbf{0} \end{aligned}$$

↑

„Regression auf $\hat{\mathbf{Y}}$ und $\bar{\mathbf{Y}}$ liefert Identität“

$$\begin{aligned} (\mathbf{Y} - \bar{\mathbf{Y}})'(\mathbf{Y} - \bar{\mathbf{Y}}) &= \mathbf{Y}'\mathbf{Q}'_e\mathbf{Q}_e\mathbf{Y} = \mathbf{Y}'\mathbf{Q}_e\mathbf{Y} \\ &= \mathbf{Y}'\mathbf{Q}_e(\mathbf{Q} + \mathbf{P})\mathbf{Y} = \mathbf{Y}'\mathbf{Q}_e\mathbf{QY} + \mathbf{Y}'\mathbf{Q}_e\mathbf{PY} \\ &\stackrel{(*)}{=} \mathbf{Y}'\mathbf{QY} + \mathbf{Y}'\mathbf{Q}_e\mathbf{PQ}_e\mathbf{PY} \\ &= \hat{\mathbf{e}}'\hat{\mathbf{e}} + \mathbf{Y}'\mathbf{P}'\mathbf{Q}_e\mathbf{PY} \\ &= \hat{\mathbf{e}}'\hat{\mathbf{e}} + (\hat{\mathbf{Y}} - \bar{\mathbf{Y}})'(\hat{\mathbf{Y}} - \bar{\mathbf{Y}}) \end{aligned}$$

Erwartungswerte der Quadratsummen

Wir betrachten das multiple Regressionsmodell (2.1) mit (2.2) bis (2.4) und

$$\mathbf{P}_e = \mathbf{e}(\mathbf{e}'\mathbf{e})^{-1}\mathbf{e}', \quad \mathbf{Q}_e = \mathbf{I} - \mathbf{P}_e \text{ mit } \mathbf{e} = (1, 1, \dots, 1)'$$

Dann gilt für die Erwartungswerte der Quadratsummen:

$$E(SST^*) = E(\mathbf{Y}'\mathbf{Y}) = \sigma^2 n + \beta' \mathbf{X}' \mathbf{X} \beta \quad (3.5)$$

$$E(SST) = E(\mathbf{Y} - \bar{\mathbf{Y}})'(\mathbf{Y} - \bar{\mathbf{Y}}) = \sigma^2(n-1) + \beta'(\mathbf{Q}_e \mathbf{X})'(\mathbf{Q}_e \mathbf{X})\beta \quad (3.6)$$

$$E(SSE) = E(\hat{\varepsilon}'\hat{\varepsilon}) = \sigma^2(n-p') \quad (3.7)$$

$$E(SSM^*) = E(\hat{\mathbf{Y}}'\hat{\mathbf{Y}}) = \sigma^2 p' + \beta' \mathbf{X}' \mathbf{X} \beta \quad (3.8)$$

$$E(SSM) = E(\hat{\mathbf{Y}} - \bar{\mathbf{Y}})'(\hat{\mathbf{Y}} - \bar{\mathbf{Y}}) = \sigma^2 p + \beta'(\mathbf{Q}_e \mathbf{X})'(\mathbf{Q}_e \mathbf{X})\beta \quad (3.9)$$

- ❶ Die stochastischen Eigenschaften der Quadratsummen werden zur Konstruktion von Tests bezüglich β genutzt
- ❷ $\beta = \mathbf{0} \implies E(\mathbf{Y}'\mathbf{Y}) = \sigma^2 n$
- ❸ $\beta_1, \dots, \beta_p = 0 \implies E(SSM) = \sigma^2 p$

Zum Nachweis von 3) benutzt man, dass $\mathbf{Q}_e$ der „Mittelwertsbereinigungs-Operator“ ist:

$$\mathbf{Q}_e \mathbf{x} = (\mathbf{I} - \mathbf{P}_e) \mathbf{x} = \mathbf{x} - \bar{\mathbf{x}}$$

Die erste Spalte von $\mathbf{Q}_e \mathbf{X}$ ist also der Nullvektor.

Allgemein berechnet man den Erwartungswert von quadratischen Formen wie folgt:

$$\begin{aligned} E(\mathbf{Y}'\mathbf{A}\mathbf{Y}) &= E\left(\sum_{i=1}^n \sum_{j=1}^n a_{ij} Y_i Y_j\right) = \sum_{i=1}^n \sum_{j=1}^n a_{ij} E(Y_i Y_j) \\ &= \sum_{i=1}^n \sum_{j=1}^n a_{ij} E(Y_i) E(Y_j) + \sum_{i=1}^n \sum_{j=1}^n a_{ij} \text{Cov}(Y_i, Y_j) \\ &= E(\mathbf{Y})' \mathbf{A} E(\mathbf{Y}) + \text{sp}(\mathbf{A}\mathbf{V}(\mathbf{Y})) \end{aligned}$$

$\mathbf{V}(\mathbf{Y})$:= Varianz-Kovarianzmatrix von $\mathbf{Y}$

Unter Benutzung von $\text{sp}(\mathbf{A}\mathbf{V}(\mathbf{Y})) = \text{sp}(\mathbf{A}) * \sigma^2 = \text{rang}(\mathbf{A}) * \sigma^2$ für Projektionsmatrizen erhält man obige Identitäten.

Mittlere Quadratsummen

Wir definieren entsprechend der Zahl der Freiheitsgrade die **mittleren Quadratsummen**:

$$MST^* := \frac{SST^*}{n} \quad (3.10)$$

$$MST := \frac{SST}{n-1} \quad (3.11)$$

$$MSE := \frac{SSE}{n-p'} \quad (3.12)$$

$$MSM^* := \frac{SSM^*}{p'} \quad (3.13)$$

$$MSM := \frac{SSM}{p} \quad (3.14)$$

Normalverteilung

Ein n -dimensionaler Zufallsvektor $\mathbf{Z}$ heißt multivariat normalverteilt, falls für seine Dichtefunktion gilt:

$$f_{\mathbf{Z}}(\mathbf{z}) = \frac{1}{\sqrt{\det \mathbf{\Sigma}} \sqrt{(2\pi)^n}} \exp \left[-\frac{1}{2}(\mathbf{z} - \boldsymbol{\mu})' \mathbf{\Sigma}^{-1} (\mathbf{z} - \boldsymbol{\mu}) \right] \quad (3.15)$$

mit positiv definiter, symmetrischer Matrix $\mathbf{\Sigma}$.

Bezeichnung: $\mathbf{Z} \sim N_n(\boldsymbol{\mu}, \mathbf{\Sigma})$

Eigenschaften der Normalverteilung

Ist $\mathbf{Z} \sim N_n(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, so gilt:

1 Momente:

$$\begin{aligned} E(\mathbf{Z}) &= \boldsymbol{\mu} \\ V(\mathbf{Z}) &= \boldsymbol{\Sigma} \end{aligned}$$

2 Lineare Transformationen:

Ist $\mathbf{A} : \mathbb{R}^n \rightarrow \mathbb{R}^m$ eine lineare Transformation mit $\text{rg}(\mathbf{A}) = m$

$$\implies \mathbf{AZ} \sim N_m(\mathbf{A}\boldsymbol{\mu}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}') \quad (3.16)$$

3 Orthogonale Transformation in unabhängige Komponenten (Spektralzerlegung)

Es existiert eine Matrix $\mathbf{T} \in \mathbb{R}^{n \times n}$ mit $\mathbf{T}'\mathbf{T} = \mathbf{I}$ und $\mathbf{T}\boldsymbol{\Sigma}\mathbf{T}' = \text{diag}(\lambda_1, \dots, \lambda_n)$, so dass

$$\mathbf{TZ} \sim N_n(\mathbf{T}\boldsymbol{\mu}, \text{diag}(\lambda_1, \dots, \lambda_n)) \text{ gilt.} \quad (3.17)$$

Chi-Quadrat-Verteilung I

Ist $\mathbf{Z} \sim N_n(\boldsymbol{\mu}, \mathbf{I})$, so heißt $W = \mathbf{Z}'\mathbf{Z}$ (nicht-zentral) Chi-Quadrat-verteilt.

Bezeichnung: $W \sim \chi^2(n, \delta)$

n : Zahl der Freiheitsgrade

$\delta := \boldsymbol{\mu}'\boldsymbol{\mu}$: Nichtzentralitätsparameter

Im Fall $\delta = 0$ erhält man die zentrale $\chi^2(n)$ -Verteilung.

Chi-Quadrat-Verteilung II

Eigenschaften: Ist $W \sim \chi^2(n, \delta)$, so gilt:

① Momente:

$$\begin{aligned} E(W) &= n + \delta \\ V(W) &= 2n + 4\delta \end{aligned}$$

② Allgemeiner Bezug zur Normalverteilung

$$\mathbf{Z} \sim N_n(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \quad \implies \quad \mathbf{Z}'\boldsymbol{\Sigma}^{-1}\mathbf{Z} \sim \chi^2(n, \boldsymbol{\mu}'\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}) \quad (3.18)$$

t-Verteilung

Seien Z und W voneinander unabhängige Zufallsgrößen mit

$$\begin{aligned}Z &\sim N(\delta, 1), \\ W &\sim \chi^2(n).\end{aligned}$$

Dann heißt $T = \frac{Z}{\sqrt{\frac{W}{n}}}$ (nicht-zentral) t-verteilt.

Bezeichnung: $T \sim t(n, \delta)$

n : Zahl der Freiheitsgrade

δ : Nichtzentralitätsparameter

Erwartungswert: Ist $T \sim t(n, \delta)$, so gilt:

$$E(T) = \delta \sqrt{\frac{n}{2}} \frac{\Gamma(\frac{n-1}{2})}{\Gamma(\frac{n}{2})} \quad \text{für } n > 1 \quad (3.19)$$

F-Verteilung

Seien W_1 und W_2 voneinander unabhängige Zufallsgrößen mit:

$$W_1 \sim \chi^2(n_1, \delta),$$

$$W_2 \sim \chi^2(n_2).$$

Dann heißt $X = \frac{W_1/n_1}{W_2/n_2}$ (nicht-zentral) F-verteilt.

Bezeichnung: $X \sim F(n_1, n_2, \delta)$

n_1 : Zählerfreiheitsgrade

n_2 : Nennerfreiheitsgrade

δ : Nichtzentralitätsparameter

Erwartungswert: Ist $X \sim F(n_1, n_2, \delta)$, so gilt:

$$E(X) = \frac{n_2}{n_2 - 2} (1 + \delta/n_1) \text{ für } n_2 > 2 \quad (3.20)$$

Unabhängigkeit von Quadratsummen (Satz von Cochran)

Sei $\mathbf{Z} \sim N(\boldsymbol{\mu}, \mathbf{I})$, $\dim \mathbf{Z} = n$,
 $\mathbf{A} \in R^{n \times n}$, $\mathbf{A}' = \mathbf{A}$, $rg(\mathbf{A}) = r$, $\mathbf{A}^2 = \mathbf{A}$,
 $\mathbf{B} \in R^{n \times n}$, $\mathbf{B}^2 = \mathbf{B}$, $\mathbf{B} = \mathbf{B}'$,
 $\mathbf{C} \in R^{m \times n}$.

Dann gilt:

$$\mathbf{Z}'\mathbf{A}\mathbf{Z} \sim \chi^2(r, \boldsymbol{\mu}'\mathbf{A}\boldsymbol{\mu}) \quad (3.21)$$

$$\mathbf{C}\mathbf{A} = \mathbf{0} \implies \mathbf{C}\mathbf{Z} \text{ und } \mathbf{Z}'\mathbf{A}\mathbf{Z} \text{ sind unabh.} \quad (3.22)$$

$$\mathbf{A}\mathbf{B} = \mathbf{0} \implies \mathbf{Z}'\mathbf{A}\mathbf{Z} \text{ und } \mathbf{Z}'\mathbf{B}\mathbf{Z} \text{ sind unabh.} \quad (3.23)$$

Beweis von (3.21)

Spektralzerlegung von $\mathbf{A}$

$$\mathbf{A} = \mathbf{T}\mathbf{\Sigma}\mathbf{T}'$$

$$\mathbf{\Sigma} = \underbrace{\begin{pmatrix} 1 & & & & \\ & \ddots & & & \\ & & 1 & & \\ & & & 0 & \\ & & & & 0 \end{pmatrix}}_r \quad \text{da } \mathbf{A}^2 = \mathbf{A}$$

$$\Rightarrow \mathbf{Z}'\mathbf{A}\mathbf{Z} = \mathbf{Z}'\mathbf{T}\mathbf{\Sigma}\mathbf{T}'\mathbf{Z}$$

Für $\tilde{\mathbf{Z}} := \mathbf{T}'\mathbf{Z}$ gilt: $\text{Var}(\tilde{\mathbf{Z}}) = \mathbf{T}'\mathbf{I}\mathbf{T} = \mathbf{I}$

$$\Rightarrow \mathbf{Z}'\mathbf{A}\mathbf{Z} = \tilde{\mathbf{Z}}'\mathbf{\Sigma}\tilde{\mathbf{Z}} = \sum_{i=1}^r \tilde{z}_i^2 \sim \chi^2(r, \boldsymbol{\mu}'\mathbf{A}\boldsymbol{\mu})$$

Beweis von (3.22) und (3.23)

$$\text{Cov}(\mathbf{CZ}, \mathbf{Z}'\mathbf{A}) = \mathbf{C}\text{Cov}(\mathbf{Z}, \mathbf{Z}')\mathbf{A} = \mathbf{CA} = \mathbf{0}$$

Damit sind $\mathbf{CZ}$ und $\mathbf{Z}'\mathbf{A}$ unabhängig. (NV-Annahme!)

$\Rightarrow \mathbf{CZ}$ und $(\mathbf{Z}'\mathbf{A})(\mathbf{Z}'\mathbf{A})' = \mathbf{Z}'\mathbf{AZ}$ unabh.

qed

$$\text{Cov}(\mathbf{AZ}, \mathbf{Z}'\mathbf{B}) = \mathbf{A}\text{Cov}(\mathbf{Z}, \mathbf{Z}')\mathbf{B} = \mathbf{AB} = \mathbf{0}$$

Damit sind $\mathbf{AZ}$ und $\mathbf{Z}'\mathbf{B}$ unabhängig. (NV-Annahme!)

$\Rightarrow (\mathbf{AZ})'(\mathbf{AZ}) = \mathbf{Z}'\mathbf{AZ}$ und $(\mathbf{Z}'\mathbf{B})(\mathbf{Z}'\mathbf{B})' = \mathbf{Z}'\mathbf{BZ}$ unabh.

qed

Verteilung des KQ-Schätzers unter Normalverteilung

Sei ein multiples Regressionsmodell (2.1) mit (2.5) und $rg(\mathbf{X}) = p'$ gegeben. Für den KQ-Schätzer $\hat{\beta}$ gilt:

$$\hat{\beta} \sim N(\beta, \sigma^2(\mathbf{X}'\mathbf{X})^{-1}) \quad (3.24)$$

$$\hat{\Sigma}_{\hat{\beta}} := \hat{\sigma}^2(\mathbf{X}'\mathbf{X})^{-1} \quad (3.25)$$

$$(n - p') \frac{\hat{\sigma}^2}{\sigma^2} \sim \chi^2(n - p') \quad (3.26)$$

$$\hat{\sigma} \text{ und } \hat{\beta} \text{ sind unabhängig} \quad (3.27)$$

$$\hat{\sigma}_{\hat{\beta}_k} := \sqrt{c_{kk}} \hat{\sigma}, \quad (3.28)$$

(c_{kk} entspr. Diagonalelement von $(\mathbf{X}'\mathbf{X})^{-1}$)

$$\frac{\hat{\beta}_k - \beta_k}{\hat{\sigma}_{\hat{\beta}_k}} \sim t(n - p', 0) \quad (3.29)$$

(vgl. Fahrmeir et al.; S. 119)

(3.24) (Normalverteilung von β) folgt aus Eigenschaften der NV (3.16).

(3.26) folgt aus (3.21), da $\hat{\sigma}^2 = \frac{1}{n-p'} \hat{\epsilon}' \hat{\epsilon} = \frac{1}{n-p'} \mathbf{Y}' \mathbf{Q} \mathbf{Y}$.
 $rg(\mathbf{Q}) = sp(\mathbf{Q})$

(3.27) folgt aus (3.22):

$$\mathbf{C} \in R^{p \times n}, \mathbf{C}\mathbf{A} = \mathbf{0} \implies \mathbf{C}\mathbf{Z} \text{ und } \mathbf{Z}'\mathbf{A}\mathbf{Z} \text{ sind unabh.}$$

mit

$$\begin{aligned}\mathbf{C} &:= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}', \quad \mathbf{A} := \mathbf{Q}, \quad \mathbf{Z} := \mathbf{Y}, \\ \mathbf{C}\mathbf{A} &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Q} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\mathbf{I} - \mathbf{P}) = \\ &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' - (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' = \mathbf{0}\end{aligned}$$

Overall-Test

Sei ein Modell (2.1) mit (2.5) und $rg(\mathbf{X}) = p'$ gegeben. Dann gilt für die mittlere Quadratsummen:

$$F_O = \frac{MSM}{MSE} \sim F(p, n - p', \sigma^{-2} \beta' (\mathbf{Q}_e \mathbf{X})' (\mathbf{Q}_e \mathbf{X}) \beta) \quad (3.30)$$

(3.30) folgt aus (3.21) und (3.23) mit

$$\begin{aligned} MSM &= SSM/p = \mathbf{Y}'(\mathbf{P} - \mathbf{P}_e)\mathbf{Y}/p \\ MSE &= SSE/(n - p') = \mathbf{Y}'\mathbf{QY}/(n - p') \\ \mathbf{Q}(\mathbf{P} - \mathbf{P}_e) &= \mathbf{QP} - \mathbf{QP}_e = \mathbf{0} \end{aligned}$$

Die Verteilung wird zur Konstruktion des folgenden Tests benutzt:

$$H_0^O : \beta_1 = \beta_2 = \dots = \beta_p = 0$$

Lehne H_0^O ab, falls

$$F_O > F_{1-\alpha}(p, n - p') \quad (3.31)$$

Lineare Hypothesen

Es sollen Hypothesen, die sich mit Hilfe linearer Transformationen von β darstellen lassen, betrachtet werden:

$$\mathbf{A} \in R^{a \times (p+1)}, \mathbf{c} \in R^a,$$

$$\mathbf{A}\beta = \mathbf{c} \text{ mit } \text{rg}(\mathbf{A}) = a$$

Beispiele:

$$p = 2 \quad \beta_1 = \beta_2 \quad \leftrightarrow \quad \mathbf{A} = \begin{pmatrix} 0 & 1 & -1 \end{pmatrix}, \mathbf{c} = 0$$

$$p = 4 \quad \beta_3 = \beta_4 = 0 \quad \leftrightarrow \quad \mathbf{A} = \begin{pmatrix} 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{pmatrix}, \mathbf{c} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$p = 4 \quad \beta_2 = 3 \quad \beta_3 + \beta_4 = 1 \quad \leftrightarrow \quad \mathbf{A} = \begin{pmatrix} 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 1 \end{pmatrix}, \mathbf{c} = \begin{pmatrix} 3 \\ 1 \end{pmatrix}$$

(vgl. Fahrmeir et al.; S.130 ff)

Allgemeine lineare Hypothese, Wald-Test

Sei das Modell (2.1) mit (2.5) und $\mathbf{A} \in R^{a \times p'}$, $rg(\mathbf{A}) = a$, $\mathbf{c} \in R^a$ gegeben.

$$V(\mathbf{A}\hat{\boldsymbol{\beta}} - \mathbf{c}) = \sigma^2 \mathbf{A}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{A}' \quad (3.32)$$

$$SSH := (\mathbf{A}\hat{\boldsymbol{\beta}} - \mathbf{c})' (\mathbf{A}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{A}')^{-1} (\mathbf{A}\hat{\boldsymbol{\beta}} - \mathbf{c}) \quad (3.33)$$

$$\sigma^{-2} SSH \sim \chi^2(a, \sigma^{-2} (\mathbf{A}\boldsymbol{\beta} - \mathbf{c})' (\mathbf{A}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{A}')^{-1} (\mathbf{A}\boldsymbol{\beta} - \mathbf{c})) \quad (3.34)$$

$$MSH := \frac{SSH}{a} \quad (3.35)$$

$$\frac{MSH}{MSE} \sim F(a, n - p', \sigma^{-2} (\mathbf{A}\boldsymbol{\beta} - \mathbf{c})' (\mathbf{A}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{A}')^{-1} (\mathbf{A}\boldsymbol{\beta} - \mathbf{c})) \quad (3.36)$$

SSH: Quadratsumme, die die Abweichung von der Hypothese $\mathbf{A}\boldsymbol{\beta} = \mathbf{c}$ beschreibt.

Test nach Wald: $H_0 : \mathbf{A}\boldsymbol{\beta} = \mathbf{c}$. Lehne H_0 ab, falls:

$$TF = MSH/MSE > F_{1-\alpha}(a, n - p') \quad (3.37)$$

Overall-Test und zweiseitiger t-Test

Die Overall-Tests (3.31) ist ein spezieller Wald-Test. Nachweis erfolgt später.

Der mit Hilfe von (3.29) konstruierte zweiseitige Test auf $\beta_k = \beta_k^0$ ist ebenfalls ein Wald-Test.

Der Nachweis erfolgt direkt unter Benutzung von $\mathbf{A} = (0 \cdots 1 \cdots 0)$

Lineare Hypothese und Modell mit Restriktion

Wir betrachten das lineare Modell mit der linearen Restriktion $\mathbf{A}\beta = \mathbf{c}$.
Alle Schätzungen aus diesem Modell werden mit $\hat{\cdot}$ gekennzeichnet.

Wir lösen das Minimierungsproblem:

$$(\mathbf{Y} - \mathbf{X}\beta)'(\mathbf{Y} - \mathbf{X}\beta) \rightarrow \min \quad \text{unter} \quad \mathbf{A}\beta = \mathbf{c}$$

mit der Lagrange-Methode:

$$S(\beta, \lambda) = (\mathbf{Y} - \mathbf{X}\beta)'(\mathbf{Y} - \mathbf{X}\beta) + 2\lambda'(\mathbf{A}\beta - \mathbf{c}).$$

Dabei ist λ der Vektor der Lagrange-Multiplikationen.

Berechnung der Lösung $\hat{\beta}$

$$\frac{\partial S}{\partial \beta} = \mathbf{0} \Leftrightarrow -2\mathbf{X}'\mathbf{Y} + 2\mathbf{X}'\mathbf{X}\hat{\beta} + 2\mathbf{A}'\lambda = \mathbf{0}$$

$$\frac{\partial S}{\partial \lambda} = \mathbf{0} \Leftrightarrow \mathbf{A}\hat{\beta} = \mathbf{c}$$

$$\mathbf{A}'\lambda = \mathbf{X}'\mathbf{Y} - \mathbf{X}'\mathbf{X}\hat{\beta} \quad | \cdot (\mathbf{X}'\mathbf{X})^{-1}$$

$$(\mathbf{X}'\mathbf{X})^{-1}\mathbf{A}'\lambda = \hat{\beta} - \hat{\beta} \quad | \cdot \mathbf{A} (*)$$

$$\Rightarrow \mathbf{A}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{A}'\lambda = \mathbf{A}\hat{\beta} - \mathbf{c} \quad (\mathbf{A}\hat{\beta} = \mathbf{c})$$

$$\Rightarrow \lambda = (\mathbf{A}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{A}')^{-1}(\mathbf{A}\hat{\beta} - \mathbf{c})$$

$$(*) \Rightarrow \hat{\beta} = \hat{\beta} - (\mathbf{X}'\mathbf{X})^{-1}\mathbf{A}'[\mathbf{A}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{A}']^{-1}(\mathbf{A}\hat{\beta} - \mathbf{c})$$

$$\mathbf{w} := (\mathbf{X}'\mathbf{X})^{-1}\mathbf{A}'[\mathbf{A}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{A}']^{-1}(\mathbf{A}\hat{\beta} - \mathbf{c})$$

Darstellung von SSH

$$\begin{aligned}\hat{\hat{\mathbf{Y}}} &= \mathbf{X}\hat{\hat{\boldsymbol{\beta}}} = \hat{\mathbf{Y}} - \mathbf{X}\mathbf{w} \\ \hat{\hat{\boldsymbol{\varepsilon}}} &= \mathbf{Y} - \hat{\hat{\mathbf{Y}}} = \hat{\boldsymbol{\varepsilon}} + \mathbf{X}\mathbf{w} \\ \Rightarrow \hat{\hat{\boldsymbol{\varepsilon}}}'\hat{\hat{\boldsymbol{\varepsilon}}} &= \hat{\boldsymbol{\varepsilon}}'\hat{\boldsymbol{\varepsilon}} + \mathbf{w}'\mathbf{X}'\mathbf{X}\mathbf{w} \quad (\text{da } \mathbf{X}'\hat{\boldsymbol{\varepsilon}} = 0) \\ &= \hat{\boldsymbol{\varepsilon}}'\hat{\boldsymbol{\varepsilon}} + (\mathbf{A}\hat{\boldsymbol{\beta}} - \mathbf{c})'[\mathbf{A}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{A}']^{-1}(\mathbf{A}\hat{\boldsymbol{\beta}} - \mathbf{c}) \\ \Rightarrow SSH &= \hat{\hat{\boldsymbol{\varepsilon}}}'\hat{\hat{\boldsymbol{\varepsilon}}} - \hat{\boldsymbol{\varepsilon}}'\hat{\boldsymbol{\varepsilon}}\end{aligned}$$

Damit haben wir eine andere Möglichkeit, SSH aus den Residuenquadratsummen zu berechnen.

Lineare Hypothese (alternative Durchführung)

Sei das Modell (2.1) mit (2.5) und $\mathbf{A} \in R^{a \times p'}$, $\text{rg}(\mathbf{A}) = a$, $\mathbf{c} \in R^a$ gegeben.

$$H_0 : \mathbf{A}\beta = \mathbf{c}$$

Berechne SSE des Modells und des Modells unter H_0 :

$$SSE = \hat{\varepsilon}'\hat{\varepsilon}$$

$$SSE(H_0) := \hat{\hat{\varepsilon}}'\hat{\hat{\varepsilon}} \quad (3.38)$$

$$SSH = SSE(H_0) - SSE \quad (3.39)$$

$$MSH = SSH/a$$

$$TF := MSH/MSE = \frac{(SSE(H_0) - SSE)/a}{SSE/(n - p')} \quad (3.40)$$

$$TF \sim F(a, n - p') \text{ unter } H_0 \quad (3.41)$$

Das Vorgehen entspricht dem Wald-Test (3.37).

Overall-Test

$$H_0^O : \beta_1 = \beta_2 = \dots = \beta_p = 0$$

Das Modell unter H_0 ist $Y = \beta_0 + \varepsilon$.

$$\begin{aligned} SSE(H_0) &= (\mathbf{Y} - \hat{\hat{\beta}}_0)'(\mathbf{Y} - \hat{\hat{\beta}}_0) = SST \\ SSH &= SSE(H_0) - SSE = SSM \end{aligned}$$

Damit entspricht hier der Wald-Test dem Test (3.31).

Weglassen von Einflussgrößen

Lineare Hypothese:

$$H_0 : \beta_k = \beta_{k+1} = \dots = \beta_p = 0$$

Das Modell unter H_0 ist M1:

$$Y = \beta_0 + \beta_1 x_1 + \dots + \beta_{k-1} x_{k-1} + \varepsilon$$

$$SSE(H_0) = SSE(M1)$$

$$SSH = SSE(M1) - SSE$$

→ Vergleich der SSE der beiden Modelle.

Beispiel: Lesetest

Welche Faktoren stehen in Zusammenhang mit den Fehlern bei einem Lesetest?

Daten von Christa Kieferle (Pädagogik, LMU)

180 Kinder aus 8 Klassen (3. und 4. Klassen Grundschule)

Zielgröße:

Anzahl der Fehler bei einem Lesetest

potentielle Einflussgrößen:

Geschlecht, Jahrgang, Leseförderzeit, sonstiges lesen (0=fast nie ,..., 4=oft), Gameboy (0= fast nie ,..., 4=oft), Jahrgang.

$$Y = \beta_0 + \beta_1 * GE + \beta_2 * JG + \beta_3 * LZ + \beta_4 * WOL + \beta_5 * WOG + \beta_6 * WOTV$$

Y: Anzahl der Fehler

GE: Indikator für männlich (= 1 für männlich, 0 sonst)

JG: Indikator für Klassenstufe (=0 für 3. Klasse, 1 für 4.Klasse)

LZ: Lesezeit in der Schule

WOL: Wie oft wird sonst gelesen

WOG: Wie oft wird Gameboy gespielt

WOTV: Wie oft TV

Interpretation der Parameter, z.B β_1 : Geschlechtsunterschied

Annahme: Bei WOL ist der durchschnittliche Unterschied in der Fehlerzahl zwischen den Stufen 0-4 gleich groß. (Änderung um 1 entspricht β_4)

- ① Schätzung des Gesamtmodells
- ② Gibt es einen Zusammenhang zwischen den Variablen WOL, WOG, WOTV und Y?
- ③ Ist der Einfluss von WOG und WOTV auf die Fehlerzahl gleich?
- ④ Gibt es einen Zusammenhang von Lesezeit und WOL und der Fehlerzahl?
- ⑤ Wie lässt die Assoziation zur Lesezeit quantifizieren?

Fragen 2-4 lassen sich als lineare Hypothesen in dem Modell formulieren.
Fragen 1 und 5 betreffen die Schätzung des Modells.

Die maximierte Likelihood des Modells ist:

$$(2\pi)^{-n/2} \cdot \hat{\sigma}^{-n} \cdot \exp \left[- \sum_{i=1}^n \frac{\hat{\varepsilon}_i^2}{2\hat{\sigma}^2} \right]$$

Es folgt (siehe Nachweis $ML = KQ$ aus Kapitel 1)

$$\hat{\sigma}^2 = \frac{\sum \hat{\varepsilon}_i^2}{n} \quad (3.42)$$

$$MaxL = c * \hat{\sigma}^{-n} = c * (SSE/n)^{(-n/2)} \quad (3.43)$$

Likelihood Quotienten-Test

Grundidee des Likelihood-Quotienten-Tests:

Vergleiche (Bilde den Quotienten) maximierte Likelihood des Modells unter H_0 mit maximierter Likelihood ohne H_0

Wir betrachten also den ML - Schätzer mit und ohne die Restriktion $\mathbf{A}\beta = \mathbf{c}$:

$\hat{\hat{\epsilon}}$: Residuen unter dem Modell mit H_0

$\hat{\epsilon}$: Residuen unter dem Modell ohne Einschränkung

Die LQ- Teststatistik lautet dann:

$$\tau_{LQ} = \left(\frac{\hat{\hat{\sigma}}}{\hat{\sigma}} \right)^{-n} = \left(\frac{\hat{\hat{\epsilon}}' \hat{\hat{\epsilon}}}{\hat{\epsilon}' \hat{\epsilon}} \right)^{-n/2} \quad (3.44)$$

Wald-Test ist Likelihood-Quotienten-Test

Sei das Modell (2.1) mit (2.5) und $\mathbf{A} \in R^{a \times p'}$, $rg(\mathbf{A}) = a$, $\mathbf{c} \in R^a$ gegeben.

$$H_0 : \mathbf{A}\beta = \mathbf{c} \quad \text{gegen} \quad H_1 : \mathbf{A}\beta \neq \mathbf{c}$$

Dann ist der Wald-Test zu dem Likelihood-Quotienten-Test äquivalent, d. h. :

Die Testgröße des LQ-Tests ist eine streng monotone Funktion der Testgröße des Wald-Tests:

$$\tau_{LQ} = g \left[\frac{MSH}{MSE} \right] \quad (3.45)$$

Dabei ist g streng monoton.

Damit ist τ_{LQ} eine monotone Funktion der Testgröße des Wald-Tests:

$$\frac{MSH}{MSE} = \frac{(\hat{\hat{\epsilon}}'\hat{\hat{\epsilon}} - \hat{\hat{\epsilon}}'\hat{\hat{\epsilon}})/a}{\hat{\hat{\epsilon}}'\hat{\hat{\epsilon}}/(n - p')} =: \tau_W$$
$$\Rightarrow \left[\tau_W \cdot \frac{a}{(n - p')} + 1 \right]^{-n/2} = \tau_{LQ}$$

Sequentielle und Partielle Quadratsummen

Gegeben sei das Modell (2.1).

Wir betrachten nun Teilmodelle, die durch Nullrestriktionen von Komponenten des Vektors β entstehen sowie deren Residuenquadratsummen.

$$R(\beta_{i1}, \dots, \beta_{ik} | \beta_{j1}, \dots, \beta_{jl}) = SSH = SSE(M1) - SSE(M2) \quad (3.46)$$

M2: Modell, das die Parameter $\beta_{i1}, \dots, \beta_{ik}, \beta_{j1}, \dots, \beta_{jl}$ enthält

M1: Modell, das die Parameter $\beta_{j1}, \dots, \beta_{jl}$ enthält

SSH: Hypothesenquadratsumme zur Hypothese
($\beta_{i1} = \dots = \beta_{ik} = 0$) im Modell M2

Partielle Quadratsummen

Die zu der Hypothese $\beta_k = 0$ gehörigen Quadratsummen bzgl. des Gesamtmodells heißen **partielle Quadratsummen**:

$$R(\beta_k | \beta_0, \dots, \beta_{k-1}, \beta_{k+1}, \dots, \beta_p) = SSE(M_{-k}) - SSE \quad (3.47)$$

M_{-k} : Modell mit $\beta_k = 0$

Beachte: Die partiellen Quadratsummen führen im Allgemeinen zu keiner Zerlegung von SST, d.h.:

$$SST \neq \sum_{k=1}^p R(\beta_k | \beta_0, \dots, \beta_{k-1}, \beta_{k+1}, \dots, \beta_p) + SSE \quad (3.48)$$

Sequentielle Quadratsummen

Wir betrachten die Folge von Modellen:

$$M_0 : \quad \mathbf{Y} = \beta_0 + \varepsilon \quad (3.49)$$

$$M_1 : \quad \mathbf{Y} = \beta_0 + \beta_1 \mathbf{x}_1 + \varepsilon \quad (3.50)$$

...

$$M_p : \quad \mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \varepsilon \quad (3.51)$$

$$R(\beta_k | \beta_0, \dots, \beta_{k-1}) = SSE(M_{k-1}) - SSE(M_k) \quad (3.52)$$

heißen **sequentielle Quadratsummen** und es gilt:

$$SST = \sum_{k=1}^p R(\beta_k | \beta_0, \dots, \beta_{k-1}) + SSE \quad (3.53)$$

Wir betrachten folgende Zerlegung des Modells (2.1):

$$\begin{aligned}\mathbf{Y} &= \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon} \\ \mathbf{Y} &= (\mathbf{X}_1\mathbf{X}_2)(\boldsymbol{\beta}'_1\boldsymbol{\beta}'_2)' + \boldsymbol{\varepsilon} = \mathbf{X}_1\boldsymbol{\beta}_1 + \mathbf{X}_2\boldsymbol{\beta}_2 + \boldsymbol{\varepsilon} \\ \hat{\boldsymbol{\beta}} &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y} = (\hat{\boldsymbol{\beta}}'_1, \hat{\boldsymbol{\beta}}'_2)' \\ \mathbf{Q}_2 &:= \mathbf{I} - \mathbf{X}_2(\mathbf{X}_2'\mathbf{X}_2)^{-1}\mathbf{X}_2' \\ \mathbf{Y}^* &:= \mathbf{Q}_2\mathbf{Y} \\ \mathbf{X}_1^* &:= \mathbf{Q}_2\mathbf{X}_1 \\ \Rightarrow \hat{\boldsymbol{\beta}}_1 &= \hat{\boldsymbol{\beta}}_1^* = (\mathbf{X}_1^{*'}\mathbf{X}_1^*)^{-1}\mathbf{X}_1^{*'}\mathbf{Y}^*\end{aligned}\tag{3.54}$$

$\mathbf{Y}^*, \mathbf{X}_1^*$: von $\mathbf{X}_2$ bereinigte Variablen

Beweis von (3.54) I

$$\mathbf{Y} = \mathbf{X}_1\beta_1 + \mathbf{X}_2\beta_2 + \epsilon \quad \mathbf{X} = (\mathbf{X}_1 \ \mathbf{X}_2) \quad \beta = \begin{pmatrix} \beta_1 \\ \beta_2 \end{pmatrix}$$

KQ:

$$\mathbf{Y} = \mathbf{X}_1\hat{\beta}_1 + \mathbf{X}_2\hat{\beta}_2 + \hat{\epsilon}$$

$$\mathbf{Q}_2 = \mathbf{I} - \mathbf{P}_2 = \mathbf{I} - \mathbf{X}_2(\mathbf{X}_2'\mathbf{X}_2)^{-1}\mathbf{X}_2'$$

$$\text{Es gilt: } \mathbf{Q}_2\mathbf{Q} = (\mathbf{I} - \mathbf{P}_2)(\mathbf{I} - \mathbf{P}) = \mathbf{I} - \mathbf{P}_2 - \mathbf{P} + \underbrace{\mathbf{P}_2\mathbf{P}}_{\mathbf{P}_2} = \mathbf{I} - \mathbf{P} = \mathbf{Q}$$

(Residuen von Regression auf $(\mathbf{X}_1 \ \mathbf{X}_2)$ und Residuen bzgl. $\mathbf{X}_2$)

$$\text{Analog: } \mathbf{Q}\mathbf{Q}_2 = \mathbf{Q}$$

Beweis von (3.54) II

$$\mathbf{Q}_2 \mathbf{Y} = \mathbf{Q}_2 \mathbf{X}_1 \hat{\beta}_1 + \underbrace{\mathbf{Q}_2 \mathbf{X}_2}_{\mathbf{0}} \hat{\beta}_2 + \underbrace{\mathbf{Q}_2 \hat{\epsilon}}_{\mathbf{Q}_2 \mathbf{Q} \mathbf{Y}}$$

$$\begin{aligned} \Rightarrow \mathbf{Q}_2 \mathbf{Y} &= \mathbf{Q}_2 \mathbf{X}_1 \hat{\beta}_1 + \hat{\epsilon} \\ \mathbf{Y}^* &= \mathbf{X}_1^* \hat{\beta}_1 + \hat{\epsilon} \quad (\text{Bereinigte Variablen}) \end{aligned}$$

$$\mathbf{X}_1^{*'} \hat{\epsilon} = (\mathbf{Q}_2 \mathbf{X}_1)' \hat{\epsilon} = \mathbf{X}_1' \mathbf{Q}_2 \mathbf{Q} \mathbf{Y} = \mathbf{X}_1' \hat{\epsilon} = 0$$

$\Rightarrow \hat{\beta}_1$ ist KQ-Lösung der Regression von $\mathbf{Y}^*$ auf $\mathbf{X}^*$.

Beispiele zur Bereinigung

Mittelwerts-Bereinigung beim einfachen linearen Regressionsmodell

$$\mathbf{X}_2 = (1 \dots 1)'$$

$$\mathbf{X}_1 = (x_1 \dots x_n)'$$

$$\mathbf{Y}^* = Y - \bar{y}$$

$$\mathbf{X}_1^* = x - \bar{x}$$

$$(\mathbf{X}'^* \mathbf{X}^*)^{-1} \mathbf{X}'^* \mathbf{Y}^* = S_x^{-2} S_{xy}$$

z.B.: Geschlechtseffekt, Trendbereinigung

Der Partial leverage plot


Wir betrachten den Fall einer Variablen x_1 und bezeichnen die Matrix der übrigen Variablen mit X_2 . Die Residuen der Regressionen von Y und x_1 aus X_2 bezeichnen wir mit Y^* bzw. x_1^* (Bereinigte Daten). Ziele:

- Identifizierung des Beitrags einer Variablen in der multiplen Regression
- Aufdecken von Ausreißern oder einflussreichen Beobachtungen
- Überprüfung der Modellannahmen

Bespiel Lesedaten

Partial leverage plot zum Zusammenhang zwischen Lesezeit und Fehlerzahl

Bereinigung bezüglich aller anderen Variablen



Beispiel Lesedaten: Bereinigung Geschlechtseffekt

Zielgröße : Anzahl der Fehler bei Test

Einflussgrößen : Geschlecht, Alter, Leseverhalten, Fernsehverhalten, etc.

Regression auf binäre Variable Geschlecht entspricht
Mittelwertsschätzung

Bereinigung nach Geschlecht: Abziehen des jeweiligen
Gruppenmittelwertes

In Modell (2.1) betrachten wir eine weitere Beobachtung mit bekanntem Vektor der x -Werte $\mathbf{x}_{n+1}$ und zugehörigem, unbekanntem Y_{n+1} . Der Prognosewert von Y_{n+1} ist gegeben durch

$$\hat{Y}_{n+1} = \mathbf{x}'_{n+1} \hat{\beta} \quad (3.55)$$

Für den Erwartungswert und die Varianz des Prognosefehlers gilt:

$$E \left[\hat{Y}_{n+1} - Y_{n+1} \right] = 0 \quad (3.56)$$

$$V \left[\hat{Y}_{n+1} - Y_{n+1} \right] = \sigma^2 (1 + \mathbf{x}'_{n+1} (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_{n+1}) \quad (3.57)$$

Der Nachweis verläuft analog zum einfachen linearen Modell unter Berücksichtigung von:

$$V(\hat{\beta}) = \sigma^2 (\mathbf{X}'\mathbf{X})^{-1}$$

Prognoseintervalle und Konfidenzintervalle

Das Prognoseintervall für eine zukünftige Beobachtung y_{n+1} bei gegebenem $\mathbf{x}_{n+1}$ erhält man mit Hilfe der Normalverteilung von $\hat{\beta}$ und durch Standardisieren:

$$[\hat{Y}_{n+1} - \hat{\sigma}_{\hat{Y}_{n+1}} t_{1-\alpha/2}(n-p'); \hat{Y}_{n+1} + \hat{\sigma}_{\hat{Y}_{n+1}} t_{1-\alpha/2}(n-p')] \quad (3.58)$$

$$\text{mit } \hat{\sigma}_{\hat{Y}_{n+1}}^2 = \hat{\sigma}^2 (1 + \mathbf{x}_{n+1}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_{n+1})$$

Das Konfidenzintervall für den Erwartungswert μ_{n+1} einer zukünftige Beobachtung y_{n+1} bei gegebenem $\mathbf{x}_{n+1}$ ist:

$$[\hat{Y}_{n+1} - \hat{\sigma}_{\hat{\mu}_{n+1}} t_{1-\alpha/2}(n-p'); \hat{Y}_{n+1} + \hat{\sigma}_{\hat{\mu}_{n+1}} t_{1-\alpha/2}(n-p')] \quad (3.59)$$

$$\text{mit } \hat{\sigma}_{\hat{\mu}_{n+1}}^2 = \hat{\sigma}^2 (\mathbf{x}_{n+1}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_{n+1})$$

(vgl. Fahrmeir et al.; S.152)

- Prognoseintervalle enthalten die Zufallsschwankung durch den Störterm ε_{n+1} **und** die Unsicherheit bezüglich der Modellparameter
- Die entsprechenden Konfidenzintervalle enthalten nur die Unsicherheit bezüglich der Modellparameter. Sie können gut zur Darstellung der Modellschätzung verwendet werden.
- Um den geschätzten Effekt einer Einflussgröße x_1 darzustellen, werden die anderen Einflussgrößen auf einen festen Wert (z.B. Modus, Median oder Mittelwert) gesetzt. Dann wird der Zusammenhang von $x_{1,n+1}$ und $\hat{Y}_{n+1}$ zusammen mit den entsprechenden Konfidenzintervallen geplottet. (R-Paket: effects)

Das Gauss-Markov-Theorem

Sei das Modell

$$\begin{aligned}\mathbf{Y} &= \mathbf{X}\beta + \varepsilon, \quad \text{rg } \mathbf{X} = p' \\ E(\varepsilon) &= \mathbf{0} \\ V(\varepsilon) &= \sigma^2 \mathbf{I}\end{aligned}$$

gegeben.

Dann ist der KQ-Schätzer $\hat{\beta}$ unter den erwartungsternen linearen Schätzern derjenige mit der kleinsten Varianz: $\hat{\beta}$ ist BLUE-Schätzer (**b**est **l**inear **u**nbiased **e**stimator).

Ist $\tilde{\beta}$ ein weiterer Schätzer von β mit $E(\tilde{\beta}) = \beta$ und $\tilde{\beta} = \mathbf{C}\mathbf{Y}$, so gilt:

$$V(\tilde{\beta}) \geq V(\hat{\beta})$$

$$V(\tilde{\beta}) \geq V(\hat{\beta}) \Leftrightarrow V(\tilde{\beta}) = V(\hat{\beta}) + \mathbf{M} \text{ mit } \mathbf{M} \text{ positiv semidefinit.}$$

(vgl. Fahrmeir et al.; S. 187)

Konsistenz des KQ-Schätzers I

Sei das Modell (2.1) - (2.4) gegeben. Wir betrachten nun das Modell mit steigendem Stichprobenumfang n . Da die Einflussgrößen fest sind, gehen wir von einer gegebenen Folge x_n der Einflussgrößen aus.

Sei zu jedem $n > p'$

$\mathbf{X}_n$: Designmatrix, die aus den ersten n Beobachtungen besteht

$\hat{\beta}^{(n)}$: KQ- Schätzer aus den ersten n Beobachtungen

Vor.: $\mathbf{X}_n$ hat vollen Rang für alle $n \geq p$.

$$\lim_{n \rightarrow \infty} (\mathbf{X}_n' \mathbf{X}_n)^{-1} = 0.$$

Konsistenz des KQ-Schätzers II

Dann folgt die schwache Konsistenz des KQ-Schätzers (Konvergenz in Wahrscheinlichkeit):

$$\hat{\beta}^{(n)} \xrightarrow{P} \beta. \quad (3.60)$$

Sind die Störgrößen zusätzlich identisch verteilt, so folgt die starke Konsistenz (fast sichere Konvergenz)

$$\hat{\beta}^{(n)} \xrightarrow{\text{f.s.}} \beta. \quad (3.61)$$

(vgl. Fahrmeir et al.; S.133)

Asymptotische Normalität des KQ-Schätzers

Sei das Modell (2.1) - (2.4) gegeben.

Sei zu jedem $n > p'$

$\mathbf{X}_n$: Designmatrix, die aus den ersten n Beobachtungen besteht
 $\hat{\beta}^{(n)}$: KQ- Schätzer aus den ersten n Beobachtungen

Vor.: $\mathbf{X}_n$ hat vollen Rang für alle $n \geq p$

$$\lim_{n \rightarrow \infty} \max_{1 \leq i \leq n} \mathbf{x}_i' (\mathbf{X}_n' \mathbf{X}_n)^{-1} \mathbf{x}_i = 0.$$

Dann folgt die asymptotische Normalität von β

$$\sigma^{-1} (\mathbf{X}_n' \mathbf{X}_n)^{1/2} (\hat{\beta}^{(n)} - \beta) \xrightarrow{d} N(0, \mathbf{I}). \quad (3.62)$$

Bemerkungen zur Asymptotik

Die asymptotische Normalität gilt auch, wenn man in (3.62) die unbekannte Varianz σ durch den Schätzer $\hat{\sigma}_n$ ersetzt.

Man kann (3.62) zur Konstruktion von Konfidenzintervallen und zum Testen der linearen Hypothese nutzen. Es gilt:

$$\hat{\beta}^{(n)} \overset{a}{\sim} N(\beta, \hat{\sigma}_n^2 (\mathbf{X}_n' \mathbf{X}_n)^{-1})$$

Statt der t-Verteilung verwendet man die Normalverteilung, was für große n aber praktisch keinen Unterschied macht.

Auch die F-Verteilung für den Test der linearen Hypothese entspricht für große n der χ^2 -Verteilung.

5. Diskrete Einflußgrößen: Dummy- und Effektkodierung, Mehrfaktorielle Varianzanalyse

Bei der ANOVA geht es um den Vergleich von Mittelwerten.

Die einfaktorielle Varianzanalyse hat die primäre Fragestellung:

Sind die Mittelwerte von verschiedenen Gruppen gleich?

Diese Frage lässt sich als lineares Modell darstellen. Wir verwenden eine diskrete Variable, die die Gruppenzugehörigkeit beschreibt.

Wir betrachten ein nominales Merkmal C mit K Ausprägungen.

a) Einfache Dummy-Kodierung

$$Z_k(C) = \begin{cases} 1 & \text{für } C = k; \\ 0 & \text{für } C \neq k; \end{cases} \quad k = 1, \dots, K \quad (4.1)$$

b) Effekt-Kodierung

$$Z_k^e(C) = \begin{cases} 1 & \text{für } C = k; \\ 0 & \text{für } C \neq k; C \neq K \\ -1 & \text{für } C = K; \end{cases} \quad k = 1, \dots, K-1; \quad (4.2)$$

(vgl. Fahrmeir et al.; S. 109)

Einfache Varianzanalyse

Gegeben sei eine nominale Einflussgröße C mit K Ausprägungen (Gruppen). Der Zielgrößenvektor $\mathbf{Y}$ wird in die K Gruppen mit jeweils n_k Beobachtungen aufgeteilt:

$$\mathbf{Y} = (Y_{11}, \dots, Y_{1n_1}, Y_{21}, \dots, Y_{Kn_K})'$$

a) Mittelwertsmodell:

$$Y_{kl} = \mu_k + \varepsilon_{kl} \quad l = 1, \dots, n_k; \quad k = 1, \dots, K$$

$$\mathbf{Y} = (Z_1(C) \dots Z_K(C)) \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_K \end{pmatrix} + \boldsymbol{\varepsilon} \quad (4.3)$$

Beispiel

Sei X die Design-Matrix für $K = 3$ Gruppen mit je $n_k = 2$ Beobachtungen pro Gruppe.

Die entsprechende Regressionsgleichung lautet:

$$\begin{pmatrix} Y_{11} \\ Y_{12} \\ Y_{21} \\ Y_{22} \\ Y_{31} \\ Y_{32} \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} \mu_1 \\ \mu_2 \\ \mu_3 \end{pmatrix} + \begin{pmatrix} \varepsilon_{11} \\ \varepsilon_{12} \\ \varepsilon_{21} \\ \varepsilon_{22} \\ \varepsilon_{31} \\ \varepsilon_{32} \end{pmatrix}$$

b) Effekt-Kodierung:

$$Y_{kl} = \mu + \tau_k + \varepsilon_{kl}; \quad \sum_{k=1}^K \tau_k = 0$$

$$\mathbf{Y} = (e \ Z_1^e(C) \dots Z_{K-1}^e(C)) \begin{pmatrix} \mu \\ \tau_1 \\ \vdots \\ \tau_{K-1} \end{pmatrix} + \varepsilon \quad (4.4)$$

Design-Matrix $\mathbf{X}$ für $K = 3$
Gruppen mit je $n_k = 2$
Beobachtungen pro Gruppe.

$$\mathbf{X} = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 0 & 1 \\ 1 & -1 & -1 \\ 1 & -1 & -1 \end{pmatrix}$$

c) Modell mit Referenzkategorie K :

$$Y_{kl} = \mu_K + \tau_k + \varepsilon_{kl}, \quad \tau_K = 0;$$

$$\mathbf{Y} = (e \ Z_1(C) \dots Z_{K-1}(C)) \begin{pmatrix} \mu_K \\ \tau_1 \\ \vdots \\ \tau_{K-1} \end{pmatrix} + \varepsilon \quad (4.5)$$

Design-Matrix $\mathbf{X}$ für 3 Gruppen
mit je 2 Beobachtungen pro
Gruppe:

$$\mathbf{X} = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 0 & 1 \\ 1 & 0 & 0 \\ 1 & 0 & 0 \end{pmatrix}$$

Nullhypothesen zum Test auf „Effekt von C “

a) $H_0 : \mu_1 = \mu_2 = \dots = \mu_K$

b) $H_0 : \tau_1 = \tau_2 = \dots = \tau_{K-1} = 0$

c) $H_0 : \tau_1 = \tau_2 = \dots = \tau_{K-1} = 0$

Zusammenhang zwischen Kodierungen

Mittelwertsmodell: $\mu_1, \dots, \mu_K$ kein Intercept

Effektkodierung: $\mu = \frac{1}{K} \sum_{k=1}^K \mu_k$ $\Leftrightarrow$ Intercept

$$\begin{aligned}\tau_k &= \mu_k - \mu \\ \Leftrightarrow \mu_k &= \mu + \tau_k\end{aligned}$$

„Unterschied zum Gesamtmittel“

Referenzkodierung: $\mu = \mu_K$ $\Leftrightarrow$ Intercept

$$\begin{aligned}\tau_k &= \mu_k - \mu_K \\ \Leftrightarrow \mu_k &= \mu_K + \tau_k\end{aligned}$$

„Unterschied zur Referenz“

- Alle 3 Kodierungen führen zu gleicher Modellanpassung (R^2).
- Parameter haben unterschiedliche Interpretation.
- Parameter und deren Schätzungen sind aus verschiedenen Varianten direkt ineinander überführbar.
- Modelle sind erweiterbar mit zusätzlichen Einflussgrößen.

Modell der zweifaktoriellen Varianzanalyse

Wir betrachten zwei diskrete Einflussgrößen C und D mit K_1 bzw. K_2 Ausprägungen. Man spricht dann von einer zweifaktoriellen Varianzanalyse mit einem K_1 -stufigen und einem K_2 -stufigen Faktor. Hier ist die Mittelwertsdarstellung nicht möglich.

a) Modell mit einfachen Effekten (Effektdarstellung)

$$\mathbf{Y} = (e \ Z_1^e(C) \dots Z_{K_1-1}^e(C) Z_1^e(D) \dots Z_{K_2-1}^e(D)) \begin{pmatrix} \mu \\ \tau_1 \\ \vdots \\ \tau_{K_1-1} \\ \gamma_1 \\ \vdots \\ \gamma_{K_2-1} \end{pmatrix} + \varepsilon \quad (4.6)$$

Test auf Effekt von C : $H_0 : \tau_1 = \dots = \tau_{K_1-1} = 0$

Test auf Effekt von D : $H_0 : \gamma_1 = \dots = \gamma_{K_2-1} = 0$

Interpretation:

τ_k, γ_l Abweichung vom Gesamtmittel der Kategorien

Beispiel: Designmatrix

Gegeben sei ein Modell mit einem zweistufigen und einem dreistufigen Faktor und jeweils zwei Beobachtungen pro Faktorkombination:

$$\mathbf{X} = \begin{pmatrix} 1 & 1 & 1 & 0 \\ 1 & 1 & 1 & 0 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & -1 & -1 \\ 1 & 1 & -1 & -1 \\ 1 & -1 & 1 & 0 \\ 1 & -1 & 1 & 0 \\ 1 & -1 & 0 & 1 \\ 1 & -1 & 0 & 1 \\ 1 & -1 & -1 & -1 \\ 1 & -1 & -1 & -1 \end{pmatrix}$$

Beispiel: 2 kategoriale Einflussgrößen

$$\mu = 1$$


$$\text{Faktor A (2-stufig): } \tau_1 = 2 \quad \Rightarrow \tau_2 = -2$$

$$\text{Faktor B (3-stufig): } \gamma_1 = 1, \gamma_2 = 2 \quad \Rightarrow \gamma_3 = -3$$

Berechnung der Mittelwerte:

Faktor A	Faktor B	MW
1	1	$1 + 2 + 1 = 4$
1	2	$1 + 2 + 2 = 5$
1	3	$1 + 2 - 3 = 0$
2	1	$1 - 2 + 1 = 0$
2	2	$1 - 2 + 2 = 1$
2	3	$1 - 2 - 3 = -4$

Graphische Darstellung



Verlauf parallel mit
Abstand $\tau_1 - \tau_2$

Darstellung mit Referenz-Kodierung

$$\mathbf{Y} = (e \ Z_1(C) \dots Z_{K_1-1}(C) Z_1(D) \dots Z_{K_2-1}(D)) \begin{pmatrix} \mu \\ \tau_1 \\ \vdots \\ \tau_{K_1-1} \\ \gamma_1 \\ \vdots \\ \gamma_{K_2-1} \end{pmatrix} + \epsilon \quad (4.7)$$

Interpretation von τ_k, γ_l :

Abweichung von der Referenzkategorie

Beispiel: Designmatrix

Gegeben sei ein Modell mit einem zweistufigen und einem dreistufigen Faktor und jeweils zwei Beobachtungen pro Faktorkombination:

$$\mathbf{X} = \begin{pmatrix} 1 & 1 & 1 & 0 \\ 1 & 1 & 1 & 0 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 \end{pmatrix}$$

Interaktion ist ein wichtiger Begriff bei der Modellierung.

Bedeutung: Der Einfluss einer Variablen hängt von dem Wert einer anderen Variablen ab.

Beispiele für Interaktionen bei zwei Einflussgrößen:

- Die Wirkung des Medikaments ist bei Männern anders als bei Frauen
- Der Geschlechtsunterschied in der Lebenszufriedenheit ist abhängig vom Alter
- Die Wirkung des Lesetrainings ist bei guten Schülern geringer als bei schwachen Schülern

Andere Begriffe: Moderation (Psychologie), Synergieeffekte

Der Begriff der Interaktion ist zu unterscheiden von dem Zusammenhang (Korrelation, Multikollinearität) zwischen zwei Einflussgrößen! Bei der Interaktion gibt es einen direkten Bezug zu der Zielgröße

(vgl. Fahrmeir et al.; S. 109 ff)

Modell mit Interaktion

Interaktionen lassen sich durch Aufnahme aller Produktterme $Z_k^e(C)Z_l^e(D)$ modellieren:

$$E(Y) = (e, Z_1^e(C) \dots Z_{K_2-1}^e(D), Z_1^e(C)Z_1^e(D) \dots Z_{K_1-1}^e(C)Z_{K_2-1}^e(D)) \begin{pmatrix} \mu \\ \tau_1 \\ \vdots \\ \gamma_{K_2-1} \\ (\tau\gamma)_{11} \\ \vdots \\ (\tau\gamma)_{K_1-1, K_2-1} \end{pmatrix}$$

Test auf Interaktion:

$$H_0 : (\tau\gamma)_{11} = \dots = (\tau\gamma)_{K_1-1, K_2-1} = 0$$

Beispiel

Design-Matrix **X** für 2-Faktor Modell mit einem zweistufigen und einem dreistufigen Faktor: (jeweils eine Beobachtung pro Merkmalskombination).

Effektkodierung:

$$\mathbf{X}\boldsymbol{\beta} = \begin{pmatrix} 1 & 1 & 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 1 & 0 & 1 \\ 1 & 1 & -1 & -1 & -1 & -1 \\ 1 & -1 & 1 & 0 & -1 & 0 \\ 1 & -1 & 0 & 1 & 0 & -1 \\ 1 & -1 & -1 & -1 & 1 & 1 \end{pmatrix} \cdot \begin{pmatrix} \mu \\ \tau_1 \\ \gamma_1 \\ \gamma_2 \\ (\tau\gamma)_{11} \\ (\tau\gamma)_{12} \end{pmatrix}$$

Effekt-Kodierung mit Interaktion

Darstellung mit allen Parametern

$$Y_{kl} = \mu + \tau_k + \gamma_l + (\tau\gamma)_{kl} + \varepsilon_{kl} \quad (4.8)$$

$$\sum_{k=1}^{K_1} \tau_k = 0$$

$$\sum_{l=1}^{K_2} \gamma_l = 0$$

$$\sum_{k=1}^{K_1} (\tau\gamma)_{kl} = 0 \text{ für } l = 1 \dots K_2$$

$$\sum_{l=1}^{K_2} (\tau\gamma)_{kl} = 0 \text{ für } k = 1 \dots K_1$$

Interpretation der Parameter

τ_k : Unterschied von Kategorie k zu Gesamtmittel

γ_l : Unterschied von Kategorie l zu Gesamtmittel

$(\tau\gamma)_{kl}$: Unterschied von Zelle (kl) zum Wert
unter Berücksichtigung der Basiseffekte

- Eine Interpretation ist am besten möglich durch die grafische Darstellung der geschätzten Effekte, z.B. mit Effectplots in R.
- Bei der Effektkodierung ist die Interpretation der Basiseffekte in vielen Fällen hilfreich.

Beispiel: 2 kategoriale Einflussgrößen mit Interaktion

$$\mu = 1$$

$$\text{Faktor A (2-stufig): } \tau_1 = 2 \quad \Rightarrow \tau_2 = -2$$


$$\text{Faktor B (3-stufig): } \gamma_1 = 1, \gamma_2 = 2 \quad \Rightarrow \gamma_3 = -3$$

$$\begin{aligned} \text{Interaktion: } (\tau\gamma)_{11} &= -2 & \Rightarrow (\tau\gamma)_{21} &= 2 \\ (\tau\gamma)_{12} &= 0 & \Rightarrow (\tau\gamma)_{22} &= 0 \\ & \Rightarrow (\tau\gamma)_{13} = 2 & \Rightarrow (\tau\gamma)_{23} &= -2 \end{aligned}$$

Berechnung der Mittelwerte:

Faktor A	Faktor B	MW
1	1	$1 + 2 + 1 - 2 = 2$
1	2	$1 + 2 + 2 + 0 = 5$
1	3	$1 + 2 - 3 + 2 = 2$
2	1	$1 - 2 + 1 + 2 = 2$
2	2	$1 - 2 + 2 + 0 = 1$
2	3	$1 - 2 - 3 - 2 = -6$

Grafische Darstellung



Verlauf unterschiedlich
⇔ Interaktion

Interaktion mit Referenzkodierung

Modell mit einem K_1 -stufigen und einem K_2 -stufigen Faktor. Darstellung mit allen Parametern

$$Y_{kl} = \mu + \tau_k + \gamma_l + (\tau\gamma)_{kl} + \varepsilon_{kl}; \quad (4.9)$$

$$\tau_{K_1} = 0$$

$$\gamma_{K_2} = 0$$

$$(\tau\gamma)_{K_1 l} = 0 \text{ für } l = 1 \dots K_2$$

$$(\tau\gamma)_{k K_2} = 0 \text{ für } k = 1 \dots K_1$$

Interpretation der Parameter:

- τ_k : Unterschied von Kategorie k zur Referenz für Faktor 2 = Referenz
- γ_l : Unterschied von Kategorie l zur Referenz, wenn Faktor 1 = Referenz
- $(\tau\gamma)_{kl}$: Unterschied von Zelle (kl) zur jeweiligen Referenz unter Berücksichtigung der Basiseffekte

Design-Matrix $\mathbf{X}$ für 2-Faktor Modell mit einem zweistufigen und einem dreistufigen Faktor: (jeweils eine Beobachtung pro Merkmalskombination).

Referenzkodierung:

$$\mathbf{X}\boldsymbol{\beta} = \begin{pmatrix} 1 & 1 & 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 1 & 0 & 1 \\ 1 & 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 \end{pmatrix} \cdot \begin{pmatrix} \mu \\ \tau_1 \\ \gamma_1 \\ \gamma_2 \\ (\tau\gamma)_{11} \\ (\tau\gamma)_{12} \end{pmatrix}$$

Erweiterung auf Kombination von diskreten und stetigen Merkmalen (Kovarianzanalyse)

Beispiel für Design-Matrix $\mathbf{X}$ für $K = 3$ Gruppen mit je $n_k = 2$ Beobachtungen pro Gruppe und stetigem Merkmal x :

$$\mathbf{X} = \begin{pmatrix} 1 & 0 & 0 & x_1 \\ 1 & 0 & 0 & x_2 \\ 0 & 1 & 0 & x_3 \\ 0 & 1 & 0 & x_4 \\ 0 & 0 & 1 & x_5 \\ 0 & 0 & 1 & x_6 \end{pmatrix} \quad \boldsymbol{\beta} = \begin{pmatrix} \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \beta_4 \end{pmatrix}$$

Interpretation:

In den drei Gruppen ergeben sich drei parallele Geraden mit Achsenabschnitt α_i und Steigung β_4 .

(vgl. Fahrmeir et al.; S. 100)

Erweiterung auf Geraden mit versch. Steigung

Modell:

$$Y_{kl} = \alpha_k + \beta_k X_{kl} + \varepsilon_{kl} \quad (4.10)$$

Matrixdarstellung (3 Gruppen, 2 Beobachtungen pro Gruppe)

$$\mathbf{X} = \begin{pmatrix} 1 & 0 & 0 & x_1 & 0 & 0 \\ 1 & 0 & 0 & x_2 & 0 & 0 \\ 0 & 1 & 0 & 0 & x_3 & 0 \\ 0 & 1 & 0 & 0 & x_4 & 0 \\ 0 & 0 & 1 & 0 & 0 & x_5 \\ 0 & 0 & 1 & 0 & 0 & x_6 \end{pmatrix} \quad \beta = \begin{pmatrix} \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \beta_1 \\ \beta_2 \\ \beta_3 \end{pmatrix}$$

Interaktion bedeutet Steigungen verschieden.

Test auf Interaktion: $\beta_1 = \beta_2 = \beta_3$

Darstellung mit Referenzkodierung

Modell:

$$Y_{kl} = \alpha_3 + \alpha_k + \beta_3 X_{kl} + \beta_k X_{kl} + \varepsilon_{kl} \quad (k = 1, 2)$$

$$Y_{kl} = \alpha_3 + \beta_3 X_{kl} + \varepsilon_{kl} \quad (k = 3)$$

Matrixdarstellung (3 Gruppen 2 Beobachtungen pro Gruppe)

$$\mathbf{X} = \begin{pmatrix} 1 & 1 & 0 & x_1 & x_1 & 0 \\ 1 & 1 & 0 & x_2 & x_2 & 0 \\ 1 & 0 & 1 & x_3 & 0 & x_3 \\ 1 & 0 & 1 & x_4 & 0 & x_4 \\ 1 & 0 & 0 & x_5 & 0 & 0 \\ 1 & 0 & 0 & x_6 & 0 & 0 \end{pmatrix} \boldsymbol{\beta} = \begin{pmatrix} \alpha_3 \\ \alpha_1 \\ \alpha_2 \\ \beta_3 \\ \beta_1 \\ \beta_2 \end{pmatrix}$$

Interaktion bedeutet Steigungen verschieden.

Test auf Interaktion: $\beta_1 = \beta_2 = 0$

Typen von Quadratsummen

In der Literatur unterscheidet man 3 Typen von Quadratsummen:

Typ1 Sequentielle Quadratsummen

Typ2 Partielle Quadratsummen ohne höhere Interaktionsterme

Typ3 Partielle Quadratsummen

Beispiel mit Effekten X_1 X_2 X_3 $X_1 \cdot X_2$ $X_1 \cdot X_3$ $X_2 \cdot X_3$ $X_1 \cdot X_2 \cdot X_3$

Effekt	Variablen im Modell bei		
	Typ1	Typ3	Typ2
X_1	-	alle anderen	X_2 X_3 $X_2 \cdot X_3$
X_2	X_1	alle anderen	X_1 X_3 $X_1 \cdot X_3$
$X_1 \cdot X_2$	X_1 X_2 X_3	alle anderen	X_1 X_2 X_3 $X_1 \cdot X_3$ $X_2 \cdot X_3$
$X_1 \cdot X_2 \cdot X_3$	alle anderen	alle anderen	alle anderen

Beachte: Falls Interaktionen vorhanden sind, sind die einfachen Koeffizienten schwer direkt interpretierbar!

Beispiel: Vorher-Nachher Vergleich

X1 : Blutwert zum Zeitpunkt 1

X2 : Blutwert zum Zeitpunkt 2

Z : Gruppenzugehörigkeit (0= Placebo / 1= Verum)
oder auch allgemeine Gruppierungsvariable

Fragestellung: Gibt es einen Unterschied zwischen den Gruppen?

Variante 1: Betrachte Differenzen $X2 - X1 = D$ und
führe 2 Stichproben t-Test durch.
Vorteil: Einfach und leicht interpretierbar

Variante 2: Regression $X2 = \beta_0 + \beta_1 X1 + \gamma * Z + \epsilon$
Teste die Nullhypothese: $H_0 : \gamma = 0$
Vorteil: „Regression to the mean“ und mögliche Abhängigkeit
der Differenz vom Anfangswert werden berücksichtigt.

6. Metrische Einflußgrößen: Interaktionen, Polynomiale Regression, Trigonometrische Polynome, Regressionssplines, Transformationen.

Interaktionen bei metrischen Variablen

Gegeben sei ein Modell mit zwei metrischen Variablen x_1 und x_2 :

$$E(Y) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 \cdot x_2$$

Interpretation durch die Darstellung

$$E(Y) = \beta_0 + \beta_1 x_1 + (\beta_2 + \beta_3 x_1) x_2$$

oder:

$$E(Y) = \beta_0 + \beta_2 x_2 + (\beta_1 + \beta_3 x_2) x_1$$

Beachte: Die Parameter β_1 und β_2 geben die Steigung bei $x_2 = 0$ bzw. $x_1 = 0$ an. Häufig sind diese nicht sinnvoll interpretierbar. Bei zentrierten Variablen ergeben sie die Steigung bei dem jeweiligen Mittelwert der anderen Variablen.

Behandlung von metrischen Einflussgrößen I

- ① Einfach linear:

$$E(Y) = \beta_0 + \beta_1 x$$

- ② Transformiert:

$$E(Y) = \beta_0 + \beta_1 T(x)$$

Beachte: Andere Interpretation von β_1 z.B.:

Logarithmisch:	$T(x) = \ln(x)$
Logarithmisch mit Nullpunkt-Erhaltung:	$T(x) = \ln(1 + x)$
Exponentiell mit bekanntem c :	$T(x) = x^c$

③ Als Polynom:

$$E(Y) = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \dots \beta_k x^k$$

Problem: Bestimmung von k

Mögliche Lösung: Tests auf $\beta_1 = \dots = \beta_k = 0$

→ Verwende Sequentielle Quadratsummen

(vgl. Fahrmeir et al.; S. 431)

- ④ als stückweise konstante Funktion

$$E(Y) = \begin{cases} \beta_0 & \text{für } x \leq x_0 \\ \beta_1 & \text{für } x_0 < x < x_1 \\ \vdots & \\ \beta_h & \text{für } x > x_{h-1} \end{cases}$$

Dies entspricht der Kategorisierung der x -Variablen.

Bei x -Variablen, die nur wenige Werte haben, kann das Modell zur Überprüfung der Linearität benutzt werden.

Behandlung von metrischen Einflussgrößen IV

- ⑤ als stückweise lineare Funktion:

$$E(Y) = \beta_0 + \beta_1 x + \beta_2(x - g_1)_+ + \beta_3(x - g_2)_+ + \dots \beta_h(x - g_k)_+$$

mit bekannten Bruchpunkten (Knoten) g_k und $t_+ = \max(t, 0)$

- ⑥ als Regressionsspline:

$$E(Y) = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \beta_4(x - g_1)_+^3 + \beta_5(x - g_2)_+^3$$

Ein Polynom 3. Grades ist 2x stetig differenzierbar, da x^3 2x stetig differenzierbar in 0 ist. (Bekannte Knoten g_k)

- 7 als fraktionale Polynome:

Beispiel: Grad $(-2,2)$

$$E(Y) = \beta_0 + \beta_1 x^{-2} + \beta_2 x^{-1} + \beta_3 x^{-0.5} + \beta_4 \ln(x) + \beta_5 x^{0.5} + \beta_6 x + \beta_7 x^2$$

Flexible Darstellung mit Strategien zur Selektion (Sauerbrei et al.,
Uni Freiburg)

Behandlung von metrischen Einflussgrößen VI

- 8 als trigonometrische Polynome zur Modellierung von periodischen Termen (Saisonfigur):

Beispiel:

$$E(Y) = \beta_0 + \beta_1 \sin\left(\frac{2\pi}{T} \cdot x\right) + \beta_2 \cos\left(\frac{2\pi}{T} \cdot x\right) + \beta_3 \sin\left(\frac{2\pi}{T} \cdot 2x\right) + \beta_4 \cos\left(\frac{2\pi}{T} \cdot 2x\right)$$

T: Periodenlänge, x: Zeit

Alternative: Saison-Dummy (Indikator) Variablen

Beachte:

$$A_1 * \cos(x) + A_2 * \sin(x) = A_3 * \sin(x + \phi)$$

Allgemeiner Ansatz mit Basisfunktionen

Bekannte Basisfunktionen: $B_1, B_2, B_3, \dots$

$$E(Y) = \beta_0 + \beta_1 B_1(x) + \beta_2 B_2(x) + \beta_3 B_3(x) + \dots$$

- Oben vorgestellte Ansätze besitzen diese allgemeine Darstellung
- Mit bestimmten Basisfunktionen und geeigneter Schätzung lässt sich bei hoher Flexibilität beinahe jeder nichtlineare Zusammenhang adäquat **datengesteuert** schätzen, z.B. P-Splines (*penalized B-splines*); (siehe Veranstaltung Generalisierte Lineare Modelle)

Beispiel: Trendmodell für die Populationsgröße von Füchsen in Baden Württemberg

Gegeben:

So genannte Jagdstrecken t

Y : Anzahl der geschossenen Füchse als Indikator für die Populationsgröße

Modelle:

$$\ln(Y) = \beta_0 + \beta_1 t + \beta_2 t^2$$

$$\ln(Y) = \beta_0 + \beta_1 t + \beta_2 t^2 + \beta_3 t^3 + \beta_4 (t - 70)_+^3 + \beta_5 (t - 85)_+^3$$

etc.

Versuchen Sie eine Modellierung von $\ln$ (Hase)

Multiples Testen und simultane Konfindenzbereiche

Häufig werden bei multiplen linearen Modellen mehrere Tests durchgeführt oder für mehrere Parameter Konfidenzintervalle bestimmt. Dann ist die Wahrscheinlichkeit, dass mindestens eine falsche Entscheidung getroffen wird, höher als das (lokale) Niveau der einzelnen Tests.

Abhilfe: multiple Testprozeduren

Gegeben: Hypothesen $H_{0,1}, \dots, H_{0,k}$

z.B.: $H_{0,1} : \tau_1 = 0, \quad H_{0,2} : \tau_2 = 0$ usw.

lokales Niveau: Einzelniveau der Tests

globales Niveau: Wahrscheinlichkeit, dass mindestens eine Nullhypothese abgelehnt wird, obwohl alle Nullhypothesen gelten.

multiples Niveau: Wahrscheinlichkeit, dass mindestens eine Nullhypothese fälschlicherweise abgelehnt wird $< \alpha$.

- **Bonferroni:** Allgemeine Methode für m Tests, die sehr allgemein anwendbar ist
- **Scheffe:** Allgemeine Methode im linearen Modell für eine große Anzahl von Hypothesen bzw. Parametern
- **Tukey, Hothorn et al.:** Methode nach dem Multiple-Range-Prinzip bzw. nach Maximum-Prinzip.
- **Abschlussprozeduren:** Für Testsysteme häufig mächtiger als andere Prozeduren : Wichtig im Fall des Vergleichs von 3 Gruppen

Andere Verfahren halten das multiple Niveau nicht und sollten daher eher gemieden werden, wie z.B.: Duncan multiple Range, Fisher LSD, Newman-Keuls.

Verwende bei k vorab festgelegten Tests jeweils das lokale

Signifikanzniveau $\alpha_I = \alpha/k$

Die Eigenschaften folgen unmittelbar aus der Bonferroni-Ungleichung.

$$P\left(\bigcup E_i\right) \leq \sum P(E_i)$$

Eigenschaften:

- Sehr allgemein anwendbar
- Einfach durchführbar
- Hält multiples Niveau
- ungeeignet bei sehr vielen Tests (Power gering)

Sei das Modell (2.1) mit NV-Annahme (2.5) gegeben.
Dann ist

$$\left\{ \beta \mid (\beta - \hat{\beta})'(\mathbf{X}'\mathbf{X})(\beta - \hat{\beta}) \leq p' \hat{\sigma}^2 F_{1-\alpha}(p', n - p') \right\} \quad (5.1)$$

eine Konfidenzregion für β .

Entsprechendes gilt für lineare Transformationen $\gamma = \mathbf{A}\beta$:

$$\left\{ \gamma \mid (\gamma - \hat{\gamma})' \widehat{V(\hat{\gamma})}^{-1} (\gamma - \hat{\gamma}) < \dim \gamma \cdot F_{1-\alpha}(\dim(\gamma), n - p') \right\}$$

ist Konfidenzregion zum Sicherheitsniveau $1 - \alpha$.

Konfidenzintervalle nach Scheffe

Sei Modell (2.1) mit NV-Annahme (2.5) gegeben.
Dann sind

$$\hat{\beta}_j \pm \sqrt{p' F_{1-\alpha}(p', n - p')} \hat{\sigma}_{\hat{\beta}_j} \quad (5.2)$$

für die Parameter β_j und

$$\hat{\gamma} \pm \sqrt{p' F_{1-\alpha}(p', n - p')} \hat{\sigma}_{\hat{\gamma}}$$

für beliebige Linearkombinationen $\gamma = a'\beta$ simultane Konfidenzintervalle.

Strategie mit Maximum-Statistiken

Tests nach **Tuckey** und **Horthorn et al.**:

Wir betrachten simultane Hypothesen der Form $\mathbf{A}\beta = \mathbf{0}$ mit den einzelnen studentisierten Komponenten (Zeilen)

$$\mathbf{T}_i = \mathbf{d}'\beta / \hat{\sigma}_{\mathbf{d}'\beta}, i = 1, \dots, a$$

$$Q = \max |\mathbf{T}_i|$$

Sei $Q(n - p', \mathbf{R})$ die Verteilung des Maximums von t -Verteilungen mit Korrelationsmatrix $\mathbf{R}$.

$$P(Q \leq q) = 1 - \alpha$$

$$\implies P(\max_i |\mathbf{T}_i| \leq q) = 1 - \alpha$$

$$\implies P(\forall i : |\mathbf{T}_i| \leq q) = 1 - \alpha$$

$$P(\forall i : \mathbf{d}'_i\beta \in [-q\hat{\sigma}_{\mathbf{d}'_i\beta}; +q\hat{\sigma}_{\mathbf{d}'_i\beta}]) = 1 - \alpha$$

d.h. wir erhalten **simultane** KIs zum Konfidenzniveau $1 - \alpha$

- Das Vorgehen ist sehr allgemein auf (asymptotisch) normalverteilte Teststatistiken anwendbar.
- Umsetzung im R-package multcomp: inclusive Angaben von entsprechenden p-Werten.
- siehe Artikel: *Simultaneous inference in general parametric models*; Hothorn, T; Bretz, F; Westfall, P.; BIOMETRICAL JOURNAL; 50; 346-363; 2008. **über 9000 mal zitiert (2024)**

7. Modelldiagnose

Probleme bei der Regression und Diagnose

Gegeben sei das multiple Regressionsmodell (2.1) und (2.5):

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

$$\boldsymbol{\varepsilon} \sim N(\mathbf{0}, \sigma^2 \mathbf{I})$$

Es geht darum, herauszufinden, ob das Modell zur Analyse der jeweiligen Daten geeignet ist.

Da sich die Modellannahmen auf die Störterme beziehen, werden typischerweise die Residuen betrachtet.

Beachte, dass sich die Annahmen nicht auf die Randverteilung von $\mathbf{Y}$ beziehen.

Verschiedene Typen von Residuen

Beachte: Die Residuen ergeben sich aus den (unbekannten) Störtermen ε durch

$$\hat{\varepsilon} = \mathbf{Q}\varepsilon = (\mathbf{I} - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}')\varepsilon = (\mathbf{I} - \mathbf{P})\varepsilon.$$

Daher gilt:

$$\text{Var}(\hat{\varepsilon}_i) = q_{ii}\sigma^2 \quad (6.1)$$

Beispiel:

$$\mathbf{X} := \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{bmatrix} \quad \mathbf{Q} := \begin{bmatrix} 2/5 & -2/5 & -1/5 & 0 & 1/5 \\ -2/5 & \frac{7}{10} & -1/5 & -1/10 & 0 \\ -1/5 & -1/5 & 4/5 & -1/5 & -1/5 \\ 0 & -1/10 & -1/5 & \frac{7}{10} & -2/5 \\ 1/5 & 0 & -1/5 & -2/5 & 2/5 \end{bmatrix}$$

$$r_i := \frac{\hat{\varepsilon}_i}{\hat{\sigma} \sqrt{q_{ii}}} \quad i = 1, \dots, n \quad (6.2)$$

$q_{ii} = 1 - h_{ii}$: Elemente der Residualmatrix **Q**

Es gilt:

$$\begin{aligned} \Rightarrow \quad \frac{1}{n} &\leq h_{ii} \leq 1 & \sum h_{ii} &= p' \\ 0 &\leq q_{ii} \leq 1 - \frac{1}{n} & \sum q_{ii} &= n - p' \end{aligned}$$

Problem: Bei der Schätzung von σ geht das Residuum mit ein.
Dies kann insbesondere bei kleinen Stichproben ein Problem sein.

Daher definiert man:

$$r_i^* := \frac{\hat{\varepsilon}_i}{\hat{\sigma}_{(i)}\sqrt{q_{ii}}} \quad i = 1, \dots, n \quad (6.3)$$

$\hat{\sigma}_{(i)}$:= Schätzung von σ **ohne** die Beobachtung i .

$$e_{(i)} := y_i - \mathbf{x}_i' \hat{\boldsymbol{\beta}}_{(i)} \quad (6.4)$$

$\hat{\boldsymbol{\beta}}_{(i)}$: Schätzung von $\boldsymbol{\beta}$ ohne Beobachtung i

$$PRESS := \sum_{i=1}^n e_{(i)}^2$$

(PRESS: Predicted Residual Sum of Squares)

Es gilt:

$$e_{(i)} = \hat{\varepsilon}_i / q_{ii} \quad (6.5)$$

$$\text{Var}(e_{(i)}) = \frac{1}{q_{ii}} \sigma^2 > \sigma^2 \quad (6.6)$$

Die Gleichung (6.5) ist ein wesentliches Hilfsmittel, um die Kreuzvalidierungsresiduen effizient zu berechnen.

Beweis von (6.5)

Lemma

Sei A eine invertierbare Matrix, b ein Vektor λ ein Skalar. Für $\lambda \neq -\frac{1}{b'A^{-1}b}$ gilt:

$$(A + \lambda bb')^{-1} = A^{-1} - \left(\frac{\lambda}{1 + \lambda b'A^{-1}b} \right) A^{-1}bb'A^{-1} \quad (6.7)$$

Nachweis durch Nachrechnen

$$\left\{ A^{-1} - \left(\frac{\lambda}{1 + \lambda b'A^{-1}b} \right) A^{-1}bb'A^{-1} \right\} (A + \lambda bb') = I.$$

Beweis II

Wir zeigen zunächst

$$\hat{\beta} - \hat{\beta}_{(i)} = \left(\frac{\hat{\varepsilon}_i}{1 - h_{ii}} \right) (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_i \quad (6.8)$$

$$\left(\mathbf{X}'_{(i)} \mathbf{X}_{(i)} \right)^{-1} \mathbf{x}_i = \left(\frac{1}{1 - h_{ii}} \right) (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_i \quad (6.9)$$

Wir nutzen $\sum_{j=1}^n \mathbf{x}_j \mathbf{x}_j' = \mathbf{X}'\mathbf{X}$ und obiges Lemma

$$\begin{aligned} \left(\mathbf{X}'_{(i)} \mathbf{X}_{(i)} \right)^{-1} &= (\mathbf{X}'\mathbf{X} - \mathbf{x}_i \mathbf{x}_i')^{-1} \\ &= (\mathbf{X}'\mathbf{X})^{-1} + \frac{(\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_i \mathbf{x}_i' (\mathbf{X}'\mathbf{X})^{-1}}{1 - \mathbf{x}_i' (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_i} \end{aligned}$$

Es gilt also :

$$\begin{aligned} \left(\mathbf{X}'_{(i)} \mathbf{X}_{(i)} \right)^{-1} \mathbf{x}_i &= (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_i + (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_i \left(\frac{\mathbf{x}_i' (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_i}{1 - \mathbf{x}_i' (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_i} \right) \\ &= \left(\frac{1}{1 - h_{ii}} \right) (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_i \end{aligned}$$

aus den Normalengleichungen folgt

$$\mathbf{X}'\mathbf{X}\hat{\beta} = \mathbf{X}'\mathbf{y}$$

$$\left(\mathbf{X}'_{(i)}\mathbf{X}_{(i)} + x_i x_i'\right) \hat{\beta} = \mathbf{X}'_{(i)}y_{(i)} + x_i y_i$$

Multiplikation mit $\left(\mathbf{X}'_{(i)}\mathbf{X}_{(i)}\right)^{-1}$:

$$\left\{ I + \left(\mathbf{X}'_{(i)}\mathbf{X}_{(i)}\right)^{-1} x_i x_i' \right\} \hat{\beta} = \hat{\beta}_{(i)} + \left(\mathbf{X}'_{(i)}\mathbf{X}_{(i)}\right)^{-1} x_i \left(x_i' \hat{\beta} + \hat{\varepsilon}_i\right)$$

$$\hat{\beta} = \hat{\beta}_{(i)} + \left(\mathbf{X}'_{(i)}\mathbf{X}_{(i)}\right)^{-1} x_i \hat{\varepsilon}_i$$

$$= \hat{\beta}_{(i)} + (\mathbf{X}'\mathbf{X})^{-1} x_i \frac{\hat{\varepsilon}_i}{1 - h_{ii}}$$

wobei die letzte Gleichung aus (6.9) folgt.

Aus (6.8) ergibt sich:

$$\begin{aligned}\hat{\varepsilon}_i &= y_i - x_i' \hat{\beta} \\ &= y_i - x_i' \hat{\beta}_{(i)} - x_i' (\mathbf{X}'\mathbf{X})^{-1} x_i \frac{\hat{\varepsilon}_i}{1 - h_{ii}} = e_{(i)} - \frac{h_{ii}}{1 - h_{ii}} \hat{\varepsilon}_i\end{aligned}$$

Es folgt

$$e_{(i)} = \frac{\hat{\varepsilon}_i}{1 - h_{ii}} = \frac{\hat{\varepsilon}_i}{q_{ii}}$$

qed

Bei Zeitreihen verwendet man häufig:

$$\omega_i := \frac{y_i - \mathbf{x}'_i \hat{\boldsymbol{\beta}}_{[i-1]}}{\sqrt{1 - \mathbf{x}'_i (\mathbf{X}'_{[i-1]} \mathbf{X}_{[i-1]})^{-1} \mathbf{x}_i}} \quad i = p' + 1, \dots, n \quad (6.10)$$

$\hat{\boldsymbol{\beta}}_{[i-1]}$: Schätzung von $\boldsymbol{\beta}$ aus den ersten $i - 1$ Beobachtungen

$\mathbf{X}_{[i-1]}$: $\mathbf{X}$ -Matrix der ersten $i - 1$ Beobachtungen

Die Störterme ε_i sind nicht normalverteilt

Ursachen: Die Y-Variable stellt eine Zählgröße, eine Überlebenszeit, oder einen Anteil dar. Y ist nicht-negativ etc.

Folgen: Der KQ-Schätzer $\hat{\beta}$ ist immer noch erwartungstreuer Schätzer mit kleinster Varianz. Der F-Test ist i. a. robust. Problematisch sind insbesondere bei kleinen Stichprobenumfängen die Konfidenzintervalle der Parameter. Außerdem sind die Prognoseintervalle nicht mehr gültig, da hierbei die NV-Annahme besonders eingeht.

Diagnose: Schiefe und Kurtosis der Verteilung der Residuen, Normal-Plots der Residuen

Therapie: Transformationen der Y-Variablen, Verwendung von generalisierten linearen Modellen

Heterogene Varianzen

Die Varianz der Störterme ε_i ist von i abhängig.

Ursachen: Y Zählraten, Anteile. Gruppierte Daten führen zu verschiedenen Residualvarianzen innerhalb der Gruppen. Multiplikative Fehlerstruktur, d. h. σ_i ist abhängig von der Größe von Y_i .

Folgen: Der Schätzer für β ist erwartungstreu, aber er hat nicht mehr die kleinste Varianz; Konfidenzintervalle und Tests für β sind nicht mehr korrekt.

Diagnose: Residualplot der $\hat{\varepsilon}_i$ auf $\hat{Y}_i$; Berechnung der Residualvarianzen in den einzelnen Gruppen (bei gruppierten Daten).

Therapie: Transformation der Y -Variable; Gewichtete KQ-Schätzung.

(vgl. Fahrmeir et al.; S. 183)

Korrelation zwischen den Störtermen

Es gilt $\text{Cov}(\varepsilon_i, \varepsilon_j) \neq 0$ für einige $i \neq j$.

Ursachen: Zeitreihenstruktur oder räumliche Struktur der Daten führen zu positiver Korrelation von aufeinander folgenden (bzw. nahen) Beobachtungen. Residuen bei gruppierten Beobachtungen, bei denen die Gruppenzugehörigkeit nicht zusätzlich modelliert wird, sind häufig positiv korreliert.

Folgen: Der Schätzer von β bleibt erwartungstreu, aber nicht mit geringster Varianz; Bias bei der Varianzschätzung führt zu fehlerhaften Konfidenzintervallen und zu Problemen bei den F-Tests.

Diagnose: Analyse der Zeitreihenstruktur der Residuen, z.B. mit Durbin–Watson–Test; Plots der Residuen gegen die Zeit; Plots von $\hat{\varepsilon}_i$ gegen $\hat{\varepsilon}_{i-1}$.

Therapie: Verwendung von Zeitreihenmethoden; Einbeziehung von Trend und Saison; Gewichtete KQ-Methode .

(vgl. Fahrmeir et al.; S. 191-195)

Durbin-Watson-Test

Um zu testen, ob die Störterme ε_i und ε_{i-1} korreliert sind, benutzt man folgende Testgröße:

$$d := \frac{\sum_{i=2}^n (\hat{\varepsilon}_i - \hat{\varepsilon}_{i-1})^2}{\sum_{i=1}^n \hat{\varepsilon}_i^2} \approx 2(1 - \hat{\rho})$$

$\hat{\rho}$: Korrelation zwischen $\hat{\varepsilon}_i$ und $\hat{\varepsilon}_{i-1}$

$H_0: \rho = 0$

Lehne H_0 ab, falls $d \in [0, d_l]$ oder $d \in [4 - d_l, 4]$.

H_0 nicht ablehnen wenn $d \in [d_u, 4 - d_u]$

(d_l, d_u sind von p und n abhängige, feste Werte).

Kleine Werte von d : positives ρ

Große Werte von d : negatives ρ

$d \approx 2 \longrightarrow$ keine Autokorrelation

(vgl. Fahrmeir et al.; S. 195-197)

Ausreißer und Punkte mit starkem Einfluss

Einflussreiche Beobachtungen (high leverage points) sind in den X-Werten weit vom Zentrum der Daten entfernt.

Ausreißer haben dem Betrag nach sehr große Störterme.

Ursachen: Falsche Erhebung; Beobachtung gehört nicht zur Grundgesamtheit; Besonderheiten bei einzelner Untersuchungseinheit.

Folgen: Einflussreiche Beobachtungen wirken stark auf die Schätzung von β . Ausreißer können zu erheblicher Verzerrung der Schätzung von β führen. Dies gilt besonders für Ausreißer, die gleichzeitig high leverage points sind.

Diagnose: Analyse der Diagonalelemente der Hat-Matrix $\mathbf{P}$ zum Auffinden von high leverage points; Verschiedene Residuenplots zur Ausreißeranalyse; Influence-Statistiken.

Therapie: Fehlerhafte Daten weglassen (Sensitivitätsanalyse); Robuste Regression; Gewichtete Regression.

(vgl. Fahrmeir et al.; S. 160,161,164)

Wichtige Einflussmaße: Leverage

Das i -te Diagonalelement der Hat-Matrix $\mathbf{P}$

$$h_{ii} := \mathbf{x}_i'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_i \quad (6.11)$$

heißt **Leverage** der Beobachtung $\mathbf{x}_i$.

Es gilt:

$$\frac{1}{n} \leq h_{ii} \leq 1$$

Normalwert: $h_{ii} = \frac{p'}{n}$

großer Wert: $h_{ii} > \frac{2p'}{n}$

(vgl. Fahrmeir et al.; S.165)

Cook's Distanz:

$$D_i = \frac{(\hat{\beta}_{(i)} - \hat{\beta})'(\mathbf{X}'\mathbf{X})(\hat{\beta}_{(i)} - \hat{\beta})}{\hat{\sigma}^2 p'} \quad (6.12)$$

$\hat{\beta}_{(i)}$: Schätzung von β ohne Beobachtung i

Es gilt:

$$D_i = \underbrace{\frac{r_i^2}{p'}}_{\text{Residuen}} \cdot \underbrace{\frac{h_{ii}}{1 - h_{ii}}}_{\text{Leverage}} \quad (6.13)$$

$$D_i = \frac{(\hat{\mathbf{Y}}_{(i)} - \hat{\mathbf{Y}})'(\hat{\mathbf{Y}}_{(i)} - \hat{\mathbf{Y}})}{p' \hat{\sigma}^2} \quad (6.14)$$

Cook's Distanz wird im Vergleich mit den Beobachtungen interpretiert.

(vgl. Fahrmeir et al.; S. 165)

Regressionsgleichung ist nicht korrekt

Die Gleichung $\mathbf{Y} = \mathbf{X}\beta + \varepsilon$ ist fehlerhaft.

Ursachen: Variablen wurden weggelassen oder überflüssigerweise in das Modell einbezogen; Der Zusammenhang ist nicht linear; Interaktionen werden nicht in das Modell einbezogen.

Folgen: Systematische Fehler bei der Schätzung der Modellparameter und bei der Prognose; **Dennoch:** Modellschätzung liefert häufig brauchbare Näherung.

Diagnose: Residuenplots $\hat{\varepsilon}_i$ gegen $\hat{y}_i$; F-Tests auf Einfluss von weiteren Variablen; Interaktionen; Polynomterme höherer Ordnung, etc.

Therapie: Modellerweiterung; Transformationen der Einflussgrößen; Variablenselektionsverfahren.

Partial Leverage Plot

$\mathbf{y}^*$ auf $\mathbf{x}_k^*$ mit

$$\mathbf{y}^* := \mathbf{Q}_{(k)} \mathbf{y}$$

$$\mathbf{x}_k^* := \mathbf{Q}_{(k)} \mathbf{x}_k$$

$\mathbf{Q}_{(k)}$: $\mathbf{Q}$ -Matrix der Einflussgrößen **ohne** Variable k

$\implies$ Darstellung des Zusammenhangs zwischen $\mathbf{y}$ und der Einflussgröße $\mathbf{x}_k$ unter Berücksichtigung der übrigen Einflussgrößen

Die Spalten von $\mathbf{X}$ sind (annähernd) linear abhängig.

Ursachen: Hohe Korrelation zwischen den Einflussgrößen; Ungünstiges Versuchs-Design; Codierung von diskreten Variablen.

Folgen: Ungenaue Schätzung von β , häufig sogar falsches Vorzeichen;
Aber: Konfidenzintervalle korrekt und damit entsprechend groß.

Diagnose: Analyse der Matrix $(\mathbf{X}'\mathbf{X})$ und der Korrelationsmatrix der metrischen Einflussgrößen.

Therapie: Zusammenfassen bzw. Weglassen von Einflussgrößen; Verwendung von anderen Schätzmethoden, z.B.: Ridge-Regression.

(vgl. Fahrmeir et al.; S. 157)

a) Konditionszahl

$$K(\mathbf{X}) := \sqrt{\frac{\lambda_{\max}}{\lambda_{\min}}} \quad (6.15)$$

$\lambda_{\min}, \lambda_{\max}$: minimaler, bzw. maximaler Eigenwert von $\mathbf{X}'\mathbf{X}$

b) Varianz Inflationsfaktor

$$\text{VIF}_j := \frac{1}{1 - R_j^2} \quad (6.16)$$

R_j^2 : Bestimmtheitsmaß der Regression von $\mathbf{x}_j$ auf die übrigen $\mathbf{x}$
Es gilt für die Varianz von β_j :

$$\sigma_{\hat{\beta}_j} = \frac{\sigma^2}{(\mathbf{x}_j - \bar{\mathbf{x}}_j)'(\mathbf{x}_j - \bar{\mathbf{x}}_j)} \text{VIF}_j \quad (6.17)$$

Beachte: VIF ist auch für kategoriale Variablen geeignet.

(vgl. Fahrmeir et al.; S. 157,158)

Ursachen: Messfehler im engeren Sinne (Messgerät) und im weiteren Sinne (z.B. falsche Beantwortung von Fragen).

Folgen: Bei additivem Messfehler in x meist systematische betragsmäßige Unterschätzung der zu den fehlerhaft gemessenen Größen gehörigen β_i ; Geringere Power der entsprechenden F-Tests.

Diagnose: Mehrfach-Messungen der entsprechenden Größen

Therapie: Verwendung von Korrektur-Verfahren $\longrightarrow$ Theorie der Fehler-in-den-Variablen-Modelle

8. Das allgemeine lineare Modell: Gewichtete KQ-Methode, Autokorrelierte und heteroskedastische Störterme

Das allgemeine lineare Modell

Das lineare Modell mit heteroskedastischen Störgrößen ist gegeben durch:

$$Y = X\beta + \varepsilon \quad (7.1)$$

$$\varepsilon \sim N(0, \sigma^2 V) \quad (7.2)$$

$$V = \text{diag}(v_1, v_2, \dots, v_n) \quad (7.3)$$

V : bekannte Matrix zur Beschreibung der Varianzstruktur

Gewichtsmatrix: $W = V^{-1} = \text{diag}(v_1^{-1}, v_2^{-1}, \dots, v_n^{-1})$

(vgl. Fahrmeir et al.; S.192ff)

Transformation des Modells

Grundidee : Standardisieren zu Modell mit gleichen Varianzen

$$y_i = \beta_0 \cdot 1 + \beta_1 x_{i1} + \dots + \beta_p x_{ip} + \varepsilon_i$$

$$\text{mit } \text{Var}(\varepsilon_i) = v_i \sigma^2$$

$$\frac{y_i}{\sqrt{v_i}} = \beta_0 \cdot \frac{1}{\sqrt{v_i}} + \beta_1 \frac{x_{i1}}{\sqrt{v_i}} + \dots + \beta_p \frac{x_{ip}}{\sqrt{v_i}} + \frac{\varepsilon_i}{\sqrt{v_i}}$$

$$\text{mit } \text{Var}\left(\frac{\varepsilon_i}{\sqrt{v_i}}\right) = \sigma^2$$

Transformation

Das Modell (7.1)-(7.3) lässt sich in ein gewöhnliches lineares Modell transformieren. Dabei bezeichnet $W^{1/2}$ die Wurzel der Diagonalmatrix W . Es gilt dann $W^{1/2}(W^{1/2})' = W$.

$$Y^* := W^{1/2}Y \quad (7.4)$$

$$X^* := W^{1/2}X \quad (7.5)$$

$$\varepsilon^* := W^{1/2}\varepsilon \quad (7.6)$$

Dann gilt:

$$Y^* = X^*\beta + \varepsilon^* \quad (7.7)$$

$$\varepsilon^* \sim N(0, \sigma^2 I) \quad (7.8)$$

Der gewichtete KQ-Schätzer

Wir berechnen jetzt den KQ-Schätzer aus dem transformierten Modell

$$\begin{aligned}\hat{\beta}_W &:= (X^{*'} X^*)^{-1} X^{*'} Y^* \\ \hat{\beta}_W &:= (X' W'^{1/2} W^{1/2} X)^{-1} X' W'^{1/2} W^{1/2} Y \\ &= (X' V^{-1} X)^{-1} X' V^{-1} Y\end{aligned}\tag{7.9}$$

$$\hat{\sigma}^2 = (\hat{\varepsilon}' V^{-1} \hat{\varepsilon}) / (n - p')\tag{7.10}$$

$\hat{\beta}_W$ ist ML-Schätzer und minimiert die **gewichtete Residuenquadratsumme**

$$(Y - X\beta)' V^{-1} (Y - X\beta) = \sum_{i=1}^n \frac{1}{v_i} (y_i - x_i' \beta)^2\tag{7.11}$$

(vgl. Fahrmeir et al.; S. 195)

Verallgemeinerte KQ-Methode

Das lineare Modell mit allgemeiner Varianzstruktur ist gegeben durch:

$$Y = X\beta + \varepsilon \quad (7.12)$$

$$\varepsilon \sim N(0, \sigma^2 V) \quad (7.13)$$

$V \in R^{n \times n}$: beliebige, bekannte Kovarianzmatrix mit vollem Rang
Der **verallgemeinerte KQ-Schätzer** ist gegeben durch:

$$\hat{\beta}_W := (X' V^{-1} X)^{-1} X' V^{-1} Y \quad (7.14)$$

$$\hat{\sigma}^2 = (\hat{\varepsilon}' V^{-1} \hat{\varepsilon}) / (n - p') \quad (7.15)$$

(vgl. Fahrmeir et al.; S. 195)

Transformation

Wir definieren die allgemeine Gewichtsmatrix $W := V^{-1}$. Zu der Matrix W gibt es eine invertierbare Matrix $W^{1/2}$ mit

$$W^{1/2}(W^{1/2})' = W,$$

Das Modell (7.12)-(7.13) lässt sich wie oben in ein gewöhnliches lineares Modell transformieren:

$$Y^* := W^{1/2}Y \quad (7.16)$$

$$X^* := W^{1/2}X \quad (7.17)$$

$$\varepsilon^* := W^{1/2}\varepsilon \quad (7.18)$$

Dann gilt:

$$Y^* = X^*\beta + \varepsilon^* \quad (7.19)$$

$$\varepsilon^* \sim N(0, \sigma^2 I) \quad (7.20)$$

Eigenschaften des verallgemeinerten KQ-Schätzers

Gegeben sei das Modell (7.12) bis (7.13).

Dann gilt:

$$E(\hat{\beta}_W) = \beta \quad (7.21)$$

$$V(\hat{\beta}_W) = \sigma^2(X'V^{-1}X)^{-1} \quad (7.22)$$

Alle Testverfahren und Quadratsummenzerlegungen lassen sich im Modell $Y^* = X^*\beta + \varepsilon^*$ betrachten und damit auf den Fall homogener Varianzen zurückführen.

Allgemeines Gauss-Markov-Theorem

Gegeben sei das Modell

$$\begin{aligned} Y &= X\beta + \varepsilon, \quad \text{rg } X = p' \\ E(\varepsilon) &= 0 \\ V(\varepsilon) &= \sigma^2 V. \end{aligned}$$

Dabei ist die Matrix V als bekannt vorausgesetzt. Dann ist $\hat{\beta}_W$ unter den erwartungstreuen linearen Schätzern derjenige mit der kleinsten Varianz bzw. der BLUE-Schätzer (**b**est **l**inear **u**nbiased **e**stimator).

Beispiele für Varianzstrukturen

- Unterschiedliche Varianzen in Gruppen
- AR(1) (allgemeine Zeitreihenstruktur)
- Longitudinale Daten (Mehrdimensionale Zeitreihen) mit blockdiagonaler Struktur
- Symmetrische Struktur (gemischte Modelle)

AR(1)-Struktur für Zeitreihen

Der Index i entspricht einer Zeiteinheit (Jahr, Monat)

$$\varepsilon_i = \rho \varepsilon_{i-1} + \eta_i$$

$\text{Var}(\varepsilon_1) = \sigma^2 / (1 - \rho^2)$ und η_i unabh. mit Varianz σ^2 Dann ist

$$V = \sigma^2 \frac{1}{1 - \rho^2} \begin{pmatrix} 1 & \rho & \rho^2 & \dots & \rho^{n-1} \\ \rho & 1 & \rho & \dots & \rho^{n-2} \\ \rho^2 & \rho & 1 & \dots & \rho^{n-3} \\ & & & \ddots & \\ \rho^{n-1} & \rho^{n-2} & \rho^{n-3} & \dots & 1 \end{pmatrix} \quad (7.23)$$

Im Allgemeinen müssen die Parameter der Varianzstruktur geschätzt werden.

Dazu gibt es verschiedene Verfahren:

- ML
- REML (Restricted Maximum Likelihood)

Gegeben sei das Modell

$$\begin{aligned}Y &= X\beta + \varepsilon, \quad \text{rg } X = p' \\E(\varepsilon) &= 0 \\V(\varepsilon) &= \sigma^2 V(\vartheta).\end{aligned}$$

Der Parameter(vektor) ϑ ist zu schätzen.

Als Log-Likelihood ergibt sich (abgesehen von additiven Konstanten):

$$l(\beta, \vartheta) = -\frac{1}{2} (\ln |V(\vartheta)| + (\mathbf{Y} - X\beta)' V^{-1}(\vartheta) (\mathbf{Y} - X\beta)) \quad (7.24)$$

Ist ϑ bekannt, so ist der MLE von β bedingt auf ϑ (gewichteter KQ-Schätzer:)

$$\hat{\beta}(\vartheta) = \left(X' V(\vartheta)^{-1} X \right)^{-1} X' V^{-1}(\vartheta) Y. \quad (7.25)$$

Einsetzen liefert die Profil-Log-Likelihood:

$$l(\vartheta) = -\frac{1}{2} \left(\ln |V(\vartheta)| + (Y - X\beta(\vartheta))' V^{-1}(\vartheta) (Y - X\beta(\vartheta)) \right) \quad (7.26)$$

Maximieren von (7.26) bezüglich ϑ liefert den ML-Schätzer. Da dieser nicht erwartungstreu ist, verwendet man häufig den sogenannten restringierten ML-Schätzer:

Dieser maximiert

$$L_R(\vartheta) = l(\vartheta) - \frac{1}{2} \ln |X' V(\vartheta)^{-1} X| \quad (7.27)$$

Im einfachen linearen Modell entspricht der REML-Schätzer dem erwartungstreuen Schätzer von σ^2 .

Es gilt: $\hat{\beta}(\vartheta)$ einer multivariaten Normalverteilung mit Erwartungswert β und Kovarianzmatrix

$$\text{var}(\hat{\beta}) = (X'V^{-1}X)^{-1} \quad (7.28)$$

Da V unbekannt ist, wird es durch den (RE)ML-Schätzer $V(\hat{\vartheta})$ ersetzt.

Zur Konstruktion von Konfidenzintervallen und entsprechenden Tests nimmt man an, dass β asymptotisch normalverteilt ist. Für spezielle Modelle ist dies bewiesen, aber eine allgemeingültige asymptotische Normalverteilungsaussage ist nicht nachgewiesen.

Da die Varianzmatrix V nur geschätzt wird, werden in der Praxis deshalb häufig approximative t -Tests und entsprechende Konfidenzintervalle benutzt, die die Verteilung von $(\hat{\beta}_j - \beta_j)/\hat{s.e.}(\hat{\beta}_j)$ durch eine t -Verteilung approximieren und die zugehörigen Freiheitsgrade geeignet schätzen.

9. Das gemischte lineare Regressionsmodell („Linear mixed Model“)

Beispiel: Studie zur Leseförderung

- Zielgröße: Verbesserung der Lesefähigkeit
- Einflussgrößen: spezielle Förderung
- Störgröße: Ausgangsniveau
- Problem: Versuch wurde klassenweise durchgeführt

Voraussetzung der Unabhängigkeit der Störterme nicht erfüllt
(Cluster Daten)

Abhilfe: Einführung eines Klasseneffekts

Problem: Zu viele Parameter

Abhilfe: Klasseneffekt wird als zufälliger Effekt eingeführt.

Das Modell mit einem einfachen zufälligen Effekt (Varianzkomponenten-Modell, Random-Intercept-Modell)

Wir betrachten gruppierte Daten mit Gruppenindex i :

$$Y_{ij} = x'_{ij}\beta + \gamma_i + \epsilon_{ij} \quad i = 1, \dots, g; \quad j = 1, \dots, n_i \quad (8.1)$$

$$\epsilon_{ij} \sim N(0, \sigma^2) \text{ i.i.d.} \quad (8.2)$$

$$\gamma_i \sim N(0, \sigma_\gamma^2) \text{ i.i.d.} \quad (8.3)$$

γ_i und ϵ unabhängig

γ_i : Zufällige Effekte (Random Intercept)

Das marginale Modell

Das obige Modell kann umgeformt werden zu dem **marginalen Modell**

$$Y_{ij} = x'_{ij}\beta + \delta_{ij} \quad (8.4)$$

$$\delta_{ij} = \epsilon_{ij} + \gamma_i \quad (8.5)$$

$$\text{Var}(\delta_{ij}) = \sigma^2 + \sigma_\gamma^2 \quad (8.6)$$

$$\text{cov}(\delta_{i_1j_1}, \delta_{i_1j_2}) = \sigma_\gamma^2 \quad (8.7)$$

$$\text{cov}(\delta_{i_1j_1}, \delta_{i_2j_2}) = 0 \text{ für } i_1 \neq i_2. \quad (8.8)$$

Darstellung als allgemeines lineares Modell:

$$Y = X\beta + \delta$$

$$\delta \sim N(0, \sigma^2 I + \text{diag}[\sigma_\gamma^2 e_i e_i'])$$

$$e_i := \text{1-Vektor der Länge } n_i$$

Longitudinale Daten (Wiederholungsmessungen)

$$Y_{ij} = x'_{ij}\beta + \gamma_i + \epsilon_{ij} \quad i = 1, \dots, g; \quad j = 1, \dots, n_i \quad (8.9)$$

$$\epsilon_i \sim N(0, \sigma^2 \Sigma_i) \quad (8.10)$$

$$\gamma_i \sim N(0, \sigma_\gamma^2) \text{ i.i.d.} \quad (8.11)$$

γ_i und ϵ_i unabhängig

Y_{ij} : Wert von Y von Person i zum Zeitpunkt j

ϵ_i : Individueller Vektor der Störterme
mit Korrelationsstruktur Σ_i

γ_i : zufälliger Effekt

Darstellung als allgemeines lineares Modell

Marginales Modell:

$$Y = X\beta + \delta$$

$$\delta \sim N(0, \text{diag}(\sigma^2 \Sigma_i) + \text{diag}[\sigma_\gamma^2 e_i e_i'])$$

$$e_i := \text{1-Vektor der Länge } n_i$$

Inferenz im gemischten linearen Modell I

Die Inferenz erfolgt mit dem marginalen Modell, das ein allgemeines lineares Modell darstellt:

Sei $\boldsymbol{\vartheta}$ ein Vektor aller Parameter, die die Varianzstruktur bestimmen.

$\boldsymbol{\vartheta}$ und β können mit ML und REML geschätzt werden.

Als Log-Likelihood ergibt sich (abgesehen von additiven Konstanten):

$$l(\beta, \boldsymbol{\vartheta}) = -\frac{1}{2} (\ln |V(\boldsymbol{\vartheta})| + (\mathbf{Y} - X\beta)' V^{-1}(\boldsymbol{\vartheta}) (\mathbf{Y} - X\beta)) \quad (8.12)$$

Maximierung und REML- Schätzung siehe Folien im Kapitel zum allgemeinen linearen Modell, (7.27).

Interpretation der Ergebnisse

- Feste Effekte (β_k) wie im linearen Modell mit allen Varianten (Interaktionen etc.)
- Geschätzte Varianz σ_ϵ^2 (Reststreuung)
- Varianz des zufälligen Effekts σ_γ^2 (Varianzkomponente)
- Intra Class Korrelation

$$\frac{\sigma_\gamma^2}{\sigma_\gamma^2 + \sigma_\epsilon^2}$$

(Varianzanteil des zufälligen Effekts)

- Korrelationsparameter

- Mehrere zufällige Effekte, z.B. 'Person' und 'Wort' bei Sprachexperimenten
- Zufällige Steigungsparameter
- Schätzung der zufälligen Effekte
- Verschiedene Typen von Residuen
- Verschiedene Typen von R^2

Modell mit festen Effekten vs. gemischtes Modell

Bei longitudinalen Daten (Panel-Daten) wird zum Teil kontrovers diskutiert, ob es sinnvoll ist, ein gemischtes Modell einem Modell mit festem Personeneffekt vorzuziehen.

Argumente für ein Modell mit zufälligem Effekt

- deutlich weniger Parameter
- Zeit-konstante Personenmerkmale können in die Modellierung einbezogen werden.
- Sinnvolle Interpretierbarkeit des zufälligen Effekts

Argumente gegen ein Modell mit zufälligem Effekt

- Modellannahme für die Unabhängigkeit des zufälligen Effekts von x könnte verletzt sein.
- Effekte nur innerhalb von Personen relevant
- Einfacheres Modell

10. Das logistische Regressionsmodell

Fragestellung

Bisher: Metrische (bedingt normalverteilte) Zielgröße

Jetzt: Zielgröße binär:

$$Y_i = \begin{cases} 1, & \text{Ereignis} \\ 0, & \text{kein Ereignis} \end{cases}$$



Beispiele

- Y: Auftreten einer Krankheit in einem bestimmten Zeitraum (Ja/Nein), X: Exposition, Geschlecht, Alter, etc.
- Y: Kreditwürdigkeit (Ja/Nein), X: Personenmerkmale
- Y: Präferenz für eine Partei, X: Persönlichkeitsmerkmale
- Y: Bestehen eines Tests, X: Lehrmethode, Geschlecht, etc.
- Y: Ausfall eines Maschinenteils (Ja/Nein), X: Belastung

→ Man interessiert sich dafür, wie Einflussgrößen X mit dem Erwartungswert/der Wahrscheinlichkeit für ein Ereignis zusammenhängen

Beispiel Bauteile



960 Bauteile wurden unterschiedlichen Belastungen ausgesetzt
Y: Bauteil versagt (Ja/Nein), x: Belastungsgrad



Beispiel Bauteile

Schätzung des Erwartungswertes mit linearem Modell

$$E(Y_i|x_i) = \beta_0 + \beta_1 x_i$$



- Kann auch Werte außerhalb des gültigen Wertebereichs $[0, 1]$ liefern
- Schlechte Approximation an den Rändern des Wertebereichs von x

Das logistische Regressionsmodell

Y_i : binäre Zielgröße, $i = 1, \dots, n$ unabhängig (bei gegebenem, festem $\mathbf{x}_i$)
 $\mathbf{x}_i$: Vektor der Einflussgrößen

$$Y_i \sim \text{Ber}(\pi_i) \quad (9.1)$$

$$\pi_i = E(Y_i | \mathbf{x}_i) = P(Y_i = 1 | \mathbf{x}_i) = G(\eta_i = \mathbf{x}_i' \boldsymbol{\beta}) \quad (9.2)$$

$$\ln \frac{\pi_i}{1 - \pi_i} = \eta_i = \mathbf{x}_i' \boldsymbol{\beta} \quad (9.3)$$

$$G(\eta) = (1 + \exp(-\eta))^{-1} \quad (9.4)$$

Bezeichnungen:

$\ln \frac{\pi_i}{1 - \pi_i}$	:	„Logarithmierte Chance“ oder Log-odds
$\eta_i = \mathbf{x}_i' \boldsymbol{\beta} = \beta_0 + \dots + \beta_p x_p$	:	linearer Prädiktor
Funktion G	:	Response-Funktion (Inverse Link-Funktion)

(vgl. Fahrmeir et al.; S. 270-273)

Die Wahl von G (Verteilungsfunktion der logistischen Verteilung) als Responsefunktion ermöglicht folgende Interpretation:

Einfaches Modell:

$$P(Y = 1|x_1) = G(\beta_0 + \beta_1 * x_1)$$

$$P(Y = 1|x_1 + 1) = G[\beta_0 + \beta_1 * (x_1 + 1)]$$

$$\frac{P(Y = 1|x_1 + 1)/(1 - P(Y = 1|x_1 + 1))}{P(Y = 1|x_1)/(1 - P(Y = 1|x_1))} = \exp(\beta_1)$$

$$\ln \frac{P(Y = 1|x_1 + 1)}{1 - P(Y = 1|x_1 + 1)} - \ln \frac{P(Y = 1|x_1)}{1 - P(Y = 1|x_1)} = \beta_1$$

Interpretation

Das logistische Regressionsmodell nimmt einen linearen Zusammenhang zwischen den „Log-odds“ von Y und den Einflussgrößen x an.

Interpretation: Die folgenden Aussagen gelten für eine Einflussgröße x_k bei Festhalten aller anderen Einflussgrößen

- Erhöht sich x_k um eine Einheit, so ändert sich die logarithmierte Chance von Y um β_k .
- Wenn x_k um eine Einheit steigt, so ändert sich die Chance von Y um den Faktor $\exp(\beta_k)$.
- Das Odds Ratio (Chancenverhältnis) zwischen Y bei x_k und Y bei $x_k + 1$ ist $\exp(\beta_k)$.

W'keit	0.01	0.05	0.1	0.3	0.4	0.5	0.6	0.7	0.9	0.95	0.99
Odds	1/99	1/19	1/9	3/7	2/3	1	1.5	7/3	9	19	99
Log odds	-4.6	-2.9	-2.2	-0.85	-0.41	0	0.41	0.85	2.2	2.9	4.6

(vgl. Fahrmeir et al.; S. 287)

Die Varianten des multiplen linearen Regressionsmodells lassen sich direkt auf das logistische Modell übertragen:

- Behandlung von Gruppenvergleichen (ANOVA) mit Hilfe von Indikatorvariablen
- Behandlung von diskreten Einflussgrößen mit Hilfe verschiedener Codierungen, Interaktionen, etc.
- Behandlung von stetigen Einflussgrößen (Polynome, Splines, etc.)

Beachte:

Beim logistischen Modell „fehlt“ der Varianz-Parameter σ ,
da $\text{Var}(Y) = E(Y) * [1 - E(Y)]$

Weiter ist keine Verteilungsannahme nötig, da Y immer Bernoulli-verteilt ist.

Logistische Regression als Klassifikationsproblem

- Die Prognose in der logistischen Regression entspricht einem Klassifikationsproblem mit 2 Gruppen.
- Analogien zu Verfahren der Diskriminanzanalyse
- Diskriminanzregeln aus logistischer Regression möglich

ML-Schätzung im logistischen Regressionsmodell

Sei das Modell (9.2)–(9.4) gegeben.

$$\hat{\beta}_{ML} := \arg \max L(\beta) = \arg \max \ln L(\beta) \quad (9.5)$$

$$L(\beta) = \prod_{i=1}^n G(\mathbf{x}'_i \beta)^{Y_i} (1 - G(\mathbf{x}'_i \beta))^{1-Y_i} \quad (9.6)$$

$$\ln L(\beta) = \sum_{i=1}^n Y_i \ln(G(\mathbf{x}'_i \beta)) + (1 - Y_i) \ln(1 - G(\mathbf{x}'_i \beta)) \quad (9.7)$$

Ableiten nach β und Null setzen liefert unter Benutzung von $G' = G(1 - G)$ die Score-Gleichungen für $\hat{\beta}_{ML}$.

$$s(\hat{\beta}_{ML}) := \sum_{i=1}^n (Y_i - G(\mathbf{x}'_i \hat{\beta}_{ML})) \mathbf{x}_i = 0. \quad (9.8)$$

Eigenschaften des ML-Schätzers

Die allgemeine Theorie der Maximum-Likelihood-Schätzung liefert folgendes:

Für $n \rightarrow \infty$ gilt unter Regularitätsbedingungen:

$$\hat{\beta}_{ML} \rightarrow N(\beta, F^{-1}(\beta)) \quad (9.9)$$

$$F(\beta) = \mathbf{X}' D(\beta) \mathbf{X} \quad (9.10)$$

$$D(\beta) = \text{diag}\{(G(\mathbf{x}'_i \beta)(1 - G(\mathbf{x}'_i \beta)))\} \quad (9.11)$$

$$\hat{\beta}' F(\beta) \hat{\beta} \rightarrow \chi^2(p') \quad (9.12)$$

- Die asymptotische Varianzmatrix ergibt sich als Inverse der Fischer-Information (negative Ableitung der Score-Funktion)
- Die asymptotische Varianzmatrix entspricht auch der Varianzmatrix aus der gewichteten (heteroskedastischen) Regression, da $\text{Var}(Y) = D(\beta) = \text{diag}(G(\mathbf{x}'_i \beta)(1 - G(\mathbf{x}'_i \beta)))$
- Die numerische Berechnung des ML-Schätzers erfolgt nach der Methode der „iterierten, gewichteten Methode der kleinsten Quadrate“ (IWLS Iteratively Weighted Least Squares).

Existenz und Eindeutigkeit des ML-Schätzers im logistischen Modell

Eindeutigkeit:

Da die Likelihood-Funktion konkav ist, ist die Lösung der Score-Gleichung immer eindeutig

Existenz:

Der ML- Schätzer existiert $\iff$ Die Werte 0 und 1 sind nicht linear trennbar, d.h. es existiert kein α mit $Y = 1$ für $\mathbf{x}'\alpha > 0$ und $Y = 0$ für $\mathbf{x}'\alpha < 0$.

Im Fall der Nicht-Existenz geht mindestens eine Komponente gegen ∞ .
Im einfachen Modell bedeutet die Bedingung, dass $Y=1$ für $x > c$ und $Y=0$ für $x < c$.

Inferenz im logistischen Regressionsmodell

Beachte:

Alle Aussagen gelten - im Gegensatz zum linearen Regressionsmodell - nur asymptotisch, d.h. für hinreichend großen Stichprobenumfang

Wald-Konfidenzintervalle:

Wir benutzen die asymptotische Normalität und erhalten folgende Konfidenzintervalle für β zum Niveau α :

$$\hat{\beta}_k \pm \hat{\sigma}_{\hat{\beta}_k} z_{1-\alpha/2}$$

$$\hat{\sigma}_{\hat{\beta}_k} = \sqrt{c_{kk}} \text{ (k-tes Diagonalelement der Matrix } F^{-1}(\hat{\beta}))$$

Für die Odds-ratios $\exp(\beta_k)$ erhält man transformierte Konfidenzintervalle zum Niveau α :

$$\exp \left[\hat{\beta}_k \pm \hat{\sigma}_{\hat{\beta}_k} z_{1-\alpha/2} \right]$$

Da kein Varianzparameter zu schätzen ist, kommt die t -Verteilung hier nicht vor.

Wald-Test für die lineare Hypothese

Sei das logistische Regressionsmodell (9.1)–(9.4) gegeben.

$H_0 : \mathbf{A}\boldsymbol{\beta} = \mathbf{c}$ mit $\text{rg}(\mathbf{A}) = a$.

Analog zum linearen Modell wird folgende quadratische Form betrachtet:

$$W = (\mathbf{A}\hat{\boldsymbol{\beta}} - \mathbf{c})'(\mathbf{A}\mathbf{F}^{-1}(\hat{\boldsymbol{\beta}})\mathbf{A}')^{-1}(\mathbf{A}\hat{\boldsymbol{\beta}} - \mathbf{c})$$

W heißt Wald-Statistik.

Aus der asymptotischen Normalität folgt unmittelbar:

$$W \underset{\sim}{\stackrel{\text{as}}{\sim}} \chi^2(a)$$

Mit dieser Statistik lässt sich die allgemeine lineare Hypothese testen.

(vgl. Fahrmeir et al.; S. 285–287)

Likelihood-Quotienten-Test für die lineare Hypothese

Gegeben sei das logistische Regressionsmodell (9.2)–(9.4).

$H_0 : \mathbf{A}\beta = \mathbf{c}$ mit $\text{rg}(\mathbf{A})=a$.

Wir definieren folgende Teststatistik:

$$LQ = -2 \left\{ \ln L(\hat{\hat{\beta}}) - \ln L(\hat{\beta}) \right\}$$
$$\hat{\hat{\beta}} : \text{ML-Schätzer unter } H_0$$

Aus der allgemeinen Theorie von Likelihood-Quotienten-Tests folgt, dass unter H_0 gilt:

$$LQ \underset{\sim}{\text{as}} \chi^2(a)$$

Beachte: Der LQ -Test ist mit dem Wald-Test für endliche Stichproben nicht äquivalent. Äquivalenz gilt nur asymptotisch.

Likelihood-Quotienten-Konfidenzintervalle

Mit Hilfe des LQ -Tests lassen sich auch Konfidenzintervalle zum Niveau α konstruieren:

$$KI := \{\tilde{\beta}_k | H_0 : \beta_k = \tilde{\beta}_k \text{ wird mit LQ-Test zum Niveau } \alpha \text{ nicht abgelehnt}\}$$

Überprüfung der Modellgüte

- Viele Vorschläge für R^2
- Residuen wenig geeignet
- Gruppierte Daten ermöglichen Residualanalyse
- Strategie: Betrachte Modellerweiterungen
- Kreuzvalidierung für Prognosegüte

Gute Methode für Goodness of fit und Vorhersagekraft

Allgemein:

$Y = 1 \longrightarrow$ Ausfall (krank)

$Y = 0 \longrightarrow$ kein Ausfall (gesund)

In der medizinischen Literatur ist das Testergebnis m :

$$\hat{Y}_i = 1 \Leftrightarrow m_i \geq c \quad (9.13)$$

c ist dabei ein Grenzwert.

Richtig Positiv = Sensitivität:

$$P(\hat{Y} = 1|Y = 1) = P(m \geq c|Y = 1) = S_1(c) = 1 - F_1(c) \quad (9.14)$$

$S_1(c)$ stellt die Survivorfunktion dar, $F_1(c)$ die Verteilungsfunktion.


Falsch Positiv = 1 - Spezifität:

$$P(\hat{Y} = 1|Y = 0) = P(m \geq c|Y = 0) = S_0(c) \quad (9.15)$$

$$(9.16)$$

Die ROC-Kurve besteht aus den Punkten $(S_0(c), S_1(c))$.

Beispiel für ROC-Kurve



Logistische Regression und ROC-Kurve

$$m_i = G(\mathbf{x}_i' \beta)$$

$$m_i = \mathbf{x}_i' \beta$$

Beachte die Invarianz der ROC-Kurve bzgl. monotonen Funktionen! Die Verteilung von F_0, F_1 bzw. S_0, S_1 kann aus den Daten geschätzt werden
 $\Rightarrow$ ROC-Kurve

Alternative: Schätze F_0, F_1 bzw. S_0, S_1 aus Validierungsdaten.

Maß zur Bewertung der Kurve: AUC

$$AUC = \int_{t=0}^1 ROC(t) dt \quad (9.17)$$

Dies stellt die Fläche unter der Kurve dar.

Es gilt:

$$AUC = P(m_1 \leq m_0) \quad (9.18)$$

m_1 ist dabei aus der Verteilung $m|Y = 1$

m_0 ist dabei aus der Verteilung $m|Y = 0$

Daher ist das empirische AUC:

$$\widehat{AUC} = \frac{N_c}{N} \quad (9.19)$$

Dabei bezeichnet N_c die Anzahl der konkordanten Paare und N die Anzahl der Paare mit unterschiedlichem Y .

Die logistische Regression für Fall-Kontroll-Studien

Sei in der Grundgesamtheit folgende Beziehung gegeben:

$$P_0(Y = 1|X = x) = G(\alpha + \beta x) \quad (9.20)$$

mit $G(t) = (1 + \exp(-t))^{-1}$

X: Exposition

Y: Erkrankung

Es wird nun aus der GG gezogen:

n_1 : Fälle ($Y = 1$) und n_2 : Kontrollen ($Y = 0$)

Gesucht ist

$$P_S(Y = 1|X = x) \quad (9.21)$$

Mit P_S werden die Wahrscheinlichkeiten (Dichten) in der Stichprobe bezeichnet, mit P_0 die in der GG.

Berechnung von P_S I

$$\begin{aligned} P_S(Y = 1|X = x) &= \frac{P_S(Y = 1, X = x)}{P_S(X = x)} = \\ &= \frac{P_S(Y = 1)P_S(X = x|Y = 1)}{P_S(Y = 1)P_S(X = x|Y = 1) + P_S(Y = 0)P_S(X = x|Y = 0)} = \\ &= \frac{c_1 P_0(X = x|Y = 1)}{c_1 P_0(X = x|Y = 1) + c_2 P_0(X = x|Y = 0)} \end{aligned}$$

Die letzte Identität gilt wegen

$$P_0(X = x|Y = 1) = P_S(X = x|Y = 1) \quad (9.22)$$

und mit $c_1 = \frac{n_1}{n_1 + n_2}$ und $c_2 = \frac{n_2}{n_1 + n_2}$

$$c_1 P_0(X = x|Y = 1) = \frac{c_1}{P_0(Y = 1)} P_0(X = x) P_0(Y = 1|X = x)$$

$$c_2 P_0(X = x|Y = 0) = \frac{c_2}{P_0(Y = 0)} P_0(X = x) P_0(Y = 0|X = x)$$

Berechnung von P_S II

Mit $\frac{c_1}{P_0(Y=1)} = d_1$ und $\frac{c_2}{P_0(Y=0)} = d_2$ folgt:

$$\begin{aligned}P_S(Y=1|X=x) &= \frac{d_1 P(Y=1|X=x)}{d_1 P(Y=1|X=x) + d_2 (1 - P(Y=1|X=x))} \\&= \frac{1}{1 + \frac{d_2}{d_1} \frac{1 - G(\alpha + \beta x)}{G(\alpha + \beta x)}} \\&= \frac{1}{1 + \exp(-\alpha - \ln(\frac{d_1}{d_2}) - \beta x)}\end{aligned}$$

Die letzte Gleichung folgt aus $\frac{1 - G(t)}{G(t)} = \frac{1}{G(t)} - 1 = \exp(-t)$.

Berechnung von P_S III

Insgesamt gilt

$$P_S(Y = 1|X = x) = G\left(\alpha + \ln\left(\frac{d_1}{d_2}\right) + \beta x\right) \quad (9.23)$$


Die Auswertung bezüglich β kann also auch bei Fall- Kontrollstudien durch eine logistische Regression erfolgen. Der Parameter α in der Grundgesamtheit kann dabei nicht geschätzt werden.

- Die logistische Regression ist ein vielseitiges Werkzeug zur Modellierung binärer Ergebnisse.
- Anwendung in vielen Bereichen.
- Viele Techniken aus dem linearen Modell können übernommen werden (z.B. Indikatorvariablen, Splines, Testen von linearen Hypothesen).
- Es gibt enge Beziehungen zu Klassifikationsverfahren.
- Zu beachten ist die Interpretation auf der Log-Odds-Skala.



11. Variablenselektion

Modellwahl: Zielsetzung der Modellierung




- a) gute Beschreibung des Verhaltens der Zielgröße
- b) Vorhersage zukünftiger Werte der Zielgröße und Schätzung des Mittels der Zielgröße
- c) Extrapolation auf Bereiche außerhalb der X -Daten
- d) Schätzung von Parametern
- e) Kontrolle eines Prozesses durch Variation des Inputs
→ Kausalität nötig
- f) Entwicklung realistischer Modelle für einen Prozess
→ Kausalität nötig



Underfitting




Overfitting



Underfitting

Overfitting



Allgemein: „Tradeoff“ zwischen Modell-Genauigkeit (R^2) und Einfachheit.

Viele Variablen → R^2 steigt
→ Komplexität nimmt zu

a) b) Modellgenauigkeit wichtig

→ viele Variablen
→ Kausale Beziehung nicht nötig „Variable enthält Information“

c) Extrapolation

→ Kausalität

d) Bias durch Weglassen von Variablen

Erhöhung der Varianz von Schätzern durch überflüssige Variablen

Beachte: Interpretation der Regressionskoeff. „bei Festhalten der anderen Variablen“.

→ Einschränkung durch viele Kovariablen.

e) Kontrolle

→ Kausalität erforderlich

Realistische Beschreibung

→ Sparsames klares Modell

Kein Verfahren kann (zunächst bei den Zielen (c, d, e, f))
das Fachwissen ersetzen

→ Verfahren eher explorativ

Bei der Prognose können bei größeren Datenmengen
Variablenselektionsverfahren sehr effizient sein.

❶ Diskrete Variablen bereiten zusätzliche Probleme:

Gleiches gilt für Interaktionseffekte.

Es gibt „Regeln“ z.B.,

- a) Interaktionen nicht ohne Haupteffekte ins Modell
- b) Effekte von kategoriellen Variablen nur als Ganzes ins Modell

Andere Möglichkeit: Verwenden von Indikator-Variablen

→ Indikator-Variablen, die nicht im Modell sind, entsprechen der gemeinsamen Referenzkategorie

❷ Multikollinearität kann ein erhebliches Problem sein.

→ Korrelation der Kandidaten-Einflussgrößen analysieren

❸ Transformation, quadratische Terme liefern weitere Möglichkeiten

(vgl. Fahrmeir et al.; S. 151)

Maße für die Modellgüte I

Gegeben sei das lineare Modell $Y = X\beta + \varepsilon$

a) **Bestimmtheitsmaß:**

$$R^2 = \frac{SSM}{SST} = 1 - \frac{SSE}{SST} \quad (10.1)$$

b) **Adjustiertes Bestimmtheitsmaß:**

$$R_{adj}^2 := 1 - \frac{MSE}{MST} = 1 - \frac{\hat{\sigma}^2}{SST/(n-1)} \quad (10.2)$$

(vgl. Fahrmeir et al.; S. 147, 148)

c) Akaikes Informationskriterium

$$\begin{aligned} AIC &:= -2\log(l(\hat{\beta}, \hat{\sigma})) + 2(p' + 1) = \\ &= \ln(\text{SSE}) - n \ln(n) + 2(p' + 1) + \text{const} \end{aligned} \quad (10.3)$$

Ausgleich zwischen Anpassung (SSE) und Komplexität ($2p'$)

d) Schwarz'sches Bayes-Kriterium BIC

$$\text{SBC} = n \ln(\text{SSE}) + \ln(n)p' - n \ln(n) \quad (10.4)$$

Komplexität wird stärker gewichtet als bei AIC


(vgl. Fahrmeir et al.; S. 148)

Verwende Schätzung der Prognosegüte eines Modells als Kriterium
k-fache Kreuzvalidierung

- 1 Teile den Datensatz in k Teile von etwa gleicher Grösse
- 2 Verwende den ersten Datensatz als Validierungs-Datensatz und die übrigen zur Schätzung
- 3 Berechne Summe der quadratischen Vorhersagefehler (oder anderes Abweichungsmaß) für den ersten Datensatz
- 4 Analoge Berechnung für die übrigen $k-1$ Teile, d.h. es wird jeder Teildatensatz als Validierungsdatensatz verwendet.
- 5 Kreuzvalidierungsscore ergibt sich als Summe der k einzelnen Quadratsummen

Sonderfall: n Gruppen (einfache Kreuzvalidierung)

(vgl. Fahrmeir et al.; S. 149)



Variablenselektionsverfahren I

Gegeben ist eine Zielgröße Y und mehrere mögliche Einflussgrößen $x_k, k = 1, \dots, K$. Gesucht ist ein möglichst gutes Modell

$$Y = \beta_0 + \sum_{j=1}^L \beta_j x_{k_l},$$

wobei die $x_{k_l}, l = 1, \dots, L$ ausgewählt werden sollen.

❶ Auswahl nach einem Kriterium

Wähle aus allen möglichen 2^k Modellen das Modell mit optimalem Kriterium C aus. C ist in der Regel ein Kriterium aus (10.1) - (10.4).

② Vorwärtsselektion

- a) Wähle im Anfangsschritt das Modell $Y = \beta_0$.
- b) Im ersten Schritt wird die Variable in das Modell aufgenommen, die zu dem höchsten R^2 führt.
- c) In den weiteren Schritten wird jeweils eine Einflussgröße in das Modell zusätzlich aufgenommen. Es wird jeweils die Variable, die zu dem höchsten R^2 des resultierenden Modells führt, aufgenommen.
- d) **Stoppregel:** Die Prozedur wird beendet, falls ein bestimmtes Zielkriterium erfüllt ist, z.B. AIC

3 Rückwärts-Selektion

- a) Wähle im Anfangsschritt das volle Modell $Y = \sum_{k=0}^K \beta_k x_k$
- b) In den weiteren Schritten wird jeweils eine Einflussgröße aus dem Modell genommen. Es wird jeweils die Einflussgröße, die zu dem höchsten R^2 des resultierenden Modells führt, ausgeschlossen.
- c) **Stoppregel:** Nach Erfüllung eines bestimmtem Zielkriteriums, z.B. AIC.



4 Schrittweise Selektion:

Kombination aus Vorwärts- und Rückwärtsselektion. Es werden jeweils abwechselnd eine Vorwärtsselektion und eine Rückwärtsselektion mit geeignetem Stoppkriterium durchgeführt.

(vgl. Fahrmeir et al.; S. 151)

Folgen von Variablenselektion

- Überschätzung von R^2
- Überschätzung der Regressionskoeffizienten
- P-Werte und Konfidenzintervalle sind nicht valide
- Instabilität des Modells




Abschließende Bemerkungen

- Möglichst inhaltlich sparsames (Maximal-)–Modell vorgeben
- Strategie bei zentraler Einflussgröße:
 - Variablenselektion für „Confounder“-Modell ohne zentrale Einflussgröße
 - Test auf Effekt der zentralen Einflussgröße mit dem gewählten Confounder-Modell
- Prognoseintervalle etc. mit Kreuzvalidierung (evtl. unter Einbeziehung der Selektion)


Welche Variablen sollen in das Modell ?

Confounder




Confounder: Ja

Mediator



Mediator: Möglich, Interpretation ändert sich


Collider



Collider: Nein

- Es wurden in den letzten Jahren Methoden entwickelt, die Modellschätzung und Variablenselektion simultan erreichen, z.B. LASSO und Boosting-Verfahren; siehe Vorlesung Generalisierte Regression.
- Es gibt in der Regel nicht einfach ein bestes Modell, sondern mehrere passende Modelle. Bayes-Verfahren ermöglichen Inferenz dazu durch Berechnung von Wahrscheinlichkeiten für bestimmte Modelle.
- Eine Strategie in der Inferenz und Prognose besteht in dem sog. Model- Averaging: Man bestimmt Prognosen aus mehreren Modellen als gewichtetes Mittel der Einzel-Prognosen.
- Es wurden in den letzten Jahren einige Strategien zur Inferenz nach Modellwahl entwickelt: **Post Selection Inferenz**;

Explanatory modeling



Predictive modeling

