

Aufgabe 4: Multiples lineares Modell (I)

Auf der Homepage der World Bank können verschiedene Informationen zu den einzelnen Ländern der Welt heruntergeladen werden wie etwa Bevölkerungszahlen, CO₂-Emissionen und weitere Kenngrößen (<http://data.worldbank.org/indicator>). Der auf der Moodle-Homepage verfügbare Datensatz `wdi.RData` enthält eine Auswahl solcher Kenngrößen für die Jahre 2005 bis 2019.

Im Rahmen dieser Aufgabe sollen die CO₂-Emissionen der Länder anhand verschiedener Einflussgrößen modelliert werden. Die folgenden Kenngrößen zu den einzelnen Ländern werden dabei verwendet:

Variable	Erklärung
<code>CO2emission</code>	CO ₂ -Emissionen [in <i>kt</i>]
<code>Population</code>	Einwohnerzahl
<code>Area</code>	Fläche [in <i>km</i> ²]
<code>Employees.M.IND</code>	Anteil der Industriearbeiter unter männlichen Beschäftigten [in %]
<code>Livestock</code>	Tierischer Produktionsindex
<code>PopulationRural</code>	Einwohnerzahl der auf dem Land lebenden Bevölkerung
<code>GDP</code>	Bruttoinlandsprodukt [in US\$]

- Lesen Sie den Datensatz in **R** ein und beschränken sie diesen auf die Beobachtungen aus dem Jahr 2013. Führen Sie anschließend eine uni- und bivariate deskriptive Analyse der Variablen `Population` und `CO2emission` durch. Aus welchem Grund sollte man darüber nachdenken, die Daten zu transformieren?
- Modellieren Sie den Zusammenhang zwischen den beiden in Teilaufgabe (a) betrachteten Variablen sowohl für die transformierten als auch für die untransformierten Daten.
- Verschaffen Sie sich nun einen ersten Überblick darüber, wie die weiteren Kenngrößen im Datensatz mit den CO₂-Emissionen zusammenhängen. Transformieren Sie weitere extrem schief verteilte Variablen.
- Erweitern Sie nun das auf den transformierten Daten basierende Modell aus Teilaufgabe (b), indem Sie die Einflussgrößen `Area`, `Employees.M.IND` und `Livestock` hinzufügen. Interpretieren Sie die erhaltenen Koeffizientenschätzer (auf Ebene der transformierten Daten).
- Visualisieren Sie unter Verwendung des R-Paketes `visreg` für jede Einflussvariable ihren individuellen Beitrag zum linearen Prädiktor sowie die zugehörige Unsicherheit der Schätzung.
- Betrachten Sie den univariaten Zusammenhang zwischen `PopulationRural` und den CO₂-Emissionen. Fügen Sie die Variable zum multiplen linearen Regressionsmodell aus Teilaufgabe (d) hinzu, Interpretieren Sie den geschätzten Effekt für `PopulationRural`. Wie lässt sich der Unterschied zur univariaten Betrachtung erklären?
- Fügen Sie nun das (geeignet transformierte) `GDP` (Bruttoinlandsprodukt) zum Regressionsmodell aus Teilaufgabe (f) hinzu. Was fällt im Vergleich zum vorherigen Modell auf? Überlegen Sie sich eine Begründung für die beobachtete Veränderung.

Aufgabe 5: Multiples lineares Modell (II)

Ziel dieser Aufgabe ist es, mit realen Gehaltsdaten von "Data Scientist" Berufen ein plausibles Multiples lineares Modell zu schätzen.

Für die Bearbeitung der Aufgabe verwenden wir einen Datensatz, der Gehaltsinformationen der Berufsgruppe "Data Scientist" enthält. Der Datensatz kann inklusive Beschreibung der Kenngrößen unter folgendem Link heruntergeladen und eingesehen werden: (<https://www.kaggle.com/datasets/arnabchaki/data-science-salaries-2023>). Alternativ sind die Rohdaten unter `ds_salaries.csv` auf der Moodle-Homepage verfügbar. Die Aufgabe ist in zwei Teile gegliedert:

Teil 1 beschäftigt sich mit der Datensammlung und dem Datenmanagement und hat unter anderem das Ziel den Umgang mit **R** und im speziellen **tidyverse** zu schulen. Teil 1 wird in Teilaufgabe a) behandelt.

Teil 2 beschäftigt sich mit der Modellierung der bereits aufbereiteten Daten und behandelt den relevanten Stoff der Vorlesung. Der benötigte Datensatz `ds_salaries_adj.csv` kann bei Moodle heruntergeladen werden.

- (a) Laden Sie den Datensatz von Kaggle herunter und lesen Sie ihn in **R** ein. Beschränken Sie den Datensatz auf die Beobachtungen der Länder Deutschland, Großbritannien, und USA. Anschließend verknüpfen Sie die Rohdaten mit den Inflationsdaten, im speziellen dem harmonisierten Verbraucherpreisindex (engl. harmonised consumer price index, hcpi), die Sie von der Website der World Bank bekommen: <https://www.worldbank.org/en/research/brief/inflation-database>. Der finale Datensatz soll alle Variablen von `ds_salaries` und zusätzlich die Inflationsrate pro Jahr mit Referenzjahr 2020 enthalten.

Tipp: Verwenden Sie die Funktion `left_join` aus der library **tidyverse** und verknüpfen Sie die Daten mittels geeigneter eindeutiger Schlüssel (Land und Jahr). Ggf. müssen diese zunächst angepasst werden. Für die Berechnung der Inflationsrate pro Jahr ist die Funktion `cumsum` hilfreich.

- (b) Falls Sie Aufgabe (a) geschafft haben, rechnen Sie mit Ihrem Datensatz weiter. Alternativ, lesen Sie den Datensatz aus Moodle in **R** ein, beschränken Sie den Datensatz auf die Beobachtungen der Länder Deutschland, Großbritannien, und USA, und machen Sie sich vertraut mit den Daten. Führen Sie anschließend eine uni- und bivariate deskriptive Analyse der Zielgröße `salary_in_USD` und `company_location` durch. Aus welchem Grund sollte man darüber nachdenken die Daten zu transformieren?
- (c) Modellieren Sie den Zusammenhang zwischen `salary_in_USD`, `company_location`, `company_size`, und `year` sowohl für die transformierten als auch für die untransformierten Daten, Schreiben Sie die Strukturgleichung und Verteilungsannahmen für alle Modelle auf und interpretieren sie das Ergebnis.
- (d) Verwenden Sie im Folgenden ausschließlich die transformierten Daten und beschränken Sie den Datensatz auf die Jahre 2020 bis 2022. Schätzen Sie anhand dieser Trainingsdaten erneut das Modell aus Teilaufgabe (b) und ersetzen Sie dabei die Variable `work_year` durch `experience_level`.

Erstellen Sie anschließend auf Grundlage dieses Modells eine Prognose für die Gehälter von Data Scientists im Jahr 2023 (Testdaten). Wie gut ist die Prognosegüte dieses Modells?

- (e) Werfen Sie erneut einen Blick auf einzelne Einflussgrößen und diskutieren Sie Modellschwächen oder Verbesserungsansätze. Vergleichen Sie das neue Modell mit dem Modell aus Teilaufgabe (c).

April 14, 2026

Fragen und Kommentare an `mona.niethammer@stat.uni-muenchen.de`