

Aufgabe 6: Konfidenz- und Prognoseintervalle

Betrachten Sie in dieser Aufgabe erneut den Datensatz `wdi.RData`, der bereits in Aufgabe 4 verwendet wurde. Nun soll der Zusammenhang zwischen der Fläche und der Bevölkerung der Länder untersucht werden.

- (a) Lesen Sie den Datensatz in R ein, beschränken Sie diesen auf die Beobachtungen aus dem Jahr 2013, rechnen Sie die Bevölkerung in Tausend um und logarithmieren Sie die Variablen **Area** und **Population**.
- (b) Wählen Sie 100 Länder zufällig aus und berücksichtigen Sie diese zunächst nicht bei der weiteren Analyse. Modellieren Sie für die restlichen Länder den Zusammenhang zwischen Fläche und Bevölkerung für die logarithmierten Daten.
- (c) Berechnen Sie ein 99%-Konfidenzintervall für den geschätzten Steigungsparameter $\hat{\beta}_1$ und interpretieren Sie diesen.
- (d) Untersuchen Sie, ob die Bevölkerungsdichte zum Signifikanzniveau $\alpha = 0.01$ von der Fläche eines Landes abhängt. Verwenden Sie dafür den Zusammenhang zwischen Fläche und Bevölkerung für die logarithmierten Daten.
- (e) Berechnen Sie ein 95%-Konfidenzintervall für die geschätzte Regressionsgerade. Visualisieren und interpretieren Sie dieses Intervall.
- (f) Berechnen Sie für die 100 aus der ursprünglichen Schätzung herausgelassenen Länder ein 95%-Prognoseintervall. Welcher Anteil der wahren Werte liegt im berechneten Prognoseintervall? Vergleichen Sie das berechnete Prognoseintervall graphisch mit dem in Teilaufgabe (e) erstellten Konfidenzintervall.

Aufgabe 7: Lineare Hypothesentests

Der auf der Moodle-Homepage verfügbare Datensatz `sambia92.raw` enthält Informationen zum Ernährungszustand von Kindern in Sambia, die im Jahr 1992 von der Weltgesundheitsorganisation WHO erhoben wurden. Als Zielgröße für die Modellierung wird der sogenannte Z-Score verwendet, der eine Maßzahl für chronische Unterernährung darstellt.

Die folgenden Variablen werden in dieser Aufgabe betrachtet:

Variable	Erklärung
<code>zscore</code>	Z-Score (Index für chronische Unterernährung)
<code>k_geschl</code>	Geschlecht des Kindes
<code>k_still</code>	Stilldauer in Monaten
<code>k_alter</code>	Alter des Kindes in Monaten
<code>m_alterg</code>	Alter der Mutter bei der Geburt in Jahren
<code>m_groesse</code>	Körpergröße der Mutter in cm
<code>m_bmi</code>	Body-Mass-Index der Mutter

- (a) Lesen Sie den Datensatz in **R** ein und beschränken Sie diesen auf die Beobachtungen aus der am häufigsten im Datensatz vorkommenden Region Sambias. Verschaffen Sie sich einen ersten Überblick über den resultierenden Datensatz.
- (b) Schätzen Sie ein multiples lineares Regressionsmodell, um den Z-Score anhand der Kovariablen `k_geschl`, `k_still`, `k_alter`, `m_alterg`, `m_groesse` und `m_bmi` zu beschreiben.

Für das in Teilaufgabe (b) geschätzte Regressionsmodell sollen im Folgenden verschiedene lineare Hypothesen zum Signifikanzniveau $\alpha = 0.05$ getestet werden. Führen Sie die nachfolgenden Aufgaben in **R** durch und bestimmen sie zusätzlich für jeden Test die verwendeten Matrizen sowie die Verteilung der Teststatistik in allgemeiner Form.

- (c) Testen Sie, ob mindestens eine der verwendeten Kovariablen einen Zusammenhang mit dem Z-Score aufweist.
- (d) Testen Sie, ob die Stilldauer einen Zusammenhang mit der Zielgröße aufweist.
- (e) Testen Sie simultan, ob ein Zusammenhang mit dem Z-score und des Geschlechtes des Kindes oder des Alters der Mutter bei der Geburt auf dem Z-score vorliegt.
- (f) Testen Sie, ob die Größe der Mutter denselben Zusammenhang mit dem Z-Score hat wie ihr BMI.
- (g) Testen Sie, ob sich der Z-Score mit einem Anstieg des Kindesalters um einen Monat um 2 verringert.

May 20, 2026

Fragen und Kommentare an `mona.niethammer@stat.uni-muenchen.de`