

**Aufgabe 6:** Konfidenz- und Prognoseintervalle

Betrachten Sie in dieser Aufgabe erneut den Datensatz `wdi.RData`, der bereits in Aufgabe 4 verwendet wurde. Nun soll der Zusammenhang zwischen der Fläche und der Bevölkerung der Länder untersucht werden.

- (a) Lesen Sie den Datensatz in R ein, beschränken Sie diesen auf die Beobachtungen aus dem Jahr 2013, rechnen Sie die Bevölkerung in Tausend um und logarithmieren Sie die Variablen `Area` und `Population`.

**Lösung:**

```
load("../Daten/wdi.Rdata")

# Herausfiltern der Daten aus dem Jahr 2013,
# Selektion benötigter Variablen und Umrechnung der Bevölkerung in Tausend,
# Hinzufügen von log10-transformierten Variablen zum Datensatz:
wdi <- wdi %>% select(continent, country, year, Population, Area, CO2emission) %>%
  filter(year == 2013)%>%
  filter(!is.na(Population) | is.na(Area))%>%
  mutate(Population = Population / 1000,
         log10.Population = log10(Population),
         log10.CO2emission = log10(CO2emission),
         log10.Area = log10(Area))
```

- (b) Wählen Sie 100 Länder zufällig aus und berücksichtigen Sie diese zunächst nicht bei der weiteren Analyse. Modellieren Sie für die restlichen Länder den Zusammenhang zwischen Fläche und Bevölkerung für die logarithmierten Daten.

**Lösung:**

```
# Aufteilung der Daten in Trainings- und Testdaten:
set.seed(29042020)
wdi_test <- sample_n(tbl = wdi, size = 100)
wdi_train <- wdi %>% filter(!(country %in% wdi_test$country))

# Schätzung eines linearen Regressionsmodells unter Verwendung der
# log10-transformierten Daten:
lm_log10 <- lm(formula = log10.Population ~ log10.Area, data = wdi_train)
coef_lm_log10 <- round(x = coefficients(lm_log10), digits = 2)
coef_lm_log10

## (Intercept)  log10.Area
##          0.33         0.70
```

- (c) Berechnen Sie ein 99%-Konfidenzintervall für den geschätzten Steigungsparameter  $\hat{\beta}_1$  und interpretieren Sie diesen.

**Lösung:**

- Allgemeines Konfidenzintervall für Steigungsparameter  $\hat{\beta}_1$ :

$$[\hat{\beta}_1 - \hat{\sigma}_{\beta_1} t_{1-\frac{\alpha}{2}}(n-2); \hat{\beta}_1 + \hat{\sigma}_{\beta_1} t_{1-\frac{\alpha}{2}}(n-2)]$$

$t_{1-\frac{\alpha}{2}}(n-2)$  bezeichnet hierbei das  $(1-\frac{\alpha}{2})$ -Quantil der t-Verteilung mit zwei Freiheitsgraden,  $1-\alpha$  das Konfidenzniveau.

- Berechnung des 99%-Konfidenzintervalls für  $\hat{\beta}_1$  ( $\alpha = 0.01$ ):

```
KI_beta1 <- lm_log10$coef[2] + c(-1, 1) * summary(lm_log10)$coef[2, 2] *
  qt(p = 0.995, df = nrow(wdi_train) - 2)
KI_beta1

## [1] 0.5847713 0.8109384
```

⇒ In 99% der Fälle liegt der wahre Parameter  $\beta_1$  innerhalb des angegebenen Konfidenzintervalls.

⇒ Da der Wert 0 nicht im Konfidenzintervall enthalten ist, weist die Fläche eines Landes zum Signifikanzniveau  $\alpha = 0.01$  einen signifikanten Zusammenhang auf die Bevölkerungszahl auf.

- (d) Untersuchen Sie, ob die Bevölkerungsdichte zum Signifikanzniveau  $\alpha = 0.01$  von der Fläche eines Landes abhängt. Verwenden Sie dafür den Zusammenhang zwischen Fläche und Bevölkerung für die logarithmierten Daten.

### Lösung:

Zusammenhang zwischen Bevölkerungsdichte und Fläche gemäß des geschätzten Regressionsmodells:

$$\log_{10}(\text{Population}_i) = \beta_0 + \beta_1 \cdot \log_{10}(\text{Area}_i)$$

$$\log_{10}(\text{Population}_i) = \beta_0 + \log_{10}(\text{Area}_i^{\beta_1})$$

$$\text{Population}_i = 10^{\beta_0 + \log_{10}(\text{Area}_i^{\beta_1})}$$

$$\text{Population}_i = 10^{\beta_0} \cdot 10^{\log_{10}(\text{Area}_i^{\beta_1})}$$

$$\text{Population}_i = 10^{\beta_0} \cdot \text{Area}_i^{\beta_1}$$

$$\text{Bevölkerungsdichte}_i = \frac{\text{Population}_i}{\text{Area}_i} = \frac{10^{\beta_0} \text{Area}_i^{\beta_1}}{\text{Area}_i} = 10^{\beta_0} \text{Area}_i^{\beta_1-1}$$

⇒ Die Fläche hat einen signifikanten Einfluss auf die Bevölkerungsdichte, wenn der Wert 1 nicht innerhalb des berechneten Konfidenzintervalls liegt.

⇒ Die Fläche weist zum Signifikanzniveau  $\alpha = 0.01$  einen signifikanten Einfluss auf die Bevölkerungsdichte eines Landes auf.

- (e) Berechnen Sie ein 95%-Konfidenzintervall für die geschätzte Regressionsgerade. Visualisieren und interpretieren Sie dieses Intervall.

### Lösung:

- Allgemeines Konfidenzintervall für  $\mathbb{E}(y_i|x_i) = \hat{y}_i = \beta_0 + \beta_1 x_i$  ( $i = 1, \dots, n$ ):

$$\left[ \hat{y}_i - \hat{\sigma} \sqrt{\frac{1}{n} + \frac{(x_i - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}} t_{1-\frac{\alpha}{2}}(n-2); \hat{y}_i + \hat{\sigma} \sqrt{\frac{1}{n} + \frac{(x_i - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}} t_{1-\frac{\alpha}{2}}(n-2) \right]$$


- Berechnung eines 95%-Konfidenzintervalls für die erwartete logarithmierte Bevölkerungszahl anhand der Beobachtungen des Trainingsdatensatzes:

```
conf_int <- predict(object = lm_log10, interval = "confidence", level = 0.95)
head(conf_int)

##          fit          lwr          upr
## 1 4.389756 4.252026 4.527487
## 2 4.782003 4.609431 4.954574
## 3 1.937641 1.700807 2.174475
## 4 2.196592 1.987680 2.405505
## 5 4.828907 4.651755 5.006060
## 6 3.453599 3.344804 3.562393
```

- Graphische Visualisierung der Regressionsgerade mit Konfidenzintervall:

```
gg_conf <- ggplot(data = wdi_train,
                  mapping = aes(x = log10.Area, y = log10.Population,
                                label = country)) +
  geom_point() + geom_smooth(method = "lm", se = TRUE, level = 0.95) +
  xlab("log10(Fläche) [km^2]") +
  ylab("log10(Bevölkerung) [in Tsd.]") + theme
gg_conf
```



⇒ Unter Berücksichtigung der Modellannahmen liegt die geschätzte Regressionsgerade in 95% der Fälle innerhalb des Konfidenzintervalls. Die Interpretation des Konfidenzintervalls bezieht sich also auf die geschätzte Gerade, nicht auf eine explizite Beobachtung.

- Anteil der Beobachtungen des Trainingsdatensatzes innerhalb des Konfidenzintervalls:

```
is_covered <- function(y, lwr, upr) {
  mean(lwr <= y & y <= upr)
}
in_ci <- is_covered(wdi_train$log10.Population, conf_int[, "lwr"],
                   conf_int[, "upr"])
in_ci

## [1] 0.2368421
```

⇒ Ca. 23.7% der Beobachtungen liegen innerhalb des Konfidenzintervalls.

⇒ Das Niveau eines Konfidenzintervalls kann nicht dahingehend interpretiert werden, dass eine Beobachtung in  $(1 - \alpha)\%$  der Fälle innerhalb des Intervalls liegen sollte.

- (f) Berechnen Sie für die 100 aus der ursprünglichen Schätzung herausgelassenen Länder ein 95%-Prognoseintervall. Welcher Anteil der wahren Werte liegt im berechneten Prognoseintervall? Vergleichen Sie das berechnete Prognoseintervall graphisch mit dem in Teilaufgabe (e) erstellten Konfidenzintervall.

### Lösung:

- Allgemeines Prognoseintervall für eine neue Beobachtung  $y_{n+1}$ :

$$[\hat{y}_{n+1} - \hat{\sigma}_{\hat{y}_{n+1}} t_{1-\frac{\alpha}{2}}(n-2); \hat{y}_{n+1} + \hat{\sigma}_{\hat{y}_{n+1}} t_{1-\frac{\alpha}{2}}(n-2)]$$

$$\text{mit } \hat{\sigma}_{\hat{y}_{n+1}} = \hat{\sigma} \sqrt{1 + \frac{1}{n} + \frac{(x_{n+1} - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}}$$

- Berechnung eines 95%-Prognoseintervalls für die aus der Schätzung herausgelassenen Länder:

```
pred_int <- predict(object = lm_log10, newdata = wdi_test,
                    interval = "prediction", level = 0.95)
head(pred_int)

##           fit          lwr          upr
## 1 3.905181 2.772606 5.037757
## 2 5.139245 3.992780 6.285710
## 3 3.970727 2.837917 5.103537
## 4 5.216375 4.068386 6.364364
## 5 3.348714 2.215837 4.481592
## 6 4.163540 3.029710 5.297370
```

- Anteil der Beobachtungen des Testdatensatzes innerhalb des Prognoseintervalls:

```
in_pi <- is_covered(wdi_test$log10.Population, pred_int[, "lwr"],
                  pred_int[, "upr"])
in_pi


## [1] 0.98
```

⇒ 98 der 100 bei der Schätzung herausgelassenen Länder liegen innerhalb des 95%-Prognoseintervalls.

⇒ insgesamt gute Coverage

- Graphischer Vergleich zwischen 95%-Konfidenzintervall und 95%-Prognoseintervall:

```
pred_int <- cbind(wdi_test, pred_int)
gg_prog <- gg_conf +
  geom_line(data = pred_int, mapping = aes(y = lwr), col = "red") +
  geom_line(data = pred_int, mapping = aes(y = upr), col = "red")
gg_prog
```



⇒ Das Prognoseintervall ist deutlich weiter als das Konfidenzintervall, da die Berechnung zusätzlich die Streuung von  $\epsilon_{n+1}$  berücksichtigt.

### Aufgabe 7: Lineare Hypothesentests

Der auf der Moodle-Homepage verfügbare Datensatz `sambia92.raw` enthält Informationen zum Ernährungszustand von Kindern in Sambia, die im Jahr 1992 von der Weltgesundheitsorganisation WHO erhoben wurden. Als Zielgröße für die Modellierung wird der sogenannte Z-Score verwendet, der eine Maßzahl für chronische Unterernährung darstellt.

Die folgenden Variablen werden in dieser Aufgabe betrachtet:

| Variable               | Erklärung                                     |
|------------------------|-----------------------------------------------|
| <code>zscore</code>    | Z-Score (Index für chronische Unterernährung) |
| <code>k_geschl</code>  | Geschlecht des Kindes                         |
| <code>k_still</code>   | Stilldauer in Monaten                         |
| <code>k_alter</code>   | Alter des Kindes in Monaten                   |
| <code>m_alterg</code>  | Alter der Mutter bei der Geburt in Jahren     |
| <code>m_groesse</code> | Körpergröße der Mutter in cm                  |
| <code>m_bmi</code>     | Body-Mass-Index der Mutter                    |

- (a) Lesen Sie den Datensatz in **R** ein und beschränken Sie diesen auf die Beobachtungen aus der am häufigsten im Datensatz vorkommenden Region Sambias. Verschaffen Sie sich einen ersten Überblick über den resultierenden Datensatz.

#### Lösung:

- Einlesen des Datensatzes und Überblick über Daten:

```
sambia <- read.table(file = "../Daten/sambia92.raw", header = TRUE)
head(sambia)

##      zscore k_geschl k_still k_alter m_alterg m_groesse m_bmi m_bildung m_arbeit
## 1    -159         0      0      4 24.66667    148.9 21.83         2         0
## 2    -205         0     13     26 22.83333    148.9 21.83         2         0
## 3    -192         1     18     56 15.33333    169.2 20.43         2         1
## 4    -146         1      0      6 21.50000    162.2 22.27         3         0
## 5     69         0      6     54 17.50000    162.2 22.27         3         0
## 6    -80         0      0      1 30.91667    162.8 22.86         2         0
##      district region zeit
## 1         81      1     1
## 2         81      1     1
## 3         81      1     1
## 4         81      1     1
## 5         81      1     1
## 6         81      1     1

str(sambia)

## 'data.frame': 4421 obs. of 12 variables:
##  $ zscore   : int  -159 -205 -192 -146 69 -80 -34 -17 -225 468 ...
##  $ k_geschl : int   0 0 1 1 0 0 0 1 0 1 ...
##  $ k_still  : int   0 13 18 0 6 0 0 0 18 19 ...
##  $ k_alter  : int   4 26 56 6 54 1 2 2 29 14 ...
##  $ m_alterg : num  24.7 22.8 15.3 21.5 17.5 ...
##  $ m_groesse: num  149 149 169 162 162 ...
##  $ m_bmi    : num  21.8 21.8 20.4 22.3 22.3 ...
##  $ m_bildung: int   2 2 2 3 3 2 2 2 2 2 ...
##  $ m_arbeit : int   0 0 1 0 0 0 0 1 1 1 ...
##  $ district : int  81 81 81 81 81 81 81 81 81 81 ...
```

```
## $ region : int 1 1 1 1 1 1 1 1 1 1 ...
## $ zeit    : int 1 1 1 1 1 1 1 1 1 1 ...

summary(sambia)

##      zscore      k_geschl      k_still      k_alter
## Min.   :-600.0    Min.    :0.0000    Min.    : 0.00    Min.    : 0.00
## 1st Qu.: -257.0    1st Qu.:0.0000    1st Qu.: 1.00    1st Qu.:12.00
## Median : -171.0    Median :0.0000    Median :14.00    Median :26.00
## Mean   : -171.2    Mean    :0.4902    Mean    :11.12    Mean    :27.12
## 3rd Qu.:  -86.0    3rd Qu.:1.0000    3rd Qu.:19.00    3rd Qu.:42.00
## Max.    : 503.0    Max.    :1.0000    Max.    :46.00    Max.    :59.00
##      m_alterg      m_groesse      m_bmi      m_bildung
## Min.    :13.17    Min.    :134.0    Min.    :13.15    Min.    :1.000
## 1st Qu.:21.08    1st Qu.:154.0    1st Qu.:19.75    1st Qu.:2.000
## Median :25.33    Median :158.1    Median :21.46    Median :2.000
## Mean    :26.40    Mean    :158.1    Mean    :22.00    Mean    :2.022
## 3rd Qu.:31.08    3rd Qu.:162.0    3rd Qu.:23.57    3rd Qu.:2.000
## Max.    :48.67    Max.    :185.0    Max.    :39.29    Max.    :4.000
##      m_arbeit      district      region      zeit
## Min.    :0.0000    Min.    :12.00    Min.    :1.000    Min.    :1
## 1st Qu.:0.0000    1st Qu.:36.00    1st Qu.:2.000    1st Qu.:1
## Median :1.0000    Median :66.00    Median :5.000    Median :1
## Mean    :0.5526    Mean    :63.09    Mean    :4.646    Mean    :1
## 3rd Qu.:1.0000    3rd Qu.:89.00    3rd Qu.:7.000    3rd Qu.:1
## Max.    :1.0000    Max.    :99.00    Max.    :9.000    Max.    :1
```

- Beschränkung auf Beobachtungen aus der am häufigsten vorkommenden Region Sambias:

```
table(sambia$region)

##
##  1  2  3  4  5  6  7  8  9
## 393 967 410 394 609 430 260 659 299


sambia <- sambia %>% filter(region == 2) %>% select(zscore:m_bmi)
head(sambia)

##      zscore k_geschl k_still k_alter m_alterg m_groesse m_bmi
## 1      -65         0      20      54 31.50000     150.5 21.77
## 2     -274         0      25      30 24.50000     155.2 20.01
## 3     -217         0      25      30 24.50000     155.2 20.01
## 4         3         1      17      58 22.16667     155.2 20.01
## 5      -37         1        1      14 23.83333     157.6 18.92
## 6     -132         1      18      44 21.33333     157.6 18.92
```


⇒ Für die weitere Aufgabe wird nur noch Region 2 betrachtet.

- Graphische Visualisierung von nach Geschlecht getrennten metrischen Variablen:

```
# Boxplots:
ggplot(data = gather(sambia, variable, value, -k_geschl)) +
  geom_boxplot(aes(y = value, x = factor(k_geschl))) +
  facet_wrap(~variable, scale = "free") + theme
```



```
# Dichteschätzungen:
ggplot(data = gather(sambia, variable, value, -k_geschl)) +
  geom_density(aes(x = value, col = factor(k_geschl))) +
  facet_wrap(~variable, scale = "free") + theme
```



- ⇒ Anhand der beiden Visualisierungen sind keine großen Unterschiede zwischen den Geschlechtern erkennbar.
- ⇒ In den Dichteschätzungen werden im Gegensatz zu den Boxplots multimodale Verteilungen erkennbar.



- (b) Schätzen Sie ein multiples lineares Regressionsmodell, um den Z-Score anhand der Kovariablen `k_geschl`, `k_still`, `k_alter`, `m_alterg`, `m_groesse` und `m_bmi` zu beschreiben.

### Lösung:

```
model_full <- lm(formula = zscore ~ k_geschl + k_still + k_alter + m_alterg +
                  m_groesse + m_bmi,
                  data = sambia)
summary(model_full)

##
## Call:
## lm(formula = zscore ~ k_geschl + k_still + k_alter + m_alterg +
##     m_groesse + m_bmi, data = sambia)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -476.45  -81.20   -3.89   83.86  645.60
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -878.3136   124.2593  -7.068 3.01e-12 ***
## k_geschl      -16.3002    8.9042   -1.831  0.0675 .
## k_still       -0.3257    0.8057   -0.404  0.6861
## k_alter       -1.9640    0.4039   -4.862 1.36e-06 ***
## m_alterg       1.2221    0.7397    1.652  0.0988 .
## m_groesse      4.4221    0.7560    5.850 6.75e-09 ***
## m_bmi          2.8108    1.2107    2.322  0.0205 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 138.1 on 960 degrees of freedom
## Multiple R-squared:  0.1013, Adjusted R-squared:  0.09571
## F-statistic: 18.04 on 6 and 960 DF, p-value: < 2.2e-16
```

Für das in Teilaufgabe (b) geschätzte Regressionsmodell sollen im Folgenden verschiedene lineare Hypothesen zum Signifikanzniveau  $\alpha = 0.05$  getestet werden. Führen Sie die nachfolgenden Aufgaben in **R** durch und bestimmen sie zusätzlich für jeden Test die verwendeten Matrizen sowie die Verteilung der Teststatistik in allgemeiner Form.

- (c) Testen Sie, ob mindestens eine der verwendeten Kovariablen einen Zusammenhang mit dem Z-Score aufweist.

### Lösung:

- Situation: Überprüfung, ob mindestens eine Kovariable einen Zusammenhang mit der Responsevariable hat
- Anzuwendender Test: Overall-F-Test mit Hypothesen

$$H_0 : \beta_1 = \dots = \beta_p = 0 \text{ vs. } H_1 : \exists \beta_j \neq 0 \text{ für } j = 1, \dots, p$$

- Matrizen:

$$A = \begin{pmatrix} 0 & 1 & \dots & 0 \\ 0 & & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & & \dots & 1 \end{pmatrix} \in \mathbb{R}^{p \times p'}, c = \begin{pmatrix} 0 \\ \vdots \\ 0 \end{pmatrix} \in \mathbb{R}^p$$

- Verteilung der Teststatistik:

$$TF \sim F(p, n - p') \text{ bzw. } TF \sim F(6, n - 7)$$

- Durchführung des Tests in **R**:

- Summary des lm-Objektes:

```
summary(model_full)
##
## Call:
## lm(formula = zscore ~ k_geschl + k_still + k_alter + m_alterg +
##     m_groesse + m_bmi, data = sambia)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -476.45  -81.20   -3.89   83.86  645.60
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -878.3136   124.2593  -7.068 3.01e-12 ***
## k_geschl     -16.3002    8.9042   -1.831  0.0675 .
## k_still       -0.3257    0.8057   -0.404  0.6861
## k_alter       -1.9640    0.4039   -4.862 1.36e-06 ***
## m_alterg       1.2221    0.7397    1.652  0.0988 .
## m_groesse      4.4221    0.7560    5.850 6.75e-09 ***
## m_bmi         2.8108    1.2107    2.322  0.0205 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 138.1 on 960 degrees of freedom
## Multiple R-squared:  0.1013, Adjusted R-squared:  0.09571
## F-statistic: 18.04 on 6 and 960 DF,  p-value: < 2.2e-16
```

- Berechnung über Package **car**:

```
A <- matrix(data = 0, nrow = 6, ncol = 7)
diag(A[, 2:7]) <- 1
c <- 0
linearHypothesis(model = model_full, hypothesis.matrix = A, rhs = c,
                  test = "F")
##
## Linear hypothesis test:
## k_geschl = 0
## k_still = NA
## k_alter = NA
## m_alterg = NA
## m_groesse = NA
## m_bmi = NA
##
## Model 1: restricted model
## Model 2: zscore ~ k_geschl + k_still + k_alter + m_alterg + m_groesse +
##     m_bmi
##
##      Res.Df      RSS Df Sum of Sq    F    Pr(>F)
## 1      966 20364927
## 2      960 18301427   6    2063500 18.04 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- Manuelle Berechnung:

```

# Definition der Modellparameter:
X <- model.matrix(model_full)
beta_hat <- as.vector(model_full$coefficients)
p <- length(beta_hat)-1
A <- cbind(rep(0, p), diag(p))
c <- rep(0, p)
a <- nrow(A)
n <- nrow(sambia)

# Berechnung der Teststatistik:
SSH <- as.vector(t(A %%% beta_hat - c) %%%
                 solve(A %%% solve(t(X) %%% X) %%% t(A)) %%%
                 (A %%% beta_hat - c))
SSE <- as.vector(sum(model_full$residuals^2))
TF <- (SSH / a) / (SSE / (nrow(sambia) - length(beta_hat)))
TF

## [1] 18.04013

# Testentscheidung:
TF > qf(p = 0.95, df1 = a, df2 = n - p - 1)

## [1] TRUE

```

⇒ Die Nullhypothese kann zum Signifikanzniveau  $\alpha = 0.05$  abgelehnt werden.

⇒ Mindestens eine der betrachteten Kovariablen weist also einen signifikanten Zusammenhang mit dem Z-score auf.

(d) Testen Sie, ob die Stlldauer einen Zusammenhang mit der Zielgröße aufweist.

### Lösung:

- Situation: Test auf Zusammenhang der Kovariable und der Responsevariable.
- Hypothesen:  $H_0 : \beta_{k_{still}} = 0$  vs.  $H_1 : \beta_{k_{still}} \neq 0$
- Matrizen:  $A = \begin{pmatrix} 0 & 0 & 1 & 0 & 0 & 0 & 0 \end{pmatrix} \in \mathbb{R}^{1 \times 7}$ ,  $c = (0) \in \mathbb{R}^1$
- Teststatistik:  $TF \sim F(1, n - 7)$
- Durchführung des Tests in **R**:

– Package **car**:

```

A <- c(0, 0, 1, 0, 0, 0, 0)
c <- 0
linearHypothesis(model = model_full, hypothesis.matrix = A, rhs = c,
                  test = "F")

##
## Linear hypothesis test:
## k_still = 0
##
## Model 1: restricted model
## Model 2: zscore ~ k_geschl + k_still + k_alter + m_alterg + m_groesse +
##           m_bmi
##
##   Res.Df      RSS Df Sum of Sq    F Pr(>F)
## 1     961 18304542
## 2     960 18301427  1    3115.1 0.1634 0.6861

```

– Vergleich der Quadratsummen über Funktion **anova()**:

```

model_d <- lm(formula = zscore ~ k_geschl + k_alter + m_alterg + m_groesse +
              m_bmi,
              data = sambia)
summary(model_d)

```

```
##
## Call:
## lm(formula = zscore ~ k_geschl + k_alter + m_alterg + m_groesse +
##      m_bmi, data = sambia)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -473.82  -81.41   -3.56   83.53  643.77
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -878.7131   124.2013  -7.075 2.88e-12 ***
## k_geschl     -16.2501     8.8995  -1.826  0.0682 .
## k_alter       -2.0891     0.2594  -8.055 2.34e-15 ***
## m_alterg       1.2278     0.7393   1.661  0.0971 .
## m_groesse      4.4250     0.7556   5.856 6.50e-09 ***
## m_bmi         2.7950     1.2096   2.311  0.0211 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 138 on 961 degrees of freedom
## Multiple R-squared:  0.1012, Adjusted R-squared:  0.0965
## F-statistic: 21.63 on 5 and 961 DF,  p-value: < 2.2e-16
anova(model_d, model_full)
## Analysis of Variance Table
##
## Model 1: zscore ~ k_geschl + k_alter + m_alterg + m_groesse + m_bmi
## Model 2: zscore ~ k_geschl + k_still + k_alter + m_alterg + m_groesse +
##      m_bmi
##      Res.Df        RSS Df Sum of Sq      F Pr(>F)
## 1         961 18304542
## 2         960 18301427  1    3115.1 0.1634 0.6861
```

⇒ Die Quadratsumme des vollen Modells wird hierbei mit der Quadratsumme des gemäß der Nullhypothese restringierten Modells verglichen, d.h. in diesem Fall mit der Quadratsumme des Modells ohne die Stildauer.

– Standardoutput des lm-Objektes (t-Test):

```
summary(model_full)
##
## Call:
## lm(formula = zscore ~ k_geschl + k_still + k_alter + m_alterg +
##      m_groesse + m_bmi, data = sambia)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -476.45  -81.20   -3.89   83.86  645.60
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -878.3136   124.2593  -7.068 3.01e-12 ***
## k_geschl     -16.3002     8.9042  -1.831  0.0675 .
## k_still       -0.3257     0.8057  -0.404  0.6861
## k_alter       -1.9640     0.4039  -4.862 1.36e-06 ***
## m_alterg       1.2221     0.7397   1.652  0.0988 .
## m_groesse      4.4221     0.7560   5.850 6.75e-09 ***
## m_bmi         2.8108     1.2107   2.322  0.0205 *
## ---
```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 138.1 on 960 degrees of freedom
## Multiple R-squared:  0.1013, Adjusted R-squared:  0.09571
## F-statistic: 18.04 on 6 and 960 DF,  p-value: < 2.2e-16
summary(model_full)$coef["k_still", ]
##      Estimate Std. Error    t value    Pr(>|t|)
## -0.3256864   0.8056894 -0.4042332   0.6861313
summary(model_full)$coef["k_still", "t value"]^2
## [1] 0.1634045
```

⇒ Bei einem Test bezüglich des Zusammenhangs einer einzigen Kovariable ist ein zweiseitiger t-Test äquivalent zum allgemeineren F-Test.

⇒ Die quadrierte angegebene t-Teststatistik entspricht der F-Teststatistik des allgemeinen linearen Hypothesentests.

⇒ Die Nullhypothese kann zum Signifikanzniveau  $\alpha = 0.05$  nicht abgelehnt werden.

⇒ Die Stilldauer weist also keinen signifikanten Zusammenhang mit dem Z-score auf.

(e) Testen Sie simultan, ob ein Zusammenhang mit dem Z-score und des Geschlechtes des Kindes oder des Alters der Mutter bei der Geburt auf dem Z-score vorliegt.

### Lösung:

- Situation: Gleichzeitiger Test auf Zusammenhang mit dem Z-score und mehrerer Variablen
- Hypothesen:  $H_0 : \beta_{\text{geschl}} = \beta_{\text{m\_alterg}} = 0$  vs.  $H_1 : \beta_{\text{geschl}} \neq 0$  oder  $\beta_{\text{m\_alterg}} \neq 0$
- Matrizen:

$$A = \begin{pmatrix} 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 \end{pmatrix} \in \mathbb{R}^{2 \times 7}, c = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \in \mathbb{R}^2$$

- Teststatistik:  $TF \sim F(2, n - 7)$
- Durchführung des Tests in **R**:

– Package **car**:

```
A <- rbind(c(0, 1, 0, 0, 0, 0, 0), c(0, 0, 0, 0, 1, 0, 0))
c <- c(0, 0)
linearHypothesis(model = model_full, hypothesis.matrix = A, rhs = c,
                  test = "F")

##
## Linear hypothesis test:
## k_geschl = 0
## m_alterg = 0
##
## Model 1: restricted model
## Model 2: zscore ~ k_geschl + k_still + k_alter + m_alterg + m_groesse +
##           m_bmi
##
##      Res.Df      RSS Df Sum of Sq    F Pr(>F)
## 1      962 18414971
## 2      960 18301427  2    113545 2.978 0.05137 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

– Vergleich der Quadratsummen:

```
model_e <- lm(formula = zscore ~ k_still + k_alter + m_groesse + m_bmi,
              data = sambia)
summary(model_e)
```

```
##
## Call:
## lm(formula = zscore ~ k_still + k_alter + m_groesse + m_bmi,
##     data = sambia)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -466.01  -82.06   -2.45    82.90   639.93
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -864.4660    123.6598  -6.991 5.11e-12 ***
## k_still      -0.3305     0.8071   -0.409 0.68229
## k_alter      -1.9757     0.4046  -4.883 1.22e-06 ***
## m_groesse     4.4077     0.7573   5.820 8.01e-09 ***
## m_bmi         3.3921     1.1505   2.948 0.00327 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 138.4 on 962 degrees of freedom
## Multiple R-squared:  0.09575, Adjusted R-squared:  0.09199
## F-statistic: 25.47 on 4 and 962 DF,  p-value: < 2.2e-16
anova(model_e, model_full)
## Analysis of Variance Table
##
## Model 1: zscore ~ k_still + k_alter + m_groesse + m_bmi
## Model 2: zscore ~ k_geschl + k_still + k_alter + m_alterg + m_groesse +
##          m_bmi
##    Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      962 18414971
## 2      960 18301427  2    113545 2.978 0.05137 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- ⇒ Die Nullhypothese kann zum Signifikanzniveau  $\alpha = 0.05$  nicht abgelehnt werden.
- ⇒ Die beiden Variablen tragen zusammen betrachtet nicht signifikant zur Erklärung des Z-Scores bei. Es ist möglich, dass
- \* Keine Variable einzeln signifikant ist
  - \* Eine Variable einzeln signifikant ist, aber ihr gemeinsamer Beitrag nicht
  - \* Multikollinearität zwischen Geschlecht und Alter der Mutter bei der Geburt den gemeinsamen Test beeinflussen könnte

(f) Testen Sie, ob die Größe der Mutter denselben Zusammenhang mit dem Z-Score hat wie ihr BMI.

### Lösung:

- Situation: Test auf Gleichheit von Parametern
- Hypothesen:  $H_0 : \beta_{m_{groesse}} = \beta_{m_{bmi}}$  vs.  $H_1 : \beta_{m_{groesse}} \neq \beta_{m_{bmi}}$
- Matrizen:  $A = \begin{pmatrix} 0 & 0 & 0 & 0 & 0 & 1 & -1 \end{pmatrix} \in \mathbb{R}^{1 \times 7}, c = (0) \in \mathbb{R}^1$
- Teststatistik:  $TF \sim F(1, n - 7)$
- Durchführung des Tests in **R**:
  - Package **car**:

```
A <- c(0, 0, 0, 0, 0, 1, -1)
c <- 0
```

```
linearHypothesis(model = model_full, hypothesis.matrix = A, rhs = c,
                 test = "F")

##
## Linear hypothesis test:
## m_groesse - m_bmi = 0
##
## Model 1: restricted model
## Model 2: zscore ~ k_geschl + k_still + k_alter + m_alterg + m_groesse +
##          m_bmi
##
##   Res.Df      RSS Df Sum of Sq      F Pr(>F)
## 1     961 18325800
## 2     960 18301427  1      24373 1.2785 0.2585
```

– Vergleich der Quadratsummen:

```
model_f <- lm(formula = zscore ~ k_geschl + k_still + k_alter + m_alterg +
              I(m_groesse + m_bmi),
              data = sambia)
summary(model_f)

##
## Call:
## lm(formula = zscore ~ k_geschl + k_still + k_alter + m_alterg +
##     I(m_groesse + m_bmi), data = sambia)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -476.94  -81.94   -3.04   84.82  637.66
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    -826.3825    115.4766  -7.156 1.64e-12 ***
## k_geschl        -16.4950     8.9038  -1.853  0.0642 .
## k_still         -0.3551     0.8054  -0.441  0.6594
## k_alter         -1.9710     0.4039  -4.879 1.25e-06 ***
## m_alterg         0.9875     0.7101   1.391  0.1647
## I(m_groesse + m_bmi)  3.9713     0.6423   6.182 9.32e-10 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 138.1 on 961 degrees of freedom
## Multiple R-squared:  0.1001, Adjusted R-squared:  0.09545
## F-statistic: 21.39 on 5 and 961 DF,  p-value: < 2.2e-16
anova(model_f, model_full)

## Analysis of Variance Table
##
## Model 1: zscore ~ k_geschl + k_still + k_alter + m_alterg + I(m_groesse +
##          m_bmi)
## Model 2: zscore ~ k_geschl + k_still + k_alter + m_alterg + m_groesse +
##          m_bmi
##
##   Res.Df      RSS Df Sum of Sq      F Pr(>F)
## 1     961 18325800
## 2     960 18301427  1      24373 1.2785 0.2585
```

⇒ Die Nullhypothese kann zum Signifikanzniveau  $\alpha = 0.05$  nicht abgelehnt werden.

⇒ Ein gleich großer Zusammenhang der Größe der Mutter und deren BMI ist also möglich.

- (g) Testen Sie, ob sich der Z-Score mit einem Anstieg des Kindesalters um einen Monat um 2 verringert.

## Lösung:

- Test auf Wert eines Regressionsparameters:
- Hypothesen:  $H_0: \beta_{k_{alter}} = -2$  vs.  $H_1: \beta_{k_{alter}} \neq -2$
- Matrizen:  $A = \begin{pmatrix} 0 & 0 & 0 & 1 & 0 & 0 & 0 \end{pmatrix} \in \mathbb{R}^{1 \times 7}, c = -2$
- Teststatistik:  $TF \sim F(1, n - 7)$
- Durchführung des Tests in R:

– Package `car`:

```
A <- c(0, 0, 0, 1, 0, 0, 0)
c <- -2
linearHypothesis(model = model_full, hypothesis.matrix = A, rhs = c,
                  test = "F")

##
## Linear hypothesis test:
## k_alter = - 2
##
## Model 1: restricted model
## Model 2: zscore ~ k_geschl + k_still + k_alter + m_alterg + m_groesse +
##           m_bmi
##
##           Res.Df      RSS Df Sum of Sq      F Pr(>F)
## 1           961 18301578
## 2           960 18301427   1    151.39 0.0079  0.929
```

– Vergleich der Quadratsummen:

```
model_g <- lm(formula = zscore ~ k_geschl + k_still + m_alterg + m_groesse +
               m_bmi + offset(-2 * k_alter),
               data = sambia)
summary(model_g)

##
## Call:
## lm(formula = zscore ~ k_geschl + k_still + m_alterg + m_groesse +
##     m_bmi + offset(-2 * k_alter), data = sambia)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -476.04  -81.16   -3.47    83.92   645.30
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -878.2722    124.1943   -7.072 2.94e-12 ***
## k_geschl      -16.3062     8.8993   -1.832  0.0672 .
## k_still       -0.2707     0.5173   -0.523  0.6009
## m_alterg        1.2204     0.7391    1.651  0.0990 .
## m_groesse       4.4240     0.7553    5.857 6.45e-09 ***
## m_bmi          2.8146     1.2093    2.327  0.0202 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 138 on 961 degrees of freedom
## Multiple R-squared:  0.04805, Adjusted R-squared:  0.0431
## F-statistic: 9.701 on 5 and 961 DF, p-value: 4.72e-09
anova(model_g, model_full)

## Analysis of Variance Table
##
```



```
## Model 1: zscore ~ k_geschl + k_still + m_alterg + m_groesse + m_bmi +
##      offset(-2 * k_alter)
## Model 2: zscore ~ k_geschl + k_still + k_alter + m_alterg + m_groesse +
##      m_bmi
##      Res.Df      RSS Df Sum of Sq      F Pr(>F)
## 1      961 18301578
## 2      960 18301427  1      151.39 0.0079  0.929
```

⇒ Die Nullhypothese kann zum Signifikanzniveau  $\alpha = 0.05$  nicht abgelehnt werden.

⇒ Der Effekt bezüglich des Kindesalters ist also nicht signifikant vom Wert  $-2$  verschieden.

May 20, 2026

Fragen und Kommentare an [mona.niethammer@stat.uni-muenchen.de](mailto:mona.niethammer@stat.uni-muenchen.de)