

**Aufgabe 11:** Metrische Kovariablen

Der auf der Moodle-Homepage verfügbare Datensatz `wagen.txt` enthält Informationen zu 172 VW Golf-Modellen. Die folgende Tabelle gibt einen Überblick über die Variablen des Datensatzes:

| Variable                | Beschreibung                                        |
|-------------------------|-----------------------------------------------------|
| <code>preis</code>      | Verkaufspreis [in 1000 €]                           |
| <code>alter</code>      | Alter des Autos [in Monaten]                        |
| <code>kilstand</code>   | Kilometerstand [in 1000 km]                         |
| <code>tuev</code>       | Anzahl der Monate bis zur nächsten TÜV-Untersuchung |
| <code>sonderaus1</code> | Sonderaustattung vorhanden? (Ja = 1, Nein = 0)      |

In dieser Aufgabe soll der Verkaufspreis eines Autos in Abhängigkeit des Alters und des Kilometerstandes modelliert werden.

- Lesen Sie den Datensatz in **R** und visualisieren Sie das Alter und den Verkaufspreis sowie den Kilometerstand und den Verkaufspreis jeweils in einem Streudiagramm. Was fällt bezüglich der beiden dargestellten Zusammenhänge auf?
- Fitten Sie ein lineares Modell in **R**, das für Alter und Kilometerstand jeweils polynomiale Terme bis zum vierten Grad inkludiert, d.h. `alter2`, `alter3`, `alter4`, `kilstand2`, `kilstand3` und `kilstand4`. Betrachten Sie den Output der Funktionen `summary()` und `anova()` für das Modell. Was fällt dabei auf?
- Bestimmen Sie für beide Kovariablen den optimalen Grad des Polynoms zur Modellierung des Verkaufspreises.
- Schätzen Sie nun die Effekte für das Alter und den Kilometerstand durch Regressionsplines, Truncated Power mit 3 Knoten und Polynomgrad 2. Vergleichen Sie die Modellgüte sowie die geschätzten Effekte mit dem besten Modell aus Teilaufgabe (c).

**Aufgabe 12:** Modelldiagnose

Betrachten Sie das multiple lineare Regressionsmodell

$$Y_i = \beta_0 + \beta_1 \cdot x_{1i} + \beta_2 \cdot x_{2i} + \epsilon_i, \quad i = 1, \dots, n, \quad (1)$$

mit  $x_{1i} = i, x_{2i} = i \bmod 2, \epsilon_i \sim N(\mu = 0, \sigma^2 = \frac{1}{3})$  unabhängig,  $\beta_0 = 7, \beta_1 = 0.01$  und  $\beta_2 = 1$ .

- Simulieren Sie drei Datensätze gemäß dieses Regressionsmodells mit  $n = 10, n = 100$  und  $n = 1000$  Beobachtungen. Berechnen Sie für jeden dieser Datensätze die Parameterschätzer für  $\beta_0, \beta_1, \beta_2$  und  $\sigma^2$  und diskutieren Sie die Ergebnisse.
- Beschreiben Sie gängige Diagnosegraphiken für lineare Regressionsmodelle und erstellen Sie diese für die in Teilaufgabe (a) geschätzten Modelle.
- Wie verändern sich die Modellschätzungen, wenn der Einfluss von  $x_1$  bzw.  $x_2$  ignoriert wird? Erstellen Sie für beide Fälle erneut geeignete Diagnosegraphiken und beurteilen Sie diese.
- Betrachten Sie nun verschiedene Modellabweichungen von Modell (1) mit  $n = 1000$  Beobachtungen:

- (i) Setzen Sie im obigen Datensatz für eine Beobachtung  $Y_i$  einen extremen Wert (Ausreißer) ein.
- (ii) Simulieren Sie einen neuen Datensatz gemäß Modell (1), wobei die Fehler  $\epsilon_i$  nun keiner Normalverteilung, sondern einer Gleichverteilung auf dem Intervall  $[-1, 1]$  folgen sollen.
- (iii) Simulieren Sie einen neuen Datensatz gemäß Modell (1) mit heteroskedastischen Fehlern  $\epsilon_i \sim N(\mu = 0, \sigma^2 = \frac{2i}{300})$ .
- (iv) Simulieren Sie einen neuen Datensatz gemäß Modell (1), wobei der Term  $\beta_1 \cdot x_{1i}$  in der Modellgleichung durch  $\beta_1 \cdot \frac{x_{1i}^2}{100}$  ersetzt werden soll.

### Aufgabe 13: Überprüfung von Modellannahmen

Betrachten Sie das lineare Modell  $Y = X\beta + \epsilon$  mit der Annahme  $\epsilon \sim \mathcal{N}_n(0, \sigma^2 I_n)$  bezüglich der Verteilung der Störterme. In dieser Aufgabe sollen die in dieser Annahme enthaltenen Aspekte genauer betrachtet werden.

- (a) Beschreiben Sie mögliche Abweichungen von dieser Annahme.
- (b) Im Folgenden sind einige Anwendungsbeispiele für lineare Modelle skizziert. Die Abweichungen von welcher Annahme würden Sie in den untenstehenden Beispielen je primär untersuchen? Welche Diagnostik würden Sie jeweils verwenden, um die entsprechenden Annahmen zu überprüfen?
  - (i)  $Y$ : Konsum in einem Quartal (in Euro)  
 $X$ : verschiedene ökonomische Größen
  - (ii)  $Y$ : Gewichtsreduktion nach einer Therapie (in kg)  
 $X$ : Gruppierungsvariable (drei Kategorien), Gewicht zu Beginn, Alter
  - (iii)  $Y$ : Mathematikfähigkeit (gemessen mit Score, erhoben bei allen Schülern einer Schule)  
 $X$ : Alter, Geschlecht, IQ
  - (iv)  $Y$ : Zeit bis zum Verlassen des Krankenhauses  
 $X$ : Typ der Krankheit (kategorial), Geschlecht, Alter

April 13, 2026

Fragen und Kommentare an [laura.bader@stat.uni-muenchen.de](mailto:laura.bader@stat.uni-muenchen.de)