

Aufgabe 14: Allgemeines lineares Modell

Der auf der Moodle-Homepage verfügbare Datensatz `zufriedenheit.txt` beinhaltet einen Auszug aus den Daten des Sozio-ökonomischen Panels der Jahre 1986 bis 2006, einer jährlich durchgeführten repräsentativen Haushaltsbefragung in Deutschland. Die zur Verfügung gestellten Daten enthalten folgende Variablen:

Variable	Erklärung
<code>id</code>	Personen-ID
<code>wellbeing</code>	Lebenszufriedenheit auf Skala von 1 bis 10
<code>age</code>	Alter in Jahren
<code>origin</code>	Herkunft aus West- oder Ostdeutschland (1: <code>west</code> , 0: <code>east</code>)
<code>sex</code>	Geschlecht (1: <code>female</code> , 0: <code>male</code>)
<code>year</code>	Jahr der Befragung

In dieser Aufgabe soll die Lebenszufriedenheit in Abhängigkeit des Alters, des Geschlechtes und der Herkunft der Befragten modelliert werden.

- Lesen Sie den Datensatz in **R** ein und verschaffen Sie sich einen ersten Überblick über die Daten. Visualisieren Sie jeweils den univariaten Zusammenhang zwischen der Lebenszufriedenheit und den Einflussgrößen `origin`, `sex`, `year` und `age`.
- Passen Sie das Regressionsmodell

$$Y = \beta_0 + \beta_1 \cdot x_{origin} + \beta_2 \cdot x_{sex} + \beta_3 \cdot x_{year} + f(x_{age}) + \varepsilon$$

an die Daten an, wobei $f(x_{age})$ mit Hilfe eines Regressionsplines von Grad $g = 3$ mit drei inneren Knotenpunkten $K = 3$ geschätzt werden soll. Interpretieren Sie die Modellergebnisse.

- Ein lineares Modell mit verallgemeinerter Varianzstruktur ist durch $Y = X\beta + \epsilon$ und $\epsilon \sim \mathcal{N}(0, \mathbf{V})$ gegeben. Erklären Sie mögliche Strukturen der Kovarianzmatrix **V**. Welche Annahmen eines klassischen linearen Modells werden jeweils aufgehoben?
- Erweitern Sie das Modell aus Teilaufgabe (b), indem Sie für die Fehler innerhalb der einzelnen Personen von einem Autoregressiven Prozess 1. Ordnung ausgehen.

Aufgabe 15: Gemischtes lineares Modell

Der bereits häufiger betrachtete Datensatz `wdi.Rdata` soll nun verwendet werden, um die logarithmierten CO_2 -Emissionen der Länder für den Zeitraum von 2005 bis 2013 gemeinsam zu modellieren. Als Einflussgrößen sollen die (geeignet transformierten) Variablen `Population`, `Area`, `Employees.M.IND`, `Livestock`, `PopulationRural`, `GDP` und `continent` in die Analyse einbezogen werden.

- Stellen Sie für die neun Länder mit den höchsten CO_2 -Emissionen im Jahr 2005 die Verläufe der CO_2 -Emissionen über die Jahre dar. Was fällt dabei auf?
- Fitten Sie nun zunächst ein lineares Modell mit allen Kovariablen und erklären Sie, warum das Modell in diesem Fall nicht passend ist.

- (c) Geben Sie an, wie man berücksichtigen könnte, dass jedes Land ein unterschiedliches Ausgangsniveau hat. Diskutieren Sie zwei Ansätze sowie deren Vor- und Nachteile.
- (d) Ausgehend vom Modell aus Teilaufgabe (b) soll nun zusätzlich für jedes Land ein individueller zufälliger Effekt (Random Intercept) in das Modell aufgenommen werden. Stellen Sie die zugehörige Modellgleichung (inkl. aller Modellannahmen) auf.
- (e) Schätzen Sie das in der vorherigen Teilaufgabe spezifizierte Modell und stellen Sie die Verteilung der zufälligen Effekte graphisch dar.
- (f) Berechnen und interpretieren Sie die Intra-Class-Correlation.

Aufgabe 16: Variablenselektion

Im Folgenden soll eine Simulationsstudie zum Vergleich verschiedener Verfahren zur Variablenselektion durchgeführt werden.

- (a) Simulieren Sie 1000 Datensätze mit jeweils $n = 100$ Beobachtungen aus dem Modell

$$y_i = 100 + 3x_1 - 0.5x_2 + 0.05x_3 + \varepsilon_i \quad \text{mit } \varepsilon_i \sim N(0, \sigma^2) \text{ und } i = 1, \dots, 100.$$

Ziehen Sie dabei x_1, x_2 und x_3 aus einer Standardnormalverteilung und fügen Sie weitere ebenfalls standardnormalverteilte Variablen $x_4, \dots, x_{10}$, die nicht mit dem Outcome zusammenhängen, zum Datensatz hinzu.

- (b) Führen Sie unter Verwendung der Funktion `stepAIC()` aus dem **R**-Paket **MASS** für alle Datensätze eine Variablenselektion nach dem AIC-Kriterium durch und betrachten Sie die Anzahl der Fälle, in denen im Endmodell die mit dem Outcome assoziierten Variablen enthalten sind. Wie oft wurde das richtige Modell gewählt?

Vergleichen Sie hierbei die folgenden Varianten der Variablenselektion:

- Vorwärtss Selektion
 - Rückwärtss Selektion
 - Stepwise forward
 - Stepwise backward
 - Vergleich aller möglichen Modelle.
- (c) Vergleichen Sie die Ergebnisse aus der vorherigen Teilaufgabe mit den Ergebnissen, die man über eine Variablenselektion mittels 10-facher Kreuzvalidierung erhält.

June 30, 2026

Fragen und Kommentare an laura.bader@stat.uni-muenchen.de