

Aufgabe 14: Allgemeines lineares Modell

Der auf der Moodle-Homepage verfügbare Datensatz `zufriedenheit.txt` beinhaltet einen Auszug aus den Daten des Sozio-ökonomischen Panels der Jahre 1986 bis 2006, einer jährlich durchgeführten repräsentativen Haushaltsbefragung in Deutschland. Die zur Verfügung gestellten Daten enthalten folgende Variablen:

Variable	Erklärung
<code>id</code>	Personen-ID
<code>wellbeing</code>	Lebenszufriedenheit auf Skala von 1 bis 10
<code>age</code>	Alter in Jahren
<code>origin</code>	Herkunft aus West- oder Ostdeutschland (1: <code>west</code> , 0: <code>east</code>)
<code>sex</code>	Geschlecht (1: <code>female</code> , 0: <code>male</code>)
<code>year</code>	Jahr der Befragung

In dieser Aufgabe soll die Lebenszufriedenheit in Abhängigkeit des Alters, des Geschlechtes und der Herkunft der Befragten modelliert werden.

- (a) Lesen Sie den Datensatz in **R** ein und verschaffen Sie sich einen ersten Überblick über die Daten. Visualisieren Sie jeweils den univariaten Zusammenhang zwischen der Lebenszufriedenheit und den Einflussgrößen `origin`, `sex`, `year` und `age`.

Lösung:

- Einlesen der Daten und Überblick über Datensatz:

```
data <- read.table(file = "../Daten/zufriedenheit.txt", header = TRUE)
head(data)

##   id wellbeing age origin sex year
## 1  1         6  47      1   0 1989
## 2  1         7  48      1   0 1990
## 3  1         5  49      1   0 1991
## 4  1         6  50      1   0 1992
## 5  1         5  51      1   0 1993
## 6  1         6  52      1   0 1994

str(data)

## 'data.frame': 1326 obs. of  6 variables:
##  $ id      : int  1 1 1 1 1 1 1 1 1 1 ...
##  $ wellbeing: int  6 7 5 6 5 6 4 5 6 6 ...
##  $ age      : int  47 48 49 50 51 52 53 54 55 56 ...
##  $ origin   : int  1 1 1 1 1 1 1 1 1 1 ...
##  $ sex      : int  0 0 0 0 0 0 0 0 0 0 ...
##  $ year     : int  1989 1990 1991 1992 1993 1994 1995 1996 1997 1998 ...

summary(data)

##           id           wellbeing           age           origin
##  Min.   :  1.00   Min.   :  1.000   Min.   :18.00   Min.   :0.0000
## 1st Qu.: 33.00   1st Qu.:  5.000   1st Qu.:41.00   1st Qu.:1.0000
##  Median : 66.50   Median :  6.000   Median :50.00   Median :1.0000
```

```
## Mean      : 66.81    Mean      : 5.753    Mean      :52.04    Mean      :0.7526
## 3rd Qu.:100.00    3rd Qu.: 6.000    3rd Qu.:63.00    3rd Qu.:1.0000
## Max.      :137.00    Max.      :10.000    Max.      :92.00    Max.      :1.0000
##          sex          year
## Min.      :0.0000    Min.      :1986
## 1st Qu.:0.0000    1st Qu.:1994
## Median :1.0000    Median :1997
## Mean      :0.5121    Mean      :1997
## 3rd Qu.:1.0000    3rd Qu.:2001
## Max.      :1.0000    Max.      :2006
```


⇒ Die Befragungen wurden mehrmals (in verschiedenen Jahren) an den selben Personen durchgeführt.

- Umkodierung einzelner Variablen:

```
data <- data %>% mutate(origin = as.factor(origin), gender = as.factor(sex))
```

- Graphische Visualisierung der univariaten Zusammenhänge:

```
plot1 <- ggplot(data = data, mapping = aes(x = origin, y = wellbeing)) +
  geom_boxplot() + theme_minimal() + ylab("Lebenszufriedenheit") +
  xlab("Herkunft") + ggtitle("Herkunft")
plot2 <- ggplot(data = data, mapping = aes(x = as.factor(sex), y = wellbeing)) +
  geom_boxplot() + theme_minimal() + ylab("Lebenszufriedenheit") +
  xlab("Geschlecht") + ggtitle("Geschlecht")
plot3 <- ggplot(data = data, mapping = aes(x = as.factor(year),
  y = wellbeing)) +
  geom_boxplot() + theme_minimal() + ylab("Lebenszufriedenheit") +
  xlab("Jahr") + ggtitle("Jahr") + scale_x_discrete(breaks = NULL)
plot4 <- ggplot(data = data, mapping = aes(x = as.factor(age),
  y = wellbeing)) +
  geom_boxplot() + theme_minimal() + ylab("Lebenszufriedenheit") +
  xlab("Alter") + ggtitle("Alter") + scale_x_discrete(breaks = NULL)
ggarrange(plot1, plot2, plot3, plot4)
```



- ⇒ Aufgrund der geringen Anzahl an unterschiedlichen Ausprägungen in der Zielgröße sind die Darstellungen der univariaten Zusammenhänge insgesamt nur wenig aussagekräftig.
- ⇒ Die Verteilung der Lebenszufriedenheit der westdeutschen Bevölkerung liegt tendenziell etwas höher als die der ostdeutschen Bevölkerung, die Lebenszufriedenheit bei den Frauen scheint etwas größer als bei den Männern zu sein.
- ⇒ Bezüglich des Alters ist in dieser Darstellung keine Struktur erkennbar.
- ⇒ Insgesamt liegt der Großteil der Werte für die Lebenszufriedenheit zwischen 3 und 8.

(b) Passen Sie das Regressionsmodell

$$Y = \beta_0 + \beta_1 \cdot x_{origin} + \beta_2 \cdot x_{sex} + \beta_3 \cdot x_{year} + f(x_{age}) + \varepsilon$$

an die Daten an, wobei $f(x_{age})$ mit Hilfe eines Regressionsplines von Grad $g = 3$ mit drei inneren Knotenpunkten $K = 3$ geschätzt werden soll. Interpretieren Sie die Modellergebnisse.

Lösung:

- Modellgleichung für ein Regressionsmodell mit Regressionssplines von Grad 3:

$$Y = \beta_0 + \beta_1 \cdot x_{origin} + \beta_2 \cdot x_{sex} + \beta_3 \cdot x_{year} + f(x_{age}) + \varepsilon,$$

mit

$$f(age) = \beta_4 \cdot x_{age} + \beta_5 \cdot x_{age}^2 + \beta_6 \cdot x_{age}^3 + \beta_7 \cdot (x_{age} - g_1)_+^3 + \beta_8 \cdot (x_{age} - g_2)_+^3 + \beta_9 \cdot (x_{age} - g_3)_+^3$$

und

$$g_1 = 36.5, g_2 = 55, g_3 = 73.5.$$

- Funktion zum Erstellen der Designmatrix für Regressionssplines:

```
regspline <- function(kovvariable, data, K = 3, g = 3) {  
  # Bestimmung der Knoten:  
  kov <- data[[kovvariable]]  
  knoten <- seq(min(kov), max(kov), length = K + 2)  
  # Anlegen der Designmatrix:  
  X <- matrix(data = 0, nrow = length(kov), ncol = K + g + 1)  
  # Polynome (in den ersten g + 1 Spalten der Designmatrix):  
  for(i in 0:g) {  
    X[, i + 1] <- kov^i  
  }  
  # Trunkierte Potenzen (von der (g + 2)-ten bis zur letzten Spalte der  
  # Designmatrix):  
  for(i in 2:(K + 1)){  
    X[, i + g] <- (kov > knoten[i]) * pmax((kov - knoten[i]), 0)^g  
  }  
  X <- X[, -1]  
  colnames(X) <- c(  
    paste0(kovvariable, c("", seq_len(g)[-1])),  
    paste0(kovvariable, "_tp", seq_len(g)))  
  result <- list(X = X, knoten = knoten)  
  return(result)  
}
```

- Manuelle Erstellung der Designmatrix:

```
X_reg <- regspline(kovvariable = "age", data = data, K = 3, g = 3)$X  
knoten <- regspline(kovvariable = "age", data = data, K = 3, g = 3)$knoten  
X <- cbind(data[, c("id", "wellbeing", "origin", "sex", "year")], X_reg)  
head(X)  
  
##   id wellbeing origin sex year age age2 age3 age_tp1 age_tp2 age_tp3  
## 1  1         6      1  0 1989  47 2209 103823 1157.625      0      0  
## 2  1         7      1  0 1990  48 2304 110592 1520.875      0      0  
## 3  1         5      1  0 1991  49 2401 117649 1953.125      0      0  
## 4  1         6      1  0 1992  50 2500 125000 2460.375      0      0  
## 5  1         5      1  0 1993  51 2601 132651 3048.625      0      0  
## 6  1         6      1  0 1994  52 2704 140608 3723.875      0      0
```

- Schätzung des linearen Regressionsmodells mit Regressionssplines von Grad 3:


```
model <- lm(  
  formula = wellbeing ~ origin + sex + year + age + I(age^2) + I(age^3) +  
    age_tp1 + age_tp2 + age_tp3,  
  data = X  
)  
summary(model)  
  
##  
## Call:  
## lm(formula = wellbeing ~ origin + sex + year + age + I(age^2) +  
##   I(age^3) + age_tp1 + age_tp2 + age_tp3, data = X)  
##  
## Residuals:  
##      Min       1Q   Median       3Q      Max
```

```
## -4.5539 -0.7767 0.0212 0.8018 4.3254
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  3.812e+00  1.406e+01   0.271 0.786263
## origin1      4.299e-01  6.793e-02   6.329 3.39e-10 ***
## sex          2.043e-01  5.881e-02   3.473 0.000531 ***
## year         1.811e-03  6.687e-03   0.271 0.786597
## age          -7.020e-02  5.413e-01  -0.130 0.896846
## I(age^2)     -3.083e-04  1.615e-02  -0.019 0.984771
## I(age^3)      1.909e-05  1.576e-04   0.121 0.903626
## age_tp1      -6.862e-05  1.898e-04  -0.362 0.717726
## age_tp2       6.884e-05  8.012e-05   0.859 0.390385
## age_tp3      -1.367e-04  2.033e-04  -0.673 0.501317
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.06 on 1316 degrees of freedom
## Multiple R-squared:  0.06483, Adjusted R-squared:  0.05843
## F-statistic: 10.14 on 9 and 1316 DF, p-value: 3.345e-15
```

- Interpretation der geschätzten linearen Effekte:
 - $\beta_1 = 0.423$: Die Lebenszufriedenheit ist bei in Westdeutschland lebenden Menschen unter Konstanthaltung aller anderen Variablen im Mittel um 0.423 größer als bei Menschen, die in Ostdeutschland leben.
 - $\beta_2 = 0.204$: Die Lebenszufriedenheit ist bei Frauen unter Konstanthaltung aller anderen Variablen um 0.204 größer als bei Männern.
 - $\beta_3 = 0.0018$: Die Lebenszufriedenheit steigt unter Konstanthaltung aller anderen Variablen jedes Jahr im Mittel um 0.0018.
- Graphische Visualisierung des nicht-linearen Alterseffektes:

```
data_new <- data[
  rep(1, 100),
  c("id", "wellbeing", "origin", "sex", "year")
]
data_new$age <- seq(from = min(data$age), to = max(data$age), length.out = 100)
reg_new <- reg spline(kovvariable = "age", data = data_new, K = 3, g = 3)$X
data_new <- cbind(data_new, reg_new[, -1])
data_new$lm <- predict(object = model, newdata = data_new)
data_new <- data_new %>% gather(model, estimate, lm)

plot <- ggplot() +
  geom_point(data = data, mapping = aes(x = age, y = wellbeing)) +
  geom_line(data = data_new, aes(x = age, y = estimate), col = "blue") +
  theme_minimal() +
  xlab("age") +
  ylab("wellbeing")
plot
```



⇒ Die Lebenszufriedenheit nimmt bei konstanten anderen Variablen tendenziell mit dem Alter ab. Lediglich zwischen dem vierzigsten und sechzigsten Lebensjahr erfolgt keine Abnahme der Lebenszufriedenheit, ab dem 80 Jahren sinkt die Zufriedenheit deutlich.

- Alternative: R-Paket `splines`:

```
library(splines)
# Schätzung des Modells:
model2 <- lm(formula = wellbeing ~ origin + gender + year +
              bs(age, knots = c(18, 36.5, 55, 73.5, 92)),
              data = data)
summary(model2)
```

```
##
## Call:
## lm(formula = wellbeing ~ origin + gender + year + bs(age, knots = c(18,
## 36.5, 55, 73.5, 92)), data = data)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -4.5539 -0.7767  0.0212  0.8018  4.3254
##
## Coefficients: (2 not defined because of singularities)
##                                Estimate Std. Error t value
## (Intercept)                   0.498919   13.351460  0.037
## origin1                      0.429883    0.067928  6.329
## gender1                      0.204268    0.058815  3.473
## year                        0.001811    0.006687  0.271
## bs(age, knots = c(18, 36.5, 55, 73.5, 92))1 2.061451    0.694288  2.969
## bs(age, knots = c(18, 36.5, 55, 73.5, 92))2 1.674552    0.566890  2.954
## bs(age, knots = c(18, 36.5, 55, 73.5, 92))3 1.065601    0.480885  2.216
## bs(age, knots = c(18, 36.5, 55, 73.5, 92))4 1.371880    0.531467  2.581
## bs(age, knots = c(18, 36.5, 55, 73.5, 92))5 1.016066    0.447915  2.268
## bs(age, knots = c(18, 36.5, 55, 73.5, 92))6 0.826425    0.701852  1.177
## bs(age, knots = c(18, 36.5, 55, 73.5, 92))7      NA         NA      NA
## bs(age, knots = c(18, 36.5, 55, 73.5, 92))8      NA         NA      NA
##                                Pr(>|t|)
## (Intercept)                   0.970197
## origin1                      3.39e-10 ***
## gender1                      0.000531 ***
## year                        0.786597
```

```

## bs(age, knots = c(18, 36.5, 55, 73.5, 92))1 0.003040 **
## bs(age, knots = c(18, 36.5, 55, 73.5, 92))2 0.003193 **
## bs(age, knots = c(18, 36.5, 55, 73.5, 92))3 0.026868 *
## bs(age, knots = c(18, 36.5, 55, 73.5, 92))4 0.009950 **
## bs(age, knots = c(18, 36.5, 55, 73.5, 92))5 0.023464 *
## bs(age, knots = c(18, 36.5, 55, 73.5, 92))6 0.239212
## bs(age, knots = c(18, 36.5, 55, 73.5, 92))7      NA
## bs(age, knots = c(18, 36.5, 55, 73.5, 92))8      NA
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.06 on 1316 degrees of freedom
## Multiple R-squared:  0.06483, Adjusted R-squared:  0.05843
## F-statistic: 10.14 on 9 and 1316 DF,  p-value: 3.345e-15

# Vergleich der erhaltenen Prädiktionen:
head(predict(model))

##          1          2          3          4          5          6
## 5.766074 5.772684 5.779439 5.786043 5.792199 5.797609


head(predict(model2))

##          1          2          3          4          5          6
## 5.766074 5.772684 5.779439 5.786043 5.792199 5.797609


# Graphische Visualisierung aller Effekte:
library(effects)
)
plot(allEffects(model2))

```


origin effect plot




gender effect plot



year effect plot




age effect plot



- Graphische Visualisierung der (standardisierten) Residuen gegen die Zeit (für die ersten 30 Personen im Datensatz):

```
library(MASS)
data <- data %>%
  mutate(fitted = model$fitted.values, residuals = stdres(model))
ggplot(data = data %>% filter(id %in% 1:30),
       mapping = aes(x = year, y = residuals, col = as.factor(id))) +
  geom_line(lwd = 0.5) + xlab("Jahr") + ylab("Standardisierte Residuen") +
  theme_minimal() +
  theme(legend.position = "none")
```



⇒ Die Residuen aufeinanderfolgender Beobachtungen bei den gleichen Personen scheinen nicht gänzlich unabhängig voneinander zu sein, die Modellannahme unabhängiger Residuen ist ggf. verletzt.

⇒ Allgemeines lineares Modell

- (c) Ein lineares Modell mit verallgemeinerter Varianzstruktur ist durch $Y = X\beta + \epsilon$ und $\epsilon \sim \mathcal{N}(0, \mathbf{V})$ gegeben. Erklären Sie mögliche Strukturen der Kovarianzmatrix $\mathbf{V}$. Welche Annahmen eines klassischen linearen Modells werden jeweils aufgehoben?

Lösung:

- Lineares Modell mit allgemeiner Varianzstruktur:
 - Das allgemeine lineare Modell $Y = X\beta + \epsilon$ mit $\epsilon \sim \mathcal{N}(0, \mathbf{V})$ lässt beliebige Kovarianzmatrizen $\mathbf{V}$ zu.
 - Die Parameter der Kovarianzmatrix sind üblicherweise nicht bekannt und werden durch ML- oder REML-Schätzung geschätzt, wobei die allgemeine Struktur der Matrix vorgegeben wird.
- Mögliche Strukturen der Kovarianzmatrix der Fehler:
 - Unterschiedliche Varianzen in Gruppen:

$$V = \begin{pmatrix} \sigma_1^2 & \dots & 0 & & & \\ \vdots & \ddots & \vdots & & & \\ 0 & \dots & \sigma_1^2 & & & \\ & & & \ddots & & \\ & & & & \sigma_G^2 & \dots & 0 \\ & & & & \vdots & \ddots & \vdots \\ & & & & 0 & \dots & \sigma_G^2 \end{pmatrix}.$$

- ⇒ Für G Gruppen werden unterschiedliche Fehlervarianzen $\sigma_1^2, \dots, \sigma_G^2$ angenommen.
- ⇒ Die Annahme der Varianzhomogenität wird somit aufgelöst.
- ⇒ Die Kovarianzmatrix stellt eine Diagonalmatrix dar, d.h. die Annahme der Unabhängigkeit der Fehler gilt weiterhin.

- Symmetrische Struktur:

$$V = \begin{pmatrix} \sigma_{\epsilon}^2 + \sigma_{\gamma}^2 & \dots & \sigma_{\gamma}^2 & & \\ \vdots & \ddots & \vdots & & \\ \sigma_{\gamma}^2 & \dots & \sigma_{\epsilon}^2 + \sigma_{\gamma}^2 & & \\ & & & \ddots & \\ & & & & \sigma_{\epsilon}^2 + \sigma_{\gamma}^2 & \dots & \sigma_{\gamma}^2 \\ & & & & \vdots & \ddots & \vdots \\ & & & & \sigma_{\gamma}^2 & \dots & \sigma_{\epsilon}^2 + \sigma_{\gamma}^2 \end{pmatrix}.$$

⇒ Bei der symmetrischen Struktur wird eine Abhängigkeit der Messungen innerhalb einer Gruppe angenommen.

⇒ Die Kovarianzstruktur wird dabei für die einzelnen Gruppen als identisch angesehen.

- Allgemeine Zeitreihenstruktur (AR-1):

$$V = \sigma^2 \frac{1}{1 - \rho^2} \begin{pmatrix} 1 & \rho & \rho^2 & \dots & \rho^{n-1} \\ \rho & 1 & \rho & \dots & \rho^{n-2} \\ \rho^2 & \rho & 1 & \dots & \rho^{n-3} \\ & & & \ddots & \\ \rho^{n-1} & \rho^{n-2} & \rho^{n-3} & \dots & 1 \end{pmatrix}$$

⇒ Der AR-1-Prozess berücksichtigt, dass bei einer Zeitreihe üblicherweise Abhängigkeiten zwischen aufeinanderfolgenden Messungen bestehen.

⇒ Die Abhängigkeit wird als umso größer angesehen, je näher Messungen zeitlich beieinander liegen.

⇒ Bei mehrdimensionalen Zeitreihen bzw. Gruppen kann die AR-1-Struktur auch in Blöcken vorliegen.

- (d) Erweitern Sie das Modell aus Teilaufgabe (b), indem Sie für die Fehler innerhalb der einzelnen Personen von einem Autoregressiven Prozess 1. Ordnung ausgehen.

Lösung:

- Schätzung des Regressionsmodells mit autoregressiver Varianzstruktur:

```
library(nlme)
model_ar <- gls(model = wellbeing ~ origin + sex + year + age + age2 +
                age3 + age_tp1 + age_tp2 + age_tp3,
                data = X, correlation = corAR1(form = ~1|id))
summary(model_ar)

## Generalized least squares fit by REML
## Model: wellbeing ~ origin + sex + year + age + age2 + age3 + age_tp1 + age_tp2 + ag
## Data: X
## AIC BIC logLik
## 3864.506 3926.694 -1920.253
##
## Correlation Structure: AR(1)
## Formula: ~1 | id
## Parameter estimate(s):
## Phi
## 0.3741386
##
## Coefficients:
```

```
##               Value Std.Error   t-value p-value
## (Intercept)  6.127067 18.660118  0.328351  0.7427
## origin1      0.431767  0.094993  4.545262  0.0000
## sex          0.219892  0.082150  2.676718  0.0075
## year         0.000995  0.008893  0.111924  0.9109
## age          -0.141705  0.705980 -0.200720  0.8409
## age2         0.002015  0.021106  0.095485  0.9239
## age3        -0.000005  0.000206 -0.024906  0.9801
## age_tp1      -0.000033  0.000250 -0.131623  0.8953
## age_tp2      0.000044  0.000108  0.410293  0.6817
## age_tp3     -0.000107  0.000266 -0.403426  0.6867
##
## Correlation:
##      (Intr) origin1 sex    year    age    age2    age3    ag_tp1 ag_tp2
## origin1 -0.016
## sex      0.031 -0.034
## year    -0.912  0.035 -0.048
## age     -0.326 -0.046  0.027 -0.090
## age2     0.328  0.042 -0.022  0.085 -0.998
## age3    -0.328 -0.040  0.018 -0.082  0.994 -0.999
## age_tp1  0.321  0.035 -0.005  0.075 -0.969  0.982 -0.990
## age_tp2 -0.182 -0.020 -0.052 -0.030  0.557 -0.595  0.626 -0.725
## age_tp3  0.073  0.034  0.005  0.024 -0.254  0.276 -0.295  0.370 -0.764
##
## Standardized residuals:
##      Min           Q1           Med           Q3           Max
## -4.31133826 -0.72357987  0.01358681  0.74152257  4.06594582
##
## Residual standard error: 1.059627
## Degrees of freedom: 1326 total; 1316 residual
```

- Geschätzter Korrelationskoeffizient des AR-1-Prozesses:

```
phi <- model_ar$modelStruct$corStruct
phi

## Correlation structure of class corAR1 representing
##      Phi
## 0.3741386
```

⇒ Der geschätzte Korrelationskoeffizient ρ des AR-1-Prozesses weicht deutlich von 0 ab, somit erscheint die Annahme eines AR-1-Prozesses für die Fehler innerhalb der Personen sinnvoll.

- Vergleich der Modellergebnisse:
 - Übersicht der linearen Effekte mit approximativen 95%-Konfidenzintervallen:


```
model_list <- list()
model_list[["model_lm"]] <- summary(model)$coefficients[2:4, 1:2]
model_list[["model_ar"]] <- summary(model_ar)$tTable[2:4, 1:2]
for(i in seq_along(model_list)) {
  colnames(model_list[[i]]) <- c("Estimate", "SE")
}
model_overview <- melt(model_list) %>% spread(Var2, value) %>%
  rename(variable = Var1, model = L1) %>%
  mutate(lower = Estimate - 1.96 * SE, upper = Estimate + 1.96 * SE)
model_overview

##   variable    model    Estimate      SE    lower    upper
## 1  origin1 model_ar  0.4317670161 0.094992761  0.24558120  0.61795283
```

```
## 2  origin1 model_lm 0.4298830840 0.067927904 0.29674439 0.56302178
## 3      sex model_ar 0.2198917567 0.082149766 0.05887822 0.38090530
## 4      sex model_lm 0.2042679358 0.058814882 0.08899077 0.31954510
## 5     year model_ar 0.0009953594 0.008893187 -0.01643529 0.01842601
## 6     year model_lm 0.0018107458 0.006686961 -0.01129570 0.01491719
```


⇒ Die erhaltenen Parameterschätzer sind sehr ähnlich, die Standardfehler sind beim AR-1-Modell im Vergleich zum klassischen linearen Modell jedoch deutlich größer.

- Graphischer Vergleich der geschätzten linearen Effekte:



- Graphischer Vergleich des nicht-linearen Alterseffektes:

```
data_new <- data[rep(1, 100),
                  c("id", "wellbeing", "origin", "sex", "year")]
data_new$age <- seq(from = min(data$age), to = max(data$age), length.out = 100)
reg_new <- regsplines(kovvariable = "age", data = data_new, K = 3, g = 3)$X
data_new <- cbind(data_new, reg_new[, -1])
data_new$lm <- predict(object = model, newdata = data_new)
data_new$ar <- predict(object = model_ar, newdata = data_new)
data_new <- data_new %>% gather(model, estimate, lm:ar)
ggplot(data = data_new, mapping = aes(x = age, y = estimate, col = model)) +
  geom_line(lwd = 0.8) + theme_minimal() +
  theme(legend.title = element_blank(),
        axis.text.y = element_blank())
```



⇒ Die Verläufe der geschätzten Alterseffekte sind bei beiden Modellen sehr ähnlich.

Aufgabe 15: Gemischtes lineares Modell

Der bereits häufiger betrachtete Datensatz `wdi.Rdata` soll nun verwendet werden, um die logarithmierten CO_2 -Emissionen der Länder für den Zeitraum von 2005 bis 2013 gemeinsam zu modellieren. Als Einflussgrößen sollen die (geeignet transformierten) Variablen `Population`, `Area`, `Employees.M.IND`, `Livestock`, `PopulationRural`, `GDP` und `continent` in die Analyse einbezogen werden.

- (a) Stellen Sie für die neun Länder mit den höchsten CO_2 -Emissionen im Jahr 2005 die Verläufe der CO_2 -Emissionen über die Jahre dar. Was fällt dabei auf?

Lösung:

- Laden der Daten und Überblick über Datensatz:

```
load("../Daten/wdi.Rdata")
head(wdi)
```

##	iso2c	country	year	GDP	Merchandise	Population	Area
## 1	AFG	Afghanistan	2005	6209140044	45.98060	25654277	652860
## 2	ALB	Albania	2005	8052075642	40.68516	3011487	28750
## 3	DZA	Algeria	2005	103198442061	64.30233	33149724	2381740
## 4	ASM	American Samoa	2005	503000000	174.95030	59562	200
## 5	AND	Andorra	2005	3255789081	NA	78867	470
## 6	AGO	Angola	2005	36970918699	87.80415	19433602	1246700

##	CO2emission	EqualityIndex	Employees.F.AGR	Employees.M.AGR	Employees.M.IND
## 1	1327.454	NA	78.491	59.362	11.535
## 2	4253.720	4	59.199	38.604	21.402
## 3	107278.085	NA	8.613	20.099	26.387
## 4	NA	NA	NA	NA	NA
## 5	575.719	NA	NA	NA	NA
## 6	19156.408	3	46.061	30.290	16.020

##	Employees.F.IND	Employees.F.SRV	Employees.M.SRV	Livestock	Unemployment.F
## 1	11.488	10.021	29.103	103.31	14.910
## 2	7.931	32.870	39.994	98.52	16.919
## 3	26.131	65.256	53.514	99.70	18.034
## 4	NA	NA	NA	99.85	NA
## 5	NA	NA	NA	NA	NA

```
## 6      1.707      52.233      53.691      102.50      2.852
## Literacy PopulationRural continent      region
## 1      NA      19829986      Asia      South Asia
## 2      NA      1604189      Europe      Europe & Central Asia
## 3      NA      11990255      Africa      Middle East & North Africa
## 4      NA      7088      Oceania      East Asia & Pacific
## 5      NA      7662      Europe      Europe & Central Asia
## 6      NA      8550785      Africa      Sub-Saharan Africa

str(wdi)

## 'data.frame': 3257 obs. of 21 variables:
## $ iso2c      : Factor w/ 217 levels "ABW","AFG","AGO",...: 2 4 56 9 5 3 10 7 8 1 ...
## $ country     : Factor w/ 217 levels "Afghanistan",...: 1 2 3 4 5 6 7 8 9 10 ...
## $ year        : Factor w/ 15 levels "2005","2006",...: 1 1 1 1 1 1 1 1 1 1 ...
## $ GDP         : num  6.21e+09 8.05e+09 1.03e+11 5.03e+08 3.26e+09 ...
## $ Merchandise : num  46 40.7 64.3 175 NA ...
## $ Population  : num  25654277 3011487 33149724 59562 78867 ...
## $ Area        : num  652860 28750 2381740 200 470 ...
## $ CO2emission : num  1327 4254 107278 NA 576 ...
## $ EqualityIndex : num  NA 4 NA NA NA 3 NA NA 4.5 NA ...
## $ Employees.F.AGR: num  78.49 59.2 8.61 NA NA ...
## $ Employees.M.AGR: num  59.4 38.6 20.1 NA NA ...
## $ Employees.M.IND: num  11.5 21.4 26.4 NA NA ...
## $ Employees.F.IND: num  11.49 7.93 26.13 NA NA ...
## $ Employees.F.SRV: num  10 32.9 65.3 NA NA ...
## $ Employees.M.SRV: num  29.1 40 53.5 NA NA ...
## $ Livestock     : num  103.3 98.5 99.7 99.8 NA ...
## $ Unemployment.F : num  14.9 16.9 18 NA NA ...
## $ Literacy      : num  NA NA NA NA NA NA NA NA NA ...
## $ PopulationRural: num  19829986 1604189 11990255 7088 7662 ...
## $ continent     : chr  "Asia" "Europe" "Africa" "Oceania" ...
## $ region        : chr  "South Asia" "Europe & Central Asia" "Middle East & North Africa"

summary(wdi)

##      iso2c      country      year      GDP
## ABW      : 15  Afghanistan      : 15  2005      : 217  Min.      :2.044e+07
## AFG      : 15  Albania          : 15  2006      : 217  1st Qu.:4.695e+09
## AGO      : 15  Algeria          : 15  2007      : 217  Median :2.103e+10
## ALB      : 15  American Samoa: 15  2008      : 217  Mean    :3.345e+11
## AND      : 15  Andorra          : 15  2009      : 217  3rd Qu.:1.540e+11
## (Other):3180 (Other)          :3180 (Other):2170 Max.    :2.054e+13
## NA's      : 2  NA's          : 2  NA's      : 2  NA's      :389
## Merchandise      Population      Area      CO2emission
## Min.      : 4.101  Min.      :9.828e+03  Min.      : 2  Min.      :7.300e+00
## 1st Qu.: 42.657  1st Qu.:7.146e+05  1st Qu.: 10450  1st Qu.:1.309e+03
## Median : 58.061  Median :5.915e+06  Median : 92226  Median :8.060e+03
## Mean    : 68.141  Mean    :3.244e+07  Mean    : 614173  Mean    :1.532e+05
## 3rd Qu.: 82.362  3rd Qu.:2.081e+07  3rd Qu.: 447400  3rd Qu.:5.916e+04
## Max.    :435.219  Max.    :1.393e+09  Max.    :17098250  Max.    :1.029e+07
## NA's    :569  NA's    :226  NA's    :252  NA's    :1222
## EqualityIndex      Employees.F.AGR      Employees.M.AGR      Employees.M.IND
## Min.      :1.500  Min.      : 0.009  Min.      : 0.091  Min.      : 2.636
## 1st Qu.:3.000  1st Qu.: 2.942  1st Qu.: 6.883  1st Qu.:17.694
## Median :3.500  Median :14.361  Median :23.333  Median :25.357
## Mean    :3.365  Mean    :26.138  Mean    :27.287  Mean    :25.120
## 3rd Qu.:4.000  3rd Qu.:45.763  3rd Qu.:43.117  3rd Qu.:32.093
## Max.    :5.000  Max.    :96.605  Max.    :87.716  Max.    :67.404
## NA's    :2188  NA's    :452  NA's    :452  NA's    :452
```

```
## Employees.F.IND Employees.F.SRV Employees.M.SRV Livestock
## Min. : 0.388 Min. : 2.843 Min. : 9.139 Min. : 32.64
## 1st Qu.: 6.929 1st Qu.:41.608 1st Qu.:37.604 1st Qu.:100.44
## Median :10.257 Median :67.769 Median :47.817 Median :107.08
## Mean :11.794 Mean :62.068 Mean :47.593 Mean :112.27
## 3rd Qu.:15.425 3rd Qu.:85.003 3rd Qu.:58.535 3rd Qu.:120.13
## Max. :56.815 Max. :98.670 Max. :82.939 Max. :364.86
## NA's :452 NA's :452 NA's :452 NA's :852
## Unemployment.F Literacy PopulationRural continent
## Min. : 0.218 Min. : 22.31 Min. : 0 Length:3257
## 1st Qu.: 3.841 1st Qu.: 77.05 1st Qu.: 193508 Class :character
## Median : 6.679 Median : 92.66 Median : 1938841 Mode :character
## Mean : 9.063 Mean : 84.08 Mean : 15616672
## 3rd Qu.:12.186 3rd Qu.: 96.55 3rd Qu.: 9424858
## Max. :42.769 Max. :100.00 Max. :892321651
## NA's :452 NA's :2679 NA's :254
## region
## Length:3257
## Class :character
## Mode :character
##
##
##
##
```

- Einschränkung des Datensatzes auf Beobachtungen aus den Jahren 2005 bis 2013 und Umkodierung der Variablen:

```
wdi <- wdi %>%
  dplyr::select(country, year, continent, region, continent, year, CO2emission, Area,
    Population, PopulationRural, GDP, Livestock, Employees.M.IND) %>%
  mutate(CO2emission = log10(CO2emission), Area = log10(Area),
    Population = log10(Population),
    PopulationRural = log10(PopulationRural + 1), GDP = log10(GDP),
    continent = as.factor(continent),
    year = as.numeric(as.character(year))) %>%
  filter(year %in% 2005:2013) %>% na.omit
```


- Auswahl der neun Länder mit den höchsten CO_2 -Emissionen im Jahr 2005:

```
wdi_2005 <- wdi %>% filter(year == 2005) %>% arrange(desc(CO2emission)) %>%
  slice(1:9)
countries <- as.character(wdi_2005$country)
countries

## [1] "China" "United States" "Russian Federation"
## [4] "Japan" "India" "Germany"
## [7] "Canada" "United Kingdom" "Italy"
```

- Graphische Visualisierung der CO_2 -Verläufe für die neun ausgewählten Länder:

```
ggplot(data = filter(wdi, country %in% countries),
  mapping = aes(x = year, y = CO2emission, col = country)) +
  geom_point() + geom_line() + theme_minimal()
```



- ⇒ Die einzelnen Länder weisen unterschiedliche Ausgangsniveaus bezüglich der CO_2 -Emissionen auf, d.h. bestimmte Länder haben in allen Jahren immer höhere CO_2 -Emissionen als andere Länder.
- ⇒ Beispielsweise weist China unter allen neun dargestellten Ländern in jedem Jahr die höchsten CO_2 -Emissionen auf, Italien dagegen jeweils immer die niedrigsten.

(b) Fitten Sie nun zunächst ein lineares Modell mit allen Kovariablen und erklären Sie, warum das Modell in diesem Fall nicht passend ist.

Lösung:

Schätzung eines linearen Regressionsmodells mit allen Kovariablen:

```
model_lm <- lm(formula = CO2emission ~ Area + PopulationRural + Population +
               GDP + Livestock + Employees.M.IND + continent,
               data = wdi)
summary(model_lm)
```

```
##
## Call:
## lm(formula = CO2emission ~ Area + PopulationRural + Population +
##     GDP + Livestock + Employees.M.IND + continent, data = wdi)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.7932 -0.1647  0.0094  0.1624  0.7323
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -5.8179833  0.0876061 -66.411  < 2e-16 ***
## Area          0.1025961  0.0109998   9.327  < 2e-16 ***
## PopulationRural 0.0003483  0.0084472   0.041  0.9671
## Population     0.2664861  0.0232066  11.483  < 2e-16 ***
## GDP           0.6553786  0.0164002  39.962  < 2e-16 ***
## Livestock     -0.0005649  0.0003389  -1.667  0.0957 .
## Employees.M.IND 0.0256583  0.0009064  28.308  < 2e-16 ***
## continentAmericas 0.1293228  0.0212196   6.095 1.38e-09 ***
## continentAsia   0.3013592  0.0192837  15.628  < 2e-16 ***
## continentEurope -0.0012357  0.0257671  -0.048  0.9618
## continentOceania 0.1612703  0.0338770   4.760 2.11e-06 ***
```

```
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.2484 on 1564 degrees of freedom
## Multiple R-squared:  0.9425, Adjusted R-squared:  0.9421
## F-statistic: 2562 on 10 and 1564 DF, p-value: < 2.2e-16
```

- ⇒ Das lineare Modell basiert auf der Annahme von unabhängigen Fehlern.
- ⇒ Somit wird die Tatsache ignoriert, dass Messungen innerhalb eines Landes zueinander ähnlicher sind als Messungen zwischen verschiedenen Ländern. Die unterschiedlichen Ausgangsniveaus der einzelnen Länder werden also nicht berücksichtigt.
- ⇒ Ohne Berücksichtigung der Ausgangsniveaus werden die Standardfehler der geschätzten Koeffizienten möglicherweise unterschätzt.

(c) Geben Sie an, wie man berücksichtigen könnte, dass jedes Land ein unterschiedliches Ausgangsniveau hat. Diskutieren Sie zwei Ansätze sowie deren Vor- und Nachteile.

Lösung:

- Ansatz 1: Modell mit festen Effekten:

- Idee:

Die kategoriale Variable *Country* wird als zusätzliche Kovariable mit in das Regressionsmodell aus Teilaufgabe (b) aufgenommen, d.h. für jedes Land i ($i = 1, \dots, g$) wird ein fester Effekt β_i geschätzt.

⇒ Diese Vorgehensweise verschiebt für jedes Land i den Intercept β_0 nach oben oder unten. Somit ergibt sich für jedes Land i ein eigener Intercept $\beta_0 + \beta_i$.

- Vorteil: einfach zu implementieren

- Nachteile:

- * sehr viele zu schätzende Parameter
- * hohe Standardfehler bei kleiner Anzahl an Beobachtungen pro Land
- * keine Berücksichtigung der Korrelationen innerhalb der einzelnen Länder
- * keine sinnvolle Interpretation zeitkonstanter Koeffizienten

- Ansatz 2: Random Intercept-Modell:

- Idee:

Die Intercepts für die einzelnen Länder streuen zufällig um den globalen Intercept.

⇒ Schätzung eines Varianzparameters σ_γ^2 für den Intercept

- Modellspezifikation:

$$Y_{ij} = x_{ij}^\top \beta + \gamma_i + \epsilon_{ij} \quad \text{für } i = 1, \dots, g \text{ und } j = 1, \dots, n_i$$

mit den Verteilungsannahmen

$$\epsilon_{ij} \stackrel{i.i.d.}{\sim} N(0, \sigma_\epsilon^2), \gamma_i \stackrel{i.i.d.}{\sim} N(0, \sigma_\gamma^2) \text{ und } \epsilon_{ij} \perp \gamma_i \quad \forall i, j.$$

⇒ β bezeichnet den Vektor der festen Effekte, γ_i den zufälligen Intercept für das Land i .

⇒ Die Modellparameter $(\beta, \sigma_\epsilon^2, \sigma_\gamma^2)$ können beispielsweise über REML geschätzt werden.

- Vorteile:
 - * Viel weniger zu schätzende Parameter
 - * Zentrierung der Random Effects um 0
 - * Berücksichtigung von Korrelationen innerhalb der Länder
 - * Sinnvolle Einbeziehung von zeitkonstanten Merkmalen
- Nachteile:
 - * Die Unabhängigkeitsannahme zwischen γ_i und ϵ_{ij} könnte verletzt sein.
 - * Die Normalverteilungsannahme der γ_i könnte verletzt sein.
 - * Schwieriger zu fitten

(d) Ausgehend vom Modell aus Teilaufgabe (b) soll nun zusätzlich für jedes Land ein individueller zufälliger Effekt (Random Intercept) in das Modell aufgenommen werden. Stellen Sie die zugehörige Modellgleichung (inkl. aller Modellannahmen) auf.

Lösung:

- Modellgleichung:

$$\begin{aligned} \log(CO_2)_{ij} = & \beta_0 + \beta_1 \log(\text{Area})_{ij} + \beta_2 \log(\text{PopulationRural})_{ij} + \beta_3 \log(\text{Population})_{ij} + \\ & \beta_4 \log(\text{GDP})_{ij} + \beta_5 \text{Livestock}_{ij} + \beta_6 \text{Employess.M.IND}_{ij} + \\ & \beta_7 I(\text{continent}_{ij} = \text{Americas}) + \beta_8 I(\text{continent}_{ij} = \text{Asia}) + \\ & \beta_9 I(\text{continent}_{ij} = \text{Europe}) + \beta_{10} I(\text{continent}_{ij} = \text{Oceania}) + \gamma_i + \epsilon_{ij}, \end{aligned}$$

für $i = 1, \dots, 177$ und $j = 1, \dots, n_i$

- Verteilungsannahmen:

- Verteilung der Fehlerterme: $\epsilon_{ij} \stackrel{i.i.d}{\sim} N(0, \sigma_\epsilon^2)$
- Verteilung der zufälligen Effekte: $\gamma_i \stackrel{i.i.d}{\sim} N(0, \sigma_\gamma^2)$
- Unabhängigkeit zwischen zufälligen Effekten $\gamma_1, \dots, \gamma_g$ und Störtermen: $\epsilon_{ij} \perp \gamma_i \quad \forall i, j$

(e) Schätzen Sie das in der vorherigen Teilaufgabe spezifizierte Modell und stellen Sie die Verteilung der zufälligen Effekte graphisch dar.

Lösung:

- Schätzung eines Random Intercept-Modells:

```
model_mixed <- lmer(formula = CO2emission ~ Area + PopulationRural +
                    Population + GDP + Livestock + Employees.M.IND +
                    continent + (1|country),
                    data = wdi)
summary(model_mixed)

## Linear mixed model fit by REML ['lmerMod']
## Formula: CO2emission ~ Area + PopulationRural + Population + GDP + Livestock +
##      Employees.M.IND + continent + (1 | country)
##      Data: wdi
##
## REML criterion at convergence: -3388.5
##
## Scaled residuals:
##      Min       1Q   Median       3Q      Max
## -7.8901 -0.4482 -0.0175  0.4298  5.8432
##
```

```

## Random effects:
## Groups Name Variance Std.Dev.
## country (Intercept) 0.146817 0.38317
## Residual 0.003366 0.05802
## Number of obs: 1575, groups: country, 177
##
## Fixed effects:
## Estimate Std. Error t value
## (Intercept) -3.7786987 0.2359917 -16.012
## Area 0.1551280 0.0437865 3.543
## PopulationRural -0.0741760 0.0324354 -2.287
## Population 0.6611674 0.0588711 11.231
## GDP 0.2163599 0.0161695 13.381
## Livestock 0.0001732 0.0001257 1.378
## Employees.M.IND 0.0105833 0.0008594 12.315
## continentAmericas 0.5671269 0.0886122 6.400
## continentAsia 0.6860061 0.0804494 8.527
## continentEurope 0.8133491 0.0857535 9.485
## continentOceania 0.3789645 0.1496731 2.532
##
## Correlation of Fixed Effects:
## (Intr) Area PpltnR Popltn GDP Lvstck E.M.IN cntnntAm cntnntAs
## Area 0.014
## PopulatnRrl 0.007 -0.355
## Population -0.562 -0.438 -0.404
## GDP -0.026 0.098 0.190 -0.519
## Livestock 0.247 0.190 -0.042 -0.133 -0.330
## Empl.M.IND 0.029 0.063 -0.047 0.021 -0.208 -0.045
## cntnntAmrcs -0.181 -0.009 0.058 0.039 -0.098 0.046 -0.068
## continentAs -0.066 0.135 0.162 -0.209 -0.013 0.100 -0.062 0.430
## continntErp -0.146 0.076 0.037 0.003 -0.160 0.125 -0.135 0.423 0.475
## continntOcn -0.272 -0.031 -0.001 0.168 -0.099 -0.019 0.002 0.239 0.226
## cntnnE
## Area
## PopulatnRrl
## Population
## GDP
## Livestock
## Empl.M.IND
## cntnntAmrcs
## continentAs
## continntErp
## continntOcn 0.245


```

- Graphische Visualisierung der Verteilung der zufälligen Effekte:

```

random <- ranef(model_mixed)$country
plot(x = density(random$`(Intercept)`), main = "")
random$country <- as.factor(rownames(random))
colnames(random)[1] <- "Intercept"
sd <- as.data.frame(VarCorr(model_mixed))[1, 5]
lines(x = seq(from = -1.2, to = 1.2, by = 0.01),
      y = dnorm(x = seq(from = -1.2, to = 1.2, by = 0.01), mean = 0, sd = sd),
      col = "red")
legend(x = "topright", col = c("black", "red"), lwd = 1,
      legend = c("Dichteschätzung", "Normalverteilung"), cex = 0.6)

```




N = 177 Bandwidth = 0.1033

- ⇒ Die Verteilung der zufälligen Effekte weicht nur geringfügig von der theoretischen Normalverteilung ab.
- ⇒ Die Normalverteilungsannahme für die zufälligen Effekte erscheint hier also sinnvoll.

- Modelldiagnose über Fitted vs. Residuals:

```
fitted <- as.data.frame(predict(model_mixed, type="response"))
names(fitted) <- "fitted"
fitted$resid <- wdi$CO2emission - fitted$fitted

ggplot(data = fitted, mapping = aes(x = fitted, y = resid)) +
  geom_point() + geom_hline(yintercept = 0, lty = 2) + theme_minimal()
```



- ⇒ Die Residuen des Random Intercept Modells zeigen keine strukturellen Auffälligkeiten. Die Modellannahme von homoskedastischen Fehlern scheint nicht (oder nur geringfügig) verletzt zu sein.

(f) Berechnen und interpretieren Sie die Intra-Class-Correlation.

Lösung:

- Idee der Maßzahl:
Die Intra-Class-Correlation quantifiziert den Anteil der noch nicht durch die festen Effekte erklärten Streuung in der Zielgröße, der durch den zufälligen Intercept erklärt werden kann. Dieser Anteil entspricht der Korrelation zwischen Beobachtungen am gleichen Subjekt bzw. Land.

- Berechnung anhand der Modellsummary:

$$ICC = \frac{\sigma_\gamma^2}{\sigma_\gamma^2 + \sigma_\epsilon^2} = \frac{0.146817}{0.146817 + 0.003366} \approx 0.9776$$

⇒ Beinahe die gesamte Streuung der logarithmierten CO_2 -Emissionen, die nicht durch die festen Effekte erklärt wird, wird im Modell durch die zufälligen Effekte aufgefangen.

Aufgabe 16: Variablenselektion

Im Folgenden soll eine Simulationsstudie zum Vergleich verschiedener Verfahren zur Variablenselektion durchgeführt werden.

- (a) Simulieren Sie 1000 Datensätze mit jeweils $n = 100$ Beobachtungen aus dem Modell

$$y_i = 100 + 3x_1 - 0.5x_2 + 0.05x_3 + \varepsilon_i \quad \text{mit } \varepsilon_i \sim N(0, \sigma^2) \text{ und } i = 1, \dots, 100.$$

Ziehen Sie dabei x_1, x_2 und x_3 aus einer Standardnormalverteilung und fügen Sie weitere ebenfalls standardnormalverteilte Variablen $x_4, \dots, x_{10}$, die nicht mit dem Outcome zusammenhängen, zum Datensatz hinzu.

Lösung:

- Funktion zur Simulation eines Datensatzes anhand des angegebenen linearen Regressionsmodells:

```
simulation <- function(n = 100, n.x = 10, n.p = 3, n.extra = 0, beta0 = 100,
  beta = c(3,-0.5,0.05), sigma.eps = 1, sigma.extra = 2) {

  # Argumente:
  # n: Anzahl der Beobachtungen
  # n.x: Anzahl der Kovariablen
  # n.p: Anzahl der Kovariablen, die mit dem Outcome assoziiert sind
  # n.extra: Anzahl der Kovariablen, deren Varianz höhere Werte annehmen soll
  # beta0: Intercept
  # beta: Effektstärken der mit Y assoziierten Kovariablen
  # sigma.eps: Varianz der Störterme
  # sigma.extra: Varianz der nicht mit Y assoziierten Variablen x8 bis x10

  # Erzeugung der Designmatrix:
  X1 <- replicate(n = n.p, expr = rnorm(n, 0, 1))
  X2 <- replicate(n = n.x - (n.p + n.extra), expr = rnorm(n, 0, 1))
  X3 <- if(n.extra != 0) {
    replicate(n = n.extra, expr = rnorm(n, 0, sigma.extra))
  } else {
    NULL
  }
  X <- cbind(X1, X2, X3)
  colnames(X) <- paste0("x", seq_len(n.x))
  # Erzeugung der Zielvariablen über lineares Regressionsmodell:
  beta <- c(beta, rep(0, n.x - length(beta)))
  y <- beta0 + X %*% beta + rnorm(n, 0, sigma.eps)
  df <- cbind.data.frame(y = y, X)
  return(df)
}
```

- Simulation von 1000 Datensätzen:

```

Nsim <- 1000
set.seed(1)
#df_list <- mclapply(X = seq_len(Nsim), FUN = function(z) {
#  dz <- simulation()},
#  mc.cores = 1)
load("../Daten/simulation_data.Rdata")
head(df_list[[1]])

```

##		y	x1	x2	x3	x4	x5	x6
## 1	99.58626	-0.6264538	-0.62036668	0.4094018	0.8936737	1.0744410	0.07730312	
## 2	101.72625	0.1836433	0.04211587	1.6888733	-1.0472981	1.8956548	-0.29686864	
## 3	97.15713	-0.8356286	-0.91092165	1.5865884	1.9713374	-0.6029973	-1.18324224	
## 4	104.90101	1.5952808	0.15802877	-0.3309078	-0.3836321	-0.3908678	0.01129269	
## 5	101.27095	0.3295078	-0.65458464	-2.2852355	1.6541453	-0.4162220	0.99160104	
## 6	95.11719	-0.8204684	1.76728727	2.4976616	1.5122127	-0.3756574	1.59396745	

##		x7	x8	x9	x10
## 1	-0.3410670	-0.70756823	-1.08690882	-1.5414026	
## 2	1.5024245	1.97157201	-1.82608301	0.1943211	
## 3	0.5283077	-0.08999868	0.99528181	0.2644225	
## 4	0.5421914	-0.01401725	-0.01186178	-1.1187352	
## 5	-0.1366734	-1.12345694	-0.59962839	0.6509530	
## 6	-1.1367339	-1.34413012	-0.17794799	-1.0329002	

- (b) Führen Sie unter Verwendung der Funktion `stepAIC()` aus dem **R**-Paket **MASS** für alle Datensätze eine Variablenselektion nach dem AIC-Kriterium durch und betrachten Sie die Anzahl der Fälle, in denen im Endmodell die mit dem Outcome assoziierten Variablen enthalten sind. Wie oft wurde das richtige Modell gewählt?

Vergleichen Sie hierbei die folgenden Varianten der Variablenselektion:

- Vorwärtssselektion
- Rückwärtssselektion
- Stepwise forward
- Stepwise backward
- Vergleich aller möglichen Modelle.

Lösung:

- Überblick über Selektionskriterien:

– AIC:

$$AIC = n \log(SSE) + 2(p' + 1) - n \log(n)$$

bzw.

$$AIC = -2 \cdot \loglik(\text{model}) + 2(p' + 1)$$

– BIC:

$$BIC = n \log(SSE) + \log(n)(p' + 1) - n \log(n)$$

bzw.

$$BIC = -2 \cdot \loglik(\text{model}) + \log(n)(p' + 1)$$

– R^2 :

$$R^2 = \frac{SSM}{SST} = 1 - \frac{SSE}{SST}$$

– R_{adj}^2 :

$$R_{adj}^2 = 1 - \frac{MSE}{MST} = 1 - \frac{n-1}{n-p'}(1 - R^2)$$

– Anmerkung:

Für lineare Regressionsmodelle mit normalverteilten Fehlern unterscheiden sich die auf der RSS basierende AIC-/BIC-Formel und die auf der Log-Likelihood basierende Formel lediglich um eine additive Konstante, die für alle verglichenen Modelle identisch ist. Daher führen beide Formeln zur gleichen Modellwahl, obwohl die ausgegebenen AIC-/BIC-Werte unterschiedlich sein können. In **R** verwendet die Funktion `extractAIC()` für lineare Modelle eine auf der RSS basierende Darstellung des AIC, während `AIC()` den AIC über die maximierte Log-Likelihood berechnet. Beide Darstellungen unterscheiden sich bei linearen Modellen mit normalverteilten Fehlern lediglich um eine additive Konstante und führen daher zur gleichen Modellwahl.

- Überblick über Selektionsmethoden (am Beispiel des AIC):

- Vorwärtsselektion (**forward selection**):

Starte mit dem Intercept-Modell und füge schrittweise Variablen hinzu, die zum niedrigsten AIC führen.

⇒ Wiederholung, bis kein niedrigeres AIC mehr erreicht werden kann

- Rückwärtsselektion (**backward selection**):

Starte mit dem vollem Modell und nimm schrittweise Variablen aus dem Modell heraus, die zum niedrigsten AIC führen.

⇒ Wiederholung, bis kein niedrigeres AIC mehr erreicht werden kann

- Schrittweise Selektion (**stepwise forward, stepwise backward**):

Schritte in beide Richtungen (Kombination aus Vorwärts- und Rückwärtsselektion)

⇒ Wiederholung, bis kein niedrigeres AIC mehr erreicht werden kann

- Vergleich aller möglichen Modelle (**best subset**):

Schätzung aller möglichen Modelle

⇒ Das Vorgehen kann bei großen Datensätzen sehr aufwändig sein, dabei p Kovariablen zu 2^p möglichen Modellen (ohne Interaktionen) führen.

- Kreuzvalidierung:

- * Teile den Datensatz in K gleich große Teilmengen auf.

- * Verwende jeweils $K - 1$ Datensätze zur Modellschätzung (Trainingsdatensatz) und einen Datensatz zur Validierung (Testdatensatz)

- * Berechnung eines Gütekriteriums (z.B. MSE, RMSE) auf allen Testdatensätzen

- * Auswahl des Modells mit geringstem mittlerem MSE bzw. RMSE

⇒ Das Verfahren ist ebenfalls sehr aufwändig, da für jede Modellspezifikation K Modelle geschätzt werden müssen.

Lösung:

- Funktion zur Bestimmung des AIC für eine gegebene Modellspezifikation:

```
calculate_aic <- function(formula, data) {  
  model <- lm(formula = formula, data = data)  
  aic <- AIC(model)  
  attr(aic, "form") <- formula  
  return(aic)  
}
```

- Funktion zur Auswahl des Modells mit dem besten AIC:

```
getbest <- function(aic_list) {
  ind1 <- sapply(X = aic_list, FUN = which.min)
  best_sub <- lapply(X = seq_along(ind1),
                    FUN = function(z) {
                      aic_list[[z]][[ind1[z]]]
                    })
  best_ind <- which.min(unlist(best_sub))
  return(best_sub[[best_ind]])
}
```

- Funktion zur Durchführung der Best Subset-Variablenselektion:

```
best_simple <- function(data) {
  x_vars <- grep(pattern = "^x.*", x = colnames(data), value = TRUE)
  all_forms <- lapply(X = seq_along(x_vars), FUN = function(z) {
    rhs <- combn(x = x_vars, m = z, FUN = paste0, collapse = "+")
    lapply(X = rhs, FUN = function(i) {
      as.formula(paste0("y~", i))
    })
  })
  res_all <- lapply(X = all_forms, FUN = function(z) {
    lapply(X = z, FUN = calculate_aic, data = data)
  })
  model <- lm(formula = attr(x = get_best(res_all), which = "form"),
              data = data)
  return(model)
}
```

- Funktion zur Anwendung der verschiedenen Variablenselektionsverfahren:

```
selection_stats <- function(data) {
  lwr <- y ~ 1
  upr <- paste0("y ~", paste0("x", seq_len(ncol(data) - 1), collapse = "+"))
  m_lower <- lm(formula = lwr, data = data)
  m_upper <- lm(formula = upr, data = data)
  # Durchführung der Variablenselektionsverfahren:
  model_list <- list(
    forward = MASS::stepAIC(object = m_lower,
                           scope = list(upper = upr, lower = lwr),
                           direction = "forward"),
    backward = MASS::stepAIC(object = m_upper,
                             scope = list(upper = upr, lower = lwr),
                             direction = "backward"),
    step_forward = MASS::stepAIC(object = m_lower,
                                 scope = list(upper = upr, lower = lwr),
                                 direction = "both"),
    step_backward = MASS::stepAIC(object = m_upper,
                                  scope = list(upper = upr, lower = lwr),
                                  direction = "both"),
    best_simple = best_simple(data)
  )
  # Zusammenfassung aller Ergebnisse in einem data.frame:
  result <- reshape2::melt(data = lapply(X = model_list, FUN = function(z) {
    do.call(cbind.data.frame, as.list(coef(z)))
  })))
  return(result)
}
```

- Durchführung aller Variablenselektionsverfahren für die simulierten Datensätze:

```
#stats_list <- mclapply(X = seq_along(df_list), FUN = function(z) {
# stats      <- selection_stats(df_list[[z]])
# stats$ID <- z
# stats
# },
# mc.cores = 1)
load("../Daten/simulation_stats.Rdata")
head(stats_list[[1]])
```

	variable	value	L1	ID
## 1	(Intercept)	100.0036985	forward	1
## 2	x1	2.8434545	forward	1
## 3	x2	-0.6193943	forward	1
## 4	(Intercept)	100.0036985	backward	1
## 5	x1	2.8434545	backward	1
## 6	x2	-0.6193943	backward	1


- Zusammenfügen aller Ergebnisse zu einem Datensatz:

```
results <- do.call(rbind, stats_list) %>% rename(Verfahren = L1) %>%
  mutate(variable = factor(x = variable,
                           levels = c("(Intercept)", paste0("x", 1:10))))
head(results)
```

	variable	value	Verfahren	ID
## 1	(Intercept)	100.0036985	forward	1
## 2	x1	2.8434545	forward	1
## 3	x2	-0.6193943	forward	1
## 4	(Intercept)	100.0036985	backward	1
## 5	x1	2.8434545	backward	1
## 6	x2	-0.6193943	backward	1

- Graphischer Vergleich der Koeffizientenschätzer:

```
ggplot(data = filter(results, variable != "(Intercept)"),
       mapping = aes(x = variable, y = value)) +
  geom_boxplot() + facet_wrap(~Verfahren) + theme_minimal()
```



⇒ Im Median werden die Effekte von x_1 , x_2 und x_3 für alle Selektionsverfahren korrekt geschätzt. Im Vergleich zu den Noise-Variablen weisen deren Verteilungen eine deutlich geringere Streuung auf.

- Übersicht über Auswahlhäufigkeiten:

```
xtabs(formula = ~Verfahren + variable, data = results)
```

##	variable											
##	Verfahren	(Intercept)	x1	x2	x3	x4	x5	x6	x7	x8	x9	x10
##	backward	1000	1000	1000	214	188	192	166	192	206	190	182
##	best_simple	1000	1000	1000	211	185	191	163	187	205	186	174
##	forward	1000	1000	1000	204	182	191	157	182	200	180	169
##	step_backward	1000	1000	1000	214	188	192	166	192	207	190	182
##	step_forward	1000	1000	1000	204	182	190	157	181	200	179	169

⇒ Die Variablen x_1 und x_2 werden bei allen Verfahren in jeder Simulation ausgewählt, x_3 dagegen jeweils nur in knapp mehr als einem Fünftel der Simulationen.

⇒ Auch die sieben Noise-Variablen sind jeweils bei ungefähr jeder fünften Simulation Bestandteil des finalen Modells.

⇒ Zwischen den einzelnen Variablenselektionsverfahren gibt es kaum Unterschiede.

- Funktion zur Bestimmung, ob das ausgewählte Modell das “korrekte” Modell ist:

```
correct_models <- function(results) {
  results <- lapply(X = split(x = results, f = results$ID), FUN = function(z) {
    lapply(X = split(x = z, f = z$Verfahren), FUN = function(i) {
      !any(is.na(match(paste0("x", 1:3), i$variable))) &
      all(is.na(match(paste0("x", 4:10), i$variable)))
    })
  })
  return(results)
}
```

- Überblickstabelle zu korrekter Modellwahl:

```
overview <- reshape2::melt(correct_models(results))
xtabs(formula = ~ value + L2, data = overview)

##           L2
## value      backward best_simple forward step_backward step_forward
##  FALSE         950         950     949           950           949
##   TRUE          50          50      51            50            51
```

- ⇒ Das “korrekte” Modell, welches nur x_1, x_2 und x_3 enthält, wird bei allen Selektionsverfahren ca. 50 mal ausgewählt.
- ⇒ In den meisten Fällen wird somit zwar nicht das exakt richtige Modell ausgewählt, allerdings ein gut geeignetes, das x_1 und x_2 enthält. Diese beiden Variablen erklären den Großteil der Streuung in der Zielgröße.

- Anmerkung:

Als Alternative zur selbst-definierten Funktion zur Durchführung der Best Subset-Variablen-selektion kann auch das **R**-Paket `leaps` verwendet werden. Hier kann das AIC nicht als Selektionskriterium gewählt werden, jedoch das Bestimmtheitsmaß R^2 . Beim linearen Modell führen beide Kriterien bei identischer Anzahl an Parametern allerdings immer zur gleichen Modellwahl, da in beiden Fällen die Residuenquadratsumme SSE minimiert wird.

- (c) Vergleichen Sie die Ergebnisse aus der vorherigen Teilaufgabe mit den Ergebnissen, die man über eine Variablenselektion mittels 10-facher Kreuzvalidierung erhält.

Lösung:

- Funktion zur Berechnung des RMSE (root mean squared error):

```
rmse <- function(observed, predicted) {
  return(sqrt(sum((observed - predicted)^2) / length(observed)))
}
```

- Funktion zur Einteilung des Datensatzes in Teildatensätze (folds):

```
get_folds <- function(n, K = 10) {
  cv_folds <- cvTools::cvFolds(n = n, K = K)
  cv_folds <- split(x = cv_folds$subsets[, 1], f = cv_folds$which)
  return(cv_folds)
}
```

- Funktion zur Durchführung der Kreuzvalidierung für eine gegebene Modellspezifikation:

```
do_cv <- function(formula, data, folds) {
  # Berechnung des Mittelwertes der RMSEs aller Teildatensätze:
  cv_mod <- mean(vapply(X = folds, FUN = function(i) {
    model <- lm(formula = formula, data = data[-i, ])
    rmse(observed = data[i, "y"],
          predicted = predict(object = model, newdata = data[i,]))
  }, FUN.VALUE = numeric(1)))
  # Ausgabe des Kreuzvalidierungs-RMSEs:
  attr(x = cv_mod, which = "formula") <- formula
  return(cv_mod)
}
```

- Funktion zur Durchführung der Kreuzvalidierung für die einzelnen Modellspezifikationen:

```
do_cvs <- function(data, folds) {
  # Generierung aller möglichen Modellspezifikationen:
  x_vars <- grep(pattern = "^x.*", x = colnames(data), value = TRUE)
```

```

all_forms <- lapply(X = seq_along(x_vars), FUN = function(z) {
  rhs <- combn(x = x_vars, m = z, FUN = paste0, collapse = "+")
  lapply(X = rhs, FUN = function(i){
    as.formula(paste0("y~", i))
  })
})
# Durchführung der Kreuzvalidierung für die einzelnen Modellspezifikationen:
res_all <- lapply(X = all_forms, FUN = function(z) {
  lapply(X = z, FUN = do_cv, data = data, folds = folds)
})
# Extraktion des gemäß des RMSEs besten Modells:
model_best <- lm(formula = attr(x = get_best(res_all), which = "formula"),
  data = data)
return(coef(model_best))
}

```

- Durchführung der Variablenselektion über Kreuzvalidierung für alle simulierten Datensätze:

```

set.seed(1)
folds <- get_folds(n = 100)
set.seed(1)
#cv_list <- mclapply(X = seq_along(df_list), function(z) {
# print(z)
# cv_list <- do_cvs(data = df_list[[z]], folds = folds)
# cv_df <- do.call(cbind.data.frame, as.list(cv_list))
# cv_df$ID <- z
# cv <- cv_df
# return(cv)
#}, mc.cores = 1)
# save(res_cv, file = "simulation_cv.RData")
load("../Daten/simulation_cv.RData")

```

- Zusammenfügen aller Ergebnisse zu einem Datensatz:

```

results_cv <- reshape2::melt(cv, id.vars = "ID") %>%
  mutate(variable = factor(x = variable, levels = paste0("x", 1:10)))
head(results_cv)

```


##	ID	variable	value	L1
## 1	1	<NA>	100.0038233	1
## 2	1	x1	2.8526452	1
## 3	1	x2	-0.6194316	1
## 4	1	x9	-0.1118377	1
## 5	2	<NA>	100.0990803	2
## 6	2	x1	3.0254401	2

- Graphischer Vergleich der Koeffizientenschätzer:

```

ggplot(data = filter(results_cv, variable != "(Intercept)"),
  mapping = aes(x = variable, y = value)) +
  geom_boxplot() +
  theme_minimal()

```



⇒ Die erhaltenen Boxplots sind sehr ähnlich zu denen der verschiedenen Variablenselektionstechniken bezüglich des AICs.

- Übersicht über Auswahlhäufigkeiten:

```
xtabs(formula = ~variable, data = results_cv)

## variable
##  x1  x2  x3  x4  x5  x6  x7  x8  x9  x10
## 1000 999 223 194 202 189 205 205 189 195
```

⇒ Die Variable x_3 wird etwas öfter korrekterweise in das finale Modell aufgenommen als bei den verschiedenen AIC-Verfahren.

⇒ Insgesamt führt die Strategie der Kreuzvalidierung zu etwas komplexeren Modellen, da auch einige der Noise-Variablen etwas häufiger ausgewählt werden.

- Überblick zu korrekter Modellwahl:

```
correct_cv <- sapply(X = split(x = results_cv, f = results_cv$ID),
  FUN = function(z) {
    !any(is.na(match(x = paste0("x", 1:3), table = z$variable))) &
    all(is.na(match(x = paste0("x", 4:10), table = z$variable)))
  })
table(correct_cv)

## correct_cv
## FALSE  TRUE
##  947    53
```

⇒ Das “korrekte” Modell wird über die Kreuzvalidierung 53 mal ausgewählt, also minimal häufiger als bei den verschiedenen AIC-basierten Verfahren.

⇒ Insgesamt führen alle betrachteten Selektionsverfahren zu sehr ähnlichen Ergebnissen.

July 8, 2026

Fragen und Kommentare an laura.bader@stat.uni-muenchen.de