

Multiples Regressionsmodell: Quadratsummenzerlegung und Inferenz

Aufgabe 1

Für das Multiple Regressionsmodell $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ kann man die Quadratsummenzerlegung $SST = SSM + SSE$ durchführen.

Gehe von n Beobachtungen und p Kovariablen aus.

- a) Schreibe die Quadratsummenzerlegung von Matrixnotation

$$(\mathbf{Y} - \bar{\mathbf{Y}})'(\mathbf{Y} - \bar{\mathbf{Y}}) = (\hat{\mathbf{Y}} - \bar{\mathbf{Y}})'(\hat{\mathbf{Y}} - \bar{\mathbf{Y}}) + (\mathbf{Y} - \hat{\mathbf{Y}})'(\mathbf{Y} - \hat{\mathbf{Y}})$$

in Summen-Notation ($\sum_{i=1}^n \dots$) um.

Forme anschließend weiter um, sodass die Terme $(n-1)\widehat{Var}(Y)$ sowie $\sum_{i=1}^n \hat{\varepsilon}_i^2$ in der Gleichung vorkommen.

- b) Interpretiere SST, SSM und SSE.
c) Definiere und interpretiere das R^2 . Welchen Werte-Bereich hat es?

Lösung:

- a)

$$\begin{aligned} (\mathbf{Y} - \bar{\mathbf{Y}})'(\mathbf{Y} - \bar{\mathbf{Y}}) &= (\hat{\mathbf{Y}} - \bar{\mathbf{Y}})'(\hat{\mathbf{Y}} - \bar{\mathbf{Y}}) + (\mathbf{Y} - \hat{\mathbf{Y}})'(\mathbf{Y} - \hat{\mathbf{Y}}) \\ \Leftrightarrow \begin{pmatrix} y_1 - \bar{y} \\ \vdots \\ y_n - \bar{y} \end{pmatrix}' \begin{pmatrix} y_1 - \bar{y} \\ \vdots \\ y_n - \bar{y} \end{pmatrix} &= \begin{pmatrix} \hat{y}_1 - \bar{y} \\ \vdots \\ \hat{y}_n - \bar{y} \end{pmatrix}' \begin{pmatrix} \hat{y}_1 - \bar{y} \\ \vdots \\ \hat{y}_n - \bar{y} \end{pmatrix} + \begin{pmatrix} y_1 - \hat{y}_1 \\ \vdots \\ y_n - \hat{y}_n \end{pmatrix}' \begin{pmatrix} y_1 - \hat{y}_1 \\ \vdots \\ y_n - \hat{y}_n \end{pmatrix} \quad (1) \\ \Leftrightarrow \sum_{i=1}^n (y_i - \bar{y})^2 &= \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n (y_i - \hat{y}_i)^2 \\ \Leftrightarrow (n-1)\widehat{Var}(Y) &= \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n \hat{\varepsilon}_i^2 \end{aligned}$$

- b) Die Sum of Squares Total (SST) ist ein Maß für die Streuung von Y . Sie kann zerlegt werden in einen Teil an Streuung, die durch das Modell erklärt wird (SSM - Sum of Squares Model), sowie einen Teil an Streuung, die unerklärt bleibt (SSE - Sum of Squares Error - die Residuen-Quadratsumme, welche bei der KQ-Methode minimiert wird).

- c) Das R^2 ist definiert durch $R^2 = \frac{SSM}{SST}$. Es gibt also den Anteil an Streuung von Y wieder, der durch das Modell erklärt werden kann (also durch die Linearkombination der Kovariablen). Der Wertebereich liegt zwischen 0 (das Modell erklärt keine Streuung von Y) und 1 (die komplette Streuung von Y wird durch die Linearkombination der Kovariablen erklärt).

Aufgabe 2

Zunächst kurze Verständnisfragen zu drei Themenbereichen.

a) Überblick über Tests:

- i.) Zum Testen welcher Hypothesen sind Wald-Test, F-Overall-Test, t -Test und LQ-Test (= Likelihood-Quotienten-Test = Likelihood-Ratio-Test = LR-Test) geeignet?
- ii.) Wie hängen die vier Tests zusammen?
- iii.) Worin unterscheiden sich die Ansätze zur Herleitung der vier Teststatistiken?

b) Bereinigung:

- i.) Was ist der Sinn von Bereinigung?
- ii.) Ist Bereinigung der Daten im Kontext von Regressions-Modellen notwendig?

c) Partielle und sequentielle Quadratsummen:

- i.) Was sind partielle und sequentielle Quadratsummen? Worin unterscheiden sie sich?
- ii.) Wofür werden partielle und sequentielle Quadratsummen benötigt?

Lösung:

a) Überblick über Tests:

- i.)
 - Wald- und LQ-Test eignen sich zum Testen allgemeiner linearer Hypothesen $H_0 : A\beta = c$ bezüglich β . Damit können die verschiedensten Annahmen bezüglich β getestet werden.
 - Der F-Overall-Test dient zur Prüfung, ob mein Modell überhaupt nichts taugt - also ob alle Regressionskoeffizienten gleichzeitig sich nicht von 0 unterscheiden (also keine der Kovariablen einen Effekt hat). Die Nullhypothese lautet: $H_0 : \beta_1, \dots, \beta_p = 0$. Die Alternativ-Hypothese lautet mindestens eine der Kovariablen hat einen von 0 signifikant verschiedenen Effekt.
 - Mit dem t -Test kann getestet werden, ob eine einzelne, bestimmte Kovariable einen signifikant von 0 verschiedenen Einfluss hat. Die Nullhypothese lautet: $H_0 : \beta_j = 0$.
- ii.)
 - Wald- und LQ-Test beruhen auf unterschiedlichen Ansätzen, sind im Falle des Multiplen Linearen Regressionsmodells jedoch äquivalent.

- Der F-Overall-Test kann direkt als Spezialfall des Wald-Tests mit
$$A = \begin{pmatrix} 0 & 1 & 0 & \dots & 0 \\ \vdots & 0 & \ddots & & \vdots \\ \vdots & \vdots & & \ddots & 0 \\ 0 & 0 & \dots & 0 & 1 \end{pmatrix} \text{ und } c = \begin{pmatrix} 0 \\ \vdots \\ 0 \end{pmatrix} \text{ geschrieben werden.}$$

- Der t -Test ist äquivalent zum Spezialfall des Wald-Tests mit

$$A = \begin{pmatrix} 0 & \dots & 0 & 1 & 0 & \dots & 0 \end{pmatrix} \text{ und } c = \begin{pmatrix} 0 \end{pmatrix}.$$

iii.) Während der Wald-Test (und F-Overall-Test) auf Quadrat-Summen basiert, nutzt der LQ-Test einen Likelihood-basierten Ansatz.

Der t -Test nutzt die (ggf. approximative) Normalverteilung der Regressions-Koeffizienten.

Hinweis: Für Modelle jenseits des Multiplen Regressionsmodells ist die Äquivalenz von Wald- und LQ-Test nicht mehr zwangsläufig gegeben. Insbesondere sind manche Tests nicht (oder nicht sinnvoll) durchführbar. Für LQ-Tests ist eine Verteilungsspezifikation notwendig und Quadratsummen sind nicht immer ein sinnvolles Maß.

b) Bereinigung:

- Bei der Bereinigung soll der Effekt von nicht interessierenden Störgrößen aus den Daten herausgerechnet werden, um korrekte Analysen auf den bereinigten Daten durchführen zu können.
- Bei Regressionsmodellen können Störgrößen einfach als zusätzliche Kovariable mit in das Modell aufgenommen werden. Eine Bereinigung ist damit nicht mehr notwendig.

c) Partielle und sequentielle Quadratsummen:

- Partielle Quadratsummen sind die Residuen-Quadratsummen-Unterschiede zwischen einem Modell mit allen p Kovariablen und je einem Modell, bei genau eine Kovariable j weggelassen wurde.

$$R(\underbrace{\beta_j}_{\text{weggelassen}} \mid \underbrace{\beta_0, \dots, \beta_{j-1}, \beta_{j+1}, \dots, \beta_p}_{\text{noch im Modell}}) = \underbrace{SSE(M_{-j})}_{\text{Modell ohne } \beta_j} - \underbrace{SSE}_{\text{Gesamtmodell}}$$

- Bei sequentiellen Quadratsummen wird Schritt für Schritt je eine weitere Kovariable weggelassen und der Residuen-Quadratsummen-Unterschied zwischen den jeweiligen Schritten betrachtet.

Die sequentielle Quadratsumme für den Schritt von nur noch k Kovariablen im Modell auf $k - 1$ Kovariablen im Modell (bei p Kovariablen insgesamt) ist wie folgt definiert:

$$R(\underbrace{\beta_k}_{\text{weggelassen}} \mid \underbrace{\beta_0, \dots, \beta_{k-1}}_{\text{noch im Modell } (k \leq p)}) = SSE(M_{k-1}) - SSE(M_k)$$

mit M_{k-1} ist das Modell mit den ersten $k - 1$ Kovariablen und M_k das Modell mit den ersten k Kovariablen. Es wird die Reihenfolge verwendet, wie man die Variablen ins Modell aufnimmt. Die Reihenfolge macht einen Unterschied, wie groß die der jeweiligen Kovariable zugeschriebenen Residuen-Quadratsummen-Reduzierung zugeschrieben wird.

- Beide Quadratsummen können als SSH für Hypothesen-Tests verwendet werden oder als Indikator für Variablenselektion dienen.

Aufgabe 3

Häufig stehen hinter der Anwendung eines Regressionsmodells Forschungshypothesen, die überprüft werden sollen. Genauer genommen Hypothesen zu den Regressionskoeffizienten. Also z.B. ‘Hat Kovariable 2 einen Einfluss auf die Zielvariable?’. Diese können im allgemeinen Framework eines Wald-Tests überprüft werden.

Gehen Sie von folgendem Regressionsmodell aus:

$$Y_{\text{ozon}, i} = \beta_0 + \beta_{\text{solar}} x_{\text{solar}, i} + \beta_{\text{temp}} x_{\text{temp}, i} + \beta_{\text{wind}} x_{\text{wind}, i} + \epsilon_i, \epsilon_i \stackrel{iid}{\sim} N(0, \sigma^2), i = 1, \dots, n$$

mit dem der Einfluss von Sonneneinstrahlung, Temperatur und Windgeschwindigkeit auf die Ozon-Konzentration untersucht werden soll (siehe `airquality`-Datensatz in R).

Stelle für folgende Forschungshypothesen die Matrix A und den Vektor c für die Nullhypothese $H_0: A\beta = c$ auf:

- i.) Keine der drei Einflussgrößen hat einen Einfluss auf die Ozon-Konzentration (ausgenommen dem Intercept).
- ii.) Die Temperatur hat keinen Einfluss auf die Ozon-Konzentration.
- iii.) Steigt die Windgeschwindigkeit um eine mph (= eine Einheit), sinkt die Ozon-Konzentration um 3 ppb (1 ppb = eine Einheit).
- iv.) Sonneneinstrahlung und Temperatur haben den selben Einfluss auf die Ozon-Konzentration.
- v.) Steigt die Sonneneinstrahlung um eine Einheit und die Temperatur um 3 Einheiten, steigt die Ozon-Konzentration um 8 Einheiten und die Windgeschwindigkeit hat keinen Einfluss.

Lösung:

$$\hat{\beta} = \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_{\text{solar}} \\ \hat{\beta}_{\text{temp}} \\ \hat{\beta}_{\text{wind}} \end{pmatrix}.$$

$$\text{i.) } A = \begin{pmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}, c = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}$$

$$\text{ii.) } A = \begin{pmatrix} 0 & 0 & 1 & 0 \end{pmatrix}, c = \begin{pmatrix} 0 \end{pmatrix}$$

$$\text{iii.) } A = \begin{pmatrix} 0 & 0 & 0 & 1 \end{pmatrix}, c = \begin{pmatrix} -3 \end{pmatrix}$$

$$\text{iv.) } A = \begin{pmatrix} 0 & 1 & -1 & 0 \end{pmatrix}, c = \begin{pmatrix} 0 \end{pmatrix}$$

$$\text{Also: } 1 \cdot \beta_{\text{solar}} - 1 \cdot \beta_{\text{temp}} = 0 \Leftrightarrow \beta_{\text{solar}} = \beta_{\text{temp}}$$

$$\text{v.) } A = \begin{pmatrix} 0 & 1 & 3 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}, c = \begin{pmatrix} 8 \\ 0 \end{pmatrix}$$

Aufgabe 4

Hinweis: Für Aufgabenteile a, b und e ist das 2. Tutorium hilfreich.

Die Normalverteilungsannahme bezüglich der Residuen ist nicht immer notwendig. In diesen Fällen kann die KQ-Methode und deren approximative Eigenschaften genutzt werden.

- a) Erkläre die inhaltliche Bedeutung der möglichen Annahmen 2.1)-2.5) im multiplen Regressionsmodell.

2.1) $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$

2.2) $E(\boldsymbol{\epsilon}) = \mathbf{0}$

2.3) $Var(\epsilon_i) = \sigma^2$ für $i = 1, \dots, n$

2.4) ϵ_i unabhängig

2.5) $\epsilon_i \sim N(0, \sigma^2)$.

- b) Welche Annahmen sind für die KQ-Schätzung notwendig?

- c) Der KQ-Schätzer ist unter bestimmten Bedingungen ein BLUE.

i.) Für was steht BLUE? Erkläre jede der drei Eigenschaften.

ii.) Welche Annahmen sind dafür hinreichend?

- d) Unter bestimmten Bedingungen ist der KQ-Schätzer konsistent.

i.) Welche Arten von Konsistenz gibt es und was ist das?

ii.) Welche Annahmen sind für die Konsistenz hinreichend?

- e) Unter bestimmten Bedingungen sind die Regressionskoeffizienten des KQ-Schätzers normalverteilt. Darauf basierend können Konfidenzintervalle und Tests für die Regressionskoeffizienten konstruiert werden.

i.) Welche Annahmen sind für die approximative Normalverteilung der Regressionskoeffizienten hinreichend.

ii.) Wie groß muss n sein, um sinnvolle Konfidenzintervalle bei Normalverteilungsannahme der Residuen (2.5)) erstellen zu können?

Lösung:

- a) 2.1) $Y = X\beta + \epsilon$: Die Zielgröße Y lässt sich durch eine Linearkombination aus den Einflussgrößen $x_1, \dots, x_p$ sowie einem zufälligen Fehler ϵ beschreiben.

2.2) $E(\epsilon) = 0$: Im Mittel ist die zufällige Störgröße 0. Es gibt also keine systematische Abweichung von der Modellannahme.

2.3) $Var(\epsilon_i) = \sigma^2$ für $i = 1, \dots, n$: Die Varianz ist für jede Beobachtung gleich groß. Insbesondere gibt es keine Wertebereiche einer Kovariablen oder der Zielvariablen,

- die die Streuung beeinflussen (z.B. hohe Werte der Kovariable bedeuten auch hohe Streuung der Residuen).
- 2.4) ϵ_i unabhängig: Die Residuen sind voneinander unabhängig. Insbesondere gibt es keine Korrelation zwischen den Residuen, wie sie z.B. bei Messwiederholung auftreten kann.
- 2.5) $\epsilon_i \sim N(0, \sigma^2)$: Die Residuen sind normalverteilt.
- b) Es ist nur die Modellgleichung 2.1) notwendig. (Mit zusätzlicher Annahme von 2.2) sind die Regressionskoeffizienten auch Erwartungstreu.)
- c) Der KQ-Schätzer ist unter bestimmten Bedingungen ein BLUE.
- i.) BLUE steht für Best Linear Unbiased Estimator.
- Best: Es gibt keinen anderen Schätzer (unter den linearen, ungebiasteten Schätzern), der eine kleinere Varianz aufweist. Er schätzt also am genauesten.
 - Linear: Der Schätzer soll linear in Y sein, sich also aus AY zusammensetzen, wobei $A \in \mathbb{R}^{p \times n}$.
Für den KQ-Schätzer gilt: $A = (X'X)^{-1}X'$, denn $\hat{\beta} = (X'X)^{-1}X'Y$.
 - Unbiased: Der Schätzer hat den Bias 0, also ist erwartungstreu.
- ii.) Es sind die Annahmen 2.1)-2.4) hinreichend.
- d) Unter bestimmten Bedingungen ist der KQ-Schätzer konsistent.
- i.) Es gibt schwache und starke Konsistenz.
- Bei schwacher Konsistenz konvergiert ein Schätzer mit steigendem Stichprobenumfang in Wahrscheinlichkeit gegen den wahren Parameter:
$$P(|\hat{\beta}^{(n)} - \beta| > \alpha) \xrightarrow{n \rightarrow \infty} 0 \quad (\forall \alpha > 0)$$
 - Bei starker Konsistenz konvergiert ein Schätzer fast sicher mit steigendem Stichprobenumfang gegen den wahren Parameter:
$$P\left(\lim_{n \rightarrow \infty} \hat{\beta}^{(n)} = \beta\right) = 1$$
- Beides sind wichtige Eigenschaften, die die Aussagekraft der Schätzer untermauern. Solange meine Annahmen stimmen (siehe Teilaufgabe ii), sind meine Schätzer für große n sehr gut.
- ii.)
- Schwache Konsistenz: Annahmen 2.1)-2.4)
 - Starke Konsistenz: Annahmen 2.1)-2.4) und ϵ_i sind identisch verteilt (aber nicht zwangsläufig normalverteilt, wie bei Annahme 2.5) der Fall).
- e) i.) 2.1)-2.4)
- ii.) Die Normalverteilung der Regressionskoeffizienten ist dann direkt und nicht nur approximativ ab groß genugem Stichprobenumfang n gegeben.