

Diskrete Einflussgrößen: ANOVA & Codierung

Aufgabe 1

In der Statistik existieren viele Methoden und insbesondere Namen für Methoden die einen engen Bezug zu Regressionsmodellen haben. In der Praxis wird man häufig mit solchen Begriffen konfrontiert - insbesondere auch, da sich die Statistik in vielen Fachbereichen unabhängig voneinander entwickelt hat.

Recherchiere, wie die Begriffe

- ANOVA
- ANCOVA
- t -Test
- einfaktorielle Varianzanalyse und
- mehrfaktorielle Varianzanalyse

mit Regression in Verbindung stehen.

Wieso wird von Varianzanalyse gesprochen, obwohl Mittelwerte verglichen werden?

Lösung:

- **ANOVA:** Die ANOVA (= Analysis of Variance bzw. Varianzanalyse) testet, ob sich der Mittelwert (einer metrischen Zielvariable) in verschiedenen Gruppen (diskrete Einflussvariable) unterscheidet.

Sie beruht auf Streuungszerlegung äquivalent zu $SST = SSM + SSE$ und ist letztendlich der bekannte F-Test mit dem getestet wird, ob eine diskrete Kovariable einen signifikanten Einfluss auf die Zielvariable hat.

Die Streuungszerlegung lässt sich in diesem Kontext als Vergleich zwischen within group variance und between group variance beschreiben. Daher stammt der Name.

Die SSM wird als *between group variance* bezeichnet, da $SSM = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$ ist und mit Mittelwertscodierung die $\hat{y}_i$ die jeweiligen Gruppenmittelwerte sind. Es handelt sich also um die Streuung zwischen den Gruppen.

Die SSE wird auch als *within group variance* bezeichnet, da $\sum_{i=1}^n (y_i - \hat{y})^2$ und somit die übrige Streuung innerhalb der Gruppen darstellt.

Gibt es kaum Streuung zwischen den Gruppenmittelwerten (im Verhältnis zu der Streuung innerhalb der Gruppen), sind diese sehr ähnlich. Sind die Gruppenmittelwerte jedoch weit auseinander, weisen diese eine hohe Varianz auf und man lehnt die Nullhypothese, dass

alle Gruppenmittelwerte identisch sind, ab.

- **ANCOVA:** Die ANCOVA (= Analysis of Covariance bzw. Kovarianzanalyse) ist identisch zur ANOVA, es wird jedoch noch für weitere Kovariablen kontrolliert. Spricht man testet also auf Mittelwertsgleichheit zwischen den Ausprägungen (Gruppen) der diskreten Kovariable und kontrolliert zusätzlich dabei auf weitere (metrische oder diskrete) Kovariablen, falls diese vermutete Störfaktoren sind oder eventuell einen Effekt haben, der nicht von Interesse ist.
- ***t*-Test:** Der klassische *t*-Test für Mittelwertsvergleich (mit Varianzhomogenität) ist ein Spezialfall der ANOVA. Die diskrete Einflussgröße hat hier nur zwei Ausprägungen, wohingegen bei der ANOVA mehrere Ausprägungen der diskreten Kovariable möglich sind.
- **einfaktorielle Varianzanalyse:** Die einfaktorielle Varianzanalyse ist eine ANOVA mit nur einer interessierenden diskreten Einflussgröße (welche mehrere Ausprägungen haben kann).
- **mehrfaktorielle Varianzanalyse:** Bei der mehrfaktoriellen Varianzanalyse ist man an mehreren diskreten Einflussgrößen (welche je mehrere Ausprägungen haben können) interessiert. Üblicherweise wird hier auch eine Interaktion zwischen den Größen mit aufgenommen.

Zusammengefasst: Alle Methoden testen, ob diskrete Einflussgrößen (Gruppen) einen signifikanten Effekt auf die metrische Zielgröße haben (es also Unterschiede zwischen den Gruppen gibt). Dabei hat der *t*-Test eine Einflussgröße mit zwei Ausprägungen, die einfaktorielle Varianzanalyse eine Einflussgröße mit mehreren Ausprägungen, die mehrfaktorielle Varianzanalyse mehrere Einflussgrößen mehreren Ausprägungen.

Der Begriff ANOVA umfasst im engeren Sinn nur die einfaktorielle Varianzanalyse, wird aber auch für generellere Methoden, die auf dem Konzept des Varianzvergleichs basieren, verwendet. Die ANCOVA kontrolliert noch auf weitere (zwar uninteressante, aber relevante) Einflussgrößen (Störgrößen).

Weitere Begriffe in dem Zusammenhang sind Faktoranalyse ($\neq$ Faktorenanalyse!) und MANOVA (multivariante ANOVA = mehrdimensionale Zielgröße wie z.B. Koordinaten). Varianzanalysen mit Messwiederholung (u.a. der Spezialfall verbundener *t*-Test) lassen sich als Regressionsmodell mit Random Effects (später im Kurs) darstellen.

Auch der *t*-Test mit unterschiedlicher Varianz lässt sich in einer verallgemeinerten Version des Multiplen Regressionsmodells darstellen (Aufweichung der Varianz-Homogenitätsannahme).

Aufgabe 2

Es sollen nun die drei Codierungs-Arten Mittelwertscodierung, Effektcodierung und Referenzcodierung miteinander verglichen werden. Diese werden zur Erstellung von Designmatrizen verwendet.

Hinweis: Dabei wird die Dummy-Codierung und Effektcodierung verwendet, um aus einer diskreten Einflussgröße mehrere binäre Einflussgrößen zu erstellen.

Verwende für diese Aufgabe den folgenden Datensatz mit einer metrischen Zielgröße $\mathbf{Y}$ und einer diskreten Einflussgröße $\mathbf{x}$.

i	y_i	x_i
1	2.2	A
2	2.4	A
3	0.5	B
4	1.1	C
5	1.0	C
6	1.2	C

a) Mittelwertscodierung

- Gib die Designmatrix $\mathbf{X}$, den Regressionskoeffizientenvektor und ggf. Restriktionen an.
- Schreibe das zu dem Beispieldatensatz gehörige Gleichungssystem übersichtlich auf.
- Gib den Wert der Schätzungen für die Regressionskoeffizienten an.

b) Effektcodierung

- Gib die Designmatrix $\mathbf{X}$, den Regressionskoeffizientenvektor und ggf. Restriktionen an.
- Schreibe das zu dem Beispieldatensatz gehörige Gleichungssystem übersichtlich auf.
- Gib den Wert der Schätzungen für die Regressionskoeffizienten an. (Gib auch die Regressionskoeffizientenschätzungen an, die nicht in der Modellgleichung vorkommen).
Tipp: $\hat{\mu}$ ist 1.3.

Die Designmatrix für die Effektcodierung ist auf den ersten Blick etwas unintuitiv. Das Modell lässt sich auch (mit Dummycodierung für die Variablen) wie folgt schreiben:

$$(A) \quad y_i = \mu + \underbrace{\tau_A I_A(x_i)}_{Z_A(x_i)} + \underbrace{\tau_B I_B(x_i)}_{Z_B(x_i)} + \underbrace{\tau_C I_C(x_i)}_{Z_C(x_i)} + \epsilon_i, \quad \sum_{k=A, \dots, C} \tau_k = 0$$

Es gibt also einen Gesamtmittelwert μ und je Gruppe einen Unterschied τ_k zu dem Gesamtmittelwert.

Das Modell könnte so optimiert werden (Lagrange-Ansatz, vgl. auch Matrixalgebra-Skript von Stefan Lang). Oder man verwendet eben die Effektcodierung, um übliche Optimierungsmethoden verwenden zu können:

$$(B) \quad y_i = \mu + \underbrace{\tau_A I_A(x_i)}_{Z_A^e(x_i)} + \underbrace{\tau_B I_B(x_i)}_{Z_B^e(x_i)} + \underbrace{-\tau_A I_C(x_i) - \tau_B I_C(x_i)}_{Z_C^e(x_i)} + \epsilon_i, \quad \sum_{k=A, \dots, C} \tau_k = 0$$

iv.) Warum ist die Restriktion $\sum_{k=A, \dots, C} \tau_k = 0$ notwendig? Gib ein Beispiel an, welches das Problem veranschaulicht.

v.) Zuletzt soll noch der Schritt von (A) zu (B) nachvollzogen werden. Forme dazu $\sum_{k=A, \dots, C} \tau_k = 0$ nach τ_C um und setze das Ergebnis in (A) ein. Wird nun klar, wie die Effektcodierung zustande kommt?

vi.) Der Mittelwert von y ist 1.4, μ jedoch 1.3. Wie lässt sich μ berechnen und interpretieren?


c) Referenzcodierung

i.) Gib die Designmatrix X , den Regressionskoeffizientenvektor und ggf. Restriktionen an.

ii.) Schreibe das zu dem Beispieldatensatz gehörige Gleichungssystem übersichtlich auf.

iii.) Gib den Wert der Schätzungen für die Regressionskoeffizienten an.

d) Visualisiere die Schätzungen der Regressionskoeffizienten der drei Codierungen in den drei Scatterplots.



Lösung:

a) Mittelwertscodierung

i.) Designmatrix und Koeffizientenvektor:

$$X = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 1 \\ 0 & 0 & 1 \end{pmatrix}, \begin{pmatrix} \mu_A \\ \mu_B \\ \mu_C \end{pmatrix}, \text{keine Restriktionen (bzw. nur: Gesamt-Intercept} = 0)$$

ii.) Gleichungssystem:

$$2.2 = \mu_A + \epsilon_1$$

$$2.4 = \mu_A + \epsilon_2$$

$$0.5 = \mu_B + \epsilon_3$$

$$1.1 = \mu_C + \epsilon_4$$

$$1.0 = \mu_C + \epsilon_5$$

$$1.2 = \mu_C + \epsilon_6$$

iii.) Schätzungen:

$$\mu_A = \frac{2.2+2.4}{2} = 2.3$$

$$\mu_B = 0.5$$

$$\mu_C = \frac{1.1+1.0+1.2}{3} = 1.1$$

b) Effektcodierung

i.) Designmatrix und Koeffizientenvektor:

$$X = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & -1 & -1 \\ 1 & -1 & -1 \\ 1 & -1 & -1 \end{pmatrix}, \begin{pmatrix} \mu \\ \tau_A \\ \tau_B \end{pmatrix}, \text{Restriktion: } \sum_{k=A,\dots,C} \tau_k = 0$$

ii.) Gleichungssystem:

$$2.2 = \mu + \tau_A + \epsilon_1$$

$$2.4 = \mu + \tau_A + \epsilon_2$$

$$0.5 = \mu + \tau_B + \epsilon_3$$

$$1.1 = \mu - \tau_A - \tau_B + \epsilon_4$$

$$1.0 = \mu - \tau_A - \tau_B + \epsilon_5$$

$$1.2 = \mu - \tau_A - \tau_B + \epsilon_6$$

iii.) Schätzungen: $\mu = \frac{2.3+0.5+1.1}{3} = 1.3$ (siehe Teilaufgabe b) vi.)

$$\tau_A = \mu_A - \mu = 2.3 - 1.3 = 1.0$$

$$\tau_B = \mu_B - \mu = 0.5 - 1.3 = -0.8$$

$$\tau_C = -\tau_A - \tau_B = -1.0 - (-0.8) = -0.2$$

iv.) Die Restriktion ist notwendig, damit die Schätzung eindeutig ist. Es können nur 3

Parameter eindeutig geschätzt werden (bei der Mittelwertscodierung die drei Gruppenmittelwerte). Hier würden aber 4 Parameter frei geschätzt (μ und die drei τ_k).

Ohne Restriktion könnte man sonst z.B. für μ auch 0.5 (oder jeden anderen beliebigen Wert) statt 1.3 einsetzen. Dann wäre jedes τ_k um 0.8 größer und führt so zu identischen Prädiktionen. Damit sind auch Residuen und die zu minimierende Residuenquadratsumme identisch (trotz unterschiedlicher Koeffizienten).

Die Restriktion verhindert diese Uneindeutigkeit.

(Zur Besseren Vorstellung kann es nützlich sein die Grafik in Teilaufgabe d) zu betrachten. Der Intercept μ kann beliebig verschoben werden und je die τ_k so modifiziert werden, dass sie immer am Mittelwert der jeweiligen Gruppe herauskommen.)

$$\text{v.) } \sum_{k=A,\dots,C} \tau_k = 0 \quad \Leftrightarrow \quad \tau_C = -\tau_A - \tau_B$$

Einsetzen in (A):

$$\begin{aligned} y_i &= \mu + \tau_A I_A(x_i) + \tau_B I_B(x_i) + \tau_C I_C(x_i) + \epsilon_i \\ &= \mu + \tau_A I_A(x_i) + \tau_B I_B(x_i) + (-\tau_A - \tau_B) I_C(x_i) + \epsilon_i \\ &= \mu + \underbrace{\tau_A I_A(x_i)}_{Z_A^c(x_i)} + \underbrace{\tau_B I_B(x_i)}_{Z_B^c(x_i)} + \underbrace{-\tau_A I_C(x_i) - \tau_B I_C(x_i)}_{Z_C^c(x_i)} + \epsilon_i \quad \square \end{aligned}$$

vi.) μ ist der Mittelwert der drei Gruppenmittelwerte μ_A, μ_B, μ_C . So ist dieser auch zu interpretieren.

Ob dieser sinnvoll (oder das gewollte Maß) ist, hängt sehr stark von dem Fall ab, den man betrachtet. Beispiel Noten:

- Alle Gruppen sind in der Grundgesamtheit gleich groß (z.B. Anzahl Schüler in der 1. Klasse = Anzahl Schüler in der 2. Klasse = ...): μ kann hier auch als Gesamtmittelwert über alle Klassen hinweg betrachtet werden.
- Gruppen sind in der Grundgesamtheit unterschiedlich groß (z.B. Anzahl Studenten im 1. Semester > Anzahl Studenten im 2. Semester > ...): μ ist hier nicht der Gesamtmittelwert aller Studenten! Sondern nur der Mittelwert der jeweiligen Semester-Mittelwerte.

Der Anteil der jeweiligen Gruppen in der Stichprobe ist dabei in beiden Fällen irrelevant!

c) Referenzcodierung

i.) Designmatrix und Koeffizientenvektor:

$$X = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 0 & 0 \\ 1 & 0 & 0 \\ 1 & 0 & 0 \end{pmatrix}, \quad \begin{pmatrix} \mu_C \\ \tau_A \\ \tau_B \end{pmatrix}, \quad \text{Restriktion: } \tau_C = 0$$

ii.) Gleichungssystem:

$$2.2 = \mu_C + \tau_A + \epsilon_1$$

$$2.4 = \mu_C + \tau_A + \epsilon_2$$

$$0.5 = \mu_C + \tau_B + \epsilon_3$$

$$1.1 = \mu_C + \epsilon_4$$

$$1.0 = \mu_C + \epsilon_5$$

$$1.2 = \mu_C + \epsilon_6$$


iii.) Schätzungen:

$$\mu_C = \frac{1.1+1.0+1.2}{3} = 1.1$$

$$\tau_A = \mu_A - \mu_C = 2.3 - 1.1 = 1.2$$

$$\tau_B = \mu_B - \mu_C = 0.5 - 1.1 = -0.6$$

d) Visualisierung der Schätzungen



Aufgabe 3

In dieser Aufgabe soll nun erarbeitet werden, wie man die verschiedenen Codierungen für diskrete Einflussvariablen in *R* implementiert.

- a) Mach dich mit dem *PlantGrowth*-Datensatz in *R* vertraut.
- b) Fitte ein Regressionsmodell *mod_1* mit dem der Ertrag anhand des Treatments vorhergesagt wird und gib die Summary aus.
Tipp: Du kannst die diskrete Einflussvariable *group* einfach so direkt ins Modell aufnehmen.
 - i.) Welche Codierung wird per Default verwendet?
 - ii.) Interpretiere die Regressionskoeffizienten und kommentiere weitere Auffälligkeiten in der Summary.
 - iii.) Gib einen Wert für die Prädiktion einer neuen Beobachtung aus der Kontrollgruppe und einer neuen Beobachtung aus der Gruppe mit Treatment 1 an.
- c) Die Referenz-Codierung ist die verbreitetste. Die Modifikation der Codierung in *R* ist nicht unbedingt besonders elegant gelöst. Die folgenden drei Modifikationen sind die einfachsten:
 - i.) Ändern der Referenz-Gruppe:
SPSS nutzt z.B. stets die letzte (und nicht die erste) Gruppe als Referenz. Um mit *R* die Ergebnisse reproduzieren zu können, muss man die Referenz ändern. Tue dies, indem Du eine neue Variable *group_trt2* dem Datensatz hinzufügst und diese anstelle der *group*-Variable im Modell verwendest.
Tipp: `relevel(MeinDatensatz$MeineVariable, ref = 'NeueRefGruppe')`.
 - ii.) Umrechnung aus der Referenz-Codierung:
Für einfache Regressionen ist es evtl. am einfachsten die Koeffizienten der Effektcodierung aus den Referenzcodierungs-Ergebnissen zu berechnen, anstatt sich mit umständlicheren R-Einstellungen zu plagen.
Berechne die Koeffizienten der Effekt-Codierung aus den Ergebnissen der Referenz-Codierung.
- d) Erstelle zuletzt noch den fiktiven Datensatz:

```
MeineDaten <- data.frame(score = 1 : 9, gruppe = c(1, 1, 1, 2, 2, 2, 3, 3, 3))
```

und fitte das Modell: `mod_2 <- lm(score ~ gruppe, data = MeineDaten)`
`summary(mod_2)`
Mit dem Modell soll ein Intelligenz-Score (*score*) anhand der drei Gruppen (1 = '*HM*', 2 = '*TUM*', 3 = '*LMU*') vorhergesagt werden.
Betrachte die Summary. Was geht hier schief? Wie kann das behoben werden?

Lösung:

Siehe *R*-Lösung.