

Multiples Regressionsmodell

Aufgabe 1

Der Datensatz *mtcars* aus *R* stammt aus dem Motor-Trend US-Magazin von 1974 und enthält für 32 Autos unter anderem die Reichweite in Meilen pro Gallone (mpg) und das Gewicht in 1000 Pfund (lbs).

Info: 10 mpg = 4.25 km/L (entspricht 23.5 L/100 km - Achtung: inverse Einheit).

Beobachtung	Reichweite in Meilen pro Gallone	Gewicht in 1000 Pfund
1: Mazda RX4	21.0	2.620
2: Mazda RX4 Wag	21.0	2.875
	$\vdots$	
32: Volvo 142E	21.4	2.780

Es soll die Reichweite anhand des Gewichts vorhergesagt werden. Gegeben ist hierfür ein multiples Regressionsmodell $Y = X\beta + \epsilon$ mit n Beobachtungen und p Kovariablen.

- Das Modell soll einen Intercept enthalten. Welche Dimensionen haben Y , X , β und ϵ ?
- Gib die Modellgleichung explizit für obiges Beispiel mit konkreten Zahlen in zwei Versionen an:
 - In Matrixnotation.
 - Als Gleichungssystem.

Gib auch n und p an.

Führe die weiteren Aufgaben in *R* durch.

- Mach dich mit dem Datensatz *mtcars* vertraut.
Tipp: `?mtcars`, `head()`, `summary()`, `str()`
- Fitte das Regressionsmodell mit dem die Reichweite anhand des Gewichts vorhergesagt werden kann und speichere das Objekt in einer Variable.
Tipp: `lm()`
- Gib das Summary des Modells aus.
 - Erkläre alle in der Ausgabe angegebenen Werte (mit Ausnahme der letzten Zeile).
Tipp: `?summary.lm`

- ii.) Gib für alle Größen eine Formel zur Berechnung an (mit Ausnahme von t -value und $Pr(> |t|)$, sowie der letzten Zeile).
- f) Mach dich mit dem Modell-Objekt vertraut.
Tipps: ?lm, MeinModell\$InteressierendeGröße
- i.) Rufe die Residuen im Modell-Objekt auf.
- ii.) Rufe die prädiktierten Werte im Modell-Objekt auf.
- iii.) Rufe die für das Modell verwendeten Daten über das Modell-Objekt auf.

ZUSATZAUFGABEN


- g) Gib die Formeln für den KQ-Schätzer sowie den ML-Schätzer in Matrix-Notation an.
- h) Die KQ-Methode liefert folgende Ergebnisse für die Schätzungen für die Regressions-Koeffizienten:

$$\hat{\beta}_0 = 37.3$$

$$\hat{\beta}_{\text{gewicht}} = -5.3$$

Zeichne folgende Dinge in das Streudiagramm ein:

- $x_{\text{gewicht},i}, y_i$ ($i = 17, 20, 29$)
- Regressionsgerade
- $\hat{\beta}_0, \hat{\beta}_{\text{gewicht}}$
- ϵ_i ($i = 17, 20, 29$)



- i) Interpretiere die Regressionsparameter.

j) Welcher Verteilung folgt $\hat{\beta}$?

Führe die weiteren Aufgaben in *R* durch.

- i.) Gib die Schätzung für den Erwartungswert-Vektor von $\hat{\beta}$ explizit an.
- ii.) Gib Schätzung für die Varianzen der Einträge von $\hat{\beta}$ explizit an.
- iii.) Gib je ein 95%-Konfidenzintervall für die $\hat{\beta}_j$ ($j = 0, \dots, 3$) an.

Aufgabe 2

Es soll die Auswirkung von *Körpergröße* und *Alter* auf das *Gewicht* bei Grundschulkindern untersucht werden. Dazu wird ein Multiples Regressionsmodell

$$y_{\text{Gewicht}, i} = \beta_0 + \beta_{\text{größe}} \cdot x_{\text{größe}, i} + \beta_{\text{Alter}} \cdot x_{\text{alter}, i} + \epsilon_i$$

geschätzt.

Die Daten werden an einer Grundschule in einem kleinen Dorf mit 200 Schülern erhoben.

- a) Welche Annahmen 1.) - 5.) sind für die in den Zeilen angegebenen Schätzer, Eigenschaften bzw. Größen notwendig?

	1.)	2.)	3.)	4.)	5.)
KQ-Schätzer					
ML-Schätzer					
$E(\hat{\beta}) = \beta$					
$\hat{\beta} \sim N(\beta, \sigma^2(X'X)^{-1})$					
Konfidenzintervalle (von Regressionskoeffizienten, Prädiktionen, ...)					
Prädiktionsintervalle (von Prädiktionen, ...)					

Annahme 1.) $Y = X\beta + \epsilon$

Annahme 2.) $E(\epsilon_i) = 0$

Annahme 3.) $Var(\epsilon_i) = \sigma^2$

Annahme 4.) ϵ_i paarweise unabhängig

Annahme 5.) $\epsilon_i \sim N(0, \sigma^2)$

- b) Diskutiere alle Annahmen, die für die ML-Schätzung notwendig sind im konkreten Beispiel Gewichts-Schätzung. Welche Annahmen sind nur bedingt realistisch?
- c) Was folgt daraus, wenn Annahmen (teilweise) nicht erfüllt sind?
- d) Müssen alle aufgenommenen Kovariablen $x_1, \dots, x_j$ unkorreliert sein?
- e) Körpergröße und Alter sind korrelierte Einflussgrößen. Was folgt daraus für die Interpretation der einzelnen Regressionskoeffizienten unter c.p.-Bedingung (ceteris paribus = alle anderen Kovariablen konstant)?