

Multiples Regressionsmodell: Quadratsummenzerlegung und Inferenz

Aufgabe 1

Für das Multiple Regressionsmodell $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ kann man die Quadratsummenzerlegung $SST = SSM + SSE$ durchführen.

Gehe von n Beobachtungen und p Kovariablen aus.

- a) Schreibe die Quadratsummenzerlegung von Matrixnotation

$$(\mathbf{Y} - \bar{\mathbf{Y}})'(\mathbf{Y} - \bar{\mathbf{Y}}) = (\hat{\mathbf{Y}} - \bar{\mathbf{Y}})'(\hat{\mathbf{Y}} - \bar{\mathbf{Y}}) + (\mathbf{Y} - \hat{\mathbf{Y}})'(\mathbf{Y} - \hat{\mathbf{Y}})$$

in Summen-Notation ($\sum_{i=1}^n \dots$) um.

Forme anschließend weiter um, sodass die Terme $(n-1)\widehat{Var}(Y)$ sowie $\sum_{i=1}^n \hat{\varepsilon}_i^2$ in der Gleichung vorkommen.

- b) Interpretiere SST, SSM und SSE.
- c) Definiere und interpretiere das R^2 . Welchen Werte-Bereich hat es?

Aufgabe 2

Zunächst kurze Verständnisfragen zu drei Themenbereichen.

a) Überblick über Tests:

- i.) Zum Testen welcher Hypothesen sind Wald-Test, F-Overall-Test, t -Test und LQ-Test (= Likelihood-Quotienten-Test = Likelihood-Ratio-Test = LR-Test) geeignet?
- ii.) Wie hängen die vier Tests zusammen?
- iii.) Worin unterscheiden sich die Ansätze zur Herleitung der vier Teststatistiken?

b) Bereinigung:

- i.) Was ist der Sinn von Bereinigung?
- ii.) Ist Bereinigung der Daten im Kontext von Regressions-Modellen notwendig?

c) Partielle und sequentielle Quadratsummen:

- i.) Was sind partielle und sequentielle Quadratsummen? Worin unterscheiden sie sich?
- ii.) Wofür werden partielle und sequentielle Quadratsummen benötigt?

Aufgabe 3

Häufig stehen hinter der Anwendung eines Regressionsmodells Forschungshypothesen, die überprüft werden sollen. Genauer genommen Hypothesen zu den Regressionskoeffizienten. Also z.B. ‘Hat Kovariable 2 einen Einfluss auf die Zielvariable?’. Diese können im allgemeinen Framework eines Wald-Tests überprüft werden.

Gehen Sie von folgendem Regressionsmodell aus:

$$Y_{\text{ozon}, i} = \beta_0 + \beta_{\text{solar}} x_{\text{solar}, i} + \beta_{\text{temp}} x_{\text{temp}, i} + \beta_{\text{wind}} x_{\text{wind}, i} + \epsilon_i, \epsilon_i \stackrel{iid}{\sim} N(0, \sigma^2), i = 1, \dots, n$$

mit dem der Einfluss von Sonneneinstrahlung, Temperatur und Windgeschwindigkeit auf die Ozon-Konzentration untersucht werden soll (siehe `airquality`-Datensatz in R).

Stelle für folgende Forschungshypothesen die Matrix A und den Vektor c für die Nullhypothese $H_0: A\beta = c$ auf:

- i.) Keine der drei Einflussgrößen hat einen Einfluss auf die Ozon-Konzentration (ausgenommen dem Intercept).
- ii.) Die Temperatur hat keinen Einfluss auf die Ozon-Konzentration.
- iii.) Steigt die Windgeschwindigkeit um eine mph (= eine Einheit), sinkt die Ozon-Konzentration um 3 ppb (1 ppb = eine Einheit).
- iv.) Sonneneinstrahlung und Temperatur haben den selben Einfluss auf die Ozon-Konzentration.
- v.) Steigt die Sonneneinstrahlung um eine Einheit und die Temperatur um 3 Einheiten, steigt die Ozon-Konzentration um 8 Einheiten und die Windgeschwindigkeit hat keinen Einfluss.

Aufgabe 4

Hinweis: Für Aufgabenteile a, b und e ist das 2. Tutorium hilfreich.

Die Normalverteilungsannahme bezüglich der Residuen ist nicht immer notwendig. In diesen Fällen kann die KQ-Methode und deren approximative Eigenschaften genutzt werden.

- a) Erkläre die inhaltliche Bedeutung der möglichen Annahmen 2.1)-2.5) im multiplen Regressionsmodell.

2.1) $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$

2.2) $E(\boldsymbol{\epsilon}) = \mathbf{0}$

2.3) $Var(\epsilon_i) = \sigma^2$ für $i = 1, \dots, n$

2.4) ϵ_i unabhängig

2.5) $\epsilon_i \sim N(0, \sigma^2)$.

- b) Welche Annahmen sind für die KQ-Schätzung notwendig?

- c) Der KQ-Schätzer ist unter bestimmten Bedingungen ein BLUE.

i.) Für was steht BLUE? Erkläre jede der drei Eigenschaften.

ii.) Welche Annahmen sind dafür hinreichend?

- d) Unter bestimmten Bedingungen ist der KQ-Schätzer konsistent.

i.) Welche Arten von Konsistenz gibt es und was ist das?

ii.) Welche Annahmen sind für die Konsistenz hinreichend?

- e) Unter bestimmten Bedingungen sind die Regressionskoeffizienten des KQ-Schätzers normalverteilt. Darauf basierend können Konfidenzintervalle und Tests für die Regressionskoeffizienten konstruiert werden.

i.) Welche Annahmen sind für die approximative Normalverteilung der Regressionskoeffizienten hinreichend.

ii.) Wie groß muss n sein, um sinnvolle Konfidenzintervalle bei Normalverteilungsannahme der Residuen (2.5)) erstellen zu können?