

Diskrete Einflussgrößen: ANOVA & Codierung

Aufgabe 1

In der Statistik existieren viele Methoden und insbesondere Namen für Methoden die einen engen Bezug zu Regressionsmodellen haben. In der Praxis wird man häufig mit solchen Begriffen konfrontiert - insbesondere auch, da sich die Statistik in vielen Fachbereichen unabhängig voneinander entwickelt hat.

Recherchiere, wie die Begriffe

- ANOVA
- ANCOVA
- t -Test
- einfaktorielle Varianzanalyse und
- mehrfaktorielle Varianzanalyse

mit Regression in Verbindung stehen.

Wieso wird von Varianzanalyse gesprochen, obwohl Mittelwerte verglichen werden?

Aufgabe 2

Es sollen nun die drei Codierungs-Arten Mittelwertscodierung, Effektcodierung und Referenzcodierung miteinander verglichen werden. Diese werden zur Erstellung von Designmatrizen verwendet.

Hinweis: Dabei wird die Dummy-Codierung und Effektcodierung verwendet, um aus einer diskreten Einflussgröße mehrere binäre Einflussgrößen zu erstellen.

Verwende für diese Aufgabe den folgenden Datensatz mit einer metrischen Zielgröße $\mathbf{Y}$ und einer diskreten Einflussgröße $\mathbf{x}$.

i	y_i	x_i
1	2.2	A
2	2.4	A
3	0.5	B
4	1.1	C
5	1.0	C
6	1.2	C

a) Mittelwertscodierung

- Gib die Designmatrix $\mathbf{X}$, den Regressionskoeffizientenvektor und ggf. Restriktionen an.
- Schreibe das zu dem Beispieldatensatz gehörige Gleichungssystem übersichtlich auf.
- Gib den Wert der Schätzungen für die Regressionskoeffizienten an.

b) Effektcodierung

- Gib die Designmatrix $\mathbf{X}$, den Regressionskoeffizientenvektor und ggf. Restriktionen an.
- Schreibe das zu dem Beispieldatensatz gehörige Gleichungssystem übersichtlich auf.
- Gib den Wert der Schätzungen für die Regressionskoeffizienten an. (Gib auch die Regressionskoeffizientenschätzungen an, die nicht in der Modellgleichung vorkommen).
Tipp: $\hat{\mu}$ ist 1.3.

Die Designmatrix für die Effektcodierung ist auf den ersten Blick etwas unintuitiv. Das Modell lässt sich auch (mit Dummycodierung für die Variablen) wie folgt schreiben:

$$(A) \quad y_i = \mu + \underbrace{\tau_A I_A(x_i)}_{Z_A(x_i)} + \underbrace{\tau_B I_B(x_i)}_{Z_B(x_i)} + \underbrace{\tau_C I_C(x_i)}_{Z_C(x_i)} + \epsilon_i, \quad \sum_{k=A, \dots, C} \tau_k = 0$$

Es gibt also einen Gesamtmittelwert μ und je Gruppe einen Unterschied τ_k zu dem Gesamtmittelwert.

Das Modell könnte so optimiert werden (Lagrange-Ansatz, vgl. auch Matrixalgebra-Skript von Stefan Lang). Oder man verwendet eben die Effektcodierung, um übliche Optimierungsmethoden verwenden zu können:

$$(B) \quad y_i = \mu + \underbrace{\tau_A I_A(x_i)}_{Z_A^e(x_i)} + \underbrace{\tau_B I_B(x_i)}_{Z_B^e(x_i)} + \underbrace{-\tau_A I_C(x_i) - \tau_B I_C(x_i)}_{Z_C^e(x_i)} + \epsilon_i, \quad \sum_{k=A, \dots, C} \tau_k = 0$$

iv.) Warum ist die Restriktion $\sum_{k=A, \dots, C} \tau_k = 0$ notwendig? Gib ein Beispiel an, welches das Problem veranschaulicht.

v.) Zuletzt soll noch der Schritt von (A) zu (B) nachvollzogen werden. Forme dazu $\sum_{k=A, \dots, C} \tau_k = 0$ nach τ_C um und setze das Ergebnis in (A) ein. Wird nun klar, wie die Effektcodierung zustande kommt?

vi.) Der Mittelwert von y ist 1.4, μ jedoch 1.3. Wie lässt sich μ berechnen und interpretieren?


c) Referenzcodierung

i.) Gib die Designmatrix X , den Regressionskoeffizientenvektor und ggf. Restriktionen an.

ii.) Schreibe das zu dem Beispieldatensatz gehörige Gleichungssystem übersichtlich auf.

iii.) Gib den Wert der Schätzungen für die Regressionskoeffizienten an.

d) Visualisiere die Schätzungen der Regressionskoeffizienten der drei Codierungen in den drei Scatterplots.



Aufgabe 3

In dieser Aufgabe soll nun erarbeitet werden, wie man die verschiedenen Codierungen für diskrete Einflussvariablen in *R* implementiert.

- a) Mach dich mit dem *PlantGrowth*-Datensatz in *R* vertraut.
- b) Fitte ein Regressionsmodell *mod_1* mit dem der Ertrag anhand des Treatments vorhergesagt wird und gib die Summary aus.
Tipp: Du kannst die diskrete Einflussvariable *group* einfach so direkt ins Modell aufnehmen.

- i.) Welche Codierung wird per Default verwendet?
 - ii.) Interpretiere die Regressionskoeffizienten und kommentiere weitere Auffälligkeiten in der Summary.
 - iii.) Gib einen Wert für die Prädiktion einer neuen Beobachtung aus der Kontrollgruppe und einer neuen Beobachtung aus der Gruppe mit Treatment 1 an.
- c) Die Referenz-Codierung ist die verbreitetste. Die Modifikation der Codierung in *R* ist nicht unbedingt besonders elegant gelöst. Die folgenden drei Modifikationen sind die einfachsten:

- i.) Ändern der Referenz-Gruppe:

SPSS nutzt z.B. stets die letzte (und nicht die erste) Gruppe als Referenz. Um mit *R* die Ergebnisse reproduzieren zu können, muss man die Referenz ändern. Tue dies, indem Du eine neue Variable *group_trt2* dem Datensatz hinzufügst und diese anstelle der *group*-Variable im Modell verwendest.

Tipp: `relevel(MeinDatensatz$MeineVariable, ref = 'NeueRefGruppe')`.

- ii.) Umrechnung aus der Referenz-Codierung:

Für einfache Regressionen ist es evtl. am einfachsten die Koeffizienten der Effektcodierung aus den Referenzcodierungs-Ergebnissen zu berechnen, anstatt sich mit umständlicheren R-Einstellungen zu plagen.

Berechne die Koeffizienten der Effekt-Codierung aus den Ergebnissen der Referenz-Codierung.

- d) Erstelle zuletzt noch den fiktiven Datensatz:

```
MeineDaten <- data.frame(score = 1 : 9, gruppe = c(1, 1, 1, 2, 2, 2, 3, 3, 3))
```

```
und fitte das Modell: mod_2 <- lm(score ~ gruppe, data = MeineDaten)
```

```
summary(mod_2)
```

Mit dem Modell soll ein Intelligenz-Score (*score*) anhand der drei Gruppen (1 = 'HM', 2 = 'TUM', 3 = 'LMU') vorhergesagt werden.

Betrachte die Summary. Was geht hier schief? Wie kann das behoben werden?