

Modelldiagnostik & Variablenselektion

Aufgabe 1

Modelldiagnostik ist einer der wesentlichsten Schritte beim Erstellen von Modellen und sollte bei jedem Modell durchgeführt werden. In dieser Aufgabe soll eine Modelldiagnostik für das bekannte Modell $y_{\text{Ozon}} = \beta_0 + \beta_{\text{Temp}}x_{\text{Temp}} + \beta_{\text{Wind}}x_{\text{Wind}} + \beta_{\text{Solar.R}}x_{\text{Solar.R}} + \epsilon$ auf Basis des `airquality`-Datensatzes in R durchgeführt werden. Dazu steht eine R-Vorlage für diese Aufgabe zur Verfügung.

In der Vorlesung werden 8 mögliche Probleme und Diagnose-Möglichkeiten angesprochen.

- i.) *Modellannahme 2.1): $Y = X\beta + \epsilon$ verletzt*
 - ii.) *Modellannahme 2.2): $E(\epsilon) = 0$*
 - iii.) *Modellannahme 2.3): $\text{Var}(\epsilon_i) = \sigma^2$ verletzt*
 - iv.) *Modellannahme 2.4): ϵ_i unabhängig verletzt*
 - v.) *Modellannahme 2.5): $\epsilon_i \sim N(0, \sigma^2)$ verletzt*
 - vi.) *Ausreißer und High-Leverage-Points im Modell*
 - vii.) *Kollinearität der Einflussgrößen*
 - viii.) *Messfehler*
- a) Beantworte mit Hilfe der R-Vorlage die folgenden Fragen zur **Diagnostik** der 8 möglichen Probleme i.)-viii.):
- Welche Diagnostik-Plots eignen sich für die Untersuchung, ob das Problem vorliegt?
 - Wie sehen die Diagnostik-Plots idealerweise aus?
 - Wie sind die Diagnostik-Plots in diesem Fall zu bewerten?
 - Lässt sich die Darstellung optimieren?

Hinweis: Nicht zu jedem Problem ist eine passende Modelldiagnostik in der Vorlage.

- b) Wenn ein Problem an einem Modell festgestellt wird, ist die Frage, wie man damit umgeht. Eine Möglichkeit ist, sich bewusst zu sein, dass das Problem besteht und entsprechend weniger Informationen aus dem Modell zu ziehen (z.B. bei Verletzung der Normalverteilungsannahme keine Prognose-Intervalle angeben oder maximal als Tendenzen interpretieren). Gib zu den 8 Problemen je an, welche **Einschränkungen** daraus folgen.

- c) Oft möchte man sich hinsichtlich der Aussagekraft bei bestehenden Problemen natürlich nicht einschränken, sondern die Probleme lösen. Gib für die 8 Probleme je eine **Lösungsstrategie** an.

Hinweis: Die Modelldiagnostik ist recht aufwendig. Eine etwas abgespeckte Version ist in *R* via `plot(MeinModell)` implementiert (*Tipp:* `?plot.lm`).

Darüber hinaus gilt: zur vollständigen Beurteilung von Modellen gehört auch die Beurteilung von Effekt-Plots, von Konfidenz-Intervallen und der Modellgüte (z.B. $R^2_{adj.}$, später: AIC, BIC) dazu.

Aufgabe 18

Sie beraten einen Epidemiologen, der den Zusammenhang zwischen der Einnahme von Vitamin D Präparaten und der Häufigkeit von Erkältungen untersuchen möchte. Geplant ist eine Kohortenstudie mit 20.000 Teilnehmenden, die nach ihrer Einnahme von Vitamin D befragt werden. Die Zielgröße ist die Anzahl der Erkältungen in den nächsten drei Jahren.

Bekannte Einflussgrößen (Confounder), die sowohl die Einnahme von Vitamin D als auch die Häufigkeit von Erkältungen beeinflussen könnten:

- Sozioökonomischer Status
- Ernährung
- Alter
- Rauchen
- Geschlecht

Bekannte Collider oder Mediatoren:

- Anzahl Arztbesuche (Collider)
 - Zustand des Immunsystems (Mediator)
- (a) Zeichnen Sie ein Directed Acyclic Graph (DAG), das den angenommenen Zusammenhang zwischen Vitamin D Einnahme, Erkältungen, Confoundern, Collidern und Mediatoren darstellt.
- (b) Es soll der Zusammenhang der Einnahme von Vitamin D auf die Anzahl der Erkältungen geschätzt werden. Welche Variablen würden Sie in Ihr Regressionsmodell aufnehmen? Begründen Sie kurz.
- (c) Angenommen, Sie wollen nicht den Zusammenhang schätzen, sondern möglichst gut vorhersagen, wie viele Erkältungen eine Person im nächsten Jahr haben wird. Welche Variablen würden Sie dann in Ihr Modell aufnehmen? Begründen Sie kurz.
- (d) In einer Analyse mit automatischer Variablenselektion wurde ein Collider (z.B. Anzahl Arztbesuche) ins Modell aufgenommen, aber ein wichtiger Confounder (z.B. Ernährung) weggelassen. Diskutieren Sie, warum dieses Modell möglicherweise ungeeignet ist, um den Zusammenhang zwischen Vitamin D und Erkältungen zu schätzen.
- (e) Diskutieren Sie, was bei einer gegebenen Studiengröße wichtiger wäre:
- Eine größere Stichprobe n
 - oder eine präzisere Messung der Vitamin D Einnahme (weniger Messfehler)?

Diskutieren Sie dies anhand der Begriffe Bias und Varianz und den entsprechenden Formeln für den Erwartungswert und die Varianz von Schätzern im linearen Modell.

Hinweis: Berücksichtigen Sie bei Ihren Überlegungen die Prinzipien der Variablenselektion aus der Vorlesung, insbesondere im Hinblick auf Confounder, Mediatoren und Collider sowie auf Bias-Varianz-Abwägungen bei der Modellbildung.