

Modelldiagnostik & Variablenselektion

Aufgabe 1

Modelldiagnostik ist einer der wesentlichsten Schritte beim Erstellen von Modellen und sollte bei jedem Modell durchgeführt werden. In dieser Aufgabe soll eine Modelldiagnostik für das bekannte Modell $y_{\text{Ozon}} = \beta_0 + \beta_{\text{Temp}}x_{\text{Temp}} + \beta_{\text{Wind}}x_{\text{Wind}} + \beta_{\text{Solar.R}}x_{\text{Solar.R}} + \epsilon$ auf Basis des `airquality`-Datensatzes in R durchgeführt werden. Dazu steht eine R-Vorlage für diese Aufgabe zur Verfügung.

In der Vorlesung werden 8 mögliche Probleme und Diagnose-Möglichkeiten angesprochen.

- i.) *Modellannahme 2.1): $Y = X\beta + \epsilon$ verletzt*
 - ii.) *Modellannahme 2.2): $E(\epsilon) = 0$*
 - iii.) *Modellannahme 2.3): $\text{Var}(\epsilon_i) = \sigma^2$ verletzt*
 - iv.) *Modellannahme 2.4): ϵ_i unabhängig verletzt*
 - v.) *Modellannahme 2.5): $\epsilon_i \sim N(0, \sigma^2)$ verletzt*
 - vi.) *Ausreißer und High-Leverage-Points im Modell*
 - vii.) *Kollinearität der Einflussgrößen*
 - viii.) *Messfehler*
- a) Beantworte mit Hilfe der R-Vorlage die folgenden Fragen zur **Diagnostik** der 8 möglichen Probleme i.)-viii.):
- Welche Diagnostik-Plots eignen sich für die Untersuchung, ob das Problem vorliegt?
 - Wie sehen die Diagnostik-Plots idealerweise aus?
 - Wie sind die Diagnostik-Plots in diesem Fall zu bewerten?
 - Lässt sich die Darstellung optimieren?

Hinweis: Nicht zu jedem Problem ist eine passende Modelldiagnostik in der Vorlage.

- b) Wenn ein Problem an einem Modell festgestellt wird, ist die Frage, wie man damit umgeht. Eine Möglichkeit ist, sich bewusst zu sein, dass das Problem besteht und entsprechend weniger Informationen aus dem Modell zu ziehen (z.B. bei Verletzung der Normalverteilungsannahme keine Prognose-Intervalle angeben oder maximal als Tendenzen interpretieren). Gib zu den 8 Problemen je an, welche **Einschränkungen** daraus folgen.

- c) Oft möchte man sich hinsichtlich der Aussagekraft bei bestehenden Problemen natürlich nicht einschränken, sondern die Probleme lösen. Gib für die 8 Probleme je eine **Lösungsstrategie** an.

Hinweis: Die Modelldiagnostik ist recht aufwendig. Eine etwas abgespeckte Version ist in R via `plot(MeinModell)` implementiert (*Tipp:* `?plot.lm`). Darüber hinaus gilt: zur vollständigen Beurteilung von Modellen gehört auch die Beurteilung von Effekt-Plots, von Konfidenz-Intervallen und der Modellgüte (z.B. R_{adj}^2 , später: AIC, BIC) dazu.

Lösung:

- a) i.) *Modellannahme 2.1): $Y = X\beta + \epsilon$ verletzt*

- Dies lässt sich am besten in den Diagnostik-Plots A (Residuen vs. Fitted/Kov-variable) erkennen.
- Die Residuen sollten unabhängig von der Höhe der gefitteten Werte unsystematisch um die 0 schwanken. Es darf also keine Bereiche geben, in denen viele Residuen in eine Richtung tendieren (also im Extremfall z.B. alle Residuen positiv sind). Die Residuen vs. Kovariablen-Plots können Hinweise geben, welche der Kovariablen mehr Flexibilität (z.B. via Splines) benötigen. Im Idealfall schwanken sie ebenso wie der Residuen-vs.-Fitted-Plot unsystematisch um die 0.
- Für dieses Modell scheint die Annahme verletzt zu sein. Während für sehr niedrige und sehr hohe gefittete Werte die Residuen tendenziell positiv sind, sind sie im Bereich zwischen ca. 30 und 60 ppb tendenziell negativ. Betrachtet man die Residuen-vs.-Kovariablen-Plots sieht man diesen Trend auch bei den Kovariablen Temp und Wind, jedoch nicht bei Solar.R. Möglicherweise liegt die Ursache für die Fehlspezifikation in der Annahme von linearen Effekten bei Temp und Wind.
- Trends lassen sich übrigens leichter erkennen, wenn man in der Funktion das Argument `line = T` setzt. Es wird dann eine Smoothline durch die Residuen ergänzt.

- ii.) *Modellannahme 2.2): $E(\epsilon) = 0$*

Diese Annahme wird beim Überprüfen von Modellannahme 2.1) eigentlich gleich mit geprüft. Streuen die Residuen in allen Bereichen unsystematisch um die 0, ist auch ihr Erwartungswert in allen Bereichen 0.

- iii.) *Modellannahme 2.3): $Var(\epsilon_i) = \sigma^2$ verletzt*

- Eine Verletzung dieser Annahme sieht man eigentlich auch schon direkt in den Diagnostik-Plots A. Die Diagnostik-Plots B sind dafür aber besser geeignet, da sie auf die Effekte bei der Schätzung kontrollieren und man durch die absoluten Residuen leichter sieht, ob es Abweichungen gibt.

- Während bei Modellannahme 2.1) der Fokus darauf liegt, dass die Residuen nirgends tendenziell niedriger oder höher sind, achtet man in diesem Fall darauf, dass sie betragsmäßig und standardisiert überall gleich hoch sind. Also nicht abhängig von z.B. der Höhe der gefitteten Werte oder Kovariablen.
- Zum einen passt etwas nicht bei prädiktierten Werten, die kleiner als 0 sind (was auch inhaltlich keinen Sinn macht). Zum anderen kann man das häufige Phänomen beobachten, dass die Residuen betragsmäßig größer werden, je größer die gefitteten Werte sind (die Varianz hier also steigt).
Die Varianz-Homogenitätsannahme ist also verletzt.
- Für die Solar.R-Variable sieht der Plot gar nicht so schlecht aus. Plottet man die Residuen jedoch gegen die Temperatur sieht man eine Abhängigkeit der Varianz. Die Ursache dafür liegt aber vermutlich in der falschen Modellgleichung.

iv.) *Modellannahme 2.4): ϵ_i unabhängig verletzt*

- Eine Verletzung dieser Annahme lässt sich mit Diagnostik-Teil C (Residuen vs. Index) überprüfen. Meist betrachtet man die Residuen gegen eine Kovariable wie die Zeit, der fortlaufenden ID bei der Datenerhebung oder auch Versuchs-Tier-ID bei Mehrfachmessung, Bewerter-ID oder ähnliches.
- Idealerweise sieht man keine Strukturen in solchen Plots. Bei Verletzung erkennt man häufig 'Schlangen' in den Residuen-Plots bei stetigen Einflussvariablen wie der Zeit (Das Residuum von Tag 1 lag bei -5, dann wäre das Residuum bei Korrelation ähnlich also z.B. bei -4 und nicht direkt bei +5. Die Residuen würden systematische Ketten/Schlangen über die Zeit bilden). Bei diskreten Einflussvariablen wie der Bewerter-ID sieht man bei Verletzung evtl, dass z.B. Bewerter/Versuchstier A eher positive Residuen hat und Bewerter/Versuchstier B eher negative Residuen.
- Entgegen der Vermutung, dass die Residuen korreliert sind, weil aufeinanderfolgende Tage tendenziell ähnliche Ozon-Werte haben sollten, bestätigt sich dies anhand des Residuen-Plots nicht. Benachbarte Residuen springen stark hin und her.
Es kann sein, dass die Ähnlichkeit zweier aufeinander folgender Tage schon über die Ähnlichkeit in den Umgebungsbedingungen (Wind, Temp, Solar.R) abgebildet und damit berücksichtigt wird. Somit taucht sie nicht mehr in den Residuen auf. Es kann auch sein, dass die Korrelation in der großen Gesamt-Streuung des Modells untergeht und somit vernachlässigt werden kann. Es ist möglich, dass mit einem besseren Modell, bei dem die Streuung insgesamt deutlich niedriger ist, die Korrelation eine größere Rolle spielt.
- Eine Möglichkeit für einen Test ist der Durbin-Watson-Test. Die Nullhypothese, dass es keine Autokorrelation gibt ($Korr = 0$) kann hier nicht abgelehnt werden ($p = 0.67$). Es deutet also auch der Test darauf hin, dass die benachbarten

Residuen nicht korreliert sind.

Unkorreliertheit liegt bei einem Teststatistik-Wert von 2 vor. Hier liegt der Wert bei 1.94 - also nah dran. Die Autokorrelation liegt bei 0.03 also auch nahe 0.

v.) *Modellannahme 2.5): $\epsilon_i \sim N(0, \sigma^2)$ verletzt*

- Sehr grobe Verletzungen können auch schon im Diagnostik-Teil A erkannt werden, jedoch eignet sich ein QQ-Plot wesentlich besser.
- Im Idealfall liegen alle Punkte auf der Winkelhalbierenden. Praktisch befinden wir uns in einem Zufallskontext. Die Annahme ist also bereits erfüllt, wenn die Punkte nah an der Geraden dran sind.

Es werden die empirischen Quantile der Residuen und die theoretischen Quantile der Normalverteilung gegeneinander aufgetragen.

Kurze Erklärung, was man dort tut:

Nehmen wir an, wir haben 10 Beobachtungen. Der Wert der niedrigsten Beobachtung sei -3. Das heißt 10% meiner Daten sollten kleiner oder gleich -3 sein. Sei der zweit-kleinste Wert -1. Dann sollten 20% (2/10 der Werte) kleiner oder gleich -1 sein und so weiter.

Das sind die empirischen Quantile.

Die theoretischen Quantile erhält man aus der Normalverteilungsannahme der Residuen ($\epsilon \sim N(0, \sigma^2)$). σ^2 kann man schätzen. Also kennt man die genaue Verteilung der Residuen, falls sie normalverteilt sind.

Bei einer Normalverteilung mit Varianz $\hat{\sigma}^2$ kann ich berechnen, bei welchem Wert 10% der Beobachtungen kleiner oder gleich diesem Wert sein sollten (Verteilungsfunktion). Sei dieser berechnete Wert 2.8. Diesen Wert kann ich dann mit dem beobachteten Wert aus der empirischen Verteilung (-3) vergleichen oder sie für alle Beobachtungen je gegeneinander plotten. Falls die Werte aus den Daten (empirische Verteilung) mit den Werten aus einer Normalverteilung (theoretische Verteilung) übereinstimmen, liegen alle Werte auf einer Geraden (der Winkelhalbierenden).

- Hier passt die Normalverteilung nicht sonderlich gut. Für niedrige und hohe theoretische Quantile sind die beobachteten Quantile je zu hoch. Es ist also eine Verteilung, welche an den Rändern breiter verläuft als eine Normalverteilung.

vi.) *Ausreißer und High-Leverage-Points im Modell*

Zur Wiederholung: Was sind Ausreißer und High-Leverage-Points? Was ist der Unterschied? Ausreißer sind Beobachtungen mit betragsmäßig hohen Residuen. (also stark abweichend hohe bzw. niedrige Werte der Zielvariablen (y) für entsprechende Werte der Einflussgrößen (x_j)). High-Leverage-Points sind dagegen Beobachtungen, deren Werte der Einflussgrößen (x_j) stark abweichend hoch bzw. niedrig sind. Beides müssen nicht zwangsläufig inhaltlich falsche Werte sein. Z.B. könnte man das Gehalt

eines DAX-Konzern-Vorstandes mit in seiner Stichprobe haben (sei es als Einflussvariable High-Leverage-Point) oder Zielvariable (Ausreißer)). Die Frage ist, ob man daran interessiert ist, so ungewöhnliche Werte mit in die Schätzung einfließen zu lassen. Es gibt für beide Seiten Argumente. Ein Herauslassen von solchen Beobachtungen muss stets sehr gut begründet werden können!

- Ausreißer erkennt man hervorragend im Diagnostik-Teil A (Residuals vs. Fitted/Kovariable). Es sind die betragsmäßig auffällig großen Residuen. Auch High-Leverage-Points sind hier gut in den Residuen-vs.-Kovariablen-Plots zu erkennen. Es sind die Punkte, die auf der x-Achse weit vom Zentrum der Punkte entfernt alleine liegen.
- Ausreißer sind auf jeden Fall die drei Residuen, welche größer 50 sind. High-Leverage-Points sind vor allem bei den Kovariablen Temp und Wind zu erkennen. Für Solar.R sind auch im Randbereich noch je etliche Beobachtungen vorhanden. Insbesondere für die Wind-Variable gibt es kaum Werte größer 17.5 mph, welche weit weg vom Zentrum liegen. Dazu sind diese Beobachtungen auch noch betragsmäßig groß und verzerren die Schätzung stark.

vii.) *Kolinearität der Einflussgrößen*

Zur Wiederholung: Was ist Kollinearität? Die stärkste Form der Kollinearität ist eine perfekte lineare Abhängigkeit zwischen zwei oder mehreren Kovariablen - sprich eine Kovariable lässt sich als Linearkombination der anderen Kovariablen berechnen (Z.B. $x_2 = 2x_4 + 1/2 x_6 + 4x_7$). Perfekte lineare Abhängigkeit tritt tendenziell nur bei sehr kleinen Datensätzen oder, wenn sehr ähnliche diskrete Kovariablen im Modell sind, auf. In anderen Fällen sind die Kovariablen dann meist nur fast linear abhängig.

- Kolinearität kann mit dem Diagnostik-Teil E (Varianz-Inflations-Faktor) kontrolliert werden. Als Faustregel gilt, dass Werte größer 10 auf ein ernsthaftes Kollinearitätsproblem hindeuten.
- Im Idealfall ist der Wert 1, im schlimmsten Fall unendlich.
- Hier liegen die Werte alle nahe 1. Man muss also nicht von einem Kollinearitätsproblem ausgehen.

viii.) *Messfehler*

Zur Wiederholung: Was sind (zufällige oder systematische) Messfehler? Bei Messfehlern entsprechen schon die erhobenen y- und/oder x-Werte nicht dem Wert, den die Beobachtung eigentlich hat. Messfehler können zufällig sein (z.B. kann ich beim Messen die Länge auf dem Lineal nicht perfekt ablesen und schwanke immer zufällig um einen Millimeter hin und her) oder systematisch (z.B. ist mein Lineal durch Wärmeausdehnung etwas länger geworden und ich gebe für jede Beobachtung daher zu niedrige Werte an oder die Skala ist eigentlich in inch, aber ich trage die Werte als cm in die Tabelle ein).

Systematische Messfehler können anhand des Modells nicht identifiziert werden.

Auch zufällige Fehler sind quasi nicht zu erkennen. Ein schlechtes R^2 könnte darauf hindeuten, aber das kann auch diverse andere Ursachen haben.

Zufällige Messfehler kann man aber durch Mehrfachmessung einzelner Beobachtungen identifizieren. Systematische Messfehler sind dagegen nicht mit statistischen Methoden zu erkennen. Hier muss fachlich auffallen, dass Werte so keinen Sinn machen oder messende Personen überprüft werden etc..

- b)
- 2.1)/2.2) verletzt: Gesamtes Modell ist nur noch eine Näherung.
 - 2.3)/2.4.) verletzt: Regressionskoeffizienten können geschätzt werden, sind aber nicht mehr BLUE. Konfidenz- und Prognose-Intervalle können nicht verwendet werden.
 - 2.5) verletzt: Regressionskoeffizienten können geschätzt werden und sind BLUE. Konfidenz-Intervalle sind für n groß genug approximativ korrekt. Prognoseintervalle können nicht verwendet werden.
 - *Ausreißer und High-Leverage-Points*: Verzerrung der Schätzungen. Gesamtes Modell mit Vorsicht zu genießen.
 - *Kollinearität*: Bei perfekter linearer Abhängigkeit ist das Modell nicht mehr schätzbar ($X'X$ nicht invertierbar). Sonst wird die Schätzung nur sehr ungenau. KIs/PIs berücksichtigen dies. Betrachtet man die Regressionskoeffizienten allein, muss man sich über dessen große Varianz bewusst sein!
 - *Messfehler*: Was man noch machen kann, hängt stark davon ab, ob die Messfehler zufällig oder systematisch sind.
Sind die Messfehler zufällig und unabhängig voneinander (insbesondere kein Zusammenhang mit y) wird die Schätzung ungenauer. Der zugehörige Regressionskoeffizient ist tendenziell kleiner.
Sobald die Messfehler mit einer anderen Größe zusammenhängen (nicht mehr unabhängig sind) bestehen größere Probleme.
Liegen systematische Messfehler vor, die nicht mit anderen Größen zusammenhängen, sind die Regressionskoeffizienten noch korrekt (die Gerade verläuft an einer anderen Stelle, aber hat noch die selbe Steigung). Prädiktionen sind mit so einem Modell aber fehlerhaft.
Liegen systematische Messfehler vor und sie hängen von anderen Größen ab, ist das gesamte Modell mit äußerster Vorsicht zu genießen.

- c)
- i.) *Modellannahme 2.1*): $Y = X\beta + \epsilon$ verletzt
Modell erweitern, also Kovariablen flexibel aufnehmen, weitere Kovariablen aufnehmen, Interaktionen einbauen oder auch nur Kovariablen transformieren, sodass der Effekt linear ist.
 - ii.) *Modellannahme 2.2*): $E(\epsilon) = 0$
Analog 2.1)

iii.) *Modellannahme 2.3): $\text{Var}(\epsilon_i) = \sigma^2$ verletzt*

Zielvariable transformieren (häufig ist die Streuung bei großen y-Werten höher als bei niedrigen y-Werten - dann kann man z.B. $\log(y)$ als Zielvariable verwenden). Dann wird jedoch die Interpretation des Modells schwieriger.

Alternativ kann man Modelle verwenden, die unterschiedliche Varianzen zulassen (z.B. allgemeines lineares Modell).

iv.) *Modellannahme 2.4): ϵ_i unabhängig verletzt*

Hierfür gibt es eine Reihe an möglichen Modellerweiterungen (siehe A18 und z.B. Wahlfach Zeitreihen).

v.) *Modellannahme 2.5): $\epsilon_i \sim N(0, \sigma^2)$ verletzt*

Manchmal hilft es wie bei der Varianz-Homogenitäts-Verletzung die Zielvariable zu transformieren, sodass die Residuen danach normalverteilt sind. Alternativ kann man Generalisierte Lineare Modell (Vorlesung GLM) verwenden, welche andere Verteilungsspezifikationen zulassen oder auch Modelle ohne Verteilungsannahme verwenden (z.B. Quantils-Regression).

vi.) *Ausreißer und High-Leverage-Points im Modell*

Ggf. kann man diese Punkte bei der Modellschätzung rauslassen. Man muss sich aber bewusst sein, dass man dann nicht mehr die vollständige Grundgesamtheit abbildet, wenn es keine tatsächlich falschen Werte sind.

Alternativen sind Robuste Regression oder gewichtete Regression, bei der man solchen Punkten weniger Gewicht in der Schätzung gibt.

vii.) *Kollinearität der Einflussgrößen*

Weglassen entsprechender Einflussgrößen oder Modelle verwenden, die Variablenselektion auf Basis der Kollinearität betreiben (Ridge-Regression - Vorlesung GLM).

viii.) *Messfehler*

Es gibt Korrekturverfahren für bestimmte Messfehler.

Aufgabe 18

Sie beraten einen Epidemiologen, der den Zusammenhang zwischen der Einnahme von Vitamin D Präparaten und der Häufigkeit von Erkältungen untersuchen möchte. Geplant ist eine Kohortenstudie mit 20.000 Teilnehmenden, die nach ihrer Einnahme von Vitamin D befragt werden. Die Zielgröße ist die Anzahl der Erkältungen in den nächsten drei Jahren.

Bekannte Einflussgrößen (Confounder), die sowohl die Einnahme von Vitamin D als auch die Häufigkeit von Erkältungen beeinflussen könnten:

- Sozioökonomischer Status
- Ernährung
- Alter
- Rauchen
- Geschlecht

Bekannte Collider oder Mediatoren:

- Anzahl Arztbesuche (Collider)
 - Zustand des Immunsystems (Mediator)
- (a) Zeichnen Sie ein Directed Acyclic Graph (DAG), das den angenommenen Zusammenhang zwischen Vitamin D Einnahme, Erkältungen, Confoundern, Collidern und Mediatoren darstellt.
- (b) Es soll der Zusammenhang der Einnahme von Vitamin D auf die Anzahl der Erkältungen geschätzt werden. Welche Variablen würden Sie in Ihr Regressionsmodell aufnehmen? Begründen Sie kurz.
- (c) Angenommen, Sie wollen nicht den Zusammenhang schätzen, sondern möglichst gut vorhersagen, wie viele Erkältungen eine Person im nächsten Jahr haben wird. Welche Variablen würden Sie dann in Ihr Modell aufnehmen? Begründen Sie kurz.
- (d) In einer Analyse mit automatischer Variablenselektion wurde ein Collider (z.B. Anzahl Arztbesuche) ins Modell aufgenommen, aber ein wichtiger Confounder (z.B. Ernährung) weggelassen. Diskutieren Sie, warum dieses Modell möglicherweise ungeeignet ist, um den Zusammenhang zwischen Vitamin D und Erkältungen zu schätzen.
- (e) Diskutieren Sie, was bei einer gegebenen Studiengröße wichtiger wäre:
- Eine größere Stichprobe n
 - oder eine präzisere Messung der Vitamin D Einnahme (weniger Messfehler)?

Diskutieren Sie dies anhand der Begriffe Bias und Varianz und den entsprechenden Formeln für den Erwartungswert und die Varianz von Schätzern im linearen Modell.


Hinweis: Berücksichtigen Sie bei Ihren Überlegungen die Prinzipien der Variablenselektion aus der Vorlesung, insbesondere im Hinblick auf Confounder, Mediatoren und Collider sowie auf Bias-Varianz-Abwägungen bei der Modellbildung.

Lösung:

Musterlösung: Variablenselektion in der Epidemiologie

(1) DAG

Beispiel für einen möglichen Directed Acyclic Graph (DAG):



(2) Ziel: Schätzung des Effekts von Vitamin D auf Erkältungen

Aufzunehmende Variablen: Alle Confounder (Sozioökonomischer Status, Ernährung, Alter, Rauchen, Geschlecht). **Nicht aufzunehmende Variablen:** Mediatoren (Zustand des Immunsystems) und Collider (Anzahl Arztbesuche).

Begründung: Diese beeinflussen sowohl Vitamin D Einnahme als auch Erkältungen und müssen kontrolliert werden, um Verzerrung der Effekte durch fehlende Confounder zu vermeiden. Mediatoren (z.B. Immunsystem) werden in der Regel nicht aufgenommen, da sie die Interpretation (z.B. vom Vitamin D Effekt auf Erkältungen) ändern. Durch hinzunahme eines Mediators wird nur noch der direkte Effekt, aber nicht mehr der totale Effekt geschätzt. Wenn Mediatoren aufgenommen werden, dann nur mit Bedacht und dem Ziel das Modell und die Effekte entsprechend zu interpretieren. Hier sind wir am totalen Effekt von Vitamin D interessiert und somit sollte der Mediator nicht aufgenommen werden. Collider (z.B. Anzahl Arztbesuche) sollten **nicht** ins Modell aufgenommen werden, da dies zur Verzerrung der Effekte führt.

(3) Ziel: Prognose der Erkältungen

Aufzunehmende Variablen: Alle Variablen, die die Zielvariable Erkältungen gut vorher-sagen — also Confounder, Mediatoren und ggf. Collider.

Begründung: Bei der Prognose zählt die Verbesserung der Vorhersagegüte, nicht die Kausalität. Daher können auch Mediatoren und Collider aufgenommen werden, wenn sie die Prognose verbessern. Da der Collider direkt Informationen über die Zielvariable enthält, kann er die Prognose verbessern, indem er zusätzliche Informationen liefert, die nicht durch andere Variablen erfasst werden. Es ist jedoch wichtig zu beachten, dass die Aufnahme von Collidern oftmals auch für die Prognose problematisch sein kann: Da Collider-Variablen durch die Zielvariable kausal beeinflusst wird, kann es sein, dass die Messung einer Collider-Variable erst dann möglich ist, wenn die Zielvariable bereits aufgetreten ist. In einem solchen Fall ist die Prognose der Zielvariable allerdings meistens überflüssig. Somit ist die Aufnahme einer Collider-Variable zwecks Prognose unsinnig, wenn wir sie zum Zeitpunkt der Prognose nicht messen können. Darüber hinaus führt die Aufnahme eines Colliders dazu, dass wir die Performance des Modells überschätzen (Optimistic Bias).

(4) Problematik bei automatischer Variablenselektion

Wenn Collider aufgenommen und Confounder weggelassen werden:

- Das Modell schätzt nicht den wahren kausalen Effekt.
- Collider-Bias wird eingeführt.
- Fehlende Kontrolle von Confounding führt zu verzerrter Schätzung.
- Automatische Verfahren (z.B. AIC, BIC) berücksichtigen keine Kausalstruktur.
- R^2 wird überoptimistisch geschätzt.
- Inferenzstatistische Aussagen (z.B. Hypothesentests) sind nicht valide, da p-Werte und Konfidenzintervalle verzerrt sind (tendenziell zu klein).

Fazit: Data-driven Selektion ohne Berücksichtigung der Kausalstruktur ist ungeeignet für kausale Fragestellungen.

(5) Diskussion: Größere Stichprobe vs. bessere Messung von Vitamin D

Bias-Varianz-Tradeoff:

- **Bias** (Verzerrung): Wird durch systematische Fehler (z.B. Messfehler bei Vitamin D) beeinflusst. Bessere Messung senkt den Bias.
- **Varianz:** Sinkt mit größerer Stichprobe ($\text{Var}(\hat{\beta}) \propto \frac{1}{n}$). Größere Stichprobe senkt die Varianz.

Formel: Für den Schätzer $\hat{\beta}$ im linearen Modell: $\mathbb{E}(\hat{\beta}) = \beta$ (unverzerrt, falls Modell korrekt) $\text{Var}(\hat{\beta}) = \sigma^2(X^T X)^{-1}$

Fazit:

- Für geringeren Bias: bessere Messung von Vitamin D.
- Für geringere Varianz: größere Stichprobe.
- Für kausale Schätzung oft wichtiger: Bias vermeiden $\rightarrow$ bessere Messung.