

Multiples Regressionsmodell

Aufgabe 1

Der Datensatz *mtcars* aus *R* stammt aus dem Motor-Trend US-Magazin von 1974 und enthält für 32 Autos unter anderem die Reichweite in Meilen pro Gallone (mpg) und das Gewicht in 1000 Pfund (lbs).

Info: 10 mpg = 4.25 km/L (entspricht 23.5 L/100 km - Achtung: inverse Einheit).

Beobachtung	Reichweite in Meilen pro Gallone	Gewicht in 1000 Pfund
1: Mazda RX4	21.0	2.620
2: Mazda RX4 Wag	21.0	2.875
	$\vdots$	
32: Volvo 142E	21.4	2.780

Es soll die Reichweite anhand des Gewichts vorhergesagt werden. Gegeben ist hierfür ein multiples Regressionsmodell $Y = X\beta + \epsilon$ mit n Beobachtungen und p Kovariablen.

- Das Modell soll einen Intercept enthalten. Welche Dimensionen haben Y , X , β und ϵ ?
- Gib die Modellgleichung explizit für obiges Beispiel mit konkreten Zahlen in zwei Versionen an:
 - In Matrixnotation.
 - Als Gleichungssystem.

Gib auch n und p an.

Führe die weiteren Aufgaben in *R* durch.

- Mach dich mit dem Datensatz *mtcars* vertraut.
Tipp: `?mtcars`, `head()`, `summary()`, `str()`
- Fitte das Regressionsmodell mit dem die Reichweite anhand des Gewichts vorhergesagt werden kann und speichere das Objekt in einer Variable.
Tipp: `lm()`
- Gib das Summary des Modells aus.
 - Erkläre alle in der Ausgabe angegebenen Werte (mit Ausnahme der letzten Zeile).
Tipp: `?summary.lm`
 - Gib für alle Größen eine Formel zur Berechnung an (mit Ausnahme von *t-value* und $Pr(> |t|)$, sowie der letzten Zeile).

f) Mach dich mit dem Modell-Objekt vertraut.

Tipps: ?lm, MeinModell\$InteressierendeGröße

i.) Rufe die Residuen im Modell-Objekt auf.

ii.) Rufe die prädiktierten Werte im Modell-Objekt auf.

iii.) Rufe die für das Modell verwendeten Daten über das Modell-Objekt auf.

ZUSATZAUFGABEN

g) Gib die Formeln für den KQ-Schätzer sowie den ML-Schätzer in Matrix-Notation an.


h) Die KQ-Methode liefert folgende Ergebnisse für die Schätzungen für die Regressions-Koeffizienten:

$$\hat{\beta}_0 = 37.3$$

$$\hat{\beta}_{\text{gewicht}} = -5.3$$

Zeichne folgende Dinge in das Streudiagramm ein:

- $x_{\text{gewicht},i}, y_i$ ($i = 17, 20, 29$)
- Regressionsgerade
- $\hat{\beta}_0, \hat{\beta}_{\text{gewicht}}$
- ϵ_i ($i = 17, 20, 29$)



i) Interpretiere die Regressionsparameter.

j) Welcher Verteilung folgt $\hat{\beta}$?

Führe die weiteren Aufgaben in *R* durch.

- i.) Gib die Schätzung für den Erwartungswert-Vektor von $\hat{\beta}$ explizit an.
- ii.) Gib Schätzung für die Varianzen der Einträge von $\hat{\beta}$ explizit an.
- iii.) Gib je ein 95%-Konfidenzintervall für die $\hat{\beta}_j$ ($j = 0, \dots, 3$) an.

Lösung:

- a)
- $Y: \mathbb{R}^n$ bzw. $\mathbb{R}^{n \times 1}$
 - $X: \mathbb{R}^{n \times (p+1)}$
 - $\beta: \mathbb{R}^{p+1}$ bzw. $\mathbb{R}^{(p+1) \times 1}$
 - $\epsilon: \mathbb{R}^n$ bzw. $\mathbb{R}^{n \times 1}$

Als Dimension für die Regressions-Koeffizienten wird je $p + 1$ benötigt. p für die p Kovariablen und $+1$ für den Intercept.

Achtung: Oftmals wird in der Literatur die Dimension der Regressions-Koeffizienten auch nur mit p bezeichnet (statt p ist nur die Anzahl der Kovariablen) und schließt das $+1$ für den Intercept mit ein.

b) i.) $Y = X\beta + \epsilon \Leftrightarrow$

$$\begin{pmatrix} 21.0 \\ 21.0 \\ \vdots \\ 21.4 \end{pmatrix} = \begin{pmatrix} 1 & 2.620 \\ 1 & 2.875 \\ \vdots & \\ 1 & 2.780 \end{pmatrix} \cdot \begin{pmatrix} \beta_0 \\ \beta_{\text{gewicht}} \end{pmatrix} + \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_{32} \end{pmatrix}$$

ii.) $y_{\text{reichweite}, 1} = \beta_0 + \beta_{\text{gewicht}} \cdot x_{\text{gewicht}, 1} + \epsilon_1$
 $y_{\text{reichweite}, 2} = \beta_0 + \beta_{\text{gewicht}} \cdot x_{\text{gewicht}, 2} + \epsilon_2$
 $\vdots$
 $y_{\text{reichweite}, 32} = \beta_0 + \beta_{\text{gewicht}} \cdot x_{\text{gewicht}, 32} + \epsilon_{32}$
 $\Leftrightarrow$
 $21.0 = (1) \cdot \beta_0 + \beta_{\text{gewicht}} \cdot 2.620 + \epsilon_1$
 $21.0 = \beta_0 + \beta_{\text{gewicht}} \cdot 2.875 + \epsilon_2$
 $\vdots$
 $21.4 = \beta_0 + \beta_{\text{gewicht}} \cdot 2.780 + \epsilon_{32}$

$$n = 32$$

$$p = 1$$

c) - f) Siehe R-Lösung.


ZUSATZAUFGABEN

g) $\hat{\beta} = (X'X)^{-1}X'Y$ - Die Mitternachtsformel des Statistikers.

Die Formel zur Berechnung des Schätzers für β ist beim Multiplen Linearen Modell für die

KQ- und die ML-Methode identisch. Das Konzept und die nötigen Annahmen sind jedoch unterschiedlich.

h) Eingezeichnete Größen:



Hinweis: Die prädiktierten Werte $\hat{y}_i$ liegen je auf der Geraden (direkt unter bzw. über den Beobachtungen).

- i) • β_0 : Hat hier keine Bedeutung. Es wäre die Reichweite für ein Auto ohne Gewicht.

Hinweis: Da 0 Pfund außerhalb des Bereiches an beobachteten Werten liegt, spricht man von Extrapolation (im Gegensatz zur Interpolation). Insbesondere Extrapolation ist mit äußerster Vorsicht zu genießen. Im nicht beobachteten Werte-Bereich können unvorhergesehene (nicht-lineare) Effekte auftreten. Eine Prädiktion ist dann schlicht falsch.

- β_{gewicht} : Steigt das Gewicht um 1000 Pfund (= **um eine Einheit**), so sinkt der Reichweite **im Mittel** um 5.3 Meilen pro Gallone.

Hinweis: Die c.p.-Annahme (ceteris paribus = alle anderen Kovariablen konstant) ist hier nicht notwendig, da es keine weiteren Kovariablen gibt.

- j) Siehe R-Lösung.

Aufgabe 2

Es soll die Auswirkung von *Körpergröße* und *Alter* auf das *Gewicht* bei Grundschulkindern untersucht werden. Dazu wird ein Multiples Regressionsmodell

$$y_{\text{gewicht}, i} = \beta_0 + \beta_{\text{größe}} \cdot x_{\text{größe}, i} + \beta_{\text{alter}} \cdot x_{\text{alter}, i} + \epsilon_i$$

geschätzt.

Die Daten werden an einer Grundschule in einem kleinen Dorf mit 200 Schülern erhoben.

- a) Welche Annahmen 1.) - 5.) sind für die in den Zeilen angegebenen Schätzer, Eigenschaften bzw. Größen notwendig?

	1.)	2.)	3.)	4.)	5.)
KQ-Schätzer					
ML-Schätzer					
$E(\hat{\beta}) = \beta$					
$\hat{\beta} \sim N(\beta, \sigma^2(X'X)^{-1})$					
Konfidenzintervalle (von Regressionskoeffizienten, Prädiktionen, ...)					
Prädiktionsintervalle (von Prädiktionen, ...)					
(adj.) R^2					

Annahme 1.) $Y = X\beta + \epsilon$

Annahme 2.) $E(\epsilon_i) = 0$

Annahme 3.) $Var(\epsilon_i) = \sigma^2$

Annahme 4.) ϵ_i paarweise unabhängig

Annahme 5.) $\epsilon_i \sim N(0, \sigma^2)$

- b) Diskutiere alle Annahmen, die für die ML-Schätzung notwendig sind im konkreten Beispiel Gewichts-Schätzung. Welche Annahmen sind nur bedingt realistisch?
- c) Was folgt daraus, wenn Annahmen (teilweise) nicht erfüllt sind?
- d) Müssen alle aufgenommenen Kovariablen $x_1, \dots, x_j$ unkorreliert sein?
- e) Körpergröße und Alter sind korrelierte Einflussgrößen. Was folgt daraus für die Interpretation der einzelnen Regressionskoeffizienten unter c.p.-Bedingung (ceteris paribus = alle anderen Kovariablen konstant)?

Lösung:

- a) Welche Annahmen 1.) - 5.) sind für die in den Zeilen angegebenen Schätzer, Eigenschaften bzw. Größen notwendig?

	1.)	2.)	3.)	4.)	5.)
KQ-Schätzer	x				
ML-Schätzer	x	x	x	x	x
$E(\hat{\beta}) = \beta$	x	x			
$\hat{\beta} \sim N(\beta, \sigma^2(X'X)^{-1})$	x	x	x	x	(x)*
Konfidenzintervalle (von Regressionskoeffizienten, Prädiktionen, ...)	x	x	x	x	(x)*
Prädiktionsintervalle (von Prädiktionen, ...)	x	x	x	x	x
(adj.) R^2	x				

*Diese Eigenschaften gelten auch für ausreichend großen Stichprobenumfang n approximativ. Für kleine Stichprobenumfänge ist die Normalverteilungsannahme jedoch zwingend notwendig!

Hinweis: Besonders anzumerken ist, dass für den KQ-Schätzer nichts weiter benötigt wird als die Modellgleichung. Nimmt man zusätzlich noch an, dass der Erwartungswert der Residuen 0 ist, sind die Schätzer für β sogar erwartungstreu.

Um Konfidenz-Intervalle bilden zu können sind alle 5 Annahmen notwendig (oder 1.)-4.) und eine große Stichprobe). Für Prädiktions-Intervalle sind stets alle 5 Annahmen notwendig (insbesondere genügt hier auch eine ausreichend große Stichprobe NICHT).

b) • Annahme 1.) $Y = X\beta + \epsilon$ (Linearität)

Es wird angenommen, dass sich die Zielgröße (Körpergewicht) als eine Linearkombination aus den Einflussgrößen (Alter, Körpergröße) beschreiben lässt - also z.B. konkret dass sich das Gewicht von Grundschulkindern direkt nach der Formel in der Angabe berechnen lässt (und nicht z.B. $Gewicht = Alter^{Größe}$ oder sonst einer anderen Formel).

Diese Annahme scheint als Laie beurteilt nicht vollkommen unplausibel und kann daher zunächst so angenommen werden.

Hinweise: Diese Annahme ist vor allem von Wissenschaftlern aus dem jeweiligen Fachgebiet zu beurteilen. Es gibt jedoch Methoden der Modelldiagnostik (Residuen-vs.-Kovariablen-Plot), welche noch später im Kurs behandelt werden, mit der man diese Annahme im Nachhinein beurteilen kann. Auch gibt es die Möglichkeit Einflussvariablen nicht-linear ins Modell aufzunehmen (z.B. via Splines, welche ebenso später im Kurs behandelt werden).

• Annahme 2.) $E(\epsilon_i) = 0$

Die Residuen sind zufällige Fehler. Man nimmt an, dass diese Fehler im Erwartungswert 0 sind. Anders ausgedrückt: Die Modellgleichung $Y = X\beta$ spiegelt den Zusammenhang wieder. Es kommt keine systematische Störgröße ϵ mehr hinzu, von der man erwarten kann, dass sie im Mittel nicht 0 ist.

Davon gehen wir aus.

• Annahme 3.) $Var(\epsilon_i) = \sigma^2$: Homoskedastizität (Varianzhomogenität)

Es wird angenommen, dass die Varianz für jede Beobachtung identisch ist.

Diese Annahme könnte verletzt sein. Z.B. könnte bei größeren Kindern das Gewicht stärker streuen, als bei kleineren Kindern. Bei größeren Kindern könnte also eine höhere Varianz vorliegen.

Hinweise: Auch dies können ggf. Wissenschaftler aus dem jeweiligen Fachbereich besser beurteilen.

Prüfen kann man diese Annahme mittels später im Kurs vorgestellten Residuen-Plots (z.B. Residuen-vs.-Fitted values oder Residuen-vs.Kovariable-Plot).

Die Varianz-Annahme kann auch aufgeweicht werden (z.B. via verallgemeinerte lineare Modelle, welche später im Kurs vorgestellt werden).

- Annahme 4.) ϵ_i paarweise unabhängig

Es wird angenommen, dass die Beobachtungen der Zielgröße bei gegebenen Einflussgrößen unabhängig sind.

Diese Annahme ist bei der Wahl einer einigen kleinen Grundschule unwahrscheinlich. Es könnten z.B. Kinder der selben Familie in die Schule gehen und vielleicht genetisch bedingt zu Fettleibigkeit neigen. Diese Beobachtungen wären also z.B. nicht unabhängig voneinander.

Hinweise: Auch bei Verletzung dieser Annahme gibt es modellierungstechnische Möglichkeiten dies zu berücksichtigen. Z.B. mittels Gemischten Modellen (Mixed Models - z.B. für einen weiteren zufälligen Effekt für jede Familie - später in diesem Kurs) oder Korrelationen zwischen Beobachtungen (Generalized Estimation Equations (GEE) -> Vorlesung: Generalisierte Regression).

- Annahme 5.) $\epsilon_i \sim N(0, \sigma^2)$

Dass die übrige Reststreuung normalverteilt ist, ist durchaus denkbar. Störgrößen sind in der Natur häufig normalverteilt. Auch der Wertebereich der Zielgröße lässt nicht auf mögliche Verletzung der Normalverteilungsannahme hindeuten.

Explizit aufpassen muss man, wenn z.B. offensichtlich ist, dass die Größe nicht normalverteilt sein kann. Dies ist z.B. der Fall wenn die Zielgröße binär ist, nur ganze Zahlen annehmen kann oder häufig Werte an den Grenzen des möglichen Wertebereichs hat.

Hintergrund: Die Normalverteilung ist eine stetige, symmetrische Verteilung mit Werten von $-\infty$ bis ∞ . In den gerade genannten Fällen können die Residuen (= tatsächlicher y-Wert - geschätzter y-Wert) nicht oder nur schwer einer Normalverteilung folgen.

Überprüfen kann man die Normalverteilungsannahme z.B. mit dem später im Kurs vorgestelltem Q-Q-Plot.

- c) Solange die Annahmen 1.) und 2.) erfüllt sind, können die Regressionsparameter problemlos interpretiert werden. Insbesondere für die Interpretation von Konfidenzintervallen, p-Werten etc. müssen aber entsprechende Annahmen erfüllt sein! (Es geht um die konkrete Bezifferung von Wahrscheinlichkeiten). Falls dies (teilweise) nicht der Fall ist, können diese wahrscheinlichkeitsbasierten Kennzahlen evtl. noch als Indikatoren für selbige verwendet werden, aber keinesfalls explizit mit Wahrscheinlichkeits-Interpretation!
- d) Nein, Unkorreliertheit der Einflussgrößen ist keine Voraussetzung. Sie dürfen nur nicht perfekt linear abhängig sein (= Korrelation von exakt ± 1). Dann ist $X'X$ nicht mehr invertierbar.

- e) Die Interpretation kann nach wie vor wie üblich durchgeführt werden. z.B. ‘Steigt das Alter um ein Jahr, steigt das Gewicht im Mittel um 3 kg unter der Bedingung, dass die Körpergröße konstant ist.’

Aber: Eine unbedachte (und vielleicht gewünschte) Interpretation wäre, dass ein Kind nun jedes Jahr 3 kg zu nimmt. Das ist so aber falsch! Die 3 kg im Mittel pro Jahr stimmen nur für konstant bleibende Körpergröße. Das Kind wird aber auch wachsen und daher um mehr als 3 kg pro Jahr zunehmen. Man muss sich also fachlich bewusst sein, dass man hier den Effekt von verschieden alten Kindern MIT GLEICHER KÖRPERGRÖßE bei der Interpretation eines einzelnen Regressions-Koeffizienten beschreibt.

Mitzunehmen: Man muss sich bewusst machen, was die c.p.-Bedingung für die Beschreibung der Ergebnisse im konkreten Fall tatsächlich bedeutet!

Hinweis: Man kann Regressions-Koeffizienten auch kombiniert interpretieren. Z.B. könnte eine interessante Größe sein, wie viel ein Kind zunimmt, wenn es um ein halbes Jahr älter wird UND 3 cm wächst. Im Mittel ist dies: $\frac{1}{2} \cdot \hat{\beta}_{\text{alter}} + 3 \cdot \hat{\beta}_{\text{größe}}$