

Aufgabe 4: Multiples lineares Modell (I)

Auf der Homepage der World Bank können verschiedene Informationen zu den einzelnen Ländern der Welt heruntergeladen werden wie etwa Bevölkerungszahlen, CO₂-Emissionen und weitere Kenngrößen (<http://data.worldbank.org/indicator>). Der auf der Moodle-Homepage verfügbare Datensatz `wdi.RData` enthält eine Auswahl solcher Kenngrößen für die Jahre 2005 bis 2019.

Im Rahmen dieser Aufgabe sollen die CO₂-Emissionen der Länder anhand verschiedener Einflussgrößen modelliert werden. Die folgenden Kenngrößen zu den einzelnen Ländern werden dabei verwendet:

Variable	Erklärung
CO2emission	CO ₂ -Emissionen [in kt]
Population	Einwohnerzahl
Area	Fläche [in km ²]
Employees.M.IND	Anteil der Industriearbeiter unter männlichen Beschäftigten [in %]
Livestock	Tierischer Produktionsindex
PopulationRural	Einwohnerzahl der auf dem Land lebenden Bevölkerung
GDP	Bruttoinlandsprodukt [in US\$]

- (a) Lesen Sie den Datensatz in **R** ein und beschränken Sie diesen auf die Beobachtungen aus dem Jahr 2013. Führen Sie anschließend eine uni- und bivariate deskriptive Analyse der Variablen `Population` und `CO2emission` durch. Aus welchem Grund sollte man darüber nachdenken, die Daten zu transformieren?

Lösung:

- Laden der Daten und Überblick über Datensatz:

```
load("../Daten/wdi.Rdata")
head(wdi)

##   iso2c      country year      GDP Merchandise Population      Area
## 1  AFG  Afghanistan 2005 6209140044  45.98060  25654277  652860
## 2  ALB    Albania 2005  8052075642  40.68516  3011487  28750
## 3  DZA    Algeria 2005 103198442061  64.30233 33149724 2381740
## 4  ASM American Samoa 2005  503000000 174.95030   59562    200
## 5  AND      Andorra 2005  3255789081      NA    78867    470
## 6  AGO      Angola 2005 36970918699  87.80415 19433602 1246700
##   CO2emission EqualityIndex Employees.F.AGR Employees.M.AGR Employees.M.IND
## 1  1327.454      NA      78.491      59.362      11.535
## 2  4253.720      4      59.199      38.604      21.402
## 3 107278.085      NA      8.613      20.099      26.387
## 4      NA      NA      NA      NA      NA
## 5  575.719      NA      NA      NA      NA
## 6 19156.408      3      46.061      30.290      16.020
##   Employees.F.IND Employees.F.SRV Employees.M.SRV Livestock Unemployment.F
## 1      11.488      10.021      29.103      103.31      14.910
## 2      7.931      32.870      39.994      98.52      16.919
## 3      26.131      65.256      53.514      99.70      18.034
```

```
## 4      NA      NA      NA      99.85      NA
## 5      NA      NA      NA      NA      NA
## 6      1.707      52.233      53.691      102.50      2.852
## Literacy PopulationRural continent      region
## 1      NA      19829986      Asia      South Asia
## 2      NA      1604189      Europe      Europe & Central Asia
## 3      NA      11990255      Africa      Middle East & North Africa
## 4      NA      7088      Oceania      East Asia & Pacific
## 5      NA      7662      Europe      Europe & Central Asia
## 6      NA      8550785      Africa      Sub-Saharan Africa

str(wdi)

## 'data.frame': 3257 obs. of 21 variables:
## $ iso2c      : Factor w/ 217 levels "ABW","AFG","AGO",...: 2 4 56 9 5 3 10 7 8 1 ...
## $ country     : Factor w/ 217 levels "Afghanistan",...: 1 2 3 4 5 6 7 8 9 10 ...
## $ year        : Factor w/ 15 levels "2005","2006",...: 1 1 1 1 1 1 1 1 1 1 ...
## $ GDP         : num  6.21e+09 8.05e+09 1.03e+11 5.03e+08 3.26e+09 ...
## $ Merchandise : num  46 40.7 64.3 175 NA ...
## $ Population  : num  25654277 3011487 33149724 59562 78867 ...
## $ Area        : num  652860 28750 2381740 200 470 ...
## $ CO2emission : num  1327 4254 107278 NA 576 ...
## $ EqualityIndex : num  NA 4 NA NA NA 3 NA NA 4.5 NA ...
## $ Employees.F.AGR: num  78.49 59.2 8.61 NA NA ...
## $ Employees.M.AGR: num  59.4 38.6 20.1 NA NA ...
## $ Employees.M.IND: num  11.5 21.4 26.4 NA NA ...
## $ Employees.F.IND: num  11.49 7.93 26.13 NA NA ...
## $ Employees.F.SRV: num  10 32.9 65.3 NA NA ...
## $ Employees.M.SRV: num  29.1 40 53.5 NA NA ...
## $ Livestock     : num  103.3 98.5 99.7 99.8 NA ...
## $ Unemployment.F : num  14.9 16.9 18 NA NA ...
## $ Literacy      : num  NA NA NA NA NA NA NA NA NA NA ...
## $ PopulationRural: num  19829986 1604189 11990255 7088 7662 ...
## $ continent     : chr  "Asia" "Europe" "Africa" "Oceania" ...
## $ region        : chr  "South Asia" "Europe & Central Asia" "Middle East & North Africa"

summary(wdi)

##      iso2c      country      year      GDP
## ABW      : 15  Afghanistan : 15  2005      : 217  Min.      :2.044e+07
## AFG      : 15  Albania      : 15  2006      : 217  1st Qu.:4.695e+09
## AGO      : 15  Algeria      : 15  2007      : 217  Median :2.103e+10
## ALB      : 15  American Samoa: 15  2008      : 217  Mean    :3.345e+11
## AND      : 15  Andorra      : 15  2009      : 217  3rd Qu.:1.540e+11
## (Other):3180 (Other)      :3180 (Other):2170 Max.    :2.054e+13
## NA's      : 2  NA's        : 2  NA's      : 2  NA's      :389
## Merchandise      Population      Area      CO2emission
## Min.      : 4.101  Min.      :9.828e+03  Min.      : 2  Min.      :7.300e+00
## 1st Qu.: 42.657  1st Qu.:7.146e+05  1st Qu.: 10450  1st Qu.:1.309e+03
## Median : 58.061  Median :5.915e+06  Median : 92226  Median :8.060e+03
## Mean    : 68.141  Mean    :3.244e+07  Mean    : 614173  Mean    :1.532e+05
## 3rd Qu.: 82.362  3rd Qu.:2.081e+07  3rd Qu.: 447400  3rd Qu.:5.916e+04
## Max.    :435.219  Max.    :1.393e+09  Max.    :17098250  Max.    :1.029e+07
## NA's    :569  NA's    :226  NA's    :252  NA's    :1222
## EqualityIndex  Employees.F.AGR  Employees.M.AGR  Employees.M.IND
## Min.      :1.500  Min.      : 0.009  Min.      : 0.091  Min.      : 2.636
## 1st Qu.:3.000  1st Qu.: 2.942  1st Qu.: 6.883  1st Qu.:17.694
## Median :3.500  Median :14.361  Median :23.333  Median :25.357
## Mean     :3.365  Mean     :26.138  Mean     :27.287  Mean     :25.120
## 3rd Qu.:4.000  3rd Qu.:45.763  3rd Qu.:43.117  3rd Qu.:32.093
```

```
## Max. :5.000 Max. :96.605 Max. :87.716 Max. :67.404
## NA's :2188 NA's :452 NA's :452 NA's :452
## Employees.F.IND Employees.F.SRV Employees.M.SRV Livestock
## Min. : 0.388 Min. : 2.843 Min. : 9.139 Min. : 32.64
## 1st Qu.: 6.929 1st Qu.:41.608 1st Qu.:37.604 1st Qu.:100.44
## Median :10.257 Median :67.769 Median :47.817 Median :107.08
## Mean :11.794 Mean :62.068 Mean :47.593 Mean :112.27
## 3rd Qu.:15.425 3rd Qu.:85.003 3rd Qu.:58.535 3rd Qu.:120.13
## Max. :56.815 Max. :98.670 Max. :82.939 Max. :364.86
## NA's :452 NA's :452 NA's :452 NA's :852
## Unemployment.F Literacy PopulationRural continent
## Min. : 0.218 Min. : 22.31 Min. : 0 Length:3257
## 1st Qu.: 3.841 1st Qu.: 77.05 1st Qu.: 193508 Class :character
## Median : 6.679 Median : 92.66 Median : 1938841 Mode :character
## Mean : 9.063 Mean : 84.08 Mean : 15616672
## 3rd Qu.:12.186 3rd Qu.: 96.55 3rd Qu.: 9424858
## Max. :42.769 Max. :100.00 Max. :892321651
## NA's :452 NA's :2679 NA's :254
## region
## Length:3257
## Class :character
## Mode :character
##
##
##
##
```


- Herausfiltern der Daten aus dem Jahr 2013:

```
wdi <- wdi %>% filter(year == 2013)
```


- Graphische Visualisierung der Verteilungen von Bevölkerung (pro Tausend Einwohner) und CO₂-Emissionen:

```
wdi$Population1000 <- wdi$Population / 1000
wdi_long <- gather(wdi, variable, value, c(CO2emission, Population1000))
gg_wdi <- ggplot(data = wdi_long, mapping = aes(x = value)) +
  geom_density() + facet_wrap(~variable, scale = "free") +
  xlab("") + theme
grid.arrange(gg_wdi + ggtitle("Uneingeschränkter Datenbereich"),
  gg_wdi + ggtitle("Eingeschränkter Datenbereich") +
  xlim(0, 1e5))
```

Uneingeschränkter Datenbereich



Eingeschränkter Datenbereich



⇒ Sowohl die Bevölkerung als auch die CO_2 -Emissionen sind extrem rechtsschief bzw. linkssteil verteilt, d.h. ein Großteil der Länder weist eine vergleichsweise kleine Bevölkerungszahl sowie vergleichsweise niedrige CO_2 -Emissionen auf.

⇒ Durchführung einer $\log_{10}$ -Transformation

- Hinzufügen von $\log$ -transformierten Variablen zum Datensatz:

```
wdi <- wdi %>%
  mutate(log10_Population = log10(Population),
         log10_CO2emission = log10(CO2emission))
head(wdi)
```

##	iso2c	country	year	GDP	Merchandise	Population	Area
## 1	AFG	Afghanistan	2013	20561054090	44.10766	32269589	652860
## 2	ALB	Albania	2013	12776277649	56.62056	2895092	28750
## 3	DZA	Algeria	2013	209754763861	57.21062	38140132	2381740
## 4	ASM	American Samoa	2013	641000000	135.25741	55713	200
## 5	AND	Andorra	2013	3281585236	NA	80774	470
## 6	AGO	Angola	2013	136709862831	69.18155	26015780	1246700

##	CO2emission	EqualityIndex	Employees.F.AGR	Employees.M.AGR	Employees.M.IND
## 1	10014.577	1.5	69.913	45.917	15.337
## 2	5064.127	NA	53.174	37.567	21.782


```
## 3 134465.223 NA 3.332 12.196 32.299
## 4 NA NA NA NA NA
## 5 476.710 NA NA NA NA
## 6 32617.965 3.0 58.270 43.790 15.748
## Employees.F.IND Employees.F.SRV Employees.M.SRV Livestock Unemployment.F
## 1 20.058 10.029 38.745 103.97 14.680
## 2 10.240 36.586 40.651 110.78 13.345
## 3 23.934 72.735 55.505 141.95 16.271
## 4 NA NA NA 100.43 NA
## 5 NA NA NA NA NA
## 6 1.155 40.574 40.462 137.03 7.772
## Literacy PopulationRural continent region Population1000
## 1 NA 24404522 Asia South Asia 32269.589
## 2 NA 1291587 Europe Europe & Central Asia 2895.092
## 3 NA 11603754 Africa Middle East & North Africa 38140.132
## 4 NA 7049 Oceania East Asia & Pacific 55.713
## 5 NA 9259 Europe Europe & Central Asia 80.774
## 6 NA 9885476 Africa Sub-Saharan Africa 26015.780
## log10_Population log10_CO2emission
## 1 7.508793 4.000633
## 2 6.461662 3.704505
## 3 7.581382 5.128610
## 4 4.745957 NA
## 5 4.907272 2.678254
## 6 7.415237 4.513457
```

- Graphische Visualisierung des Zusammenhangs zwischen Bevölkerung und CO_2 -Emissionen:

```
# Originalvariablen:
gg_streu <- ggplot(data = wdi,
  mapping = aes(x = Population * 1000, y = CO2emission,
    label = country)) +
  geom_point() + xlab("Bevölkerung") + ylab("Co2-Emissionen [kt]") +
  geom_text(mapping = aes(label = ifelse(test = CO2emission >=
    sort(CO2emission,
      decreasing = TRUE)[3] |
    Population >=
    sort(Population,
      decreasing = TRUE)[3],
    yes = as.character(country), no = "")),
    hjust = 1, vjust = 1, size = 3) + theme

# Transformierte Variablen:
gg_streu_log10 <- gg_streu %>% wdi +
  aes(x = log10_Population, y = log10_CO2emission) +
  xlab("log10(Bevölkerung)") + ylab("log10(CO2-Emissionen) [kt]") +
  geom_text(mapping = aes(label = ifelse(test = log10_CO2emission >=
    sort(log10_CO2emission,
      decreasing = TRUE)[3] |
    log10_Population >=
    sort(log10_Population,
      decreasing=TRUE)[3],
    yes = as.character(country), no = "")),
    hjust = 1, vjust = 1, size = 3)

# Gemeinsame Visualisierung:
grid.arrange(gg_streu + ggtitle("Originaldaten"),
  gg_streu_log10 + ggtitle("Transformierte Daten"), nrow = 1)
```



⇒ Ein (annähernd) linearer Zusammenhang ist nur auf der Ebene der log-transformierten Daten gegeben.

- (b) Modellieren Sie den Zusammenhang zwischen den beiden in Teilaufgabe (a) betrachteten Variablen sowohl für die transformierten als auch für die untransformierten Daten.

Lösung:

- Lineares Regressionsmodell ohne Transformation der Daten ($i = 1, \dots, n$):

$$CO_2\text{-Emissionen}_i = \beta_0 + \beta_1 \text{population}_i + \epsilon_i \quad \text{mit } \epsilon_i \sim N(0, \sigma^2)$$

```
lm_original <- lm(formula = CO2emission ~ Population, data = wdi)
summary(lm_original)

##
## Call:
## lm(formula = CO2emission ~ Population, data = wdi)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -4261244  -35946    4868   11324  3611528
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -7.478e+03  3.577e+04  -0.209   0.835
## Population   4.921e-03  2.576e-04  19.103 <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 495700 on 203 degrees of freedom
## (12 Beobachtungen als fehlend gelöscht)
## Multiple R-squared:  0.6426, Adjusted R-squared:  0.6408
## F-statistic: 364.9 on 1 and 203 DF, p-value: < 2.2e-16
```

- Lineares Regressionsmodells mit log10-Transformation der Daten ($i = 1, \dots, n$):


$$\log_{10}(CO_2\text{-Emissionen}_i) = \beta_0 + \beta_1 \log_{10}(\text{population}_i) + \epsilon_i \quad \text{mit } \epsilon_i \sim N(0, \sigma^2)$$

```
lm_log10 <- lm(formula = log10_CO2emission ~ log10_Population, data = wdi)
summary(lm_log10)

##
## Call:
## lm(formula = log10_CO2emission ~ log10_Population, data = wdi)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.8033 -0.4487  0.1106  0.4968  1.2023
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   -1.88015     0.30409  -6.183  3.4e-09 ***
## log10_Population  0.88048     0.04516  19.495  < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.6571 on 203 degrees of freedom
## (12 Beobachtungen als fehlend gelöscht)
## Multiple R-squared:  0.6518, Adjusted R-squared:  0.6501
## F-statistic: 380.1 on 1 and 203 DF, p-value: < 2.2e-16
```

- Graphische Visualisierung der beiden Regressionsmodelle:

```
grid.arrange(gg_streu %+% wdi + geom_smooth(method = "lm", se = FALSE) +
  ggtitle("Originaldaten"),
  gg_streu_log10 %+% wdi +
  geom_smooth(method = "lm", se = FALSE) +
  ggtitle("Transformierte Daten"),
  nrow = 1)
```




⇒ Beim Modell ohne Transformation fällt auf, dass die Varianz der Residuen nicht konstant ist. Dies stellt eine Verletzung der Annahme der Varianzhomogenität dar.

- (c) Verschaffen Sie sich nun einen ersten Überblick darüber, wie die weiteren Kenngrößen im Datensatz mit den CO_2 -Emissionen zusammenhängen. Transformieren Sie weitere extrem schief verteilte Variablen.

Lösung:

- Graphische Visualisierung der Dichtekurven der einzelnen Variablen:

```
ggplot(data = gather(wdi, variable, value, GDP:PopulationRural),
       mapping = aes(x = value)) +
  geom_density(aes()) +
  facet_wrap(facets = ~variable, scales = "free") + theme
```




- ⇒ Die graphische Darstellung in Form von Kerndichteschätzungen ermöglicht die Identifikation von schiefen Verteilungen und Ausreißern.
- ⇒ Einige der Variablen mit stark linkssteiler bzw. rechtsschiefer Verteilung sollten transformiert werden.

- Transformation einzelner Variablen (Bemerkung: $\log(x + 1)$ bei rechtsschiefen Variablen, die ebenfalls den Wert 0 enthalten):

```
wdi <- wdi %>%
  mutate(Area = log10(Area), CO2emission = log10(CO2emission),
         Population = log10(Population),
         PopulationRural = log10(PopulationRural + 1), GDP = log10(GDP))
```


- Graphische Visualisierung der Dichtekurven nach durchgeführten Transformationen:

```
ggplot(data = gather(wdi, variable, value, GDP:PopulationRural),
       mapping = aes(x = value)) +
  geom_density(aes()) +
  facet_wrap(facets = ~variable, scales = "free") + theme
```



- Graphische Visualisierung des Zusammenhangs der Variablen Area, Population, Livestock und Employees.M.IND mit den CO_2 -Emissionen der Länder in Streudiagrammen:

```
ggplot(data = gather(wdi, variable, value, Area, Population, Livestock, GDP),
       mapping = aes(y = CO2emission, x=value)) + geom_point(alpha = 0.1) +
  geom_smooth(method = "lm") +
  facet_wrap(facets = ~variable, scale = "free_x") + theme
```



⇒ Für die Fläche, die Einwohnerzahl und das GDP besteht ein positiver Zusammenhang mit den CO_2 -Emissionen. Zwischen dem Livestock-Index und den CO_2 -Emissionen ist kein ausgeprägter Zusammenhang erkennbar.

- (d) Erweitern Sie nun das auf den transformierten Daten basierende Modell aus Teilaufgabe (b), indem Sie die Einflussgrößen **Area**, **Employees.M.IND** und **Livestock** hinzufügen. Interpretieren Sie die erhaltenen Koeffizientenschätzer (auf Ebene der transformierten Daten).

Lösung:

- Schätzung eines multiplen linearen Regressionsmodells unter Verwendung der Einflussgrößen **Area**, **Population**, **Livestock** und **Employees.M.IND**:

```
lm_co2_mult <- lm(formula = CO2emission ~ Area + Population + Livestock +
  Employees.M.IND,
  data = wdi, na.action = na.exclude)
summary(lm_co2_mult)
```

```
##
## Call:
## lm(formula = CO2emission ~ Area + Population + Livestock + Employees.M.IND,
##     data = wdi, na.action = na.exclude)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.54283 -0.26210  0.01381  0.25052  1.25791
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -3.5129484   0.3174464 -11.066  <2e-16 ***
## Area          0.0070830   0.0497679   0.142   0.887
## Population    0.9376060   0.0632914  14.814  <2e-16 ***
## Livestock     -0.0008871   0.0010309  -0.860   0.391
## Employees.M.IND 0.0519518   0.0031864  16.304  <2e-16 ***
## ---
```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4265 on 175 degrees of freedom
## (37 Beobachtungen als fehlend gelöscht)
## Multiple R-squared:  0.8234, Adjusted R-squared:  0.8194
## F-statistic:    204 on 4 and 175 DF,  p-value: < 2.2e-16
```


- Interpretation der Koeffizientenschätzer:
 - β_0 : β_0 bezeichnet die erwarteten logarithmierten CO_2 -Emissionen, wenn alle Einflussgrößen gleich 0 sind.
 $\Rightarrow$ Der Parameter ist in diesem Fall nicht sinnvoll interpretierbar.
 - β_1 : Steigt die logarithmierte Fläche um einen km^2 , so erhöhen sich die logarithmierten CO_2 -Emissionen eines Landes c.p. durchschnittlich um 0.0071 kt .
 - β_2 : Steigt die logarithmierte Bevölkerungszahl um eine Einheit, so erhöhen sich die logarithmierten CO_2 -Emissionen eines Landes c.p. durchschnittlich um 0.9376 kt .
 - β_3 : Steigt der Livestock-Index um eine Einheit, so sinken die logarithmierten CO_2 -Emissionen eines Landes c.p. um durchschnittlich 0.0009 kt .
 - β_4 : Steigt der Anteil männlicher Angestellter in der Industrie um einen Prozentpunkt, so erhöhen sich die logarithmierten CO_2 -Emissionen c.p. durchschnittlich um 0.0520 kt .
- Generelle Anmerkungen zur Interpretation:
 - Bei einem linearen Regressionsmodell mit mehreren Kovariablen müssen die geschätzten Koeffizienten immer unter Konstanthaltung aller anderen Variablen (*ceteris paribus* bzw. c.p.) interpretiert werden.
 - Die Interpretation zu diesem Modell kann auch hinsichtlich der (unlogarithmierten) CO_2 -Emissionen erfolgen:
 Steigt die logarithmierte Bevölkerungszahl um eine Einheit, so erhöhen sich die erwarteten CO_2 -Emissionen c.p. um den Faktor $10^{0.9376} \approx 8.66$.

(e) Visualisieren Sie unter Verwendung des R-Paketes **visreg** für jede Einflussvariable ihren individuellen Beitrag zum linearen Prädiktor sowie die zugehörige Unsicherheit der Schätzung.

Lösung:

- Berechnung von individuellen Effekten:
 - Zwei Strategien: Konditionale Darstellung, Kontrastdarstellung
 - Beide Betrachtungsweisen sind im R-Paket **visreg** implementiert.
- Konditionale Darstellung:
 - Idee:
 - * Betrachtung des Erwartungswertes $\mathbb{E}(y_i | x_{i1}, \dots, x_{ij}, \dots, x_{ip})$ für verschiedene Werte von x_{ij} der interessierenden Kovariable j unter konstanten anderen Einflussgrößen $x_{i1}, \dots, x_{i(j-1)}, x_{i(j+1)}, \dots, x_{ip}$ (z.B. Verwendung der Mittelwerte)
 $\rightarrow$ Betrachtung von $\tilde{x}_i = (\bar{x}_1, \dots, x_{ij}, \dots, \bar{x}_p)$
 - * Die Unsicherheit der Schätzung $\hat{y}_i$ ist dann gegeben durch $\hat{y}_i + \hat{\sigma}_{\hat{y}_i} t_{1-\frac{\alpha}{2}}(n - (p + 1))$.
 - Anwendung für geschätztes Regressionsmodell:

```
par(mfrow = c(2, 2))
visreg(fit = lm_co2_mult, type = "conditional",
       ylim = range(wdi$CO2emission, na.rm = TRUE))
```



- Kontrastdarstellung:

- Idee:

- * Wie ändert sich $\hat{y}_i$, wenn sich x_{ij} in Bezug auf einen Referenzwert x_j^* (meist $x_j^* = \bar{x}_j$) ändert?


$$\begin{aligned}\hat{y}_i - \hat{y}_i^* &= \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \dots + \hat{\beta}_j x_{ij} + \dots + \hat{\beta}_p x_{ip} - (\hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \dots + \hat{\beta}_j x_j^* + \dots + \hat{\beta}_p x_{ip}) \\ &= (x_{ij} - x_j^*) \hat{\beta}_j\end{aligned}$$

- * Die Unsicherheit der Schätzung ergibt sich durch

$$\text{Var}(\hat{y}_i - \hat{y}_i^*) = \text{Var}((x_{ij} - x_j^*) \hat{\beta}_j) = (x_{ij} - x_j^*)^2 \text{Var}(\hat{\beta}_j).$$


⇒ Die Kontrastdarstellung ermöglicht eine isolierte Betrachtung einer einzelnen Kovariable x_j , berücksichtigt bei der Schätzung der Unsicherheit allerdings auch nur die Schätzung von β_j .

```
par(mfrow = c(2, 2))
visreg(fit = lm_co2_mult, type = "contrast", ylim = c(-2, 2))
```



- Vergleich der beiden Darstellungsformen:
 - Beide Darstellungsformen führen zu sehr ähnlichen individuellen Effekte für alle Einflussvariablen des Regressionsmodells.
 - In beiden Fällen zeigt sich, dass die Beiträge der Variablen **Population** und **Employees.M.IND** zum linearen Prädiktor deutlich stärker sind als diejenigen der Variablen **Area** und **Livestock**.
- Alternative: Verwendung des R-Paketes **effects**:

```
plot(allEffects(lm_co2_mult), ylim = range(wdi$C02emission, na.rm = TRUE))
```



⇒ Dieses Paket verwendet standardmäßig die konditionale Darstellung.


- Anmerkung:
Für eine bessere Vergleichbarkeit der geschätzten Effekte sollte üblicherweise eine identische Skalierung der y-Achse bezüglich aller Kovariablen gewählt werden.

(f) Betrachten Sie den univariaten Zusammenhang zwischen `PopulationRural` und den CO_2 -Emissionen. Fügen Sie die Variable zum multiplen linearen Regressionsmodell aus Teilaufgabe (d) hinzu, Interpretieren Sie den geschätzten Effekt für `PopulationRural`. Wie lässt sich der Unterschied zur univariaten Betrachtung erklären?

Lösung:

- Graphische Visualisierung des univariaten Zusammenhangs zwischen der Landbevölkerung und den CO_2 -Emissionen:

```
ggplot(data = wdi, mapping = aes(x = PopulationRural, y = CO2emission)) +  
  geom_point() + geom_smooth(method = "lm") + theme
```



⇒ Es ist ein klar positiver Zusammenhang zwischen der Landbevölkerung und den CO_2 -Emissionen erkennbar.

- Schätzung eines multiplen linearen Regressionsmodells mit zusätzlicher Einflussgröße PopulationRural:

```
lm_co2_rur <- lm(formula = CO2emission ~ Area + Population + Livestock +
  Employees.M.IND + PopulationRural,
  data = wdi, na.action = na.exclude)
summary(lm_co2_rur)
```

```
##
## Call:
## lm(formula = CO2emission ~ Area + Population + Livestock + Employees.M.IND +
##     PopulationRural, data = wdi, na.action = na.exclude)
##
## Residuals:
```

	Min	1Q	Median	3Q	Max
	-1.39267	-0.24728	0.01172	0.25460	1.24624


```
##
## Coefficients:
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-3.5342792	0.2949315	-11.983	< 2e-16 ***
Area	0.1095168	0.0500221	2.189	0.0299 *
Population	1.0377388	0.0616890	16.822	< 2e-16 ***
Livestock	-0.0005886	0.0009593	-0.614	0.5403
Employees.M.IND	0.0497383	0.0029887	16.642	< 2e-16 ***
PopulationRural	-0.1849735	0.0344825	-5.364	2.56e-07 ***

```
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.3962 on 174 degrees of freedom
## (37 Beobachtungen als fehlend gelöscht)
## Multiple R-squared:  0.8485, Adjusted R-squared:  0.8441
## F-statistic: 194.8 on 5 and 174 DF, p-value: < 2.2e-16
```

- Graphische Visualisierung der individuellen Effekte:

```
par(mfrow = c(2, 3))
visreg(fit = lm_co2_rur, type = "contrast", ylim = c(-2, 2))
```



- Auffälligkeit:

- Obwohl die Landbevölkerung stark mit den CO_2 -Emissionen eines Landes korreliert, führt eine Erhöhung um eine Einheit bei Konstanthaltung aller anderen Variablen im Mittel zu einer Verringerung der logarithmierten CO_2 -Emissionen eines Landes um 0.185 kt .
- Eine mögliche Erklärung hierfür könnte darin liegen, dass der Effekt der Bevölkerung bereits für die Variable **Population** im Modell berücksichtigt ist und bei konstanter Bevölkerungszahl eine höhere Landbevölkerung zu einer weniger ausgeprägten Industrialisierung und somit zu niedrigeren CO_2 -Emissionen führt.

(g) Fügen Sie nun das (geeignet transformierte) **GDP** (Bruttoinlandsprodukt) zum Regressionsmodell aus Teilaufgabe (f) hinzu. Was fällt im Vergleich zum vorherigen Modell auf? Überlegen Sie sich eine Begründung für die beobachtete Veränderung.

Lösung:

- Schätzung eines multiplen linearen Regressionsmodells mit zusätzlicher Einflussgröße **GDP**:


```
lm_co2_gdp <- lm(formula = CO2emission ~ Area + Population + Livestock +
                  Employees.M.IND + PopulationRural + GDP,
                  data = wdi, na.action = na.exclude)
```

```
summary(lm_co2_gdp)

##
## Call:
## lm(formula = CO2emission ~ Area + Population + Livestock + Employees.M.IND +
##      PopulationRural + GDP, data = wdi, na.action = na.exclude)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.56542 -0.16940 -0.00238  0.17013  0.81530
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   -6.2583379   0.2552915  -24.514 < 2e-16 ***
## Area           0.0601833   0.0323181    1.862 0.064309 .
## Population     0.2461910   0.0648196    3.798 0.000203 ***
## Livestock      0.0012684   0.0006289    2.017 0.045300 *
## Employees.M.IND 0.0228872   0.0025654    8.921 7.37e-16 ***
## PopulationRural -0.0068032   0.0247997   -0.274 0.784170
## GDP           0.7270435   0.0459845   15.811 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.2535 on 169 degrees of freedom
## (41 Beobachtungen als fehlend gelöscht)
## Multiple R-squared:  0.939, Adjusted R-squared:  0.9368
## F-statistic: 433.5 on 6 and 169 DF, p-value: < 2.2e-16
```

- Graphische Visualisierung der individuellen Effekte:

```
par(mfrow = c(2, 3))
visreg(fit = lm_co2_gdp, type = "contrast", ylim = c(-2, 2))
```



- Auffälligkeit:
 - Bei Einbeziehung des GDP in das Regressionsmodell hat die Landbevölkerung keinen signifikanten Einfluss auf die CO_2 -Emissionen eines Landes mehr.
 - Der Grund hierfür liegt vermutlich darin, dass das GDP die Industrialisierung eines Landes besser abbildet als die Landbevölkerung und diese nichts mehr zusätzlich erklären kann.

Aufgabe 5: Multiples lineares Modell (II)

Ziel dieser Aufgabe ist es, mit realen Gehaltsdaten von "Data Scientist" Berufen ein plausibles Multiples lineares Modell zu schätzen.

Für die Bearbeitung der Aufgabe verwenden wir einen Datensatz, der Gehaltsinformationen der Berufsgruppe "Data Scientist" enthält. Der Datensatz kann inklusive Beschreibung der Kenngrößen unter folgendem Link heruntergeladen und eingesehen werden: (<https://www.kaggle.com/datasets/arnabchaki/data-science-salaries-2023>). Alternativ sind die Rohdaten unter `ds_salaries.csv` auf der Moodle-Homepage verfügbar. Die Aufgabe ist in zwei Teile gegliedert:

Teil 1 beschäftigt sich mit der Datensammlung und dem Datenmanagement und hat unter anderem das Ziel den Umgang mit **R** und im speziellen **tidyverse** zu schulen. Teil 1 wird in Teilaufgabe a) behandelt.

Teil 2 beschäftigt sich mit der Modellierung der bereits aufbereiteten Daten und behandelt den relevanten Stoff der Vorlesung. Der benötigte Datensatz `ds_salaries_adj.csv` kann bei Moodle heruntergeladen werden.

- (a) Laden Sie den Datensatz von Kaggle herunter und lesen Sie ihn in **R** ein. Beschränken Sie den Datensatz auf die Beobachtungen der Länder Deutschland, Großbritannien, und USA. Anschließend verknüpfen Sie die Rohdaten mit den Inflationsdaten, im speziellen dem harmonisierten Verbraucherpreisindex (engl. harmonised consumer price index, hcpi), die Sie von der Website der World Bank bekommen: <https://www.worldbank.org/en/research/brief/inflation-database>. Der finale Datensatz soll alle Variablen von `ds_salaries` und zusätzlich die Inflationsrate pro Jahr mit Referenzjahr 2020 enthalten.

Tipp: Verwenden Sie die Funktion `left_join` aus der library **tidyverse** und verknüpfen Sie die Daten mittels geeigneter eindeutiger Schlüssel (Land und Jahr). Ggf. müssen diese zunächst angepasst werden. Für die Berechnung der Inflationsrate pro Jahr ist die Funktion `cumsum` hilfreich.

- (b) Falls Sie Aufgabe (a) geschafft haben, rechnen Sie mit Ihrem Datensatz weiter. Alternativ, lesen Sie den Datensatz aus Moodle in **R** ein, beschränken Sie den Datensatz auf die Beobachtungen der Länder Deutschland, Großbritannien, und USA, und machen Sie sich vertraut mit den Daten. Führen Sie anschließend eine uni- und bivariate deskriptive Analyse der Zielgröße `salary_in_USD` und `company_location` durch. Aus welchem Grund sollte man darüber nachdenken die Daten zu transformieren?

Lösung:

- Laden der Daten und Überblick über Datensatz:

```
dat_dssal <- read.csv("../Daten/ds_salaries.csv")

head(dat_dssal)

##   work_year experience_level employment_type      job_title salary
## 1      2023                SE             FT Principal Data Scientist 80000
## 2      2023                MI             CT           ML Engineer 30000
## 3      2023                MI             CT           ML Engineer 25500
## 4      2023                SE             FT           Data Scientist 175000
## 5      2023                SE             FT           Data Scientist 120000
## 6      2023                SE             FT Applied Scientist 222200
## salary_currency salary_in_usd employee_residence remote_ratio
## 1              EUR       85847                ES           100
```

```
## 2          USD          30000          US          100
## 3          USD          25500          US          100
## 4          USD          175000         CA          100
## 5          USD          120000         CA          100
## 6          USD          222200         US           0
##   company_location company_size
## 1              ES             L
## 2              US             S
## 3              US             S
## 4              CA             M
## 5              CA             M
## 6              US             L

summary(dat_dssal)

##   work_year  experience_level  employment_type  job_title
##   Min.    :2020  Length:3755      Length:3755      Length:3755
##   1st Qu.:2022  Class :character  Class :character  Class :character
##   Median :2022  Mode  :character  Mode  :character  Mode  :character
##   Mean   :2022
##   3rd Qu.:2023
##   Max.   :2023
##   salary      salary_currency  salary_in_usd  employee_residence
##   Min.    :   6000  Length:3755      Min.    :  5132  Length:3755
##   1st Qu.: 100000  Class :character  1st Qu.: 95000  Class :character
##   Median : 138000  Mode  :character  Median :135000  Mode  :character
##   Mean   : 190696                Mean   :137570
##   3rd Qu.: 180000                3rd Qu.:175000
##   Max.   :30400000                Max.   :450000
##   remote_ratio  company_location  company_size
##   Min.    :  0.00  Length:3755      Length:3755
##   1st Qu.:  0.00  Class :character  Class :character
##   Median :  0.00  Mode  :character  Mode  :character
##   Mean   : 46.27
##   3rd Qu.:100.00
##   Max.   :100.00


# what happened to the outlier in the salary column
# dat_dssal %>% filter(salary == 30400000) # -> currency CLP

# only interested in Germany, US, GB
dat_dssal <- dat_dssal %>% filter(company_location %in% c("DE", "GB", "US"))
```

- Graphische Visualisierung der Zielgröße über die Zeit je Land:


```
# aggregate data per year to analyze inflation based increase
dat_dssal_yrly <- dat_dssal %>%
  group_by(work_year, company_location) %>%
  summarise(median_salary_in_usd = median(salary_in_usd, na.rm = TRUE))

# plot yearly salary to analyze inflation based increase
ggplot(data = dat_dssal_yrly,
       aes(x=work_year, y=median_salary_in_usd, col=company_location)) +
  geom_line(linewidth = 0.75) +
  xlab("") +
  ylab("Gehalt in USD")+
  ylim(c(0, 150000))
```




- Graphische Visualisierung der Zielgröße je Land:

```
# plot yearly salary to analyze inflation based increase
ggplot(data = dat_dssal,
       aes(x=company_location, y=salary_in_usd, fill = company_location)) +
  geom_violin() +
  geom_boxplot(width = 0.25, color = "black") +
  theme(legend.position = "none") +
  xlab("") +
  ylab("Gehalt in USD")+
  scale_y_continuous(labels=scales::comma)
```



- Graphische Visualisierung der log-transformierten Zielgröße je Land:

```
# plot yearly salary to analyze inflation based increase
ggplot(data = dat_dssal,
       aes(x=company_location, y=log(salary_in_usd), fill = company_location)) +
  geom_violin() +
  geom_boxplot(width = 0.25, color = "black") +
  theme(legend.position = "none") +
  xlab("") +
  ylab("Logarithmiertes Gehalt")+
  scale_y_continuous(labels=scales::comma)
```



- ⇒ Das Gehalt der Data Scientists ist rechtsschief bzw. linkssteil verteilt, d.h. ein kleiner Teil der Angestellten weist ein vergleichsweise hohes Gehalt auf
- ⇒ Es ist zu erwarten, dass ein zeitlicher Effekt die Zielgröße beeinflusst, da in den Jahren 2020 – 2023 die Inflation sehr hoch war.
- ⇒ Durchführung einer **log**-Transformation und einer Inflationsanpassung der Zielgröße

(c) Modellieren Sie den Zusammenhang zwischen **salary_in_USD**, **company_location**, **company_size**, und **year** sowohl für die transformierten als auch für die untransformierten Daten, Schreiben Sie die Strukturgleichung und Verteilungsannahmen für alle Modelle auf und interpretieren sie das Ergebnis.

Lösung:

- Lineares Regressionsmodell ohne Transformation der Daten ($i = 1, \dots, n$):

$$\begin{aligned}
 \text{salary_in_usd}_i = & \beta_0 + \beta_1 I(\text{location} = \text{GB}_i) + \beta_2 I(\text{location} = \text{US}_i) \\
 & + \beta_3 I(\text{size} = \text{M}_i) + \beta_4 I(\text{size} = \text{S}_i) \\
 & + \beta_5 \text{year}_i + \epsilon_i, \quad \epsilon_i \sim N(0, \sigma^2)
 \end{aligned}$$

$$\begin{aligned}\log(\text{salary_in_usd}_i) = & \tilde{\beta}_0 + \tilde{\beta}_1 I(\text{location} = \text{GB}_i) + \tilde{\beta}_2 I(\text{location} = \text{US}_i) \\ & + \tilde{\beta}_3 I(\text{size} = \text{M}_i) + \tilde{\beta}_4 I(\text{size} = \text{S}_i) \\ & + \tilde{\beta}_5 \text{year}_i + \epsilon_i, \quad \epsilon_i \sim N(0, \sigma^2)\end{aligned}$$

```
dat_dssal_adj <- read.csv("../Daten/ds_salaries_adj.csv")

model <- lm(formula = salary_in_usd ~ company_location +
            company_size +
            year,
            data = dat_dssal_adj)
summary(model)

##
## Call:
## lm(formula = salary_in_usd ~ company_location + company_size +
##     year, data = dat_dssal_adj)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -142143  -36201   -6616   29963  345294
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)      88990      8321  10.694 < 2e-16 ***
## company_locationGB -13433      8670  -1.549  0.1214
## company_locationUS  49035      7728   6.345 2.53e-10 ***
## company_sizeM      -6002      3545  -1.693  0.0906 .
## company_sizeS     -38161      7044  -5.417 6.49e-08 ***
## year              8059      1653   4.874 1.14e-06 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 54920 on 3262 degrees of freedom
## Multiple R-squared:  0.0982, Adjusted R-squared:  0.09682
## F-statistic: 71.04 on 5 and 3262 DF, p-value: < 2.2e-16
```

- Lineares Regressionsmodells mit log-Transformation der Daten und Inflationsbereinigung

```
model_adj <- lm(formula = log_salary_adj ~ company_location +
               company_size +
               year,
               data = dat_dssal_adj)
summary(model_adj)

##
## Call:
## lm(formula = log_salary_adj ~ company_location + company_size +
##     year, data = dat_dssal_adj)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.72746 -0.22760  0.02194  0.26100  1.69235
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    11.25187    0.06001 187.515 < 2e-16 ***
## company_locationGB -0.09016    0.06252  -1.442   0.149
```

```
## company_locationUS 0.44883 0.05573 8.054 1.11e-15 ***
## company_sizeM -0.01294 0.02556 -0.506 0.613
## company_sizeS -0.39147 0.05080 -7.706 1.71e-14 ***
## year 0.01686 0.01192 1.414 0.157
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.396 on 3262 degrees of freedom
## Multiple R-squared: 0.1319, Adjusted R-squared: 0.1306
## F-statistic: 99.12 on 5 and 3262 DF, p-value: < 2.2e-16
```

- ⇒ Die Variable **year** hat einen signifikanten Einfluss im Modell ohne Inflationsanpassung, insignifikant bei der adjustierten Zielgröße
- ⇒ In dem untransformierten Modell ist das durchschnittliche Gehalt einer mittelgroßen Firma 6002 USD und das einer kleinen Firma 38161 USD geringer als das einer großen Firma, unter Gleichhaltung aller anderen Variablen (c.p.).
- ⇒ In dem transformierten Modell ist das durchschnittliche Gehalt einer mittelgroßen Firma um Faktor $\exp(-0.013) = 0.987$ und das einer kleinen Firma um Faktor $\exp(-0.391) = 0.676$ geringer als das einer großen Firma, unter Gleichhaltung aller anderen Variablen (c.p.)
- ⇒ Interpretation des Intercepts: Das durchschnittliche Gehalt eines Data Scientists in einer großen deutschen Firma im Jahr 2020 beträgt etwa $\exp(11.25187) = 77.000$ USD.

- (d) Verwenden Sie im Folgenden ausschließlich die transformierten Daten und beschränken Sie den Datensatz auf die Jahre 2020 bis 2022. Schätzen Sie anhand dieser Trainingsdaten erneut das Modell aus Teilaufgabe (b) und ersetzen Sie dabei die Variable **work_year** durch **experience_level**.

Erstellen Sie anschließend auf Grundlage dieses Modells eine Prognose für die Gehälter von Data Scientists im Jahr 2023 (Testdaten). Wie gut ist die Prognosegüte dieses Modells?

Lösung:

- Bestimmung der Prognosegüte:
 - Als Maßzahl zur Bestimmung der Prognosegüte kann der Root Mean Squared Error (RMSE) verwendet werden:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Der RMSE ist eine Maßzahl für die durchschnittliche Abweichung der Prädiktion vom tatsächlich beobachteten Wert. Er ist definiert als die Wurzel des mittleren quadratischen Fehlers.

- Die Prognosegüte sollte immer auf Basis von Testdaten bestimmt werden, die nicht in die Modellschätzung einbezogen wurden.
- Einschränkung des Trainingsdatensatzes auf Beobachtungen vor 2023:

```
dat_dssal_adj_train <- dat_dssal_adj %>%
  filter(work_year<2023)
dat_dssal_adj_test <- setdiff(dat_dssal_adj, dat_dssal_adj_train)
```

- Schätzung eines multiplen linearen Regressionsmodells:

```

model_d <- lm(formula = log_salary_adj ~ company_location +
              company_size +
              experience_level,
              data = dat_dssal_adj_train)
summary(model_d)

##
## Call:
## lm(formula = log_salary_adj ~ company_location + company_size +
##     experience_level, data = dat_dssal_adj_train)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.72410 -0.19040  0.02189  0.25249  1.72431
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    10.95609     0.06859  159.740 < 2e-16 ***
## company_locationGB -0.01660     0.07204   -0.230  0.8177
## company_locationUS  0.36852     0.06334    5.818 7.16e-09 ***
## company_sizeM      -0.07157     0.02786   -2.569  0.0103 *
## company_sizeS      -0.28451     0.05415   -5.254 1.69e-07 ***
## experience_levelEX  0.86101     0.06971   12.352 < 2e-16 ***
## experience_levelMI  0.28262     0.04219    6.698 2.91e-11 ***
## experience_levelSE  0.51305     0.03970   12.923 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.3832 on 1610 degrees of freedom
## Multiple R-squared:  0.2736, Adjusted R-squared:  0.2705
## F-statistic: 86.65 on 7 and 1610 DF, p-value: < 2.2e-16

```

- Berechnung der Prognosegüte in R (transformierte Daten):

```

# Funktion zur Berechnung des RMSE in Abhängigkeit der wahren Werte y und der
# prädizierten Werte y_hat:
rmse <- function(y, y_hat) {
  sqrt(sum((y - y_hat)^2) / length(y))
}

# Prädiktion der Beobachtungen im Testdatensatz:
prediction <- predict(object = model_d, newdata = dat_dssal_adj_test)
# Berechnung des RMSE:
rmse_test <- rmse(dat_dssal_adj_test$log_salary_adj, prediction)
rmse_test

## [1] 0.3732063

```

⇒ Der RMSE beträgt ca. 0.37.


- Graphischer Vergleich zwischen prädizierten und tatsächlich beobachteten Werten auf der Originalskala:

```

ggplot()+
  geom_point(aes(x = dat_dssal_adj_test$salary_adj, y = exp(prediction))) +
  geom_line(aes(x = dat_dssal_adj_test$salary_adj,
                y = dat_dssal_adj_test$salary_adj, col = "red",
                linewidth = 1) + xlim(50000, 450000) + ylim(50000, 450000) +
  geom_text(aes(x = 300000,
                y = 50000,
                label = paste("RMSE", round(rmse_test, 2)))) +

```

theme



⇒ Im graphischen Vergleich erkennt man, dass sehr hohe Gehälter deutlich unterschätzt werden.

- (e) Werfen Sie erneut einen Blick auf einzelne Einflussgrößen und diskutieren Sie Modellschwächen oder Verbesserungsansätze. Vergleichen Sie das neue Modell mit dem Modell aus Teilaufgabe (c). **Lösung:**

```
# employment_type has multiple categories, which are not comparable, i.e. part time vs full time.
table(dat_dssal_adj$employment_type)

##
##      CT      FL      FT      PT
##      8       4 3248       8

# Datensatz filtern und nur ganztags Beschäftigte aufnehmen
dat_dssal_adj_neu <- dat_dssal_adj %>%
  filter(employment_type == "FT")

model_e1 <- lm(formula = log_salary_adj ~ company_location +
               company_size +
               experience_level,
               data = dat_dssal_adj_neu)
summary(model_e1)

##
## Call:
## lm(formula = log_salary_adj ~ company_location + company_size +
##     experience_level, data = dat_dssal_adj_neu)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.76572 -0.20342  0.00757  0.24575  1.74669
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    11.07543    0.05548  199.632 < 2e-16 ***
## company_locationGB -0.08906    0.05788  -1.539   0.124
```

```

## company_locationUS  0.33586    0.05170    6.496 9.51e-11 ***
## company_sizeM      -0.08786    0.02233   -3.935 8.49e-05 ***
## company_sizeS      -0.27659    0.04875   -5.674 1.52e-08 ***
## experience_levelEX  0.72915    0.04395   16.591 < 2e-16 ***
## experience_levelMI  0.22965    0.02936    7.821 7.05e-15 ***
## experience_levelSE  0.45568    0.02687   16.959 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.3583 on 3240 degrees of freedom
## Multiple R-squared:  0.2438, Adjusted R-squared:  0.2422
## F-statistic: 149.3 on 7 and 3240 DF,  p-value: < 2.2e-16

# alternativ: ins Modell aufnehmen, mit "FT" als Referenz
employment_type_factor <- factor(dat_dssal_adj$employment_type, levels = c("FT", "CT", "FL", "PT"))

model_e2 <- lm(formula = log_salary_adj ~ company_location +
               company_size +
               experience_level +
               employment_type_factor,
               data = dat_dssal_adj)
summary(model_e2)

##
## Call:
## lm(formula = log_salary_adj ~ company_location + company_size +
##     experience_level + employment_type_factor, data = dat_dssal_adj)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.77144 -0.20761  0.00776  0.24840  1.74782
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)      11.08384    0.05537  200.168 < 2e-16 ***
## company_locationGB -0.09826    0.05777   -1.701 0.089070 .
## company_locationUS  0.32515    0.05139    6.327 2.84e-10 ***
## company_sizeM      -0.08731    0.02246   -3.888 0.000103 ***
## company_sizeS      -0.26768    0.04741   -5.646 1.78e-08 ***
## experience_levelEX  0.74277    0.04420   16.804 < 2e-16 ***
## experience_levelMI  0.22875    0.02946    7.765 1.09e-14 ***
## experience_levelSE  0.45723    0.02700   16.935 < 2e-16 ***
## employment_type_factorCT -0.23778    0.13033   -1.824 0.068171 .
## employment_type_factorFL -0.74369    0.18276   -4.069 4.83e-05 ***
## employment_type_factorPT -1.16431    0.13133   -8.865 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.3625 on 3257 degrees of freedom
## Multiple R-squared:  0.274, Adjusted R-squared:  0.2717
## F-statistic: 122.9 on 10 and 3257 DF,  p-value: < 2.2e-16

```

May 4, 2026

Fragen und Kommentare an mona.niethammer@stat.uni-muenchen.de