

Aufgabe 8: Einfaktorielle Varianzanalyse

In dieser Aufgabe soll erneut der von den beiden vorherigen Übungsblättern bekannte Datensatz `wdi.Rdata` betrachtet werden. Nachdem bis jetzt nur Zusammenhänge zwischen den CO₂-Emissionen der Länder und verschiedenen metrischen Einflussgrößen untersucht wurden, soll nun der Zusammenhang zwischen den CO₂-Emissionen und der kategorialen Variable `continent` genauer analysiert werden. Betrachten Sie hierfür wiederum nur das Jahr 2013.

(a) Betrachten Sie folgende Kodierungsmöglichkeiten für kategoriale Variablen:

- Mittelwertsmodell
- Effektkodierung
- Referenzkodierung

Stellen Sie jeweils die sich aus der Kodierung ergebenden Designmatrizen schematisch dar.

Lösung:

- Komponenten der kategorialen Variable:
 - K Gruppen bzw. Kategorien
 - n_k Beobachtungen in Gruppe k ($k = 1, \dots, K$)
- Mittelwertsmodell:
 - Modellspezifikation:

$$Y_{kl} = \mu_k + \epsilon_{kl} \quad \text{mit } k = 1, \dots, K \text{ und } l = 1, \dots, n_k$$

- Designmatrix:

$$\begin{array}{l} \textit{Afrika} \\ \textit{Amerika} \\ \textit{Asien} \\ \textit{Europa} \\ \textit{Ozeanien} \end{array} \begin{pmatrix} 1 \\ \vdots \\ 1 \\ 1 \\ \vdots \\ 1 \\ 1 \\ \vdots \\ 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix}$$

- Interpretation der Parameter:
 - Die Schätzer entsprechen den jeweiligen Mittelwerten der einzelnen Gruppen.

⇒ Die Schätzer sollten nur isoliert (ohne Einbeziehung weiterer Kovariablen) betrachtet werden.

- Effektkodierung:

- Modellspezifikation:

- * Modellgleichung:

$$Y_{kl} = \mu + \tau_k + \epsilon_{kl} \quad \text{mit } k = 1, \dots, K \text{ und } l = 1, \dots, n_k$$

- * Parameterrestriktion: $\sum_{k=1}^K \tau_k = 0 \Leftrightarrow \tau_K = -\sum_{k=1}^{K-1} \tau_k$

- * Eine Kategorie muss als Referenzkategorie definiert werden, in R wird hierzu standardmäßig die letzte Kategorie verwendet.

- Designmatrix:

$$\begin{array}{l} \textit{Afrika} \\ \textit{Amerika} \\ \textit{Asien} \\ \textit{Europa} \\ \textit{Ozeanien} \end{array} \begin{pmatrix} 1 & 1 & & & \\ \vdots & \vdots & & & \\ & 1 & & & \\ \vdots & & 1 & & \\ \vdots & & \vdots & & \\ \vdots & & 1 & & \\ \vdots & & & 1 & \\ \vdots & & & \vdots & \\ \vdots & & & 1 & \\ \vdots & & & & 1 \\ \vdots & & & & \vdots \\ \vdots & & & & 1 \\ \vdots & -1 & -1 & -1 & -1 \\ \vdots & \vdots & \vdots & \dots & \dots \\ 1 & -1 & -1 & -1 & -1 \end{pmatrix}$$

- Interpretation der Parameter:

- * μ : Mittelwert aller Gruppenmittelwerte

- * τ_k ($k = 1, \dots, K$): Abweichung des Mittelwerts von Gruppe k vom Mittelwert aller Gruppenmittelwerte μ

- Referenzkodierung:

- Modellspezifikation:

- * Modellgleichung:

$$Y_{kl} = \mu_K + \tau_k + \epsilon_{kl} \quad \text{mit } k = 1, \dots, K \text{ und } l = 1, \dots, n_k$$

- * Parameterrestriktion: $\tau_K = 0$

- * Eine Kategorie muss als Referenzkategorie definiert werden, in R wird hierzu standardmäßig die erste Kategorie verwendet.

– Designmatrix:

$$\begin{array}{l}
 \textit{Afrika} \\
 \vdots \\
 \textit{Amerika} \\
 \vdots \\
 \textit{Asien} \\
 \vdots \\
 \textit{Europa} \\
 \vdots \\
 \textit{Ozeanien} \\
 \vdots \\
 1
 \end{array}
 \begin{pmatrix}
 1 & 0 & 0 & 0 & 0 \\
 \vdots & \vdots & \vdots & \vdots & \vdots \\
 \vdots & 0 & 0 & 0 & 0 \\
 \vdots & 1 & & & \\
 \vdots & \vdots & & & \\
 \vdots & 1 & & & \\
 \vdots & & 1 & & \\
 \vdots & & \vdots & & \\
 \vdots & & 1 & & \\
 \vdots & & & 1 & \\
 \vdots & & & \vdots & \\
 \vdots & & & 1 & \\
 \vdots & & & & 1 \\
 \vdots & & & & \vdots \\
 1 & & & & 1
 \end{pmatrix}$$

– Interpretation der Parameter:

- * μ_K : Mittelwert der Referenzkategorie
- * τ_k ($k = 1, \dots, K - 1$): Abweichung des Mittelwerts von Gruppe k vom Mittelwert der Referenzkategorie μ_K
- Vergleich der Kodierungsformen:
Die modellierten Erwartungswerte sind bei allen drei Varianten identisch, einzig die Interpretation der Koeffizienten ändert sich.

- (b) Passen Sie für jede der in Teilaufgabe (a) angegebenen Kodierungsmöglichkeiten jeweils ein lineares Regressionsmodell an. Interpretieren Sie jeweils die geschätzten Koeffizienten.

Lösung:

- Einlesen des Datensatzes:

```
load("../Daten/wdi.Rdata")
```

- Einschränkung auf Beobachtungen aus dem Jahr 2013 und log10-Transformation der CO2-Emissionen:

```
wdi <- wdi %>% filter(year == "2013") %>%
  filter(!is.na(CO2emission) | is.na(continent)) %>%
  mutate(CO2emission = log10(CO2emission)) %>%
  mutate(continent = as.factor(continent))
```

- Mittelwertsmodell:

– Schätzung:

```
lm_mw <- lm(formula = CO2emission ~ -1 + continent, data = wdi)
summary(lm_mw)
##
## Call:
## lm(formula = CO2emission ~ -1 + continent, data = wdi)
##
## Residuals:
```

```
##      Min      1Q   Median      3Q      Max
## -2.72508 -0.68659  0.00954  0.55617  2.93454
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## continentAfrica      3.5525     0.1311   27.10 <2e-16 ***
## continentAmericas    3.7780     0.1469   25.72 <2e-16 ***
## continentAsia        4.6108     0.1362   33.84 <2e-16 ***
## continentEurope      4.4355     0.1469   30.19 <2e-16 ***
## continentOceania     2.7019     0.2408   11.22 <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.9634 on 201 degrees of freedom
## Multiple R-squared:  0.9468, Adjusted R-squared:  0.9455
## F-statistic: 715.7 on 5 and 201 DF, p-value: < 2.2e-16
```

Hinweis: Bitte beachten, dass R-squared hier anders als bei den anderen Kodierungen berechnet wird. Theorie kann in den Vorlesungsunterlagen Folie 70 nachgeschlagen werden.

- Interpretation der Koeffizienten:

```
coefs_mw <- round(x = coefficients(lm_mw), digits = 2)
coefs_mw
##      continentAfrica continentAmericas      continentAsia      continentEurope
##              3.55              3.78              4.61              4.44
##      continentOceania
##              2.70
wdi %>% group_by(continent) %>% summarize(mean(x = CO2emission, na.rm = TRUE))
## # A tibble: 5 x 2
##   continent `mean(x = CO2emission, na.rm = TRUE)`
##   <fct>      <dbl>
## 1 Africa      3.55
## 2 Americas    3.78
## 3 Asia        4.61
## 4 Europe      4.44
## 5 Oceania     2.70
```

⇒ Die Parameterschätzer entsprechen den Mittelwerten der einzelnen Kontinente.

- Kontrastmatrix:

```
diag(1, nlevels(wdi$continent))
##      [,1] [,2] [,3] [,4] [,5]
## [1,]    1    0    0    0    0
## [2,]    0    1    0    0    0
## [3,]    0    0    1    0    0
## [4,]    0    0    0    1    0
## [5,]    0    0    0    0    1
```

- Auszug aus Designmatrix:

```
mm_mw <- model.matrix(lm_mw)
cbind.data.frame(mm_mw, continent = wdi$continent) %>%
  slice_sample(n = 10) %>% arrange(continent)
##      continentAfrica continentAmericas continentAsia continentEurope
## 32              1              0              0              0
## 25              1              0              0              0
## 121             1              0              0              0
## 108             1              0              0              0
```

```
## 149      0      0      1      0
## 133      0      0      1      0
## 195      0      0      1      0
## 91       0      0      0      1
## 154      0      0      0      1
## 66       0      0      0      1
##      continentOceania continent
## 32      0      Africa
## 25      0      Africa
## 121     0      Africa
## 108     0      Africa
## 149     0      Asia
## 133     0      Asia
## 195     0      Asia
## 91      0      Europe
## 154     0      Europe
## 66      0      Europe
```

- Effektkodierung

- Schätzung eines Modells mit Referenzkategorie Oceania:

```
lm_effect <- lm(formula = CO2emission ~ continent, data = wdi,
                 contrasts = list(continent = "contr.sum"))
summary(lm_effect)

##
## Call:
## lm(formula = CO2emission ~ continent, data = wdi, contrasts = list(continent = "contr.sum"))
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.72508 -0.68659  0.00954  0.55617  2.93454
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   3.81575    0.07401  51.560  < 2e-16 ***
## continent1    -0.26328    0.12566  -2.095   0.0374 *
## continent2    -0.03770    0.13575  -0.278   0.7815
## continent3     0.79509    0.12890   6.168 3.73e-09 ***
## continent4     0.61977    0.13575   4.566 8.67e-06 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.9634 on 201 degrees of freedom
## Multiple R-squared:  0.263, Adjusted R-squared:  0.2484
## F-statistic: 17.93 on 4 and 201 DF, p-value: 1.311e-12
```

- Interpretation der Koeffizienten:

```
coefs_effect <- round(x = coefficients(lm_effect), digits = 2)
coefs_effect

## (Intercept) continent1 continent2 continent3 continent4
##          3.82      -0.26      -0.04          0.80          0.62
group_means <- tapply(X = wdi$CO2emission, INDEX = wdi$continent, FUN = mean,
                      na.rm = TRUE)
group_means

## Africa Americas      Asia  Europe Oceania
## 3.552465 3.778044 4.610842 4.435520 2.701870
mean(group_means)
```

```
## [1] 3.815748
group_means - mean(group_means)
##      Africa      Americas      Asia      Europe      Oceania
## -0.26328301 -0.03770453  0.79509405  0.61977186 -1.11387837
```

⇒ Der geschätzte Intercept entspricht dem Mittelwert aller Gruppenmittelwerte.

⇒ Die weiteren geschätzten Koeffizienten entsprechen den Abweichungen der jeweiligen Gruppenmittelwerte vom globalen Mittelwert.

– Kontrastmatrix:

```
levels(wdi$continent)
## [1] "Africa" "Americas" "Asia" "Europe" "Oceania"
contr.sum(levels(wdi$continent))
##      [,1] [,2] [,3] [,4]
## Africa      1      0      0      0
## Americas     0      1      0      0
## Asia         0      0      1      0
## Europe       0      0      0      1
## Oceania     -1     -1     -1     -1
```

– Auszug aus Designmatrix:

```
mm_effect <- model.matrix(lm_effect)
cbind.data.frame(mm_effect, continent = wdi$continent) %>%
  slice_sample(n = 10) %>% arrange(continent)
##      (Intercept) continent1 continent2 continent3 continent4 continent
## 98              1              1              0              0              0 Africa
## 70              1              1              0              0              0 Africa
## 36              1              0              1              0              0 Americas
## 180             1              0              0              1              0 Asia
## 143             1              0              0              1              0 Asia
## 203             1              0              0              1              0 Asia
## 154             1              0              0              0              1 Europe
## 110             1              0              0              0              1 Europe
## 167             1             -1             -1             -1             -1 Oceania
## 146             1             -1             -1             -1             -1 Oceania
```

– Schätzung eines Modells mit Referenzkategorie **Europe**:

```
wdi$continent2 <- relevel(x = wdi$continent, ref = "Oceania")
levels(wdi$continent)
## [1] "Africa" "Americas" "Asia" "Europe" "Oceania"
levels(wdi$continent2)
## [1] "Oceania" "Africa" "Americas" "Asia" "Europe"
# Schätzung:
lm_effect2 <- lm(formula = CO2emission ~ continent2, data = wdi,
  contrasts = list(continent2 = "contr.sum"))
summary(lm_effect2)
##
## Call:
## lm(formula = CO2emission ~ continent2, data = wdi, contrasts = list(continent2 = "contr.sum"))
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.72508 -0.68659  0.00954  0.55617  2.93454
##
## Coefficients:
```

```
##           Estimate Std. Error t value Pr(>|t|)
## (Intercept)  3.81575    0.07401  51.560 < 2e-16 ***
## continent21 -1.11388    0.20070  -5.550 8.95e-08 ***
## continent22 -0.26328    0.12566  -2.095  0.0374 *
## continent23 -0.03770    0.13575  -0.278  0.7815
## continent24  0.79509    0.12890   6.168 3.73e-09 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.9634 on 201 degrees of freedom
## Multiple R-squared:  0.263, Adjusted R-squared:  0.2484
## F-statistic: 17.93 on 4 and 201 DF, p-value: 1.311e-12
```

⇒ Die für die Kontinente **Africa**, **Americas** und **Asia** geschätzten Koeffizienten sind identisch zum Modell mit Referenzkategorie **Oceania**.

⇒ Auch für τ_{Europe} und $\tau_{Oceania}$ erhält man anhand der beiden Outputs die gleichen Werte.

Anmerkung:

Die Koeffizienten werden bei Effektkodierung im Output generell immer der Reihe nach durchnummeriert.

- Referenzkodierung:

- Schätzung eines Modells mit Referenzkategorie **Africa**:

```
lm_ref <- lm(formula = CO2emission ~ continent, data = wdi)
summary(lm_ref)
##
## Call:
## lm(formula = CO2emission ~ continent, data = wdi)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.72508 -0.68659  0.00954  0.55617  2.93454
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)      3.5525    0.1311  27.097 < 2e-16 ***
## continentAmericas  0.2256    0.1969   1.146  0.2533
## continentAsia      1.0584    0.1891   5.598 7.06e-08 ***
## continentEurope    0.8831    0.1969   4.485 1.23e-05 ***
## continentOceania  -0.8506    0.2742  -3.102  0.0022 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.9634 on 201 degrees of freedom
## Multiple R-squared:  0.263, Adjusted R-squared:  0.2484
## F-statistic: 17.93 on 4 and 201 DF, p-value: 1.311e-12
```

- Interpretation der Koeffizienten:

```
coefs_ref <- round(x = coefficients(lm_ref), digits = 2)
coefs_ref
##      (Intercept) continentAmericas continentAsia continentEurope
##           3.55           0.23           1.06           0.88
## continentOceania
##          -0.85
coefs_mw
```

```
##      continentAfrica continentAmericas      continentAsia      continentEurope
##              3.55              3.78              4.61              4.44
##      continentOceania
##              2.70
```

⇒ Der geschätzte Intercept entspricht dem Mittelwert der Referenzkategorie.

⇒ Die weiteren geschätzten Koeffizienten entsprechen den Abweichungen der jeweiligen Gruppenmittelwerte vom Mittelwert der Referenzkategorie.

– Kontrastmatrix:

```
contr.treatment(levels(wdi$continent))
##           Americas Asia Europe Oceania
## Africa           0    0     0      0
## Americas         1    0     0      0
## Asia             0    1     0      0
## Europe           0    0     1      0
## Oceania          0    0     0      1
```


– Auszug aus Designmatrix:

```
mm_ref <- model.matrix(lm_ref)
cbind.data.frame(mm_ref, continent = wdi$continent) %>%
  slice_sample(n = 10) %>% arrange(continent)
##      (Intercept) continentAmericas continentAsia continentEurope
## 70              1                0              0              0
## 118             1                0              0              0
## 139             1                0              0              0
## 46              1                0              0              0
## 176             1                0              0              0
## 13              1                1              0              0
## 94              1                1              0              0
## 7               1                1              0              0
## 143             1                0              1              0
## 153            1                0              0              1
##      continentOceania continent
## 70                  0 Africa
## 118                 0 Africa
## 139                 0 Africa
## 46                  0 Africa
## 176                 0 Africa
## 13                  0 Americas
## 94                  0 Americas
## 7                   0 Americas
## 143                 0 Asia
## 153                 0 Europe
```

– Graphische Visualisierung der geschätzten Mittelwerte:

* Package **visreg**:


```
visreg(lm_ref)
```



* Package **effects** (die Konfidenzintervalle sind berechnet für den jeweiligen geschätzten Gruppenmittelwert, also für $\hat{\mu}_{\text{Afrika}}$, $\hat{\mu}_{\text{Afrika}} + \hat{\tau}_{\text{Amerika}}$, $\hat{\mu}_{\text{Afrika}} + \hat{\tau}_{\text{Asien}}$ usw.)

```
plot(allEffects(lm_ref))
```

continent effect plot



– Bestimmung von Konfidenzintervallen:

```
confint(lm_ref)
##               2.5 %      97.5 %
## (Intercept)   3.2939582  3.8109722
## continentAmericas -0.1626826  0.6138396
## continentAsia     0.6855530  1.4312011
## continentEurope    0.4947937  1.2713160
## continentOceania  -1.3913015 -0.3098892
# CIs für den erwarteten Gruppenmittelwert:
predict(lm_ref, newdata = data.frame(continent = levels(wdi$continent)),
        interval = "confidence")
##      fit      lwr      upr
## 1 3.552465 3.293958 3.810972
## 2 3.778044 3.488353 4.067735
## 3 4.610842 4.342194 4.879491
## 4 4.435520 4.145829 4.725211
## 5 2.701870 2.226962 3.176777
```

Aufgabe 9: Zweifaktorielle Varianzanalyse

Der auf der Moodle-Homepage verfügbare Datensatz `weightGainRats.Rds` enthält die Daten einer Studie zur Gewichtszunahme (`weightgain`) von Ratten, die anhand ihrer Ernährung durch folgende zwei Variablen in vier Gruppen eingeteilt werden können:

- Proteinmenge (`amount`) mit Ausprägungen “niedrig”(Low) und “hoch”(High)
- Quelle der Proteinzufuhr (`source`) mit Ausprägungen “Rindfleisch”(Beef) und “Getreide”(Cereal).

- (a) Stellen Sie die Modellgleichung für eine zweifaktorielle Varianzanalyse (ohne und mit Interaktion) unter Verwendung von Referenzkodierung auf.

Lösung:

- Ausgangssituation:

Modell mit zwei diskreten Einflussgrößen mit jeweils zwei Ausprägungen

$\Rightarrow K = k_1 \cdot k_2 = 2 \cdot 2 = 4$ mögliche Kombinationen

- Modell ohne Interaktion zwischen Proteinmenge und Quelle der Proteinzufuhr:

– Beobachtungsebene:

$$Y_{klj} = \mu + \tau_k + \gamma_l + \epsilon_{klj}$$

mit $k = 1, 2; l = 1, 2; j = 1, \dots, 10; \epsilon_{klj} \sim \mathbb{N}(0, \sigma^2); \tau_2 = 0; \gamma_2 = 0$.

– Matrixnotation:

$$Y = (e \ Z_1(\text{amount}) \ Z_1(\text{source})) \begin{pmatrix} \mu \\ \tau_1 \\ \gamma_1 \end{pmatrix} + \epsilon$$

mit

$$Z_1(\text{amount}) = \begin{cases} 1 & \text{für amount = Low} \\ 0 & \text{für amount = High} \end{cases}$$

und

$$Z_1(\text{source}) = \begin{cases} 1 & \text{für source = Cereal} \\ 0 & \text{für source = Beef.} \end{cases}$$

- Modell mit Interaktion zwischen Proteinmenge und Quelle der Proteinzufuhr:

– Beobachtungsebene:

$$Y_{klj} = \mu + \tau_k + \gamma_l + (\tau\gamma)_{kl} + \epsilon_{klj}$$

mit $k = 1, 2; l = 1, 2; j = 1, \dots, 10; \epsilon_{klj} \sim \mathbb{N}(0, \sigma^2); \tau_2 = \gamma_2 = (\tau\gamma)_{22} = (\tau\gamma)_{12} = (\tau\gamma)_{21} = 0$.

– Matrixnotation:

$$Y = (e \ Z_1(\text{amount}) \ Z_1(\text{source}) \ Z_1(\text{amount})Z_1(\text{source})) \begin{pmatrix} \mu \\ \tau_1 \\ \gamma_1 \\ (\tau\gamma)_{11} \end{pmatrix} + \epsilon$$

$$\text{mit } Z_1(\text{amount})Z_1(\text{source}) = \begin{cases} 1 & \text{für amount = Low und source = Cereal} \\ 0 & \text{für sonst.} \end{cases}$$

- (b) Schätzen Sie das in Teilaufgabe (a) spezifizierte Modell mit Interaktion in **R** und interpretieren Sie die erhaltenen Parameterschätzungen.

Lösung:

- Einlesen der Daten und Überblick über Datensatz:

```
weight <- readRDS("../Daten/weightGainRats.Rds")
head(weight)

##   source amount weightgain
## 1  Beef     Low         90
## 2  Beef     Low         76
## 3  Beef     Low         90
## 4  Beef     Low         64
## 5  Beef     Low         86
## 6  Beef     Low         51

str(weight)

## 'data.frame': 40 obs. of  3 variables:
## $ source      : Factor w/ 2 levels "Beef","Cereal": 1 1 1 1 1 1 1 1 1 1 ...
## $ amount      : Factor w/ 2 levels "High","Low": 2 2 2 2 2 2 2 2 2 2 ...
## $ weightgain: int  90 76 90 64 86 51 72 90 95 78 ...

summary(weight)

##      source      amount      weightgain
## Beef :20    High:20   Min.   : 51.00
## Cereal:20    Low :20   1st Qu.: 75.50
##                               Median : 88.50
##                               Mean   : 87.25
##                               3rd Qu.: 98.00
##                               Max.   :118.00

table(weight$amount, weight$source)

##
##      Beef Cereal
## High   10     10
## Low    10     10
```

⇒ Für jede Kombination aus Proteinmenge und Proteinquelle gibt es zehn Beobachtungen im Datensatz.

- Berechnung von Mittelwerten und Standardabweichungen für alle Kombinationen der beiden Variablen:

```
# Mittelwert:
tapply(X = weight$weightgain, INDEX = list(weight$source, weight$amount),
      FUN = mean)

##      High Low
## Beef  100.0 79.2
## Cereal  85.9 83.9

# Standardabweichung:
tapply(X = weight$weightgain, INDEX = list(weight$source, weight$amount),
      FUN = sd)

##      High      Low
## Beef  15.13642 13.88684
## Cereal 15.02184 15.70881
```

- ⇒ Die Streuungen innerhalb der vier Gruppen sind sehr ähnlich.
- ⇒ Die Modellannahme der Varianzhomogenität kann als gültig betrachtet werden.

- Schätzung einer zweifaktoriellen Varianzanalyse mit Interaktion:

```
model_aov <- aov(formula = weightgain ~ source * amount, data = weight)
summary(model_aov)

##               Df Sum Sq Mean Sq F value Pr(>F)
## source         1     221   220.9    0.988 0.3269
## amount         1    1300  1299.6    5.812 0.0211 *
## source:amount   1     884   883.6    3.952 0.0545 .
## Residuals      36    8049   223.6
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Komponenten des Outputs (Tabelle der Quadratsummen):

- Spalte 1: Freiheitsgrade bezüglich der jeweiligen Hypothesen
- Spalte 2: durch den jeweiligen Modellterm erklärte Streuung (SSH) sowie Residualstreuung
- Spalte 3: mittlere erklärte Streuung (MSH) bzw. mittlere Residualstreuung
- Spalte 4: F-Statistik zur entsprechenden Hypothesenquadratsumme
- Spalte 5: p-Werte zum jeweiligen Hypothesentest

- Manuelle Berechnung einzelner Komponenten des Outputs:

```
# p-Werte der Referenzverteilung:
1 - pf(q = c(0.988, 5.812, 3.952), df1 = 1, df2 = 36)

## [1] 0.32686610 0.02114809 0.05446170

# Nicht durch die beiden Variablen erklärte Reststreuung in der Zielgröße:
SSE0 <- sum((weight$weightgain - mean(weight$weightgain))^2)
SSE0 - 221 - 1300 - 884

## [1] 8048.5
```

- ⇒ Die manuell berechneten Werte stimmen mit dem R-Output überein.

- Auszug aus Designmatrix:

```
head(cbind(model.matrix(model_aov), weight[, 1:2]), 10)

##      (Intercept) sourceCereal amountLow sourceCereal:amountLow source amount
## 1              1             0          1                    0 Beef      Low
## 2              1             0          1                    0 Beef      Low
## 3              1             0          1                    0 Beef      Low
## 4              1             0          1                    0 Beef      Low
## 5              1             0          1                    0 Beef      Low
## 6              1             0          1                    0 Beef      Low
## 7              1             0          1                    0 Beef      Low
## 8              1             0          1                    0 Beef      Low
## 9              1             0          1                    0 Beef      Low
## 10             1             0          1                    0 Beef      Low
```

- Interpretation der geschätzten Koeffizienten:

```
coef(model_aov)
```

```
##           (Intercept)           sourceCereal           amountLow
##           100.0           -14.1           -20.8
## sourceCereal:amountLow
##           18.8
```

- $\hat{\mu} = 100$: Der Mittelwert der Gruppe mit hoher Proteinmenge und Zufuhr durch Rindfleisch beträgt 100.
- $\hat{\tau}_1 \approx -20.8$: Eine niedrige Proteinmenge verringert die Gewichtszunahme bei Zufuhr durch Rindfleisch im Mittel um 20.8.
- $\hat{\gamma}_1 = -14.1$ Die Proteinzufuhr durch Getreide verringert die Gewichtszunahme bei hoher Proteinmenge im Mittel um 14.1.
- $\hat{\tau\gamma}_{11} = 18.8$:
Eine niedrige Proteinmenge führt bei Proteinzufuhr durch Getreide im Vergleich zur Proteinzufuhr durch Rindfleisch im Mittel zu einer um 18.8 höheren Gewichtszunahme, d.h. eine niedrige Proteinmenge verringert die Gewichtszunahme bei Zufuhr durch Getreide um 2 ($-20.8 + 18.8$).

bzw.

Die Proteinzufuhr durch Getreide führt bei einer niedrigen im Vergleich zu einer hohen Proteinmenge im Mittel zu einer um 18.8 höheren Gewichtszunahme, d.h. Proteinzufuhr durch Getreide erhöht die Gewichtszunahme bei einer niedrigen Proteinmenge im Mittel um 4.7 ($-14.1 + 18.8$).


- ⇒ Bei niedriger Proteinmenge ist die Gewichtszunahme mit Getreide größer, bei hoher Proteinmenge mit Rindfleisch.
- ⇒ Alle geschätzten Parameter werden in Bezug zur Referenzkategorie (hohe Proteinmenge, Zufuhr durch Rindfleisch) interpretiert.

- Erwartungswerte der einzelnen Gruppen:

$$\begin{array}{cc} & \textit{Beef} \quad \textit{Cereal} \\ \textit{High} & \left(\begin{array}{cc} 100 & 85.9 \end{array} \right) \\ \textit{Low} & \left(\begin{array}{cc} 79.2 & 83.9 \end{array} \right) \end{array}$$

- Graphische Visualisierung der geschätzten Effekte:

```
fit_table <- weight %>% group_by(source, amount) %>%
  summarize(y_hat = mean(weightgain))
ggplot(data = fit_table,
  mapping = aes(x = amount, y = y_hat, group = source,
    linetype = source)) +
  geom_line() + ylab("E[weightgain|source, amount]") + theme
```



⇒ Die unterschiedliche Steigung der beiden Geraden bildet den geschätzten Interaktionseffekt ab.

- Anmerkung:

Ein varianzanalytisches Modell kann wie jedes andere lineare Regressionsmodell auch mit der Funktion `lm()` geschätzt werden:

```
model_lm <- lm(formula = weightgain ~ source * amount, data = weight)
summary(model_lm)
```

```
##
## Call:
## lm(formula = weightgain ~ source * amount, data = weight)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -29.90  -9.90   2.05  10.85  25.10
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)      100.000      4.729  21.148 < 2e-16 ***
## sourceCereal      -14.100      6.687  -2.109  0.04201 *
## amountLow        -20.800      6.687  -3.110  0.00364 **
## sourceCereal:amountLow  18.800      9.457   1.988  0.05447 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 14.95 on 36 degrees of freedom
## Multiple R-squared:  0.23, Adjusted R-squared:  0.1658
## F-statistic: 3.584 on 3 and 36 DF, p-value: 0.02297
```

⇒ Die erhaltenen Koeffizientenschätzer sind identisch zu den Schätzern der Funktion `aov()`.

Aufgabe 10: Interaktionen zwischen metrischen und kategorialen Einflussgrößen

Der Datensatz `teengamb` aus dem **R**-Paket `faraway` enthält Informationen zum Glücksspielverhalten von Teenagern in Großbritannien. In dieser Aufgabe soll die Variable `gamble` in Abhängigkeit verschiedener Kovariablen modelliert werden.

Die folgenden Variablen sind im Datensatz enthalten:

Variable	Beschreibung
<code>gamble</code>	Ausgaben für Glücksspiel [in Pfund pro Jahr]
<code>status</code>	Sozio-ökonomischer Status (basierend auf Beruf der Eltern)
<code>income</code>	Einkommen [in Pfund pro Woche]
<code>verbal</code>	Test-Score bezüglich der Erklärung von Wörtern
<code>sex</code>	Geschlecht (0 = männlich, 1 = weiblich)

- (a) Machen Sie sich mit dem Datensatz vertraut und schätzen Sie ein lineares Regressionsmodell mit den Einflussgrößen `income` und `geschlecht`.

Lösung:

- Laden der Daten und Überblick über Datensatz:

```
data(teengamb)
head(teengamb)

##   sex status income verbal gamble
## 1    1    51   2.00      8    0.0
## 2    1    28   2.50      8    0.0
## 3    1    37   2.00      6    0.0
## 4    1    28   7.00      4    7.3
## 5    1    65   2.00      8   19.6
## 6    1    61   3.47      6    0.1

str(teengamb)

## 'data.frame': 47 obs. of  5 variables:
##  $ sex      : int  1 1 1 1 1 1 1 1 1 1 ...
##  $ status: int  51 28 37 28 65 61 28 27 43 18 ...
##  $ income: num  2 2.5 2 7 2 3.47 5.5 6.42 2 6 ...
##  $ verbal: int  8 8 6 4 8 6 7 5 6 7 ...
##  $ gamble: num  0 0 0 7.3 19.6 0.1 1.45 6.6 1.7 0.1 ...

summary(teengamb)

##           sex           status           income           verbal
##  Min.      :0.0000   Min.      :18.00   Min.      : 0.600   Min.      : 1.00
## 1st Qu.:0.0000   1st Qu.:28.00   1st Qu.: 2.000   1st Qu.: 6.00
## Median :0.0000   Median :43.00   Median : 3.250   Median : 7.00
## Mean   :0.4043   Mean   :45.23   Mean   : 4.642   Mean   : 6.66
## 3rd Qu.:1.0000   3rd Qu.:61.50   3rd Qu.: 6.210   3rd Qu.: 8.00
## Max.    :1.0000   Max.    :75.00   Max.    :15.000   Max.    :10.00
##           gamble
##  Min.      : 0.0
## 1st Qu.: 1.1
## Median : 6.0
## Mean   : 19.3
## 3rd Qu.: 19.4
## Max.    :156.0
```

- Umkodierung der Variable `sex`:

```
teengamb <- teengamb %>% mutate(sex = as.factor(sex))
```


- Schätzung eines linearen Regressionsmodells mit Einflussgrößen `income` und `sex`:

```
model_main <- lm(formula = gamble ~ income + sex, data = teengamb)
summary(model_main)

##
## Call:
## lm(formula = gamble ~ income + sex, data = teengamb)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -49.757 -11.649   0.844   8.659 100.243
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    4.041      6.394   0.632  0.53070
## income         5.172      0.951   5.438 2.24e-06 ***
## sex1        -21.634      6.809  -3.177  0.00272 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 22.75 on 44 degrees of freedom
## Multiple R-squared:  0.5014, Adjusted R-squared:  0.4787
## F-statistic: 22.12 on 2 and 44 DF, p-value: 2.243e-07
```

- Graphische Visualisierung der geschätzten Regressionsgeraden für beide Geschlechter:

```
fitted_main <- augment(model_main)
ggplot(data = fitted_main, mapping = aes(x = income, y = gamble, col = sex)) +
  geom_point() + geom_line(aes(y = .fitted)) + theme
```



⇒ Die Graphik lässt bereits vermuten, dass die Annahmen einer gleichen Steigung des Einkommenseffektes für Männer und Frauen für die Datensituation nicht adäquat ist.

- (b) Untersuchen Sie nun, ob der Einfluss der Variable `income` auf die Glücksspielausgaben vom Geschlecht der Jugendlichen abhängt, indem Sie das Modell aus Teilaufgabe (a) um eine Interaktion zwischen diesen beiden Variablen ergänzen. Interpretieren Sie die Parameterschätzer des Modells ausführlich.

Lösung:

- Modellgleichung für ein Regressionsmodell mit zusätzlicher Interaktion:

$$Y_i = \beta_0 + \beta_1 x_{income,i} + \beta_2 x_{sex,i} + \beta_3 x_{sex,i} x_{income,i} + \epsilon_i \quad \text{für } i = 1, \dots, n$$

$$\text{mit } x_{sex,i} = \begin{cases} 1 & \text{für } x_{sex,i} = \text{female} \\ 0 & \text{für } x_{sex,i} = \text{male} \end{cases}$$

- Schätzung des Regressionsmodells mit zusätzlicher Interaktion:

```
model_int <- lm(formula = gamble ~ income * sex, data = teengamb)
summary(model_int)

##
## Call:
## lm(formula = gamble ~ income * sex, data = teengamb)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -56.522  -4.860  -1.790   6.273  93.478
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -2.6596     6.3164  -0.421  0.67580
## income         6.5181     0.9881   6.597 4.95e-08 ***
## sex1          5.7996    11.2003   0.518  0.60724
## income:sex1   -6.3432     2.1446  -2.958  0.00502 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 20.98 on 43 degrees of freedom
## Multiple R-squared:  0.5857, Adjusted R-squared:  0.5568
## F-statistic: 20.26 on 3 and 43 DF,  p-value: 2.451e-08
```

- Geschätzte Regressionsgeraden:

- Weibliche Jugendliche:

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i + \hat{\beta}_2 + \hat{\beta}_3 x_i = (\hat{\beta}_0 + \hat{\beta}_2) + x_i(\hat{\beta}_1 + \hat{\beta}_3)$$

- Männliche Jugendliche (Referenzkategorie):

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$$


- Interpretation der Parameterschätzer:

- $\hat{\beta}_0 \approx -2.66$: Die erwarteten Ausgaben für Glücksspiel bei einem männlichen Jugendlichen mit einem Einkommen von 0 Pfund pro Woche betragen -2.66 Pfund pro Jahr.
 - Der Parameter ist hier nicht sinnvoll interpretierbar.
- $\hat{\beta}_1 \approx 6.52$: Steigt das Einkommen männlicher Jugendlicher um 1 Pfund pro Woche, so erhöhen sich die Ausgaben für Glücksspiel durchschnittlich um 6.52 Pfund pro Jahr.
- $\hat{\beta}_2 \approx 5.80$: Bei einem Einkommen von 0 Pfund pro Woche geben weibliche Jugendliche durchschnittlich 5.80 Pfund pro Jahr mehr für Glücksspiel aus als männliche Jugendliche.
- $\hat{\beta}_3 \approx -6.34$: Steigt das Einkommen um 1 Pfund pro Woche, so steigen die Ausgaben für Glücksspiel für weibliche Jugendliche durchschnittlich um 6.34 Pfund pro Jahr weniger als für männliche Jugendliche.

→ Bei Anstieg des Einkommens um 1 Pfund pro Woche steigen die Glücksspielausgaben für weibliche Jugendliche durchschnittlich um $6.52 - 6.34 = 0.18$ Pfund pro Jahr an.

- Graphische Visualisierung der geschätzten Regressionsgeraden für beide Geschlechter:

```
fitted_int <- augment(model_int)
ggplot(data = fitted_int, mapping = aes(x = income, y = gamble, col = sex)) +
  geom_point() + geom_line(aes(y = .fitted)) + theme
```




⇒ Das Modell mit Interaktion führt zu individuellen Intercepts und Steigungskoeffizienten für beide Geschlechter.

⇒ Die Graphik unterstreicht nochmals die deutlichen Unterschiede bezüglich des Einkommenseffektes zwischen den Geschlechtern.

- Vergleich der Residuen der beiden Modelle:

```
fitted_main <- fitted_main %>% mutate(model = "No Interaction")
fitted_int <- fitted_int %>% mutate(model = "Interaction")
fitted <- rbind(fitted_main, fitted_int)
ggplot(data = fitted, mapping = aes(x = income, y = gamble, col = sex)) +
  geom_point() + geom_line(aes(y = .fitted)) + theme +
  geom_segment(aes(xend = income, yend = .fitted, col = sex)) +
  facet_wrap(~model)
```



⇒ Insbesondere die Residuen bezüglich der weiblichen Jugendlichen sind im Modell mit Interaktion deutlich geringer als im Modell aus Teilaufgabe (a).

- (c) Wie hoch ist die erwartete Differenz bezüglich der Glücksspielausgaben gemäß der beiden geschätzten Modelle zwischen einem männlichen Jugendlichen und einer weiblichen Jugendlichen, die ein um 10 Pfund pro Woche höheres Einkommen hat?

Lösung:

- Modell ohne Interaktion:

$$\begin{aligned} & \hat{\mathbb{E}}(Y|x_{income} = x + 10, x_{sex} = \text{female}) - \hat{\mathbb{E}}(Y|x_{income} = x, x_{sex} = \text{male}) = \\ & \hat{\beta}_0 + \hat{\beta}_1(x + 10) + \hat{\beta}_2 - (\hat{\beta}_0 + \hat{\beta}_1x) = 10\hat{\beta}_1 + \hat{\beta}_2 = 51.70 - 21.63 = 30.07 \end{aligned}$$

```
unnname(coef(model_main)[2]*10 + coef(model_main)[3])
## [1] 30.08145
```

⇒ Gemäß des Modells ohne Interaktion sind für die weibliche Jugendliche mit um 10 Pfund pro Woche höherem Einkommen um ca. 30 Pfund pro Jahr höhere Glücksspielausgaben zu erwarten.

- Modell mit Interaktion:

$$\begin{aligned} & \hat{\mathbb{E}}(Y|x_{income} = x + 10, x_{sex} = \text{female}) - \hat{\mathbb{E}}(Y|x_{income} = x, x_{sex} = \text{male}) \\ & = \hat{\beta}_0 + \hat{\beta}_1(x + 10) + \hat{\beta}_2 + \hat{\beta}_3(x + 10) - (\hat{\beta}_0 + \hat{\beta}_1x) = 10(\hat{\beta}_1 + \hat{\beta}_3) + \hat{\beta}_3x + \hat{\beta}_2 \end{aligned}$$

```
# income = 2:
unnname(coef(model_int)[2]*10 + coef(model_int)[3] + coef(model_int)[4] * 12)
## [1] -5.137626

# income = 4:
unnname(coef(model_int)[2]*10 + coef(model_int)[3] + coef(model_int)[4] * 14)
## [1] -17.82403
```

⇒ Im Gegensatz zum Modell ohne Interaktion hängt die erwartete Differenz zwischen den beiden Jugendlichen vom konkreten Einkommen ab.

⇒ Bei einem Einkommen des männlichen Jugendlichen von 2 Pfund pro Woche ist die erwartete Differenz jetzt negativ (das heißt, der männliche Jugendliche gibt mehr aus) und beträgt ca. 5 Pfund pro Jahr, bei einem Einkommen von 4 Pfund pro Woche sogar ca. 18 Pfund pro Jahr.

- (d) Betrachten Sie nun das Modell, bei dem zusätzlich die Variablen **verbal** und **status** sowie die jeweiligen Interaktionen mit Geschlecht enthalten sind. Visualisieren Sie die Effektschätzungen in geeigneter Form.

Lösung:

- Modellspezifikation für ein Modell mit zusätzlichen Einflussvariablen ($i = 1, \dots, n$):

$$Y_i = \beta_0 + \beta_1x_{income,i} + \beta_2x_{stat,i} + \beta_3x_{verbal,i} + \beta_4x_{sex,i} + \beta_5x_{income,i}x_{sex,i} + \beta_6x_{stat,i}x_{sex,i} + \beta_7x_{verbal,i}x_{sex,i} + \epsilon_i$$

$$\text{mit } x_{sex,i} = \begin{cases} 1 & \text{für } x_{sex,i} = \text{female} \\ 0 & \text{für } x_{sex,i} = \text{male} \end{cases}$$


- Schätzung des linearen Modells:

```
model_full <- lm(formula = gamble ~ (income + status + verbal) * sex,
                 data = teengamb)
summary(model_full)

##
## Call:
## lm(formula = gamble ~ (income + status + verbal) * sex, data = teengamb)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -56.654  -7.589  -1.016   3.323  83.903
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  27.6354    17.6218   1.568   0.1249
## income        6.0291     1.0538   5.721 1.26e-06 ***
## status       -0.1456     0.3316  -0.439   0.6631
## verbal       -2.9748     2.4265  -1.226   0.2276
## sex1        -33.0132    35.0530  -0.942   0.3521
## income:sex1  -5.3478     2.4244  -2.206   0.0334 *
## status:sex1   0.3529     0.5492   0.643   0.5243
## verbal:sex1   2.8355     4.5973   0.617   0.5410
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 20.98 on 39 degrees of freedom
## Multiple R-squared:  0.6243, Adjusted R-squared:  0.5569
## F-statistic:  9.26 on 7 and 39 DF,  p-value: 1.06e-06
```

- Graphische Visualisierung aller geschätzten Effekte:

```
plot(x = allEffects(model_full), rows = 3, cols = 1, ylim = c(-50, 150))
```



(e) Testen Sie, ob das Modell aus Teilaufgabe (d) auf die Einflussgrößen `income` und `sex` reduziert werden kann.

Lösung:

- Hypothesen:

$$H_0 : \beta_2 = \beta_3 = \beta_6 = \beta_7 = 0 \text{ vs. } H_1 : \exists \beta_j \neq 0 \quad \text{für } j \in 2, 3, 6, 7$$

⇒ Verwendung eines F-Tests zur Überprüfung linearer Hypothesen

⇒ $TF \sim F(a, n - p')$ bzw. $TF \sim F(4, 39)$

- Durchführung des Hypothesentests in **R**:

```
anova(model_int, model_full)

## Analysis of Variance Table
##
## Model 1: gamble ~ income * sex
## Model 2: gamble ~ (income + status + verbal) * sex
##   Res.Df  RSS Df Sum of Sq    F Pr(>F)
## 1      43 18930
## 2      39 17164  4    1766.4 1.0034 0.4175
```

- ⇒ Die Nullhypothese kann zum Signifikanzniveau $\alpha = 0.05$ nicht abgelehnt werden. Es gibt also nicht ausreichend Evidenz für das vollständige Modell.
- ⇒ Wir wählen somit das reduzierte Modell mit den beiden Einflussgrößen **income** und **sex**.

June 10, 2026

Fragen und Kommentare an laura.bader@stat.uni-muenchen.de